

فصل ۱

یادگیری فعال مبتنی بر توزیع

۱.۱ مقدمه

در بسیاری از مسائل یادگیری ماشین، دسترسی به نمونه‌های بدون برچسب آسان است؛ اما برچسب‌گذاری نمونه‌ها پرهزینه، زمان‌بر یا وابسته به نظر کارشناس است. یادگیری فعال پاسخی به این وضعیت است: به جای آن‌که همه‌ی نمونه‌ها برچسب‌گذاری شوند، الگوریتم در هر تکرار، نمونه‌هایی را انتخاب می‌کند که انتظار می‌رود بیشترین اثر را بر بهبود مدل داشته باشند. بنابراین یادگیری فعال، فرایند آموزش را از یک فرایند منفعل به یک فرایند تعاملی تبدیل می‌کند که در آن مدل، خود درباره‌ی نیاز اطلاعاتی‌اش تصمیم می‌گیرد.

با وجود این، بسیاری از معیارهای کلاسیک یادگیری فعال فقط به میزان عدم قطعیت مدل توجه می‌کنند. این نگاه، هرچند ساده و مؤثر است، ممکن است نمونه‌هایی را انتخاب کند که روی مرز تصمیم قرار دارند اما از نظر توزیع داده‌ها نماینده‌ی بخش مهمی از جامعه‌ی داده نیستند. به بیان دیگر، نمونه‌ای می‌تواند بسیار نامطمئن باشد، اما در ناحیه‌ای کم‌چگال یا پرت قرار گیرد؛ در چنین حالتی برچسب‌گذاری آن لزوماً باعث بهبود تعمیم مدل روی توزیع واقعی داده‌ها نمی‌شود. از این رو، در این فصل یادگیری فعال از دیدگاه distribution-aware بررسی می‌شود؛ یعنی انتخاب نمونه‌ها نه فقط بر اساس ابهام مدل، بلکه بر اساس جایگاه آن‌ها در توزیع داده، چگالی، نمایندگی، پوشش و تنوع انجام می‌شود.

ایده‌ی اصلی این فصل آن است که پرس‌وجوی فعال باید همزمان به دو پرسش پاسخ دهد: نخست، «کدام نمونه برای مدل مبهم‌تر است؟» و دوم، «کدام نمونه برای توزیع داده‌ها نماینده‌تر است؟». ترکیب این دو نگاه سبب می‌شود الگوریتم از انتخاب نمونه‌های پرت، تکراری یا غیرنماینده دور شود و بودجه‌ی محدود برچسب‌گذاری به نواحی مهم‌تر فضای داده اختصاص یابد.

۲.۱ صورت‌بندی مسئله

فرض کنید فضای ورودی با $\mathcal{X} \subseteq \mathbb{R}^d$ و فضای برچسب با $\mathcal{Y} = \{1, \dots, C\}$ نشان داده شود. داده‌ها از یک توزیع ناشناخته‌ی مشترک P_{XY} تولید می‌شوند. در یادگیری فعال، مجموعه‌ی داده در هر مرحله به دو بخش تقسیم می‌شود:

$$\mathcal{D}_L = \{(x_i, y_i)\}_{i=1}^{n_L}, \quad \mathcal{D}_U = \{x_j\}_{j=1}^{n_U}, \quad (1.1)$$

که $\mathcal{D}_L$ مجموعه‌ی برچسب‌دار و $\mathcal{D}_U$ مجموعه‌ی بدون برچسب است. هدف، آموزش مدلی مانند Δ^{C-1} $f_\theta : \mathcal{X} \rightarrow \Delta^{C-1}$ است؛ به گونه‌ای که با کمترین تعداد برچسب، ریسک تعمیم کمینه شود:

$$R(\theta) = \mathbb{E}_{(x,y) \sim P_{XY}} [\ell(f_\theta(x), y)]. \quad (2.1)$$

در این رابطه، ℓ تابع زیان و Δ^{C-1} سیمپلکس احتمال روی C کلاس است.

در هر دور یادگیری فعال، الگوریتم یک زیرمجموعه‌ی پرس‌وجو $\mathcal{S}_t \subseteq \mathcal{D}_U$ را با اندازه‌ی b انتخاب می‌کند:

$$\mathcal{S}_t = \arg \max_{\mathcal{S} \subseteq \mathcal{D}_U, |\mathcal{S}|=b} A(\mathcal{S}; \theta_t, \mathcal{D}_L, \mathcal{D}_U), \quad (3.1)$$

که در آن A تابع اکتساب یا معیار انتخاب است. پس از دریافت برچسب‌های S_t از کارشناس، مجموعه‌ی برچسب‌دار و بدون برچسب به‌روزرسانی می‌شوند:

$$\mathcal{D}_L \leftarrow \mathcal{D}_L \cup \{(x, y) : x \in S_t\}, \quad \mathcal{D}_U \leftarrow \mathcal{D}_U \setminus S_t. \quad (۴.۱)$$

تعریف ۱.۱ (یادگیری فعال مبتنی بر توزیع). یادگیری فعال مبتنی بر توزیع رویکردی است که در آن تابع اکتساب، علاوه بر عدم قطعیت یا اثر مورد انتظار نمونه بر مدل، ساختار توزیع داده‌های بدون برچسب را نیز لحاظ می‌کند. بنابراین انتخاب نمونه به صورت تابعی از سه مؤلفه‌ی اصلی انجام می‌شود:

$$A(x) = \Phi(U(x), R(x), D(x)), \quad (۵.۱)$$

که در آن $U(x)$ میزان سودمندی اطلاعاتی یا عدم قطعیت، $R(x)$ میزان نمایندگی یا چگالی توزیعی، و $D(x)$ میزان تنوع نسبت به نمونه‌های انتخاب‌شده یا برچسب‌دار است.

۳.۱ سناریوهای اصلی یادگیری فعال

در ادبیات یادگیری فعال معمولاً سه سناریوی اصلی مطرح می‌شود.

۱.۳.۱ تولید پرس‌وجوی عضویت

در این سناریو، الگوریتم می‌تواند هر نقطه‌ای را از فضای ورودی $\mathcal{X}$ تولید کند و برچسب آن را از کارشناس بخواهد. این حالت از نظر نظری جذاب است، اما در بسیاری از کاربردهای واقعی مشکل دارد؛ زیرا نمونه‌ی تولیدشده ممکن است از نظر فیزیکی، معنایی یا تجربی معتبر نباشد. برای نمونه، در داده‌های تصویر، تولید یک نقطه‌ی دلخواه در فضای پیکسل‌ها لزوماً به یک تصویر طبیعی منجر نمی‌شود.

۲.۳.۱ نمونه‌گیری انتخابی جریانی

در این حالت، نمونه‌ها به صورت جریان وارد می‌شوند. الگوریتم برای هر نمونه‌ی ورودی x_t تصمیم می‌گیرد که آیا برچسب آن را درخواست کند یا خیر. اگر $q_t \in \{0, 1\}$ تصمیم پرس‌وجو باشد، می‌توان نوشت:

$$q_t = \mathbb{I}(A(x_t) > \tau_t), \quad (۶.۱)$$

که τ_t آستانه‌ای ثابت یا تطبیقی است. این سناریو برای داده‌های برخط، حسگرها، جریان‌های تصویری و داده‌های زمانی مناسب است.

۳.۳.۱ نمونه‌گیری از مخزن داده‌های بدون برچسب

رایج‌ترین حالت، نمونه‌گیری از یک مخزن بزرگ بدون برچسب است. در این حالت، مجموعه‌ی $\mathcal{D}_U$ از ابتدا در دسترس است و الگوریتم در هر دور، یک یا چند نمونه را برای برچسب‌گذاری انتخاب می‌کند. نگاه توزیعی در این سناریو بسیار مهم است؛ زیرا ساختار هندسی و آماری $\mathcal{D}_U$ می‌تواند برای تخمین چگالی، خوشه‌بندی، تنوع و پوشش استفاده شود.

۴.۱ معیارهای کلاسیک انتخاب نمونه

۱.۴.۱ نمونه‌گیری بر اساس عدم قطعیت

ساده‌ترین راهبرد یادگیری فعال، انتخاب نمونه‌هایی است که مدل درباره‌ی آن‌ها کمترین اطمینان را دارد. اگر خروجی مدل برای نمونه‌ی x به صورت $p_\theta(y | x)$ باشد، معیار کمترین اطمینان چنین تعریف می‌شود:

$$U_{LC}(x) = 1 - \max_{y \in \mathcal{Y}} p_\theta(y | x). \quad (۷.۱)$$

در مسائل چندکلاسه، معیار حاشیه نیز رایج است. اگر $p_{(1)}(x)$ و $p_{(2)}(x)$ به ترتیب بزرگترین و دومین احتمال پیش‌بینی شده باشند، عدم قطعیت حاشیه‌ای به صورت زیر تعریف می‌شود:

$$U_{\text{margin}}(x) = 1 - (p_{(1)}(x) - p_{(2)}(x)). \quad (۸.۱)$$

همچنین می‌توان از آنتروپی پیش‌بینی استفاده کرد:

$$U_{\text{ent}}(x) = - \sum_{c=1}^C p_{\theta}(y = c | x) \log p_{\theta}(y = c | x). \quad (۹.۱)$$

هرچه آنتروپی بیشتر باشد، توزیع پیش‌بینی مدل پخش‌تر و تصمیم مدل نامطمئن‌تر است.

۲.۴.۱ پرس‌وجو بر اساس کمیته

در روش پرس‌وجو با کمیته، مجموعه‌ای از مدل‌ها یا فرضیه‌ها با داده‌ی برچسب‌دار فعلی آموزش داده می‌شوند. نمونه‌ای انتخاب می‌شود که بیشترین اختلاف نظر را میان اعضای کمیته ایجاد کند. اگر کمیته شامل M مدل باشد و رأی مدل m برای نمونه‌ی x با $h_m(x)$ نشان داده شود، آنتروپی رأی به صورت زیر است:

$$U_{\text{VE}}(x) = - \sum_{c=1}^C \frac{v_c(x)}{M} \log \frac{v_c(x)}{M}, \quad (۱۰.۱)$$

که در آن $v_c(x)$ تعداد مدل‌هایی است که کلاس c را برای x انتخاب کرده‌اند. شکل دیگر اختلاف نظر، میانگین واگرایی KL از پیش‌بینی هر عضو کمیته نسبت به میانگین پیش‌بینی‌ها است:

$$U_{\text{KL}}(x) = \frac{1}{M} \sum_{m=1}^M \text{KL}(p_{\theta_m}(y | x) \| \bar{p}(y | x)), \quad (۱۱.۱)$$

که

$$\bar{p}(y | x) = \frac{1}{M} \sum_{m=1}^M p_{\theta_m}(y | x). \quad (۱۲.۱)$$

۳.۴.۱ تغییر مورد انتظار مدل

در معیار تغییر مورد انتظار مدل، نمونه‌ای ترجیح داده می‌شود که پس از برچسب‌گذاری، بیشترین تغییر را در پارامترهای مدل ایجاد کند. چون برچسب واقعی نمونه‌ی بدون برچسب مشخص نیست، امید ریاضی روی برچسب‌های ممکن گرفته می‌شود:

$$U_{\text{EGL}}(x) = \sum_{y \in \mathcal{Y}} p_{\theta}(y | x) \|\nabla_{\theta} \ell(f_{\theta}(x), y)\|. \quad (۱۳.۱)$$

این معیار از نظر مفهومی قوی است؛ زیرا نمونه‌هایی را انتخاب می‌کند که آموزش روی آن‌ها جهت گرادین مدل را بیشتر تغییر می‌دهد. با این حال، محاسبه‌ی آن در مدل‌های بزرگ می‌تواند پرهزینه باشد.

۴.۴.۱ کاهش مورد انتظار خطا و واریانس

در این خانواده از روش‌ها، نمونه‌ای انتخاب می‌شود که انتظار می‌رود پس از برچسب‌گذاری، خطای تعمیم مدل را بیشترین مقدار کاهش دهد. یک صورت کلی از این معیار چنین است:

$$U_{\text{ER}}(x) = - \sum_{y \in \mathcal{Y}} p_{\theta}(y | x) \hat{R}(\theta^+(x, y)), \quad (۱۴.۱)$$

که $\theta^+(x, y)$ پارامترهای مدل پس از افزودن نمونه‌ی (x, y) و بازآموزی یا به‌روزرسانی مدل است. این روش‌ها معمولاً دقیق‌تر اما محاسباتی‌تر از نمونه‌گیری عدم قطعیت هستند.

۵.۱ چرا نگاه توزیعی لازم است؟

معیارهای کلاسیک، به ویژه معیارهای مبتنی بر عدم قطعیت، عمدتاً محلی هستند؛ یعنی هر نمونه را به صورت جداگانه ارزیابی می کنند. این امر دو مشکل ایجاد می کند. نخست، نمونه های پرت می توانند به اشتباه جذاب به نظر برسند. اگر نمونه ای در ناحیه ای کم چگال از فضای ورودی قرار گیرد، مدل ممکن است درباره ی آن نامطمئن باشد. اما برچسب گذاری چنین نمونه ای لزوماً به بهبود رفتار مدل روی بخش های پرجمعیت توزیع داده کمک نمی کند. دوم، انتخاب نمونه ها می تواند تکراری شود. در یادگیری فعال دسته ای، اگر چند نمونه ی نزدیک به هم همگی عدم قطعیت بالایی داشته باشند، معیارهای نقطه ای ممکن است همه ی آن ها را انتخاب کنند. در این حالت، بودجه ی برچسب گذاری صرف نمونه های مشابه می شود و پوشش مناسبی از توزیع داده به دست نمی آید. برای رفع این دو مشکل، باید تابع اکتساب به ساختار توزیع داده حساس باشد. به طور خلاصه، نمونه ی مطلوب در یادگیری فعال توزیعی باید سه ویژگی داشته باشد:

- (۱) برای مدل اطلاعاتی یا مبهم باشد؛
- (۲) در ناحیه ای نماینده از توزیع داده قرار داشته باشد؛
- (۳) نسبت به نمونه های انتخاب شده ی دیگر تنوع کافی داشته باشد.

۶.۱ چگالی و نمایندگی در فضای داده

فرض کنید $z = g_\phi(x)$ نمایش نهفته ی نمونه ی x باشد. این نمایش می تواند همان ویژگی های خام، خروجی یک لایه ی میانی شبکه ی عصبی، یا بردار ویژگی استخراج شده از یک مدل از پیش آموزش دیده باشد. چگالی تجربی نمونه ی x_i را می توان با تخمین هسته ای زیر محاسبه کرد:

$$\hat{p}(z_i) = \frac{1}{n_U} \sum_{j=1}^{n_U} K_\sigma(z_i, z_j), \quad (15.1)$$

که در آن K_σ یک هسته ی شباهت است. برای نمونه، هسته ی گاوسی به صورت زیر تعریف می شود:

$$K_\sigma(z_i, z_j) = \exp\left(-\frac{\|z_i - z_j\|_2^2}{2\sigma^2}\right). \quad (16.1)$$

هرچه $\hat{p}(z_i)$ بزرگ تر باشد، نمونه ی x_i در ناحیه ای پرتراکم تر از داده های بدون برچسب قرار دارد و از نظر توزیعی نماینده تر است. یک تابع اکتساب ساده ی توزیعی را می توان به صورت حاصل ضرب عدم قطعیت و چگالی تعریف کرد:

$$A_{DW}(x_i) = U(x_i) (\hat{p}(z_i))^\beta, \quad (17.1)$$

که $\beta \geq 0$ شدت اثر چگالی را کنترل می کند. اگر $\beta = 0$ باشد، معیار به روش عدم قطعیت خالص تبدیل می شود. اگر β بزرگ باشد، نمونه های پرت حتی در صورت عدم قطعیت بالا، امتیاز کمتری می گیرند.

گزاره ۱۰.۱ (کاهش اثر نمونه های پرت). اگر برای نمونه ای مانند x_o مقدار چگالی تجربی $\hat{p}(z_o)$ به صفر میل کند و $\beta > 0$ باشد، آنگاه امتیاز چگالی وزن دار آن نیز به صفر میل می کند، حتی اگر عدم قطعیت $U(x_o)$ بزرگ باشد:

$$\lim_{\hat{p}(z_o) \rightarrow 0} U(x_o) (\hat{p}(z_o))^\beta = 0. \quad (18.1)$$

اثبات. چون $U(x_o)$ برای معیارهای رایج عدم قطعیت کران دار است، یعنی $0 \leq U(x_o) \leq M$ ، داریم:

$$0 \leq U(x_o)(\hat{p}(z_o))^\beta \leq M(\hat{p}(z_o))^\beta. \quad (19.1)$$

با میل کردن $\hat{p}(z_o)$ به صفر و با توجه به $\beta > 0$ ، کران بالایی نیز به صفر میل می‌کند؛ پس نتیجه از قضیه‌ی فشردگی به دست می‌آید. $\square$

۷.۱ تنوع و پوشش توزیع

در یادگیری فعال دسته‌ای، انتخاب چند نمونه‌ی مشابه، اطلاعات جدید زیادی به مدل اضافه نمی‌کند. بنابراین باید علاوه بر امتیاز نقطه‌ای هر نمونه، شباهت میان نمونه‌های انتخابی نیز کنترل شود. اگر s_{ij} شباهت بین دو نمونه‌ی x_i و x_j باشد، می‌توان انتخاب دسته‌ای را چنین نوشت:

$$\mathcal{S}^* = \arg \max_{\mathcal{S} \subseteq \mathcal{D}_U, |\mathcal{S}|=b} \left[\sum_{x_i \in \mathcal{S}} A_{\text{DW}}(x_i) - \lambda \sum_{\substack{x_i, x_j \in \mathcal{S} \\ i < j}} s_{ij} \right], \quad (20.1)$$

که $\lambda \geq 0$ ضریب جریمه‌ی افزونگی است. یک انتخاب رایج برای شباهت، هسته‌ی گاوسی در فضای نهفته است:

$$s_{ij} = \exp \left(-\frac{\|z_i - z_j\|_2^2}{2\rho^2} \right). \quad (21.1)$$

روش دیگر برای مدل کردن پوشش، معیار k -center است:

$$\mathcal{S}^* = \arg \min_{\mathcal{S} \subseteq \mathcal{D}_U, |\mathcal{S}|=b} \max_{x \in \mathcal{D}_U} \min_{s \in \mathcal{D}_L \cup \mathcal{S}} \|g_\phi(x) - g_\phi(s)\|_2. \quad (22.1)$$

این معیار تلاش می‌کند فاصله‌ی هر نمونه‌ی بدون برچسب تا نزدیک‌ترین نمونه‌ی برچسب دار یا انتخاب شده را کاهش دهد؛ بنابراین به پوشش هندسی کل مخزن داده کمک می‌کند.

۸.۱ تطبیق توزیع با معیارهای فاصله‌ی آماری

یک نگاه پیشرفته‌تر آن است که زیرمجموعه‌ی انتخاب شده باید توزیع داده‌های بدون برچسب را تا حد امکان بازنمایی کند. فرض کنید $\hat{P}_U$ توزیع تجربی کل مجموعه‌ی بدون برچسب و $\hat{P}_S$ توزیع تجربی زیرمجموعه‌ی انتخاب شده باشد:

$$\hat{P}_U = \frac{1}{n_U} \sum_{x_i \in \mathcal{D}_U} \delta_{z_i}, \quad \hat{P}_S = \frac{1}{b} \sum_{x_i \in \mathcal{S}} \delta_{z_i}. \quad (23.1)$$

در این صورت، می‌توان انتخاب نمونه را به صورت مسئله‌ی مصالحه میان اطلاعات و تطبیق توزیع تعریف کرد:

$$\mathcal{S}^* = \arg \min_{\mathcal{S} \subseteq \mathcal{D}_U, |\mathcal{S}|=b} \left[\text{MMD}^2(\hat{P}_U, \hat{P}_S) - \eta \frac{1}{b} \sum_{x_i \in \mathcal{S}} U(x_i) \right], \quad (24.1)$$

که $\eta \geq 0$ تعادل میان نمایندگی توزیعی و عدم قطعیت را تعیین می‌کند.

فاصله‌ی MMD با هسته‌ی مثبت‌معین k به صورت زیر نوشته می‌شود:

$$\text{MMD}^2(\hat{P}_U, \hat{P}_S) = \frac{1}{n_U} \sum_{i=1}^{n_U} \sum_{j=1}^{n_U} k(z_i, z_j) + \frac{1}{b^2} \sum_{x_i, x_j \in \mathcal{S}} k(z_i, z_j) \quad (25.1)$$

$$- \frac{2}{n_U b} \sum_{i=1}^{n_U} \sum_{x_j \in \mathcal{S}} k(z_i, z_j). \quad (26.1)$$

همچنین می‌توان از انتقال بهینه برای اندازه‌گیری فاصله‌ی توزیعی استفاده کرد. اگر وزن‌های تجربی دو توزیع با a و b و ماتریس هزینه با $\|z_i - z_j\|_2^2$ نشان داده شود، فاصله‌ی انتقال بهینه چنین است:

$$W_C(\hat{P}_U, \hat{P}_S) = \min_{\pi \in \Pi(a, b)} \sum_{i, j} \pi_{ij} C_{ij}, \quad (27.1)$$

که در آن $\Pi(a, b)$ مجموعه‌ی کوپلینگ‌هایی است که حاشیه‌های آن‌ها برابر a و b است. این نگاه برای انتخاب نمونه‌هایی که ساختار کلی توزیع را حفظ می‌کنند مناسب است، هرچند هزینه‌ی محاسباتی آن باید با تقریب‌ها یا نسخه‌های منظم‌شده کنترل شود.

۹.۱ سوگیری نمونه‌گیری فعال و وزندهی اهمیت

یکی از نکات مهم در یادگیری فعال این است که داده‌ی برچسب‌دار تولیدشده توسط الگوریتم، نمونه‌گیری تصادفی مستقل از توزیع واقعی نیست. اگر $q(x)$ توزیع انتخاب فعال و $p_X(x)$ توزیع واقعی ورودی باشد، ریسک واقعی برابر است با:

$$R(\theta) = \mathbb{E}_{x \sim p_X, y \sim p(y|x)} [\ell(f_\theta(x), y)]. \quad (28.1)$$

اما داده‌های برچسب‌دار طبق $q(x)$ انتخاب می‌شوند. اگر $q(x) > 0$ هر جا که $p_X(x) > 0$ می‌توان ریسک را با وزندهی اهمیت نوشت:

$$R(\theta) = \mathbb{E}_{x \sim q, y \sim p(y|x)} \left[\frac{p_X(x)}{q(x)} \ell(f_\theta(x), y) \right]. \quad (29.1)$$

بنابراین، یک الگوریتم فعال شدیداً متمرکز بر نواحی خاص، ممکن است تخمین ریسک را دچار سوگیری کند. روش‌های توزیع‌آگاه با حفظ نمایندگی و پوشش داده‌ها، این مشکل را کاهش می‌دهند.

۱۰.۱ تابع اکتساب پیشنهادی برای یادگیری فعال توزیعی

بر اساس بحث‌های قبل، یک تابع اکتساب ترکیبی را می‌توان به صورت زیر تعریف کرد:

$$A(x_i) = \underbrace{U(x_i)}_{\text{ابهام مدل}} \cdot \underbrace{(\hat{p}(z_i) + \epsilon)^\beta}_{\text{نمایندگی توزیعی}} \cdot \underbrace{(1 - d_L(x_i))^\gamma}_{\text{فاصله از دانسته‌های فعلی}}, \quad (30.1)$$

که در آن $\epsilon > 0$ برای پایداری عددی است و $d_L(x_i)$ شباهت نمونه‌ی x_i به مجموعه‌ی برچسب‌دار فعلی را نشان می‌دهد:

$$d_L(x_i) = \max_{(x_j, y_j) \in \mathcal{D}_L} \exp \left(-\frac{\|z_i - z_j\|_2^2}{2\rho^2} \right). \quad (31.1)$$

در این رابطه، اگر نمونه‌ای بسیار نزدیک به داده‌های برچسب‌دار قبلی باشد، مقدار $d_L(x_i)$ بزرگ می‌شود و عامل $1 - d_L(x_i)$ امتیاز آن را کاهش می‌دهد. بنابراین الگوریتم به سمت نمونه‌هایی می‌رود که هم مبهم و نماینده‌اند و هم اطلاعات تکراری نسبت به مجموعه‌ی برچسب‌دار فعلی ندارند. برای انتخاب دسته‌ای، می‌توان پس از محاسبه‌ی امتیاز نقطه‌ای، یک مرحله‌ی انتخاب تنوع‌محور اضافه کرد:

$$S^* = \arg \max_{S \subseteq \mathcal{D}_U, |S|=b} \left[\sum_{x_i \in S} A(x_i) - \lambda \sum_{i < j} s_{ij} \right]. \quad (32.1)$$

این مسئله در حالت کلی ترکیبیاتی است؛ اما می‌توان آن را با روش حریصانه حل کرد.

الگوریتم ۱ یادگیری فعال مبتنی بر توزیع

Require: مجموعه‌ی برچسب‌دار اولیه $\mathcal{D}_L$ ، مجموعه‌ی بدون برچسب $\mathcal{D}_U$ ، بودجه‌ی کل B ، اندازه‌ی دسته b

Ensure: مدل نهایی f_θ

- ۱: مدل f_θ را روی $\mathcal{D}_L$ آموزش دهید.
- ۲: **do** $t = 1, 2, \dots, \lfloor B/b \rfloor$ **for**
- ۳: نمایش نهفته‌ی نمونه‌ها را محاسبه کنید: $z_i = g_\phi(x_i)$ برای $x_i \in \mathcal{D}_U$.
- ۴: برای هر $x_i \in \mathcal{D}_U$ عدم قطعیت $U(x_i)$ را محاسبه کنید.
- ۵: چگالی تجربی $\hat{p}(z_i)$ را با هسته‌ی گاوسی یا روش همسایگی محاسبه کنید.
- ۶: فاصله یا شباهت هر نمونه به مجموعه‌ی برچسب‌دار فعلی را محاسبه کنید.
- ۷: امتیاز $A(x_i)$ را طبق رابطه‌ی (۳۰.۱) به دست آورید.
- ۸: یک دسته‌ی متنوع $\mathcal{S}_t$ را با حل حریصانه‌ی رابطه‌ی (۳۲.۱) انتخاب کنید.
- ۹: برچسب نمونه‌های $\mathcal{S}_t$ را از کارشناس دریافت کنید.
- ۱۰: $\mathcal{D}_U \leftarrow \mathcal{D}_U \setminus \mathcal{S}_t$ و $\mathcal{D}_L \leftarrow \mathcal{D}_L \cup \{(x, y) : x \in \mathcal{S}_t\}$.
- ۱۱: مدل f_θ را با مجموعه‌ی برچسب‌دار جدید به‌روزرسانی کنید.
- ۱۲: **for end**
- ۱۳: f_θ **return**

۱۱.۱ تحلیل پارامترها

در تابع پیشنهادی، پارامترهای γ و λ رفتار الگوریتم را کنترل می‌کنند. پارامتر β شدت توجه به چگالی را مشخص می‌کند. اگر β کوچک باشد، الگوریتم بیشتر به عدم قطعیت توجه می‌کند؛ اگر β بزرگ باشد، نمونه‌های پرت حذف می‌شوند اما ممکن است برخی نمونه‌های مرزی کم‌چگال نیز نادیده گرفته شوند. پارامتر γ نقش فاصله از داده‌های برچسب‌دار را کنترل می‌کند. مقدار زیاد آن باعث می‌شود الگوریتم از نمونه‌های نزدیک به داده‌های برچسب‌دار دور شود و پوشش بیشتری ایجاد کند. پارامتر λ نیز میزان تنوع در انتخاب دسته‌ای را تعیین می‌کند. یک راه عملی برای تنظیم این پارامترها استفاده از برنامه‌ی افزایشی است. در تکرارهای ابتدایی، به دلیل کوچک بودن مجموعه‌ی برچسب‌دار، بهتر است چگالی و پوشش وزن بیشتری داشته باشند. در تکرارهای بعدی که مدل پایدارتر می‌شود، می‌توان وزن عدم قطعیت را افزایش داد. برای نمونه:

$$\beta_t = \beta \cdot \exp(-\alpha t), \quad \eta_t = 1 - \exp(-\alpha t), \quad (33.1)$$

که در آن η_t وزن عدم قطعیت و β_t وزن نمایندگی توزیعی در دور t است.

۱۲.۱ معیارهای ارزیابی

برای ارزیابی یادگیری فعال، فقط دقت نهایی مدل کافی نیست. باید بررسی شود که الگوریتم با چه تعداد برچسب به چه سطحی از عملکرد می‌رسد. مهم‌ترین معیارها عبارت‌اند از:

(۱) منحنی عملکرد بر حسب بودجه: دقت، F1-score یا زیان آزمون در برابر تعداد نمونه‌های برچسب‌گذاری شده رسم می‌شود.

(۲) مساحت زیر منحنی یادگیری: اگر $M(b)$ عملکرد مدل در بودجه‌ی b باشد، شاخص کلی می‌تواند به صورت زیر تعریف شود:

$$AULC = \frac{1}{B} \sum_{t=1}^B M(t). \quad (34.1)$$

(۳) نرخ صرفه‌جویی برچسب: تعداد برچسب‌های لازم برای رسیدن به یک آستانه‌ی عملکرد مشخص با روش‌های منفعل و فعال مقایسه می‌شود.

(۴) پوشش توزیعی: فاصله‌ی توزیع زیرمجموعه‌ی انتخاب‌شده از توزیع کل داده‌های بدون برچسب با معیارهایی مانند MMD یا فاصله‌ی مرکزها اندازه‌گیری می‌شود.

(۵) پایداری در برابر نمونه‌های پرت: حساسیت الگوریتم به داده‌های دورافتاده و نویزی بررسی می‌شود.

۱۳.۱ جمع‌بندی

در این فصل یادگیری فعال از دیدگاه توزیعی بررسی شد. ابتدا صورت‌بندی کلی یادگیری فعال و معیارهای کلاسیک مانند عدم قطعیت، پرس‌وجو با کمیته، تغییر مورد انتظار مدل و کاهش مورد انتظار خطا معرفی شد. سپس نشان داده شد که انتخاب صرفاً مبتنی بر عدم قطعیت می‌تواند به انتخاب نمونه‌های پرت یا تکراری منجر شود. برای رفع این مشکل، مؤلفه‌های چگالی، نمایندگی، تنوع و تطبیق توزیع وارد تابع اکتساب شدند.

نتیجه‌ی اصلی فصل آن است که نمونه‌ی مناسب برای برچسب‌گذاری فقط نمونه‌ی نامطمئن نیست؛ بلکه نمونه‌ای است که در عین نامطمئن بودن، بخشی مهم و نماینده از توزیع داده‌ها را پوشش دهد. این نگاه، یادگیری فعال را از یک مسئله‌ی صرفاً نقطه‌ای به یک مسئله‌ی انتخاب زیرمجموعه‌ی توزیع‌آگاه تبدیل می‌کند. چنین چارچوبی برای مسائل عملی که بودجه‌ی برچسب‌گذاری محدود و توزیع داده‌ها ناهمگن، نامتوازن یا دارای نواحی کم‌چگال است اهمیت ویژه‌ای دارد.

کتاب نامه

- [۱] Report Technical Sciences Computer ،Active Learning Literature Survey Settles، B. [۱]
،۲۰۰۹ Wisconsin—Madison، of University ،۱۶۴۸
- Active Learning with Statistical Jordan، I. M. and Ghahramani، Z. Cohn، A. D. [۲]
،۱۹۹۶، ۱۴۵—۱۲۹ pp. ،۴ vol. Research، Intelligence Artificial of Journal ،Models
- ،A Sequential Algorithm for Training Text Classifiers Gale، A. W. and Lewis D. D. [۳]
،۱۹۹۴، ۱۲—۳ pp. SIGIR، of Proceedings
- Proceedings ،Query by Committee Sompolinsky، H. and Oppor، M. Seung، S. H. [۴]
،۲۹۴—۲۸۷ pp. Theory، Learning Computational on Workshop Annual Fifth the of
،۱۹۹۲
- Toward Optimal Active Learning through Sampling Esti- McCallum، A. and Roy N. [۵]
،۲۰۰۱، ۴۴۸—۴۴۱ pp. ICML، of Proceedings ،mation of Error Reduction
- An Analysis of Active Learning Strategies for Sequence Craven، M. and Settles B. [۶]
،۲۰۰۸، ۱۰۷۹—۱۰۷۰ pp. EMNLP، of Proceedings ،Labeling Tasks
- Active Learning for Convolutional Neural Networks: A Core- Savarese، S. and Sener O. [۷]
،۲۰۱۸ Representations، Learning on Conference International ،Set Approach
- Deep Bayesian Active Learning with Image Ghahramani، Z. and Islam، R. Gal، Y. [۸]
،۲۰۱۷، ۱۱۹۲—۱۱۸۳ pp. ICML، of Proceedings ،Data