



رساله دکتری
در رشته
مهندسی کامپیوتر، گرایش نرم افزار

عنوان

یادگیری فعال در فضای ورودی و پارامتر

استاد راهنما
هادی صدوقی یزدی

نگارنده
سیدحسین غفاریان

بهار ۱۳۹۸

الحمد لله

اظهارنامه

عنوان رساله : یادگیری فعال در فضای ورودی و پارامتر

اینجانب سیدحسین غفاریان دانشجوی دوره دکتری دانشکده مهندسی دانشگاه دانشگاه فردوسی مشهد نویسنده رساله تحت راهنمایی هادی صدوقی یزدی متعهد می‌شوم:

- آ. تحقیقات در این رساله توسط اینجانب انجام شده و از صحت و اصالت برخوردار است.
- ب. در استفاده از نتایج پژوهش‌های محققان دیگر به مرجع مورد استفاده استناد شده است.
- ج. مطالب مندرج در این رساله تاکنون توسط خود یا فرد دیگری برای دریافت هیچ نوع مدرک یا امتیازی به جایی ارائه نشده است.
- د. کلیه حقوق این اثر متعلق به دانشگاه دانشگاه فردوسی مشهد است و مقالات مستخرج با نام ”دانشگاه دانشگاه فردوسی مشهد“ و یا ”Ferdowsi University of Mashhad“ به چاپ خواهد رسید.
- ه. حقوق معنوی تمام افرادی که در به دست آمدن نتایج اصلی رساله تاثیرگذار بوده‌اند در مقالات مستخرج از آن رعایت شده است.
- و. در کلیه مراحل انجام این رساله، در مواردی که از موجود زنده (یا بافت‌های آن‌ها) استفاده شده، ضوابط و اصول اخلاقی رعایت شده است.
- ز. در کلیه مراحل انجام این رساله، در مواردی که به حوزه اطلاعات شخصی افراد دسترسی یافته یا استفاده شده، اصل رازداری، ضوابط و اصول اخلاقی انسانی رعایت شده است.

تاریخ
امضای دانشجو

مالکیت نتایج و حق نشر

- کلیه حقوق این اثر و محصولات آن (مقالات مستخرج، برنامه‌های رایانه‌ای، نرم‌افزارها و تجهیزات ساخته شده) متعلق به دانشگاه دانشگاه فردوسی مشهد است. این مطلب بایستی به نحو مقتضی در تولیدات علمی مربوطه ذکر شود.
- استفاده از اطلاعات و نتایج این رساله بدون ذکر مرجع مجاز نیست.

صورتجلسه دفاع از رساله دکتری

جلسه دفاع از رساله آقای/خانم سیدحسین غفاریان دانشجوی دوره دکتری رشته گرایش
..... در ساعت روز در محل دانشکده با حضور
امضاء کنندگان ذیل تشکیل گردید. پس از بررسی های لازم، هیأت داوران پایان نامه نامبرده را با نمره به
عدد.....، به حروف و با درجه مورد تایید قرارداد/نداد.
عنوان رساله

.....
هیئت داوران امضا

- داور: دکتر.....
گروه..... دانشگاه.....
- داور: دکتر.....
گروه..... دانشگاه.....
- استاد راهنما: دکتر.....
گروه..... دانشگاه.....
- استاد مشاور: دکتر.....
گروه..... دانشگاه.....
- نماینده تحصیلات تکمیلی: دکتر.....
- مدیرگروه: دکتر.....
گروه..... دانشگاه.....



بسمه تعالی
مشخصات رساله تحصیلی دانشجویان
دانشگاه دانشگاه فردوسی مشهد

عنوان: یادگیری فعال در فضای ورودی و پارامتر

نام نویسنده: سیدحسین غفاریان

استاد راهنما: هادی صدوقی یزدی

دانشکده: مهندسی گروه: مهندسی کامپیوتر

رشته تحصیلی: مهندسی کامپیوتر

تاریخ دفاع: ۱۳۹۸/۰۴/۲۹

تاریخ تصویب: ۱۳۹۸/۰۲/۱۰

تعداد صفحات: ۱۹۳

مقطع تحصیلی: دکتری

چکیده: الگوریتم های نظارت شده برای یادگیری نیاز به دانش زمینه در قالب مناسب دارند. الگوریتم های یادگیری فعال با هدف افزایش دقت و کاهش هزینه نظارت بصورتی کنجکاوانه به پرس وجو از ناظر می پردازند. در بسیاری از کاربردها، دانش مورد نظر در سطح نمونه های برداشته شده از توزیع وجود ندارد بلکه این دانش در سطح توزیع قرار دارد. بنابراین مساله یادگیری فعال روی توزیع را پیشنهاد می کنیم. یادگیری فعال روی توزیع گامی برای ارتباط غنی تر با ناظر است. در یادگیری روی توزیع، هر مثال خود توزیع است. با توجه به اینکه اندازه نمونه برداشته شده از توزیع محدود و برای هر مثال متفاوت است، چالشهای زیادی در یادگیری فعال روی توزیع مطرح است. بنابراین ابتدا مسئله یادگیری فعال را در جامع ترین شکل ممکن از دو دیدگاه کمینه سازی ریسک تجربی و نظریه یادگیری برای طبقه بند الحاقی تحلیل می کنیم. سپس حدبالایی برای ریسک طبقه بند در مسئله یادگیری فعال ارائه کردیم. با کمینه کردن این حدبالا روشی برای یادگیری فعال ارائه کردیم که بصورت قابل اثبات بهینه است. این اولین روش کاملاً بی‌زیان در یادگیری فعال است که نیاز به کمترین پیش فرض ها در مسئله یادگیری دارد. در تطابق با خصوصیات ذاتی مسئله یادگیری فعال، این روشی بیشینه-کمینه و احتمالاتی در یادگیری فعال است. در گام بعد این روش را برای مسئله یادگیری فعال مقاوم تحلیل کرده و الگوریتمی برای آن ارائه نمودیم. در یادگیری فعال مقاوم، تخمین دقیق از هر نمونه وجود ندارد و اندازه گیری نمونه ها دارای خطا است. با توجه به این ویژگیها این الگوریتم زیربنای مناسبی برای حل مسئله یادگیری فعال روی توزیع فراهم می کند. چالش دیگری که برای حل مسئله یادگیری فعال روی توزیع وجود دارد، اندازه های متفاوت برای هر توزیع است. به منظور حل این مسئله رویکردی بی‌زیان برای حل مسئله در فضای کرنل هیلبرت پیشنهاد کردیم. متأسفانه با چالش رام نشدنی بودن محاسبه تابع هدف این مسئله برمی خوریم. به این منظور تخمینی مناسبی از این تابع هدف ارائه کرده و ثابت کردیم که این تخمین، تخمین مناسب و تنگی از مسئله است.

واژگان کلیدی: یادگیری فعال، یادگیری فعال روی توزیع، یادگیری فعال بیشینه-کمینه احتمالاتی

امضای استاد راهنما:

تاریخ:

فهرست نمادها و علائم ریاضی

نماد	نام
$\sum$	جمع
$\prod$	ضرب
$/$	تقسیم
$x \sim P$	x دارای توزیع P
I_A	تابع ایندیکاتور برای مجموعه A
$E_{x \sim p(x)}[g(x)]$	امید ریاضی تابع $g(x)$ نسبت به متغیر x با چگالی p
$\int_x$	انتگرال نسبت به متغیر x
$O(\cdot)$	نماد O بزرگ
$ \cdot $	قدر مطلق (با آرگومان اسکالر)
$ A $	کاردینالیتی مجموعه
$Tr(\cdot)$	Trace مجموع عناصر قطری ماتریس
$\lambda_{max}(\cdot)$	بزرگترین مقدار ویژه ماتریس
$A \succeq B$	ماتریس $A - B$ نیمه معین مثبت
$\ \cdot\ $	نرم بردار یا تابع در فضای مورد نظر
$\mathbf{1}$	برداری با مولفه های برابر یک
sup	سوپریمم
$sign(\cdot)$	علامت
$(x)_+$	تابع Hinge
∇	گرادیان
$\mu(dx)$	measure معادل $d(\mu(x))$
$\langle \cdot, \cdot \rangle$	ضرب داخلی

فهرست مطالب

۳	۱ مقدمه
۴	۱.۱ انگیزه تحقیق
۵	۱.۱.۱ دانش در سطح توزیع
۶	۲.۱.۱ پرسش
۷	۲.۱ تعریف مسئله و اهداف رساله
۱۱	۲ پیشینه تحقیق
۱۱	۱.۲ یادگیری روی توزیع
۱۵	۲.۲ یادگیری فعال
۱۸	۱.۲.۲ روشهای حاوی اطلاعات
۲۲	۲.۲.۲ روشهای نماینده
۲۴	۳.۲.۲ سایر روشهای ابتکاری
۲۸	۴.۲.۲ رویکردهای اصولی به یادگیری فعال
۳۳	۳ یادگیری فعال روی توزیع
۳۴	۱.۳ تحلیل راهکارهای تئوریک برای مسئله یادگیری فعال

۳۴	به سوی یادگیری فعال برای کمینه سازی ریسک تجربی	۱۰.۱.۳
۴۹	یادگیری فعال چند وظیفه ای	۲۰.۱.۳
۵۲	یادگیری مبتنی بر انتقال دانش ممتاز	۳۰.۱.۳
۶۲	یادگیری فعال بیشینه-کمینه احتمالاتی	۴۰.۱.۳
۷۴	رویکرد تابعی به یادگیری فعال بیشینه کمینه احتمالاتی	۲۰.۳
۸۴	یادگیری فعال در حوزه توزیع	۳۰.۳
۸۴	یادگیری روی توزیع	۱۰.۳.۳
۸۹	یادگیری فعال روی توزیع مبتنی بر یادگیری فعال بیشینه-کمینه احتمالاتی	۲۰.۳.۳
۹۰	یادگیری فعال بیزی مقاوم روی فضای ورودی	۳۰.۳.۳
۱۰۰	یادگیری فعال مقاوم روی توزیع با استفاده از یادگیری بیزی نهفته سازی کرنل	۴۰.۳.۳

۴ آزمایشها ۱۰۷

۱۰۷	آزمایشهای مربوط به رویکردگرایان تابعی	۱۰۰.۴
۱۱۱	مقایسه با رویکردهای مبتنی بر boosting	۲۰۰.۴
۱۱۳	پایگاه داده های توزیعی	۳۰۰.۴
۱۱۵	پایگاه داده های دنیای واقعی	۴۰۰.۴
۱۱۸	آنالیز اثر یادگیری بیزی نهفته سازی کرنلی توزیع ها	۵۰۰.۴
۱۱۹	نتیجه گیری	۱۰۴

۵ نتیجه گیری ۱۲۹

۱۳۰	پیشنهادی های آتی	۱۰۵
-----	------------------	-----

آ اثبات های خصوصیات تئوریک طبقه بند-ساده پیچیده ۱۳۳

۱۶۴

واژه‌نامه فارسی به انگلیسی

۱۷۳

واژه‌نامه انگلیسی به فارسی

۱۸۳

نمایه

فهرست شکل‌ها

- ۱۰۳ داده‌های پرت بسیار واضح برای نشان دادن کانتور توابع به داده اضافه شده‌اند. چنانکه دیده می‌شود، طبقه بند ساده تاثیر نسبتاً کمی از داده‌های پرت پذیرفته است و طبقه بند پیچیده همه داده‌های پرت را در خود جذب کرده است. در مقایسه کانتور تابع SVM به شدت تاثیر گرفته است. این موضوع در مرز طبقه بند در انتخاب یادگیری فعال تاثیر می‌گذارد. ۴۱
- ۲۰۳ برای بررسی رفتار طبقه بند ساده-پیچیده وقتی پایگاه داده سنتزی با چند مثال با برجسب نویزی در نزدیکی مرز طبقه بند افزوده شده‌اند. چنانکه دیده می‌شود، کانتور طبقه بند ساده انحراف پیدا نکرده است. برعکس، طبقه بندی پیچیده مثالهای برجسب-نویزی را شناسایی کرده است. مرز SVM به شدت اعوجاج پیدا کرده است. ۴۲
- ۳۰۳ مثالهای با برجسب نویزی وقتی که دور از مرز طبقه بند هستند. کانتور SVM به شدت انحراف پیدا کرده است. بعلاوه مرز طبقه بند SVM نیز شدیداً دچار اعوجاج شده است. در حالیکه طبقه بند ساده تقریباً هیچ تغییری نکرده است و طبقه بند پیچیده این مثالها را شناسایی کرده است. ۴۳
- ۴۰۳ بررسی رفتار الگوریتم وقتی داده‌های پرت نزدیک مرز هستند. اگرچه هر دو طبقه بند SVM و طبقه بند پیشنهادی نسبتاً خوب عمل کرده‌اند، کانتور SVM تاثیر نسبتاً بیشتری پذیرفته است. ۴۴
- ۵۰۳ رویکرد گرادیان تابعی به یادگیری بیشینه-کمینه احتمالاتی ۷۶
- ۱۰۴ مقایسه کارایی الگوریتم پیشنهادی و سایر الگوریتم‌ها روی پایگاه داده‌های مختلف ۱۰۸
- ۲۰۴ مقایسه کارایی الگوریتم پیشنهادی و سایر الگوریتم‌ها روی پایگاه داده‌های مختلف ۱۰۹

۳.۴	مقایسه کارآیی الگوریتم پیشنهادی و سایر الگوریتم ها روی پایگاه داده های مختلف	۱۲۰
۴.۴	مقایسه روش پیشنهادی با سایر روشهای boosting	۱۲۱
۵.۴	مقایسه روش پیشنهادی با روشهای مبتنی بر تفاوت بین دو توزیع	۱۲۲
۶.۴	مقایسه دقت طبقه بند در یادگیری فعال روی پایگاه داده GAUSSDIST برای دو حالت با اندازه نمونه متفاوت و اندازه نمونه ثابت از هر توزیع	۱۲۳
۷.۴	مقایسه دقت طبقه بندی برای گروهی از مجموعه پایگاه داده ۲۰newsgroup هر شکل در بالا یک طبقه بندی بین دو کلاس با شماره کلاسهای مذکور را نشان می دهد. شماره کلاس ها در جدول ۴.۴ قرار دارند.	۱۲۴
۸.۴	مقایسه دقت طبقه بندی برای گروه دیگری از مجموعه پایگاه داده ۲۰newsgroup هر شکل در بالا یک طبقه بندی بین دو کلاس با شماره کلاسهای مذکور را نشان می دهد. شماره کلاس ها در جدول ۴.۴ قرار دارند.	۱۲۵
۹.۴	مقایسه دقت در یادگیری فعال برای پایگاه داده USPDSDIST	۱۲۶
۱۰.۴	مقایسه دقت طبقه بندی بین یادگیری فعال بیزی در فضای هیلبرت PMARLDS با PMARLDB برای پایگاه داده ۲۰newsgroup. شماره کلاس ها در جدول ۴.۴ قرار دارند.	۱۲۷

فهرست جدول‌ها

۶۳	جدول نمادهای مربوط به یادگیری بیشینه-کمینه احتمالاتی	۱۰۳
۸۹	جدول نمادهای مربوط به یادگیری فعال روی توزیع	۲۰۳
۱۱۰	خصوصیات پایگاه داده ها	۱۰۴
۱۱۲	زمان صرف شده توسط روشهای یادگیری فعال روی پایگاه داده های مختلف	۲۰۴
۱۱۳	زمان صرف شده در الگوریتم ها روی تعدادی از پایگاه داده	۳۰۴
۱۱۷	کلاسهای پایگاه داده 20newsgroup	۴۰۴

فهرست الگوریتم‌ها

۷۸		Learning Active Probabilistic Gradient Functional General	۱
۸۲		Algorithm KernelL۲Boost Active	۲

فصل ۱

مقدمه

To think deeply about simple things, Arnold Ross

در اغلب مسائل دنیای واقعی یادگیری برای انسان ساده اما ارائه الگوریتم برای آن دشوار است. عبارت دیگر رمزگشایی از دانش انسانی در یادگیری و تبدیل این دانش به الگوریتم بسیار پیچیده است. پیش از ظهور یادگیری ماشین، توسعه الگوریتم برای هر مسئله متمرکز بر ارائه الگوریتمی بود که بتواند براساس ورودی ها نتایج مورد انتظار را برای مسئله مورد نظر ارائه کند. بزودی مشخص شد که ارائه الگوریتم برای حل بسیاری از مسائل یادگیری با این رویکرد بسیار مشکل است. در فرایند حل این مسئله، حوزه یادگیری ماشین^۲ بوجود آمد. اکنون پس از گذشت سه دهه گذشته، تحقیقات در حوزه یادگیری ماشین بطور چشمگیری گسترش یافته و به نتایج فوق العاده ای رسیده است. الگوریتم های یادگیری ماشین در کاربردهای بسیاری در زندگی روزمره و صنعت در حال استفاده اند. در این مدت، یادگیری ماشین از موضوعی کاملاً تحقیقاتی به موضوع اساسی تحول تکنولوژیکی در صنایع گوناگون تبدیل شده است.

²Machine Learning

برای یادگیری موفقیت آمیز یک مفهوم^۱ سیستم های یادگیری ماشین نیاز به دانش دارند. بدون در اختیار داشتن دانش، سیستم های یادگیری^۲ نمی توانند یادگیری را به داده های دیده نشده، داده های آزمون^۳، تعمیم^۴ دهند. دانش در سیستم های یادگیری می تواند بصورت دانش پیشین^۵ باشد و یا با انتقال دانش کاربر انسانی بدست آید. دانش پیشین برای بسیاری از مسائل به اندازه کافی در دسترس نیست بنابراین دست یابی به دانش کاربر انسانی اهمیت حیاتی دارد. در انتقال دانش می توانیم از رابطه بین معلم و شاگرد الهام بگیریم.

۱.۱ انگیزه تحقیق

رابطه بین کاربر انسانی یا در اصطلاح یادگیری فعال پیش گو^۶ و سیستم یادگیر^۷، مشابه رابطه بین معلم و شاگرد است. سیستم یادگیر، نقش شاگرد و کاربر انسانی نقش معلم را دارد. انتقال دانش از کاربر انسانی، به سیستم یادگیر، صورت می گیرد. فرایند یادگیری توسط ارائه اطلاعات و پرسش و پاسخ توسط معلم و شاگرد و یا پیش گو و سیستم یادگیر، انجام می شود.

در رابطه معلم و شاگرد، دانش از طریق تدریس و پاسخ به پرسش های شاگرد به او منتقل می شود. دانش ارائه شده توسط معلم معمولاً در سطحی جزئی نیست بلکه معلم اغلب دانش را در قالب مفاهیمی کلی و انتزاعی به شاگرد ارائه می کند. گاه دانش را در قالب مجموعه قوانینی کلی در رابطه با مفهوم مورد یادگیری ارائه می کند و گاه از مفاهیمی انتزاعی به عنوان ابزاری برای انتقال دانش استفاده می کند. به همین ترتیب شاگرد نیز از ابزارهای انتزاعی برای پرسش استفاده می کند. بعبارت دیگر، ارتباط بین معلم و شاگرد ارتباطی غنی است از این جهت که معلم با استفاده از ارائه دانش در قالب های انتزاعی تر می تواند با تلاش کمتر سطح عمیق تر و بهتری از یادگیری را با صرف زمان کمتر به شاگرد ارائه کند.

برخلاف رابطه بین معلم و شاگرد، رابطه بین سیستم های یادگیر و پیش گو رابطه ای سطحی است. در این سیستم ها، دانش کاربر انسانی در قالب نظارت^۸، تعیین نوع برای تعدادی مثال از داده ها، به سیستم یادگیر منتقل می شود. با در اختیار داشتن تعدادی مثال، الگوریتم های یادگیری نظارت شده^۹ تلاش می کنند تابعی را یاد بگیرند که نوع یا بعبارت دیگر، برچسب^{۱۰} مثال را

^۱ Concept

^۲ Learning Systems

^۳ Test data

^۴ Generalize

^۵ Prior Knowledge

^۶ Oracle

^۷ Learning System

^۸ Supervision

^۹ Supervised learning

^{۱۰} Label

شناسایی کند. در اینجا منظور از مثال^۱ هر داده ای است که الگوریتم، باید دانشی در مورد آن فرا بگیرد. در یادگیری نظارت شده، نیاز به تعداد کافی مثال به همراه برچسب داریم. معمولاً مثال برداری n -بعدی است. این رابطه ای سطحی است زیرا انتقال اطلاعات در پایین ترین سطح از نظر انتزاعی، برچسب برای مثالهای برداری، صورت می گیرد.

در رابطه ای چنین سطحی بین سیستم یادگیر و کاربر انسانی، نیاز به تهیه برچسب برای تعداد زیادی مثال داریم که امری هزینه بر است. اغلب لازم است شخصی برخوردار از سطح کافی دانش در موضوع، مثال ها را مورد به مورد بررسی و برچسب آنها را تعیین کند. بعنوان نمونه، در شناسایی بیماری از روی نتایج آزمایشها، پزشکی متخصص می بایست نتایج آزمایشها و تصاویر پزشکی را بررسی کرده و نوع بیماری را تعیین کند.

ضعف اصلی رابطه معمول بین سیستم های یادگیر و کاربر انسانی، عدم توانایی آنها در انتقال اطلاعات در قالب های سطح بالاتر است. بعبارت دیگر، در این سیستم ها دانش باید قابل نمایش در سطح بردار باشد. با فراهم کردن انتقال اطلاعات در قالب های سطح بالاتر در رابطه سیستم یادگیر و کاربر انسانی مشابه رابطه شاگرد و معلم، راه برای توسعه سیستم هایی با راندمان بالاتر در محاوره بین سیستم یادگیر و کاربر انسانی باز می شود.

برای حصول به رابطه ای شبیه تر به رابطه معلم و شاگرد، نیاز به امکان محاوره بین سیستم یادگیر و کاربر انسانی در سطحی از نظر انتزاعی بالاتر داریم. در چندسال اخیر، تلاشهایی برای یادگیری در سطوح بالاتر مانند یادگیری ساخت یافته^۲ و یادگیری روی توزیع^۳ شده است. بعنوان مثال، در یادگیری ساخت یافته یادگیری روی اشیاء ساخت یافته مانند گراف و درخت انجام می شود. همچنین در یادگیری روی توزیع، هر مثال خود توزیع است.

۱.۱.۱ دانش در سطح توزیع

در بسیاری از کاربردهای یادگیری ماشین، دانش در سطح بردار نیست. مثلاً در حملات پیچیده به شبکه های کامپیوتری، تراکنش ها ممکن است دارای ویژگی خاصی نباشند. حمله کننده تلاش می کند بدون برانگیختن شک افراد و شناسایی شدن توسط الگوریتم ها حمله ای طراحی کند که در آن هر تراکنش بسیار معمولی و قابل قبول باشد و در عین حال حمله با استفاده از مجموعه ای از این تراکنش ها انجام گیرد. طراح حمله تلاش می کند که اطلاعات حمله در سطح تراکنش ها روشن نباشد. بلکه اطلاعات حمله

¹Example

²Structured Learning

³Learning On Distributions

در سطح توزیع تراکنش ها قرار داشته باشد. در چنین شرایطی، رویکردهای جاری، بهینه نیستند.

رویکردهای جاری در یادگیری ماشین فرض می کنند اطلاعات بصورت برداری نمایش داده شده اند [۱۴۴]. این در حالیستکه اطلاعات در این کاربردها بصورت طبیعی در قالب بردارهایی ساده قرار ندارند. در مثال حمله به شبکه های کامپیوتری از بین تعداد زیادی تراکنش در هر حمله لازم است تعدادی انتخاب شود و در یک بردار ذخیره سازی شود. این رویکرد باعث می شود که اطلاعات زیادی در این تبدیل از بین برود.

به منظور حل این مشکل، در چندسال اخیر تحقیقاتی در خصوص یادگیری داده ها با ساختارهای انتزاعی تری مانند یادگیری روی داده های ساخت یافته یا یادگیری روی توزیع انجام شده است. بسیاری از داده های موجود دارای ساختارهایی هستند که بدون توجه به آنها، امکان یادگیری آنها با دقت مناسب وجود ندارد. به عنوان مثال، یادگیری روی داده های مطرح در قالب صفحات وب بدون توجه به داده های ساخت یافته ای که در قالب HTML یا XML هستند، ممکن نیست. همچنین ساختارهای پروتئینی و توالی های DNA نمونه های دیگری از داده های ساخت یافته هستند [۲۷، ۱۳۳]. هدف از این تحقیقات، یادگیری دانش غنی موجود در داده ها در شرایطی است که اطلاعات کمتری در فرایند تبدیل از بین برود. با این وجود، بسیار طبیعی تر است که برخی از انواع داده ها در قالب توزیع نمایش داده شوند.

در یادگیری روی توزیع، هر نمونه خود توزیع است. از آنجا که بسیاری از انواع داده ها را می توان بصورت طبیعی با توزیع نمایش داد، یادگیری روی توزیع کاربردهای بسیاری دارد. در کاربرد شناسایی حمله به شبکه های کامپیوتری، همه تراکنش ها را می توان بصورت توزیع نمایش داد. همینطور در کاربردهای پردازش متن، می توان کل متن را بصورت توزیع نمایش داد. چنین پدیده هایی، ماهیتی توزیعی دارند. در این پدیده ها، داده ها بصورت طبیعی از یک توزیع نمونه برداری می شوند. در روشهای معمول یادگیری، داده های نمونه برداری شده تبدیل به بردار می شوند. حال آنکه بهتر است مستقیماً خود توزیع را یادگیری کنیم. در چنین سیستم هایی پرسش و نظارت برای مثالها اهمیت بیشتری می بابد.

۲.۱.۱ پرسش

در رابطه بین معلم و شاگرد، پرسش اهمیتی بسزا دارد. با استفاده از پرسش هایی هوشمندانه، شاگرد می تواند مفهوم مورد یادگیری را بسیار سریعتر و با دقت بهتر فرا بگیرد. این مفهومی اساسی در یادگیری است. همه داده ها به یک اندازه در درک مفهوم موثر

نیستند. درک برخی از نکات، تاثیر فوق العاده بیشتری در یادگیری مفهوم بطورکل دارد. این موضوع را در یادگیری ماشین، تحت عنوان یادگیری فعال^۱ می شناسیم. در یادگیری فعال، سیستم یادگیر، فعال است به این معنی که بدنبال مثالهایی می گردد که با پرسش برچسب آنها از پیش گو، دقت یادگیری آن افزایش پیدا کند.

فعال بودن سیستم یادگیر اگرچه موهبت بزرگی است اما چالشی عمیق ایجاد می کند. هنگامیکه شاگرد دائما پرسش می کند این خطر وجود دارد که بخشهایی از فضای مسئله یادگیری به اندازه کافی از بودجه یادگیری^۲ برخوردار نشوند. در نتیجه یادگیری ممکن است اریب^۳ شود. با این وجود اغلب سیستم های یادگیری فعال، چه در دنیای واقعی مانند معلم و شاگرد و چه در دنیای یادگیری ماشین به امید مفیدتر بودن دانش حاصل از پرسش در مورد برخی مثالهای بااهمیت به این موضوع به اندازه کافی توجه نمی کنند.

یادگیری فعال مبتنی بر این فرض است که همه مثال ها دانش یکسان برای تابع یادگیری ارائه نمی کنند. از جنبه ای دیگر، می توان گفت که همه مثال ها به یک اندازه نماینده مثال های دیده نشده نیستند. با این فرض، الگوریتم های یادگیری فعال، تلاش می کنند مثال هایی را انتخاب کرده و برچسب آنها را از پیش گو سؤال کنند. با انتخاب هوشمند مثال هایی حاوی دانش بیشتر، الگوریتم یادگیری فعال می تواند با تعداد کمتری مثال برچسب دار، به یادگیری با دقت بالاتر دست یابد. بنابراین تحقیقات در حوزه یادگیری فعال بسیار امیدبخش است زیرا باعث پیشرفت قابل ملاحظه ای در بهبود دقت و کاهش هزینه سیستم های یادگیری ماشین می شود.

۲.۱ تعریف مسئله و اهداف رساله

امید به بهبود دقت و کاهش هزینه به همراه وجود حجم عظیمی از داده های بدون نظارت مشوق فوق العاده ای برای تحقیقات بسیار گسترده در یادگیری فعال در یک دهه گذشته بوده است. جستجویی ساده در پایگاه های علمی براحتی حجم و گستردگی این تحقیقات را نشان می دهد. این موضوع نشان از چالش ها و اهمیت فوق العاده یادگیری فعال دارد.

مسئله یادگیری فعال، مسئله ای بنیادی و غیرقابل فروکاستن به سایر مسائل یادگیری ماشین است. مسئله یادگیری فعال، مسئله ای بسیار مشکل است؛ در مقایسه با مسئله طبقه بندی، که نزدیک به پنجاه سال است در مورد آن دانش تئوریک داریم [۱۴۴]،

¹Active Learning

³Biased

²Learning Budget

دانش تئوریک در مورد یادگیری فعال هنوز در مراحل بسیار اولیه ای است [۵۷].

یکی از دلایل پیچیدگی و سختی مسئله یادگیری فعال، آنستکه در مسئله یادگیری فعال فرض های پایه ای یادگیری ماشین مانند مستقل و هم توزیع بودن^۱ بودن مثالها، برقرار نیست. هنگامیکه از بین مثالها، زیرمجموعه ای را برای پرس و جو انتخاب می کنیم، دیگر توزیع مثالهای برجسب دار با توزیع داده ها یکسان نیست. در نتیجه چون اکثریت الگوریتم های یادگیری ماشین براساس این فرض اثبات شده و یا توسعه پیدا کرده اند، عملکرد این الگوریتم ها دچار اشکال می شود. درواقع در این شرایط حتی باوجود تعداد بینهایت مثال برجسب دار ممکن است به طبقه بند بهینه دست نیابیم و یا اصطلاحا الگوریتم سازگار^۲ نباشد.

بویژه که در مورد طبقه بند و یا تابع یادگیر کمبود شدید دانش داریم. دلیل دیگر، کمبود شدید دانش بویژه در مراحل اولیه یادگیری فعال است. با توجه به عدم وجود دانش، هرگونه فرضی در رابطه با خصوصیات تابع یادگیری محدود کننده و زیر-بهینه^۳ خواهد بود.

بنابراین چالش اصلی، حل مسئله یادگیری فعال در شرایطی است که کمترین فرضهای محدود کننده را در خصوص تابع یادگیری داشته باشیم و در عین حال نقض فرض مستقل و هم توزیع بودن، باعث عدم سازگاری^۴ مسئله یادگیری نشود. حتی با وجود حجم عظیم تحقیقات، اکثریت قریب به اتفاق رویکردهای یادگیری ماشین نتوانسته اند این چالش را حل کنند.

در این رساله به یادگیری فعال بعنوان یک بازی بین سیستم یادگیر و پیش گو از منظر کمینه سازی ریسک طبقه بند نگاه می کنیم. هنگامیکه در حال توسعه سیستم یادگیری فعال در شرایطی هستیم که فرض های بسیار کمی در مورد تابع یادگیری داریم، می توانیم به سیستم یادگیر و پیش گو از دیدگاه دو بازیگر در نظریه بازی فکر کنیم. در این بازی، هدف ما برنده شدن سیستم یادگیر در برابر واقعیت هایی است که پیش گو ارائه می کند. در نتیجه برای رسیدن به حداکثر منفعت در این بازی باید خود را برای هر جوابی که پیش گو در پاسخ به پرسش به ما بدهد، آماده کنیم. در واقع استراتژی سیستم یادگیر، آنستکه با فرض بدترین جواب برای هر پرسش، پرسش خود را مطرح کند.

بنابراین سیستم یادگیر و پیش گو هریک می خواهند تابع هدف خود را بهینه کنند. در اینجا بدترین جواب به یک پرسش جوابی فرض می شود که با انتظار سیستم یادگیر یا بعبارت بهتر، مدل جاری سیستم یادگیری، حداکثر مغایرت را دارد. سیستم یادگیر باید خود را آماده بدترین شرایط کند. این شرایط وقتی است که پیش گو دائما جوابهایی می دهد که با مدل جاری سیستم

^۱Independent and identically distributed (i.i.d)

^۲Consistent

^۳Sub-optimal

^۴Inconsistency

یادگیر مغایرت داشته باشد. بنابراین دیده می شود که در واقع از دید سیستم یادگیر، مسئله یادگیری فعال مشابه مسائل نظریه بازی، مسئله ای با ساختار کمینه-بیشینه^۱ است. در نتیجه تمرکز این رساله بر ساختار کمینه-بیشینه در یادگیری فعال است.

با توجه به پیچیدگی مسئله یادگیری فعال و ساختار کمینه-بیشینه آن، حتی با وجود حجم عظیم تحقیقات صورت گرفته در این حوزه، اغلب قریب به اتفاق تحقیقات انجام شده در یادگیری فعال، رویکردهایی ابتکاری^۲ ارائه می کنند. عیب اساسی این روشها، آنستکه تضمین تئوریک کافی برای عملکرد مناسب این روشها در یادگیری فعال وجود ندارد. بنابراین، حل بهینه مسئله یادگیری فعال بدون فرض های محدود کننده هدفی دور از دسترس برای تحقیقات انجام شده در یادگیری فعال بوده است. تقریباً همه تحقیقات انجام شده در یادگیری فعال مبتنی بر رویکردهای ابتکاری و فاقد مبانی تئوریک هستند. چنانکه در بخش پیشینه خواهیم داد، چند رویکرد تئوریک به یادگیری فعال ارائه شده است که استفاده از آنها دارای چالش های متعددی است. چنانکه خواهیم دید برخی از این تلاشها، در تطابق با تحلیل ارائه شده در بالا، به مسئله بهینه سازی ای به فرم کمینه-بیشینه رسیده اند.

با توجه به عدم وجود رویکردی اصولی در یادگیری فعال، یادگیری فعال روی توزیع چالش بزرگتری ایجاد می کند زیرا دسترسی مستقیم به توزیع ها وجود ندارد. دسترسی به توزیع ها، صرفاً از طریق نمونه های برداشته شده با اندازه محدود از توزیع ها میسر است. بعلاوه نمونه برداشته شده از هر توزیع، اندازه متفاوتی دارد.

هدف اصلی این رساله، حل مسئله یادگیری فعال روی توزیع است. برای دستیابی به این هدف ابتدا به دو مسئله اساسی مطرح در یادگیری فعال روی توزیع می پردازیم. چنانکه ذکر شد در یادگیری روی توزیع به مثال ها بصورت مستقیم دسترسی نداریم. دسترسی به توزیع ها از طریق تعدادی نمونه که از توزیع نمونه برداری شده است، صورت می گیرد. این امر باعث می شود که تخمین توزیع ها نادقیق باشد. بنابراین الگوریتم های یادگیری و یادگیری فعال باید بتوانند با تخمین های نادقیق از مثال ها کار کنند. بعلاوه، اندازه نمونه ها متفاوت است و در نتیجه دقت تخمین هر توزیع بسته به اندازه نمونه ای که از آن برداشته شده است، متفاوت خواهد بود. چالش مهم دیگر این است که الگوریتم یادگیری فعال باید بتواند این مسئله را در انتخاب توزیع ها در نظر بگیرد. به منظور حل این مسئله، تلاش می کنیم رویکردی اصولی اتخاذ کنیم تا رفتار مسئله یادگیری فعال را بهتر بشناسیم.

در فصل دوم به پیشینه تحقیقات انجام شده در حوزه های مرتبط با اهداف رساله می پردازیم.

در فصل سوم به ارائه رویکرد یادگیری فعال روی توزیع می پردازیم. در راستای حصول به این هدف، روشهایی ارائه می کنیم که

^۱ min-max

^۲Heuristic

ابزارهای ما برای حل این مسئله خواهد بود.

در فصل چهارم آزمایشهای انجام شده در یادگیری فعال در فضای ورودی و توزیع را ارائه می کنیم.

در فصل پنجم نتیجه گیری و کارهای پیشنهادی آتی مطرح می شود.

فصل ۲

پیشینه تحقیق

در این فصل به بررسی پیشینه می پردازیم. پیشینه تحقیقات انجام شده از جنبه های مرتبط به رساله را در بخش های مرتبط بررسی می کنیم. چنانکه در فصل قبل دیدیم، با توجه به ایده و اهداف رساله، یادگیری فعال و یادگیری روی توزیع موضوعاتی هستند که بصورت مستقیم به محتوی رساله ارتباط دارند. بنابراین ابتدا پیشینه یادگیری روی توزیع و سپس یادگیری فعال را بررسی می کنیم.

۱.۲ یادگیری روی توزیع

در بسیاری از کاربردها، داده ها از یک توزیع برداشته می شوند. سپس داده های نمونه برداری شده از توزیع، توسط روشی به ویژگیهای توصیف کننده داده اصلی تبدیل می شوند. طبیعی تر آنستکه بتوانیم داده را بصورت مستقیم در قالب توزیع اصلی نمایش بدهیم. بعنوان مثال، یک جمله یا پاراگراف، تشکیل شده از تعدادی کلمه است. می توان فرض کرد که کلمات از یک توزیع برداشته شده اند. این توزیع بیانگر معنای مشخصی است که جمله یا پاراگراف دارد. برای یادگیری خصوصیتی از این جمله یا پاراگراف می توان مستقیماً یادگیری را روی توزیعی که کلمات از آن برداشته شده است، انجام داد. بنابراین لازم است مسئله یادگیری بتواند

روی نقاطی کار کند که هر نقطه خود یک توزیع است. اخیراً این مسئله یادگیری، تحت عنوان یادگیری روی توزیع^۱ معرفی شده است [۸۹].

در یادگیری روی توزیع، هر مثال خود توزیع است. در مقایسه، در روشهای معمولی یادگیری، هر مثال صرفاً یک بردار است. چون در عمل، بندرت به توزیع تولید کننده داده دسترسی داریم، در یادگیری روی توزیع، مثال‌ها مجهول هستند. در عوض یک نمونه با اندازه ای محدود از بردار از توزیع برداشته شده است. چالش اصلی در یادگیری روی توزیع آنستکه دسترسی مستقیم به توزیع‌ها نداریم بلکه دسترسی صرفاً از طریق این نمونه برداشته شده است. بنابراین مسئله یادگیری روی توزیع مسئله دومرحله ای است که می باید تابعی را برای توزیع‌ها با استفاده از نمونه‌های برداشته شده از توزیع‌ها یاد بگیریم [۱۳۰، ۱۳۲]. چون اندازه نمونه محدود است، هر تخمینی از توزیع نادقیق است. این نکته چالشی به چالش‌های یادگیری طبقه بند می افزاید.

رویکردهای متنوعی به مسئله یادگیری روی توزیع پیشنهاد شده است. یکی از اولین روشهای پیشنهادی، روش ماشین معیارپشتیبان^۲ است [۸۸]. این تحقیق ثابت کرد که یادگیری روی توزیع با استفاده از مفاهیم کرنل از دیدگاه نظریه یادگیری امکان پذیر است و روشی مبتنی بر ماشین بردار پشتیبان ارائه کرد. این روش با توسعه به فرم تک-کلاسه برای مسئله شناسایی ناهنجاری گروهی^۳ استفاده شد. در این مسئله، هدف شناسایی ناهنجاری وقتی است که هر جزء خود معمولی است اما کلیت اجزاء خصوصیت ناهنجاری دارد. بعنوان مثال، در نظر بگیرید که برای نفوذ به یک سیستم، هر جزء از اعمال حمله کننده قابل قبول و معمولی است اما وقتی کلیت اعمال را در نظر بگیریم ماهیت نفوذ ممکن است روشن شود [۹۰]. همچنین این مسئله برای طبقه بندی نمایش بسته ای -از-کلمات^۴ از متن بکار رفته است [۱۶۰].

فرمهای متنوعی از یادگیری روی توزیع ارائه شده است. بعنوان مثال [۹۵] روش رگرسیون ناپارامتری روی توزیع پیشنهاد می کند. سپس خصوصیات این مسئله یادگیری را از جنبه نظریه یادگیری و سرعت همگرایی بیان می کند. در اکثریت روشهای یادگیری روی توزیع، خروجی تابع یادگیری مقداری عددی (طبقه بندی یا رگرسیون) است. در گروهی از تحقیقات مسئله یادگیری روی توزیع به شرایطی توسعه داده شد که در آن خروجی هم توزیع است [۹۶]. مقاله [۱۳۱] نظریه یادگیری را برای رگرسیون روی توزیع توسعه داد. بسیاری از وظیفه های مهم یادگیری ماشین مانند یادگیری چندنسخه ای^۵ می توانند در قالب کاری ”رگرسیون به بردارهای خروجی از توزیع های احتمالی” طرح شوند. این مقاله ثابت می کند که با وجود دومرحله ای بودن مسئله یادگیری روی

¹ Learning On Distribution

² Support Measure Machine (SMM)

³ Group Anomaly Detection

⁴ Bag-of-Words

⁵ Multi-Instance Learning

توزیع [۱۳۰]، امکان ارائه تخمینگری که نرخ همگرایی آن با نرخ همگرایی مسئله یادگیری تطبیق کند وجود دارد.

به منظور انجام یادگیری روی توزیع، نیاز به نوعی مقایسه توزیع ها داریم. یکی از رویکردها ارائه تخمین گر کرنل مبتنی بر نوعی تابع دیورژانس بین توزیع ها است [۱۰۳]. اما رویکردی که مورد استقبال بسیار بیشتری قرارگرفت رویکردهای مبتنی بر نگاشت توزیع به فضای هیلبرت کرنل بازتولیدکننده^۱ است. ثابت شد که اگر تابع کرنل، کرنل مشخصه^۲ باشد، نگاشت میانگین کرنل^۳ نگاشت میانگین این توزیع به این فضا، همه خصوصیات توزیع را حفظ می کند. تابع کرنل مشخصه، تابعی است که تبدیل فوریه آن همه فضای $\mathbb{R}^d$ را می پوشاند. بعنوان مثال تابع کرنل $k(x, z) = \exp(-\frac{1}{2}\gamma\|x - z\|^2)$ که تابع RBF نامیده می شود، مشخصه است. با دراختیار داشتن تابع کرنل $k(., .)$ ، آنگاه نگاشت میانگین کرنل برای توزیع P که آن را نهفته سازی میانگین توزیع^۴ یا به اختصار نهفته سازی توزیع^۵ می نامیم، عبارتست از

$$\mu(P) = \mathbb{E}_{x \sim P}[k(., x)] = \int_x k(., x) dP(x)$$

بنابراین اگر دو توزیع دارای نگاشت یکسان برپایه تابع کرنل مشخصه k باشند، آنگاه دو توزیع یکسان خواهند بود [۸۹].
بعبارت دیگر،

$$\mu(P_1) = \mu(P_2) \Rightarrow P_1 = P_2$$

در [۸۰] نظریه یادگیری برای مسئله طبقه بندی روی توزیع توسعه داده شد و سپس آنرا برای استنتاج علی^۶ بکار بردند. با نمونه

بردار $\{x^u\}_{u=1}^{n_P}$ از توزیع P ، آنگاه نهفته سازی تجربی^۷ توزیع P برابر خواهد بود با

$$\hat{\mu}_P = \frac{1}{n_P} \sum_{i=1}^{n_P} \phi(x_i)$$

داده های بسیاری از پدیده های طبیعی معمولا به شکل توزیع است. بنابراین مزیت مهمی است که بتوانیم مستقیما توزیع ها را مدل کنیم بجای اینکه آنها مطابق روش معمول در یادگیری ماشین، آنها را تبدیل به بردار کنیم. در یادگیری روی توزیع هر مثال خود توزیع است. هدف الگوریتم یادگیری طبقه بندی است که بتواند برچسب توزیع ورودی را پیش بینی کند.

این مفهوم با ارائه ماشین معیارپشتیبان^۱ [۸۸] پرتعداد شد. SMM، مسئله SVM روی داده های توزیع با استفاده از کرنل امید ریاضی^۲ را حل می کند. فرض کنید P_i و P_j دو توزیع باشند، کرنل امید ریاضی ارزیابی شده یا به اختصار کرنل امید ارزیابی شده برای این دو توزیع برابر است با

$$K(P_i, P_j) = \langle \mu_{P_i}^*, \mu_{P_j}^* \rangle = E_{x_i \sim P_i, x_j \sim P_j} [k(x_i, x_j)] \quad (۱-۲)$$

در اینجا $\mu_{P_i}^*$ کرنل نهفته سازی میانگین [۸۹] از توزیع P_i است که توزیع P_i در یک فضای هیلبرت منتسب به تابع کرنل k قرار دارد.

چالش این است که دسترسی مستقیم به خود توزیع نداریم بلکه صرفاً دسترسی به نمونه ای که از آن برداشته شده است، داریم. بنابراین این مسئله ای دو مرحله ای است که در آن تخمین ها اجباراً باید مبتنی بر شباهت محاسبه شده بین دو مجموعه از نقاط و نه مستقیماً بین خود توزیع ها باشند. [۱۳۲].

با استفاده از $\{x_i^u\}_{u=1}^{n_i}$ و $\{x_j^v\}_{v=1}^{n_j}$ معمولاً تخمین تجربی کرنل امید ریاضی استفاده می شود:

$$K(P_i, P_j) = \frac{1}{n_i n_j} \sum_{u=1}^{n_i} \sum_{v=1}^{n_j} k(x_i^u, x_j^v)$$

اخیراً [۱۳۲] تحقیق جامعی در خصوص آنالیز تئوری یادگیری برای رگرسیون روی توزیع ارائه کرده است. جالب است که [۸۰] مسئله استنتاج علی^۳ را به عنوان یک مسئله طبقه بندی روی توزیع حل کرده است. بعلاوه [۸۰] خصوصیات هر دو، طبقه بندی روی توزیع و استنتاج علی را بررسی کرده است.

اندازه نمونه های برداشته شده از توزیع اغلب بسیار متفاوت هستند. براساس قضیه ذیل، در بخش ۳.۳.۳ رویکردی ساده به یادگیری فعال مقاوم که بسادگی عدم قطعیت در تخمین توزیع ها را براساس وابستگی آنها به اندازه نمونه در نظر می گیرد، ارائه می کنیم. قضیه ذیل [۸۰] همگرایی نهفته سازی میانگین تجربی توزیع P_i یا $\hat{\mu}_{P_i}$ را از طریق نمونه ای با اندازه n_i به نهفته سازی واقعی μ_{P_i} در فضای کرنل منتسب به تابع کرنل را بیان می کند:

قضیه ۱.۱.۲. فرض کنید $\|f\|_{\infty} \leq 1, \forall f \in \mathcal{H}_k$ با $\|f\|_{\mathcal{H}_k} \leq 1$ آنگاه با احتمال حداقل $1 - \delta$ داریم:

$$\|\mu_{P_i}^* - \hat{\mu}_{P_i}\|_{\mathcal{H}} \leq 2\sqrt{\frac{\mathbb{E}_{z \sim P_i}[k(z, z)]}{n_i}} + \sqrt{\frac{2\log \frac{1}{\delta}}{n_i}} \quad (۲-۲)$$

براساس قضیه بالا، عدم قطعیت در تخمین و میزان شباهت بین توزیع ها وابسته به اندازه نمونه است، هرچند اکثر تحقیقات وابستگی عدم قطعیت به اندازه نمونه ها در توزیع را در نظر نگرفته اند. در [۷۲] محققان این عدم قطعیت را بدون محاسبه عدم قطعیت در فضای کرنل هیلبرت در نظر گرفته و یک فرمولاسیون شبکه RBF برای رگرسیون با استفاده از نقاط landmark ارائه کرده اند.

در روش پیشنهادی یادگیری فعال روی توزیع، ما هم عدم قطعیت در تخمین توزیع و هم وابستگی عدم قطعیت به اندازه نمونه را در نظر گرفته ایم. برای اطلاعات بیشتر در یادگیری روی توزیع خواننده را به [۱۳۲] ارجاع می دهیم. همچنین [۸۹] مرور تحقیقات در خصوص نهفته سازی کرنل توزیع ها و همچنین یادگیری روی توزیع را ارائه داده است.

بنابراین بطور خلاصه در یادگیری روی توزیع به تخمینی از توزیع ها دسترسی داریم که دارای خطایی از مرتبه $O(\frac{1}{\sqrt{n}})$ از اندازه نمونه برداشته شده از توزیع است. این موضوع در یادگیری فعال که برچسب ها و طبقه بند بهینه برای داده ها نیز خود مجهول هستند، چالشی مضاعف ایجاد می کند.

۲.۲ یادگیری فعال

در یادگیری فعال، سیستم یادگیری ماشین، در حین یادگیری می تواند سؤال نیز بپرسد. هدف از این سؤال ها، بدست آوردن دقت بیشتر در یادگیری همزمان با کاهش زمان و هزینه یادگیری است. بعبارت دیگر، در یادگیری فعال، سیستم یادگیری ماشین کنجکاو است و در حین یادگیری دائما در حال پرسش است. هر قدر این پرسش ها، هوشمندانه تر باشند با تعداد کمتری پرسش دقت بیشتری بدست می آید. پرسش های انجام شده توسط الگوریتم یادگیری فعال را پرس وجو^۱ می نامیم. معمولا الگوریتم های یادگیری فعال از تعداد بسیار کمی نمونه برچسب دار شروع می کنند و هر بار برچسب نقطه داده یا دسته^۲ ای از نقاط را از کاربر پرسش می کنند. در حالت اخیر، الگوریتم یادگیری فعال دسته ای^۳ نامیده می شود.

^۱Query

^۲Batch

^۳Batch Active Learning

در هر مرحله از یادگیری فعال، تعدادی داده برچسب دار و تعدادی داده بدون برچسب وجود دارد. معمولاً با استفاده از داده های برچسب دار، طبقه بندی آموزش داده می شود. هدف این است که با وجود تعداد بسیار کم داده های برچسب دار، این طبقه بند هرچه سریعتر به طبقه بند ایده آل نزدیک شود. عبارت دیگر فرض آنستکه هرچه مجموعه طبقه بندهای ممکن روی داده های برچسب دار سریعتر کوچک شود، طبقه بندهای نزدیکتری به طبقه بند ایده آل در آن قرار خواهند داشت. تعریف ذیل این مفهوم را روشن می کند:

تعریف ۱.۲.۲. فضای نسخه

مجموعه همه طبقه بندهای ممکن که داده های برچسب دار را درست طبقه بندی می کنند، را فضای نسخه^۱ می نامیم. کاهش اندازه فضای نسخه، با توجه به آنکه طبقه بند بهینه نیز در آن وجود دارد، باعث افزایش دقت می شود. بنابراین هدف الگوریتم های یادگیری فعال را می توان کاهش هرچه سریعتر فضای نسخه دانست. با انتخاب بهتر نقاط برای پرس و جوی برچسب آنها، فضای نسخه بیشتر کاهش پیدا می کند. متأسفانه روشی برای محاسبه مستقیم فضای نسخه وجود ندارد. با این وجود معیارهایی وجود دارد که می تواند تخمینی از فضای نسخه ارائه بدهد. کاهش اندازه فضای نسخه به منظور افزایش دقت یا رسیدن به دقت مورد نظر صورت می گیرد. در رابطه با هر کاربرد یا مسئله یادگیری، بسته به خصوصیات داده ها، تعداد نمونه های لازم برای یادگیری به منظور رسیدن به دقت مورد نظر متفاوت است. تعریف ذیل این مفهوم را بیان می کند:

تعریف ۲.۲.۲. پیچیدگی نمونه

پیچیدگی نمونه^۲ تعداد نمونه لازم برای رسیدن به دقت مورد نظر در یک مسئله یادگیری است.

Hanneke ثابت کرد که در شرایطی امکان بهبود نمایی در پیچیدگی نمونه وجود دارد [۵۸، ۵۶]. البته در حالت کلی، حصول به این میزان بهبود امکان پذیر نیست. هر قدر مسئله یادگیری، پیچیده تر باشد، پیچیدگی نمونه برای آن بیشتر است. توجه داشته باشید که پیچیدگی نمونه مفهومی تئوریک است و بجز در مسائل فوق العاده ساده مانند طبقه بندی یک بعدی فاقد داده جداشده^۳

^۱Version Space

^۲Sample Complexity

^۳Disjunct

روش محاسبه آن روشن نیست [۲۸، ۱۴۷]. در مسائل یادگیری، هرچه فضای نسخه را بتوان سریعتر کوچک کرد، پیچیدگی نمونه آن مسئله کمتر است.

بنابراین الگوریتم های یادگیری فعال تلاش دارند که نقاطی را پیدا کنند که باعث هرچه کوچکتر شدن فضای نسخه شوند و در نتیجه طبقه بند ساخته شده روی داده های برجسب دار، دقت بهتری داشته باشد. این الگوریتم ها نقاطی را برای پرس وجو انتخاب می کنند که حاوی بیشترین اطلاعات برای ساخت طبقه بند بهینه بیز^۱ باشند. روشهای مبتنی بر معیار حاوی اطلاعات بودن^۲ تلاش می کنند که تخمینی از میزان تأثیری که یک نقطه داده در حصول به طبقه بند بهینه بیز دارد را اندازه بگیرند. به روشهایی که بر این معیار در انتخاب نقاط با بیشترین اطلاعات تمرکز دارند، روشهای حاوی اطلاعات^۳ می گوئیم.

تمرکز صرفا بر معیار حاوی اطلاعات بودن باعث اریب شدن به نمونه^۴ می شود و ساختار داده های بدون برجسب را در نظر نمی گیرد. بویژه اینکه داده های برجسب دار در فرایند یادگیری فعال بصورت مستقل و هم توزیع^۵ انتخاب نشده اند. بعلاوه، در مراحل اولیه یادگیری فعال که تعداد نقاط برجسب دار بسیار کم است، هر تخمینی از محتوی اطلاعاتی هر نقطه داده بسیار نادقیق است. در نتیجه، انتخاب نقاط صرفا برپایه معیاری بسیار نادقیق چندان خوب نیست. در نبود هرگونه دانش قابل توجه از طبقه بند بهینه، تنها اطلاعاتی که وجود دارد در مورد ساختار داده است. بعبارت دیگر، به دنبال نقاطی هستیم که در ساختار داده بهتر نماینده سایر نقاط هستند. معیار نماینده نقاط بودن^۶ میزان نمایندگی هر نقطه داده از سایر نقاط را اندازه گیری می کند. انتخاب نقاطی با بیشترین درجه نمایندگی سایر نقاط با توجه به فرض های پایه ای مانند فرض چگالی کم^۷ یا فرض مانیفولد^۸ می تواند برای هر طبقه بندی مفید باشد. به این روشها، روشهای نماینده^۹ می گوئیم.

تقریبا همه الگوریتم های یادگیری فعال، یک یا هر دو معیار حاوی اطلاعات بودن و نماینده سایر نقاط بودن را در نظر می گیرند. نقاط حاوی اطلاعات آنهایی هستند که بیشترین اطلاعات را در مورد طبقه بند آموزش داده شده روی داده ها دارند. با دانش محدود در یادگیری فعال، هر تخمینی از معیار حاوی اطلاعات بودن ممکن است نادقیق باشد. برخلاف الگوریتم های حاوی اطلاعات، معیار نماینده سایر نقاط به برجسب های نقاط وابسته نیست. نقاط نماینده نقاطی هستند که بهتر سایر نقاط را نمایندگی می کنند. نقاط نماینده کمک می کنند که تخمین بهتری از برجسب های سایر نقاط بدست آید و در نتیجه کارایی بهتری بدست می

^۱Bayes Optimal Classifier

^۲Informativeness Measure

^۳informative Methods

^۴Sample Bias

^۵independent and identically distributed

^۶Representativeness Measure

^۷Low-density Assumption

^۸Manifold Assumption

^۹Representative Methods

آید. در دوبخش بعدی به بررسی این روشها، می پردازیم.

۱.۲.۲ روشهای حاوی اطلاعات

رویکردهای مبتنی بر پرس و جو توسط کمیته، ensemble و گرادیان تابعی

یکی از اولین کارهای انجام شده در زمینه یادگیری فعال به سال ۱۹۹۲ باز می گردد [۴۱، ۱۱۹]. رویکرد این کار، مبتنی بر پرس و جو توسط کمیته^۱ بود. این رویکرد مثالهایی را پرس و جو می کند که در مورد برجسب آنها، بیشترین اختلاف نظر بین تعدادی طبقه بند متفاوت که اعضاء کمیته را تشکیل می دهند، دارد. در این روشها، چنین فرض می شود که برجسب نقاط داده ای که بیشترین میزان اختلاف نظر بین گروه متنوعی از طبقه بند که روی داده های برجسب دار آموزش دیده اند، بیشترین میزان حاوی اطلاعات بودن را دارد. براساس این رویکرد، [۱۴۶] الگوریتمی تکاملی PSO برای بهینه سازی ارائه کرده است. قالب کاری یادگیری فعال مبتنی بر شواهد^۲ نوعی از نمونه برداری عدم قطعیت است که دو نوع متفاوت از اوقاتی که عدم قطعیت بوجود می آید را در نظر می گیرد. عدم قطعیت در این سیستم به دو نوع شواهد قوی متناقض برای هر دو کلاس یا شواهد ناکافی برای هر کلاس تقسیم می شود.

برای بدست آوردن معیار دقیق تری از حاوی اطلاعات بودن می توان از مجموعه متنوعی از طبقه بند ها و سپس بررسی اینکه آیا آنها در مورد برجسب یک نقطه توافق دارند، استفاده کرد. هر تخمینی از حاوی اطلاعات بودن نقطه به شدت به طبقه بندهای استفاده شده وابسته است. وقتی که دقت طبقه بند کم است، نقطه انتخاب شده ممکن است انتخاب مناسبی نباشد. پرس و جو توسط کمیته یک قالب کاری یادگیری فعال است که حاوی اطلاعات بودن برای نقاط را با استفاده از میزان عدم توافق بین مجموعه ای از طبقه بندهای متنوع که روی داده های برجسب دار آموزش داده شده اند، اندازه گیری می کند [۱، ۲۶، ۴۱، ۴۳، ۸۵، ۱۱۹، ۱۲۷]. اخیرا [۸۱] نشان داد که یادگیری فعال با مجموعه ای از طبقه بندهای متنوع تر کارایی بهتری دارد. برای مقایسه این الگوریتم ها، می توانید به [۱۰۹] مراجعه کنید.

در رویکرد تابعی، [۱] پیشنهاد داد که نقطه ای پرس و جو شود که حداقل فاصله از طبقه بند boosting را داشته باشد. این استراتژی براساس این واقعیت است که طبقه بندی با بیشترین حاشیه دقت بیشتری روی داده های دیده نشده دارد. مقاله [۹۲]

¹Query by Committee

²Evidence based Active Learning framework

الگوریتمی را در ارتباط بین یادگیری فعال به همراه طبقه بند boosting ارائه می دهد که در آن حاوی اطلاعات بودن بوسیله عدم قطعیت طبقه بندی اندازه گیری می شود. عدم قطعیت طبقه بندی توسط آنتروپی خروجی طبقه بند قبل از گسسته سازی اندازه گیری می شود. مطالعه [۶۵] قالب کاری پرس و جو توسط کمیته در یادگیری فعال ارائه می کند. روش پیشنهادی در [۱۳۹] نقاطی را انتخاب می کند بنحویکه حجم فضای نسخه برای طبقه بندهای boosting ممکن کمینه شود. آنها نشان دادند که به منظور موثر بودن روش، باید فرضی برای پراکندگی در طبقه بندهای boosting برای این روش وجود داشته باشد.

براساس [۸۱] همه روشهای یادگیری فعال موجود مبتنی بر ensemble و boosting در واقع فقط بر داشتن مجموعه ای متنوع از طبقه بندها برای حصول به معیار بهتری برای حاوی اطلاعات بودن تمرکز می کنند. بنابراین روش یادگیری فعال مبتنی بر گرادیان تابعی که معیار نماینده سایر نقاط بودن را در نظر بگیرد، وجود ندارد.

رویکرد کمینه سازی فضای نسخه برای ماشین بردار پشتیبان

از جنبه ای دیگر، برای حل مسئله یادگیری فعال در طبقه بند ماشین بردار پشتیبان^۱ محققان در [۱۳۷] استدلال کردند که انتخاب نقاط در یادگیری فعال لازم است بصورتی انجام گردد که فضای نسخه^۲ را با هر انتخاب کوچکتر کند. سپس براساس تحلیلی در فضای نسخه در طبقه بند ماشین بردار پشتیبان، آنها استدلال کردند که نقطه ای انتخاب شود که صرفنظر از برچسب آن کمترین میزان حاشیه را داشته باشد. بعبارت دیگر، آنها پیشنهاد کردند که برای یادگیری فعال برای طبقه بند ماشین بردار پشتیبان^۳ [۲۳] از مسئله بهینه سازی ذیل استفاده کنیم:

$$x^* = \arg \min_x |f(x)| \quad (۳-۲)$$

به این روش یادگیری فعال مبتنی بر طبقه بند ماشین بردار پشتیبان می گوئیم. سپس استدلال شده است که پس از انتخاب نقطه و پرسش برچسب آن از کاربر، طبقه بند ساخته شده دستخوش تغییر قابل ملاحظه ای خواهد شد [۶۲]. تابع هدف (۳-۲) با ثابت فرض کردن تابع هدف، اثر نقاط پرس و جو را کم تخمین می زند. چنانکه قبلاً ذکر شد، فضای نسخه مجموعه ای از طبقه بندهایی است داده های برچسب دار را درست طبقه بندی می کنند. بنابراین یادگیری فعال برای SVM نقاطی را انتخاب می کند که فضای نسخه جاری را کمینه می کند. این نقاط، نقاطی با بیشترین اطلاعات و نزدیکترین نقاط به مرز جاری طبقه بند صرفنظر

^۱Support Vector Machine (SVM)

^۳Support Vector Machines (SVM)

^۲Version Space

از برچسب هستند. مولفین در [۶۷، ۶۲]، استدلال کردند که ثابت فرض کردن طبقه بند پس از دریافت برچسب های جدید تاثیر نقاط جدید را بیش تخمین می زند و بنابراین آنها پیشنهاد کردند که همزمان طبقه بند نیز یادگیری شود. به منظور تخمین همزمان طبقه بند و نقطه پرس و جو، تحقیق مذکور تابع هدفی پیشنهاد می کند که مبتنی بر جایگذاری قدرمطلق در تابع هدف (۲-۳) با تابع max براساس رابطه مقدماتی $|a| = max(a, -a)$ در تابع هدف مسئله ماشین بردار پشتیبان است. در این رویکرد نقطه ای انتخاب می شود که صرفنظر از برچسب آن کمترین فاصله با مرز طبقه بند جاری داشته باشد [۶۲]. در [۱۵۲، ۱۵۱، ۵۴] روش های بسیار مشابه همین روش اما براساس معیارهای دیگری مانند فاصله کسینوسی بین بردارهای طبقه بند ارائه شده است. محققین در [۷۳] مطرح کردند که تخمین حاوی اطلاعات بودن برای هر نقطه داده با استفاده از فضای نسخه وقتی فضای نسخه نامتقارن باشد، دقیق نیست. چون فضای نسخه اغلب نامتقارن است و بسیار سخت که گستره فضایی کلاسها را با استفاده از تعداد کمی داده برچسب دار تخمین بزنیم، آنها نقاط مرکزی کلاس^۱ را برای بدست آوردن توصیف بهتری از فضای نسخه و توزیع کلاسها پیشنهاد کردند. نقاط مرکزی کلاس، نقاطی در هر طرف مرز با فاصله میانه از مرز در مسئله طبقه بندی هستند. با روش نقاط مرکزی کلاس، آنها از معیار نماینده نقاط بودن برای ارتقاء روش های قبلی مبتنی بر معیار حاوی اطلاعات بودن استفاده کردند.

نمونه برداری عدم قطعیت

نمونه برداری عدم قطعیت^۲ یکی از اولین رویکردهای ابتکاری پیشنهاد شده در یادگیری فعال است. در این رویکرد، نقطه ای پرس وجو می شود که در مورد برچسب آن، کمترین قطعیت وجود دارد [۱۱۸، ۷۴]. این روش برای مدل های احتمالی، سراسر است. مثلاً برای انتخاب نقطه ای در طبقه بندی باینری، نقطه ای انتخاب می شود که احتمال پسین^۳ آن، نزدیک تر به 0.5 باشد. وقتی تعداد بیشتری کلاس وجود دارد، نقطه ای پرس وجو می شود که در مورد برچسب آن کمترین قطعیت را داریم:

$$x^* = \arg \max_x 1 - \mathbf{P}(\hat{y}|x)$$

که در آن $\hat{y} = \arg \max_y \mathbf{P}(y|x)$ است. مشکل این رویکرد آنستکه اطلاعات مربوط به سایر برچسب ها را اساساً بکار نمی برد. برای حل این مشکل، پیشنهاد شد که تفاوت فاصله بین بهترین برچسب و دومین بهترین برچسب برای هر نقطه در نظر گرفته

^۱Class Central Examples

^۳posterior

^۲Uncertainty Sampling

شود و نقطه ای با کمترین فاصله بین این دو محاسبه شود. عبارت دیگر، پرس وجو براساس تابع هدف ذیل بدست آید:

$$x^* = \arg \min_x \mathbf{P}(\hat{y}_1|x) - \mathbf{P}(\hat{y}_2|x)$$

که در آن $\hat{y}_1, \hat{y}_2$ بهترین و دومین بهترین برچسب ها برای نقطه x هستند. استراتژی دیگر در روشهای عدم قطعیت، استفاده از آنتروپی به عنوان معیار عدم قطعیت است:

$$x^* = \arg \max_x - \sum_i \mathbf{P}(y_i|x) \log \mathbf{P}(y_i|x)$$

که در آن y_i همه انواع برچسب ها را در بر می گیرد.

کاهش امیدخطا

روش کاهش امیدخطا^۱ تلاش می کند خطای تعمیم پذیری را با انتخاب نقطه پرس وجو کاهش بدهد [۱۱۴]. ایده آن است که میزان امید خطای مدلی که روی داده های برچسب دار بعلاوه داده پرس وجو را تخمین بزنیم و نقطه ای را انتخاب کنیم که این خطا را حداقل کند. با این وجود برای تخمین امید خطای طبقه بندی تابع اتلاف 0/1 روی متغیر مستقل از مجموع عدم قطعیت طبقه بند روی داده های بدون برچسب دار استفاده می کند:

$$x^* = \arg \min_x \sum_i \mathbf{P}(y_i|x) \left(\sum_{u=1}^U 1 - \mathbf{P}_+(\hat{y} | x_u) \right)$$

اخیرا، [۳۷] نشان داد که تخمین امید خطای طبقه بندی تابع اتلاف 0/1، با مجموع عدم قطعیت طبقه بند روی داده های بدون برچسب، تخمین درستی نیست. علت این موضوع آنستکه می توان داده هایی (مانند داده های پرت) در نظر گرفت که اگرچه دریافت برچسب آنها عدم قطعیت طبقه بند را کاهش می دهد اما باعث افزایش خطای طبقه بندی نیز می شود [۳۷].

^۱ Expected Error Reduction

۲.۲.۲ روشهای نماینده

الگوریتم های مبتنی بر خوشه بندی یا وزندهی مبتنی بر چگالی به نقاط

روشهای نماینده سایر نقاط معمولا ساختار داده را در انتخاب نقاط در نظر می گیرند. این ساختار می تواند به فرم خوشه ها یا مانیفولدهایی در فضا باشد [۱۵، ۲۹، ۳۲، ۶۴، ۷۵، ۱۰۰، ۱۴۸]. محققین در [۲۹] روشی را پیشنهاد کردند که نقاطی را از طریق خوشه بندی پیشنهاد می کند. آنها درخت خوشه سلسله مراتبی ساختند که رابطه بین نقاط و خوشه ها را بیان می کند. الگوریتم فرض می کند خوشه ها نسبتا خالص هستند از این جنبه که برچسب نقاط در هر خوشه تقریبا یکسان است. روش نمونه برداری در این الگوریتم انتخاب نقاط در نواحی که ممکن است حاوی بلوک های غیرخالص باشد را ترجیح می دهد. در [۱۴۸] یک درخت اصلی از خوشه ها ساخته و در حین فرایند یادگیری فعال نگهداری می شود بنحویکه تا آنجا که ممکن است خوشه ها برای تکرار جاری خالص باشند. الگوریتم خوشه بندی آنها مبتنی بر خوشه بندی CFSDP است [۱۱۳]. در هر تکرار، این الگوریتم هر خوشه را به دو خوشه تقسیم می کند و نقاط را براساس معیاری که هم چگالی بالاتر و هم فاصله بیشتر بین دو مرکز خوشه را در نظر می گیرد، انتخاب می کند. الگوریتم پیشنهادی معیار حاوی اطلاعات بودن را در نظر نمی گیرد.

الگوریتم های مبتنی بر کمینه سازی واریانس و طراحی بهینه آزمایشها

وقتی امکان محاسبه مستقیم تاثیر انتخاب پرس و جو بر خطای تعمیم پذیری یادگیری وجود ندارد، یکی از راهها تمرکز بر کمینه کردن واریانس پارامترهای مدل است. با کمینه کردن واریانس پارامترهای مدل می توانیم بصورت غیرمستقیم بر تعمیم پذیری یادگیری تاثیر بگذاریم. روشهای مبتنی بر طراحی بهینه آزمایشها^۱ بر کمینه کردن این واریانس تمرکز دارند. اطلاع فشر^۲ واریانس score یا همان مشتق جزئی مرتبه دوم از لگاریتم تابع likelihood نسبت به پارامترهای مدل است:

$$\mathcal{I}(\theta) = N \int_x P(x) \int_y P_{\theta}(y|x) \frac{\partial^2}{\partial \theta^2} \log P_{\theta}(y|x)$$

که در آن N تعداد نمونه مستقل برداشته شده از توزیع ورودی است. معیار اطلاع فشر بسیار مفید است زیرا معکوس آن، براساس نامساوی کرامر-رائو حدپایینی برای واریانس تخمین از پارامترهای مدل ایجاد می کند [۲۴]. بنابراین، برای کمینه کردن

^۱Optimal Experiment Design^۲Fisher Information

واریانس پارامترهای مدل، یادگیر فعال باید داده ای را انتخاب کند که اطلاع فیشر را بیشینه می کند. وقتی که تعدادی پارامتر در مدل وجود دارد، اطلاع فیشر تبدیل به ماتریس می شود. معمولاً معیاری از این ماتریس کمینه می شود.

• A-Optimal مجموع عناصر قطر معکوس ماتریس اطلاع فیشر را کمینه می کند

• D-Optimal دترمینان معکوس ماتریس اطلاع فیشر را کمینه می کند

• E-Optimal بزرگترین مقدار ویژه از معکوس ماتریس اطلاع فیشر را کمینه می کند.

روشهای مبتنی بر طراحی بهینه آزمایشها، رویکرد سراسری به مسئله یادگیری فعال دارند و صرفاً ساختار داده ها را در نظر می گیرند. برخی از روشها مانند [۱۶۳] تلاش کرده اند که با استفاده از بازسازی خطی محلی^۱ ساختار محلی داده ها را در انتخاب نقاط در نظر بگیرند. این روشها مبتنی بر این نکته است که داده ها معمولاً در مانیفولد^۲ با ابعاد کمتر قرار داشته باشند [۱۷]. برخی از کارهای انجام شده در رابطه با طراحی بهینه آزمایشها در یادگیری فعال، عبارتند از [۱۶۲، ۵۲، ۳۹، ۲۱].

پرس و جوی نماینده ترین مثالها از بین داده های بدون برچسب می تواند زحمات برچسب زنی را کاهش بدهد زیرا هر مثال نماینده باعث می شود که الگوریتم راحت تر بتواند برچسب سایر نقاط را با دقت بیشتر تخمین بزند. بنابراین روشهای یادگیری فعال نماینده معمولاً بر ساختار یا مانیفولد^۲ داده ها تمرکز می کنند. در [۲۹] از الگوریتم خوشه بندی سلسله مراتبی برای انتخاب نقاطی که نماینده ترین نقاط برای داده های بدون برچسب هستند، استفاده شده است. همچنین [۱۰] روشی مبتنی بر طرح بهینه روی مانیفولد آزمایشها^۳ ارائه کرد.

مشکل اصلی این روشها، آنستکه کارآمدی الگوریتم به شدت بستگی به فرض خوشه^۴ یا فرض مانیفولد^۵ در داده ها دارد. روش پیشنهادی نماینده بودن را براساس مفید بودن مثال بدون برچسب در کمک به تخمین نزدیک تر از احتمال شرطی برچسب ها به فرض مثالها به مقدار واقعی احتمال شرطی مذکور در نظر می گیرد. بعلاوه عیب اصلی روشهای نماینده آنستکه این روشها از ساختار برچسب داده صرف نظر می کنند.

برخی دیگر از رویکردهای کمینه سازی واریانس مبتنی بر ماتریس لاپلاسین داده ها هستند. بعنوان مثال مولفین در [۶۰] روشی مبتنی بر میدان تصادفی گوسی^۶ ارائه کردند که بدون وابستگی به ویژگیها، در یک گراف روی نودهای داده تعریف شده با

¹ Locally Linear Reconstruction

² Manifold

³ Manifold Optimal Experiment Design

⁴ Cluster Assumption

⁵ Manifold Assumption

⁶ Gaussian Random Field

استفاده از ماتریس لاپلاسیین گراف عمل می کند. باتوجه به اینکه میدان گوسی تعریف شده به شرط داده های برچسب دار، یک توزیع نرمال چندمتغیره برابر با $\mathcal{N}(y_u^* = -L_{uu}^{-1}L_{ul}y_l, L_{uu}^{-1})$ است، به منظور کمینه سازی مجموع توان دو واریانس خطای پیش بینی برچسب ها، کافی است نقطه ای انتخاب شود که مجموع عناصر قطری ماتریس L_{uu}^{-1} کمینه شود یا بعبارت دیگر:

$$\arg \min_{L \in \mathcal{D}} Tr(L_{uu}^{-1})$$

مشابه همین مقاله، در [۱۶۹] یک میدان گوسی تصادفی به فرم بالا برای کمینه سازی تخمین ریسک بصورت

$$\hat{\mathcal{R}}(f) = \sum_{i=1}^n \min(f_i, 1 - f_i)$$

را استفاده کردند. بعنوان مثالی دیگر، مطالعه [۹۷، ۵۰] رویکرد یادگیر فعالی مبتنی بر واریانس طبقه بند از طبقه بند بهینه ارائه می کند. آنها حدبالایی برای واریانس طبقه بند logisitic regression براساس بزرگترین مقدار ویژه ماتریس بدست آمده از داده وزن دهی شده براساس عدم قطعیت طبقه بند logisitic regression در مورد هر داده بدست آوردند:

$$\mathbb{E}_{Y|X}[\|\hat{w} - w_*\|_2] \leq C\lambda_{max}\left(\{\lambda I + \frac{1}{n}XDX^T\}^{-1}\right)$$

که در آن $X = [x_1, x_2, \dots, x_n]$ و D ماتریسی قطری با عناصر $D_{ii} = (1 - \sigma(w_*^T x_i))\sigma(w_*^T x_i)$ و $\sigma(a) = (1 + \exp(-a))^{-1}$ است. سپس با کمینه سازی این حدبالا، مسئله بهینه سازی عدد صحیحی بوجود می آید که با حل تقریبی آن، نقاط پرس وجو تعیین می شود. مشابه همین روش در مقاله [۵۱] برای حالتی که همه داده های بدون برچسب در اختیار نیستند، ارائه شده است.

برخی دیگر از روشهای نماینده عبارتند از [۱۱۲]

۳.۲.۲ سایر روشهای ابتکاری

اغلب روشهای فوق الذکر، مبتنی بر رابطه ای مستقیم با ریسک طبقه بند نبوده و رویکردهایی ابتکاری هستند. روشهای بسیاری با ترکیب ایده های روش های فوق و یا به فرم های ابتکاری دیگر بوجود آمده اند. بعنوان مثال محققین در [۱۴] با استفاده از

خروجی طبقه بند و با استفاده از آنتروپی معیاری یک بعدی به شکل ذیل ساختند

$$c(i) = - \sum_{y \in Y} P(y|x_i, w) \log P(y|x_i, w)$$

سپس ماتریسی برای داده های بدون برجسب ساختند که اعضاء آن بیانگر تکرار اطلاعات بین نقاط داده اند. فرض کنید که p^i و p^j بیانگر احتمال پسین دو نقطه x_i, x_j نسبت به همه کلاس ها باشند، آنگاه اعضاء ماتریس R دیورژانس^۱ KL بین این دو بردار از مقادیر احتمالی است:

$$R(i, j) = \sum_{y=1}^{|Y|} (p_y^i - p_y^j) \log \frac{p_y^i}{p_y^j}$$

سپس ماتریس ذیل تعریف می شود:

$$D(i, j) = \begin{cases} R(i, j), & \text{if } i \neq j \\ \lambda c(i), & \text{if } i = j \end{cases}$$

سپس در نهایت مسئله بهینه سازی ذیل را برای بدست آوردن نقاط پرس وجو مطرح می کند:

$$\begin{aligned} \max_m \quad & m^T D m \\ \text{s.t.} \quad & m_i \in \{0, 1\}, \forall i \quad \text{and} \quad \mathbf{1}^T m = k \end{aligned}$$

این مسئله بهینه سازی و ساختار بوجود آمده برای مجموعه های کوچک از داده های برجسب دار که هدف یادگیری فعال است جواب های خوبی نمی دهند. این مسئله در آزمایشهای انجام شده در این مقاله دیده می شود [۱۴].

یکی دیگر از روشهای ترکیبی، [۱۲۶] است. این روش مبتنی بر الگوریتم Vector Relevance Machine (RVM) است. در این الگوریتم مدل رگرسیونی براساس بهینه سازی ابرپارامتر^۲ برای توزیع پسین برجسب نسبت به داده ها و بردار رگرسیون ارائه می شود [۱۳۵]. با توجه به اینکه نشان داده شد، این مسئله معادل رگولاریزاسیون مرتبه یک است [۱۳۶]، در نتیجه مدل رگرسیونی حاصل صرفا وابسته به کرنل نقاط محدودی از ورودی بوده و سایر ضرایب صفر است. به این نقاط، relevance vector می گوئیم. استراتژی ارائه شده نقاطی را پرس وجو می کند که کمترین فاصله آن با نقاط برجسب دار در بین داده های

^۱KL Divergence

^۲hyperparameters

بدون برچسب از بین نقاط relevance بیشترین مقدار است. عبارت دیگر:

$$x_q = \arg \max_{x \in RV_U} \min_{x_l} \text{dist}(x, x_l)$$

که در آن RV_U مجموعه بردارهای relevance بدون برچسب هستند.

در فرایند یادگیری فعال، سه مجموعه متفاوت داریم: مجموعه داده های برچسب دار، مجموعه داده های بدون برچسب و مجموعه پرس وجو که بخش کوچکی از مجموعه داده های بدون برچسب است. از این دیدگاه، الگوریتم یادگیری فعال بنحوی پرس وجو می کند که تفاوت بین مجموعه برچسب دار و بدون برچسب کاهش پیدا کند. پرس وجویی دلخواه ما است که افزودن آن به مجموعه داده های برچسب دار، مجموعه داده های برچسب دار را بیشتر مشابه داده های بدون برچسب کند. مولفین در [۳۳] این رویکرد را برای محاسبه نماینده سایر نقاط بودن استفاده کردند. به این منظور کمیت های M_1, M_2, M_3, C را تعریف کردند. کمیت M_1 ماتریسی است که عناصر آن شباهت بین نقاط داده در داده های بدون برچسب را نشان می دهد. M_2 میزان شباهت هر نقطه با توزیع داده های برچسب دار را نشان می دهد و M_3 میزان شباهت بین هر نقطه و داده های بدون برچسب را نشان می دهد. C عدم قطعیت عناصر بدون برچسب را نشان می دهد که براساس رابطه ذیل بدست می آید:

$$C(i) = l(f, x_i), \quad x_i \in U$$

که در آن l تابع اتلاف است. سپس مسئله بهینه سازی ذیل مطرح می شود:

$$\begin{aligned} \min_{\alpha} \quad & \alpha^T M_1 \alpha + \alpha^T (M_2 - M_3) + \beta C \\ \text{s.t.} \quad & \mathbf{1}^T \alpha = 1, \alpha_i \in [0, 1] \end{aligned}$$

سپس مولفین برای تعیین کمیت های M_1, M_2, M_3, C ابتدا طبقه بندی مانند LIBSVM [۱۶] روی داده های برچسب

دار آموزش می دهند و احتمال خروجی آن برای داده های بدون برچسب را برای کلاسهای مختلف بصورت یک بردار $P^i =$

$\{p_1^i, p_2^i, \dots, p_{|Y|}^i\}$ در محاسبه این کمیتها به شکل ذیل استفاده می کنند:

$$M_1(i, j) = \frac{1}{2} \exp(-\gamma * \|P^i - P^j\|^2)$$

$$M_2(i) = \frac{n_l + 1}{n} \sum_{j=1}^{n_l} \exp(-\gamma * \|P^i - P^j\|^2)$$

$$M_3(i) = \frac{u_t - 1}{n} \sum_{j=1}^{u_t} \exp(-\gamma * \|P^i - P^j\|^2)$$

برای محاسبه بخش عدم قطعیت، آنها از معیار بهترین در برابر دومین بهترین^۱ یا BvSB استفاده می کنند:

$$d_{BvSB}^i = p_B^i - p_{SB}^i$$

که حاصل تفریق احتمال در بهترین کلاس از احتمال دومین بهترین کلاس برای طبقه بند است. مشکل این روش آنستکه نقاطی را که نزدیک به مرز طبقه بنداست، انتخاب می کنند. در نتیجه مولفین می گویند که نقاط انتخاب شده نه تنها باید به مرز طبقه بند نزدیک باشند، بلکه باید به بردارهای پشتیبان نیز نزدیک باشند. برای اندازه گیری شباهت مجموعه ها، آنها از احتمال یک برچسب برای هر نقطه محاسبه شده توسط پیاده سازی طبقه بند مانند LIBSVM استفاده کردند. حاوی اطلاعات بودن با استفاده از فاصله RBF با بردارهای بردار پشتیبان که در میزان تفاوت اعتماد طبقه بند به بهترین برچسب از اعتماد طبقه بند به برچسب دومین برچسب ضرب شده استفاده کردند. تابع هدف یادگیری فعال جمع این دو معیار حاوی اطلاعات بودن و نماینده سایر نقاط بودن با استفاده از پارامتر موازنه بین این دو معیار است. بنابراین نزدیک ترین بردار پشتیبان براساس معیار بردار ساخته شده احتمالی برای کلاس ها را به شکل ذیل بدست می آورند:

$$SV_c = \arg \min_{SV_j \in SV} \exp(\|P^i - P^j\|^2)$$

سپس قرار می دهند:

$$C(x_i) = d_{BvSB}^i \times f(x_i, SV_c)$$

گذشته از ابتکاری بودن، این روش چندین پارامتر دارد که آنها را براساس درهم سازی بدست می آورد. این رویکرد به شدت به طبقه بند استفاده شده وابسته است. در آزمایشها رویکرد پیشنهادی را با روشهای مبتنی بر تفاوت توزیع مقایسه می کنیم.

در [۱۶۴] مضربودن داده های پرت و داده های برچسب نویزی برای فرایند یادگیری فعال مطرح شده است. در این مقاله، مطرح می شود که در حضور نویز لازم است در فرایند یادگیری فعال، نقاط مظنون به برچسب خطا را در هنگام پرس وجو از داده

¹ Best vs Second Best

های برچسب دار حذف کنیم. سپس آنها الگوریتمی ابتکاری ارائه می کنند که براساس آنتروپی روی داده های بدون برچسب و داده های برچسب دار، برخی از داده ها را حذف می کند. با توجه به اینکه این رویکرد بسیار امکان خطا دارد، آنها امکان برچسب زنی مجدد یا پرس وجوی مجدد برچسب هر نقطه و یا انتخاب مجدد آن نقطه با همان برچسب را فراهم می کنند. حاصل رویکردی بسیار ابتکاری است. راه حل ارائه شده در این مقاله مبتنی بر دو گام روبه جلو و روبه عقب است. در گام روبه جلو داده هایی برای پرس وجو انتخاب می شود. در گام روبه عقب هدف بررسی داده های برچسب دار به منظور حذف داده های مضر از فرایند یادگیری است. در گام روبه عقب داده هایی که بیشترین عدم اطمینان در مورد آنها وجود دارد، تعیین و حذف می شوند. این نقاط، بیشترین مسئولیت را در انحراف مدل^۱ دارند. به این منظور در دو سطح متفاوت سطح نسخه^۲ و سطح برچسب^۳ تشخیص را انجام می دهد. سپس در گام دیگری روشهایی برای بررسی شرایط لازم برای حذف نقطه، مطرح شده است. روش ارائه شده در این مقاله کاملاً ابتکاری است و دلایل تئوریک چندانی برای توجیه آن ارائه نشده است.

روشهای بسیاری وجود دارند که هریک بر مبنی ایده ای ابتکاری توسعه یافته اند. تقریباً همه این روشها، مبتنی بر تغییرات یا ترکیب روشهای پایه مطرح شده در بالا هستند. مثلاً [۲۰]، مسئله بهینه سازی زیرپیمانه ای^۴ برای هر نقطه داده به نسبت سایر داده ها تعریف می کند. بهینه سازی زیرپیمانه ای در یادگیری فعال، بهینه سازی روی تابعی است که وقتی هر برچسب به مجموعه کوچکی از داده های برچسب دار بهبود زیاد است اما وقتی به مجموعه بزرگی از داده های برچسب دار اضافه می شود، بهبود کم است [۲۰]. بعنوان مثالی دیگر، [۲۵] روشی مبتنی بر آنتروپی ارائه کرده است که رویکرد حریصانه در انتخاب نقطه پرس و جو اتخاذ می کند. برخی روشهای ابتکاری دیگر عبارتند از [۱۲، ۴۸، ۷۶، ۱۴۹، ۱۵۵، ۱۶۶، ۱۶۸]. [۱۱۰] آنالیز بسیار روشنی از برخی از روشهای پایه ارائه می کند.

روشهای زیادی برای یادگیری فعال در حوزه یادگیری عمیق^۵ ارائه شده است که برخی از آنها عبارتند از [۴۴، ۱۲۳، ۱۳۸،

[۱۶۷، ۱۵۹]

^۱Model Deterioration^۲instance-level^۳label-level^۴Submodular Optimization^۵Deep Learning

۴.۲.۲ رویکردهای اصولی به یادگیری فعال

چنانکه دیدیم، اغلب روشهای یادگیری فعال، روشهای ابتکاری هستند که تلاش می کنند نقاطی را انتخاب کنند که دقت یادگیری بهبود پیدا کند. مشکل اساسی این روشها آنستکه مبتنی بر اصول پایه یادگیری و عبارت بهتر مبتنی بر نظریه یادگیری نیستند. در نتیجه اگر در بعضی از کاربردها نتایج قابل قبولی ارائه می دهند اما در بسیاری از موارد، نتایج خوبی نخواهند داشت. به همین دلیل در این رساله توجه ویژه ای به رویکردهای اصولی به یادگیری فعال^۱ خواهیم داشت.

اگرچه تقریباً هیچ یک از تحقیقات ارائه شده، توجهی به ارتباط بین یادگیری فعال و نظریه بازی نداشته اند، اکثر روشهای اصولی در یادگیری فعال دارای مسئله ای بهینه سازی بصورت بیشینه-کمینه^۲ هستند. البته این موضوع در برخی روشها چندان روشن نیست اما در برخی روشها مانند روشی که در ادامه خواهیم دید، در ساختار تابع هدف بوضوح دیده می شود. این موضوع کاملاً با تحلیل ارائه شده در مقدمه در مورد ارتباط یادگیری فعال و نظریه بازی تطبیق دارد.

چون در یادگیری فعال، داده های برچسب دار بصورت مستقل و هم توزیع انتخاب نمی شوند، حدبالای معمول ارائه شده در نظریه یادگیری برای مسئله یادگیری فعال قابل استفاده نیست. در روشی فوق العاده جالب، مولفین [۱۵۳] حدبالایی برای ریسک طبقه بند در یادگیری فعال براساس تفاوت بین توزیع مجهول داده های واقعی و توزیع تخمینی از داده های برچسب دار جاری پیشنهاد کردند. تفاوت بین این دو توزیع براساس معیار بیشترین اختلاف میانگین^۳ اندازه گیری شد [۸۹]. آنها ثابت کردند با احتمال حداقل $1 - \delta$ داریم:

$$\mathbb{E}_{\mathcal{D}}[l(f(x), y)] \leq \hat{\mathbb{E}}_Q[l(f(x), y)] + MMD[C, p(x), q(x)] + 2R_q(\mathcal{L}) + \sqrt{\frac{\ln(\frac{1}{\delta})}{q}}$$

که در آن $\mathcal{D}$, Q بترتیب توزیع های داده های انتخاب شده در یادگیری فعال و توزیع همه داده ها، MMD تفاوت این دو توزیع و پیچیدگی رادماخر^۴ برای کلاس توابع $\mathcal{L}$

$$R_n(\mathcal{L}) = \mathbb{E}_S \left[\mathbb{E}_{\sigma} \left[\sup_{l \in \mathcal{L}} \left(\frac{1}{n} \sum_{i=1}^n \sigma_i l(x_i, y_i) \right) \right] \right]$$

که $\sigma_1, \sigma_2, \dots, \sigma_n$ متغیرهای تصادفی مستقل که بصورت یکنواخت از مجموعه $\{-1, 1\}$ انتخاب شده اند و بعنوان متغیرهای

^۱Principled Approach to Active Learning^۲Maximum-minimum^۳Maximum Mean Discrepancy (MMD)^۴Rademacher Complexity

رادماخر^۵ شناخته می شوند. بعلاوه داریم:

$$MMD(\mathcal{C}, p(x), q(x)) = \sup_{g \in \mathcal{C}} \left\{ \mathbb{E}_{x \sim p(x)}[g(x)] - \mathbb{E}_{x \sim q(x)}[g(x)] \right\}$$

می توان این حدبالا را کمینه کرد تا نقاط پرس وجوی جاری را بدست آورد. اما بهرحال، برای کمینه کردن این حدبالا، آنها مجبور بودند که پارامتری برای توازن بین دو معیار حاوی اطلاعات بودن و نماینده سایر نقاط بودن اضافه کنند. بعلاوه آنها از MMD تجربی برای اندازه گیری بخشی از این حدبالا استفاده کردند. بخوبی می دانیم که MMD تجربی وقتی که اندازه نمونه برداشته شده از توزیع کوچک است، دقیق نیست [۸]. این شرایط تقریباً همیشه در یادگیری فعال وجود دارد. با کمی ساده سازی به مسئله بهینه سازی ذیل می رسم:

$$\max_{y_i, \forall i \alpha_i = 1} \min_{\substack{f, \alpha_i = 1, \forall x_i \in \mathcal{L}, \\ \alpha^T \mathbf{1} = b+l}} \sum_{i=1}^n \alpha_i (y_i - f(x_i))^2 + \lambda \|f\|^2 + \beta \left(\frac{1}{2} \alpha_u^T K_{uu} \alpha_u + \mathbf{k} \alpha \right)$$

که در آن $\mathbf{k} = \frac{u-b}{n} \sum_{x_j \in \mathcal{L}} K(i, j) - \frac{l+b}{n} \sum_{x_j \in \mathcal{U}} K(i, j)$ است. در نهایت، بهینه سازی حاصل برای تعیین نقطه پرس و جو به شدت نامحذب و ارائه حل سراسری برای آن بسیار سخت است. اگرچه ایده پیدا کردن حدبالا برای یادگیری فعال، امیدبخش است، مسئله بهینه سازی حاصل بسیار چالش آفرین است. حل تقریبی آن، زمان بر است. از دیدگاهی دیگر، الگوریتم آنها تلاش می کند که تفاوت بین دو توزیع داده های برچسب دارو داده های بدون برچسب را کمینه کند. لازم بذکر است که Hanneke نشان داد با استفاده از توابع اتلاف محذب دستیابی به بهبود نمایی در تعداد نمونه های مورد نیاز برای رسیدن به دقت مورد نظر، یا همان پیچیدگی نمونه امکان پذیر نیست [۵۹]. علت این موضوع این است که نقاط پرت خیلی دور از مرز طبقه بند می توانند تاثیر بزرگی روی طبقه بند بگذارند، بنابراین طبقه بند را از طبقه بند بهینه دور می کنند و در نتیجه برچسب های بیشتری پرس و جو خواهد شد [۵۳].

[۳۸] رویکردی قاعده مند برای انتخاب نقاط پیشنهاد کرد که براساس کمینه سازی حدبالای ریسک طبقه بند چندوظیفه ای به همراه رگولاریزاسیون نرم اثر^۱ معرفی می کند. این رویکرد از مزیت یادگیری همزمان چندین وظیفه و پرسیدن پرس و جو ها بهره می برد. در مقایسه کار ما، براساس کمینه سازی حدبالای ریسک برای طبقه بند در یک وظیفه از طریق رویکردی کاملاً متفاوت

^۵Rademacher Variables

^۱Trace Norm

است. در [۸۷] مسئله یادگیری فعال در رابطه طبقه بند الحاقی با فرض کم بودن نویز^۲ Tsybakov تحلیل شده است و الگوریتمی تئوریک ارائه شده است.

اخیرا روشی در [۱۱] مبتنی بر پیشینه سازی امید ریاضی تغییرات مدل^۳ پیشنهاد شد. هدف این مطالعه آن است که خطای تعمیم پذیری را در داده های آزمون کمینه کند. این خطا را به فرم $\int_{\mathcal{X} \times \mathcal{Y}} \mathcal{L}[f(x), y(x)] dP(x, y)$ که در آن $\mathcal{L}$ تابع اتلاف و $f(x)$ مقدار پیش بینی شده برای برچسب واقعی $y(x)$ است. فرض کنید که مدل با Θ پارامترگذاری شده است. برای کمینه کردن Θ ، براساس روش بهینه سازی گرادیانی تصادفی^۱ این پارامتر را تخمین می زند:

$$\Theta_{new} \leftarrow \Theta - \alpha \frac{\partial \mathcal{L}_{x_i}(\Theta)}{\partial \Theta}, \quad i = 1, \dots, n$$

در نتیجه چون داده پرس وجو تنها داده ای است که برای تخمین پارامتر اضافه می شود، بنابراین تغییر پارامتر متناسب با مشتق جزئی در نقطه پرس وجو است. هدف بیشترین تغییر در این روش است، در نتیجه تابع هدف یادگیری فعال برابر است با $x^* = \arg \max_{x \in \mathcal{U}} \left\| \frac{\partial \mathcal{L}_{x_i}(\Theta)}{\partial \Theta} \right\|$ چون برچسب داده های پرس وجو نامعلوم است، در نهایت خواهیم داشت:

$$x^* = \arg \max_{x \in \mathcal{U}} \int_Y \left\| \frac{\partial \mathcal{L}_x(\Theta)}{\partial \Theta} \right\| P(y|x) dy$$

سپس مولفین روشهایی برای تخمین این کمیت برای تابع اتلاف درجه دو ارائه می کنند.

باتوجه به فرایند یادگیری فعال و مستقل و هم توزیع نبودن داده های انتخابی، بسیاری از فرض های اولیه الگوریتم های یادگیری ماشین در اینجا صادق نیستند. در تقریبا همه الگوریتم های یادگیری ماشین فرض براینستکه داده ها بصورت مستقل و هم توزیع انتخاب شده اند. نقض این فرض باعث می شود که الگوریتم در شرایطی عملکرد کاملا صحیحی نداشته باشد. در این شرایط اریبی به نمونه^۲ خواهیم داشت. به منظور رفع اریبی به نمونه، لازم است که مقدار تابع اتلاف در ضریب مناسبی ضرب شود. مولفین در [۶] روشی ارائه کردند که با انتخاب ضریبی مناسب اریبی به نمونه را در یادگیری فعال حذف می کند. این ضریب برابر با معکوس طول بازه تابع اتلاف برای توابع مختلف در مجموعه توابع قابل قبول در آن لحظه است. بعبارت دیگر ضریب برابر

²Tsybakov's Low noise assumption

³Expected Model Change Maximization

¹Stochastic Gradient Descent

²Sampling Bias

عکس مقدار ذیل است:

$$p_t = \max_{f, g \in \mathcal{H}_t, y \in Y} l(f(x), y) - l(g(x), y)$$

که $\mathcal{H}_t$ مجموعه توابع قابل قبول برای طبقه بندی در زمان انتخاب داده t -ام است. اگر قرار بدهیم:

$$L(h) = \mathbb{E}[l(h(x), y)] \quad (۴-۲)$$

$$L_n(h) = \frac{1}{n} \sum_{i=1}^n \frac{Q_i}{p_i} l(h(x_i), y_i) \quad (۵-۲)$$

که در آن $Q_i \in \{0, 1\}$ و $\mathbb{E}[Q_i] = p_i$. آنگاه قضیه ذیل صادق است:

قضیه ۳.۲.۲. برای همه توزیع های P و همه کلاسه های محدود توابع H ، برای هر کمیت $\delta > 0$ اگر ثابت $p_{min} > 0$ وجود

داشته باشد که $p_i \geq p_{min}, \forall i$ آنگاه خواهیم داشت:

$$\mathbf{P} \left[\max_{h \in \mathcal{H}} |L_n(h) - L(h)| > \frac{\sqrt{2}}{p_{min}} \sqrt{\frac{\ln|H| + \ln \frac{2}{\delta}}{n}} \right] < \delta \quad (۶-۲)$$

یادگیری فعال در کاربردهای بسیاری مانند مدیریت بحران [۱۰۵]، شناسایی بیومتریکی چهره [۱۳]، تشخیص اشیا در تصاویر [۱۴۵]، تشخیص بیماریها [۸۴، ۱۱۵]، قطعه سازی محاوره ای سلول ها [۱۲۹]، آنالیز گرایش و طبقه بندی داده های متنی [۶۳، ۱۲۴]، و طبقه بندی و بازیابی تصویر [۱۸، ۹۴، ۱۰۷، ۱۱۶، ۱۳۴، ۱۵۸]، annotation در ویدئو [۷۸]، جمع سپاری [۱۸، ۱۲۱]، ترکیب داروها [۹۹]، آنالیز داده های شبکه های اجتماعی [۱۰۵]، داده کاوی جریانی مبتنی بر متن [۱۳۴]، تشخیص بیماریها [۸۴]، آنالیز مالی [۱۲۴]، یادگیری انتقالی [۱۶۵]، طبقه بندی سیگنال های الکتروکاریوگرافی در ترکیب با deep learning [۱۰۸]، و سایر کاربردها [۳۱، ۷۰، ۸۲، ۹۳، ۱۴۰، ۱۵۰] بصورت موفقیت آمیز استفاده شده است. [۱۵۸، ۱۶۱] مسئله مشکل وجود داده های نامتوازن^۱ و داده های برچسب نویزی را در یادگیری فعال برای برچسب زنی جمعی^۲ حل کرده است. تحلیل لینک های متنی با استفاده از یادگیری فعال در [۱۰۶] ارائه شده است. مروری نسبتاً خوب بر روشهای یادگیری فعال را می توانید در [۱۱۸] پیدا کنید.

^۱ Imbalanced data

^۲ Crowd Sourcing

فصل ۳

یادگیری فعال روی توزیع

هدف از این رساله ارائه یادگیری فعال روی توزیع است. عدم دسترسی مستقیم به توزیع، چالشی اساسی در مسئله یادگیری فعال است. چنانکه ذکر کردیم، دسترسی به توزیع ها بصورت غیرمستقیم و از طریق نمونه های برداشته از آنها است. در نتیجه، دقت تخمینِ توزیع ها در یادگیری فعال موثر خواهد بود.

در بخش اول از این فصل، بخش ۱.۳، ابتدا راهکارهای تئوریک برای مسئله یادگیری فعال در حالت کلی را بررسی می کنیم. در این بخش در ۴.۱.۳ روشی که نقش مهمی در ادامه و در بخش های بعدی دارد را ارائه و ثابت می کنیم که بهینه است. سپس در بخش دوم، روش مذکور را برای مسئله یادگیری فعال در فضای ورودی با استفاده از رویکرد تابعی حل می کنیم. این الگوریتمی کلی است که می تواند برای مجموعه های متفاوت از توابع برای یادگیری فعال استفاده شود. حالت خاصی از این الگوریتم، را براساس فرم خطی برای مجموعه توابع ارائه می کنیم و خصوصیات تئوریک آنرا بررسی می کنیم. اکنون پس از آماده سازی ابزارهای تئوریک، دربخش سوم به هدف اصلی رساله، توسعه الگوریتم یادگیری فعال برای داده های توزیعی، می پردازیم.

۱.۳ تحلیل راهکارهای تئوریک برای مسئله یادگیری فعال

هدف از این بخش، ارائه راهکاری اصولی برای یادگیری فعال است. در نظریه یادگیری، دو رویکرد برای طبقه بندی وجود دارد: کمینه سازی ریسک تجربی^۱ و طبقه بند الحاقی^۲. در ادامه در ابتدا در ۱.۱.۳ به توسعه روشی برای یادگیری فعال با استفاده از کمینه سازی ریسک تجربی می پردازیم و سپس در ۴.۱.۳ بر طبقه بند الحاقی برای یادگیری فعال تمرکز می کنیم. در بخش ۴.۱.۳ روش یادگیری فعال بیشینه-کمینه احتمالاتی^۳ را معرفی می کنیم.

۱.۱.۳ به سوی یادگیری فعال برای کمینه سازی ریسک تجربی

فرض کنید مجموعه $\mathcal{L} = \{(x_i, y_i) | x_i \in \mathbb{R}^d, y_i \in \{-1, 1\}\}$ مجموعه داده های برچسب دار و $\mathcal{U} = \{x_i | x_i \in \mathbb{R}^d\}$ مجموعه داده های بدون برچسب باشد. اگر تابع هزینه روی این داده ها را با استفاده از تابع اتلاف l بصورت

$$J(f, \lambda) = \sum_{i=1}^{n_l} l(y_i, f(x_i)) + \frac{\lambda}{2} \|f\|^2$$

تعریف کنیم، آنگاه براساس کمینه سازی ریسک تجربی، طبقه بند بهینه در مجموعه توابع $\mathcal{F}$ برابر خواهد بود با

$$f^* = \arg \min_{f \in \mathcal{F}} J(f, \lambda)$$

برای انتخاب نقطه پرس و جو براساس رویکرد کاهش فضای نسخه، باید داده ای را مورد پرس و جو قرار دهیم که با هر برچسبی کمترین اتلاف را داشته باشد. عبارت دیگر

$$\begin{aligned} x_q^* &= \arg \min_{x_q \in \mathcal{U}} \max \{l(1, f^*(x_q)), l(-1, f^*(x_q))\} \\ &= \arg \min_{x_q \in \mathcal{U}} \max_{y_q} l(y_q, f(x_q)) \end{aligned} \quad (۱-۳)$$

متاسفانه در مراحل یادگیری فعال، مرز طبقه بند جاری با مرز طبقه بند بهینه تفاوت زیادی دارد. بتدریج با افزایش تعداد نمونه های برچسب دار، انتظار می رود تفاوت طبقه بند جاری با طبقه بند بهینه کاهش پیدا کند. تابع هدف ۱-۳ معادل است با تابع

^۱Empirical Risk Minimization

^۲Plug-in Classifier

^۳Probabilistic Minimax Active Learning (PMAL)

هدف ذیل:

$$x_q^* = \arg \min_{x_q \in \mathcal{U}} \min_{f \in \mathcal{F}, \{J(f, \lambda) \leq J(f^*, \lambda)\}} \max_{y_q} l(y_q, f(x_q)) \quad (۲-۳)$$

میدانیم که برای این مسئله بهینه سازی مقید، $\exists c_q \geq 0$ که مسئله فوق معادل است با

$$x_q^* = \arg \min_{x_q \in \mathcal{U}} \min_{f \in \mathcal{F}} \max_{y_q} c_q l(y_q, f(x_q)) + J(f, \lambda) \quad (۳-۳)$$

با جابجا کردن کمینه سازی نسبت به f و بیشینه سازی نسبت به y_q خواهیم داشت:

$$x_q^* = \arg \min_{x_q \in \mathcal{U}} \max_{y_q} \min_{f \in \mathcal{F}} c_q l(y_q, f(x_q)) + J(f, \lambda) \quad (۴-۳)$$

با تکرار انتخاب نقاط در یادگیری فعال با استفاده از تابع هدف فوق، ریسک تجربی برای این مسئله بصورت ذیل تبدیل می

شود:

$$\hat{J}(f, \lambda) = \sum_{i=1}^n c_i l(y_i, f(x_i)) + \frac{\lambda}{2} \|f\|^2$$

که در آن ضریب c_i برای داده های برچسب دار اولیه برابر یک است. با توجه به اینکه برچسب داده های بدون برچسب مجهول است، تابع هدف مسئله یادگیری فعال عبارت خواهد بود از:

$$x_q^* = \arg \min_{x_q \in \mathcal{U}} \max_{y_q} \min_{f \in \mathcal{F}} \min_{\substack{y_i, \forall x_i \in \mathcal{U}, \\ i \neq q}} \hat{J}(f, \lambda) \quad (۵-۳)$$

ضریب c_s که باعث هم ارزی دو مسئله بهینه سازی ۲-۳ و ۳-۳ می شود، به مقدار $f(x_q)$ و میزان اتلاف سایر نقاط وابسته است. با توجه به مستقل و هم توزیع نبودن نقاط انتخاب شده در یادگیری فعال این ضریب نمی تواند برای همه نقاط یکسان فرض شود. با استفاده از این ضریب می توانیم اهمیت ریسک تجربی مربوط به سایر نقاط در برابر مقدار اتلاف در نقطه مورد نظر را تنظیم کنیم. اگر این ضریب کوچک باشد، یعنی اتلاف در نقطه مورد نظر اهمیت زیادی ندارد. اگر این ضریب بزرگ باشد به معنی مهم بودن اتلاف این نقطه و در نتیجه اهمیت آن برای یادگیری در مسئله مورد نظر است.

چنانکه می دانیم داده های بدون برچسب می توانند به یادگیری صدمه بزنند [۷۷]. بعلاوه چنانکه در فصل قبل مطرح شد، [۳۷] نشان داد که افزودن برخی از داده ها به داده های برچسب دار می تواند باعث افزایش خطای طبقه بند شود. بنابراین

هدف آنستکه اثر داده های نامطلوب در فرایند یادگیری را به صفر برسانیم. فرض کنیم مجموعه نقاط حذفی مورد نظر را D_o بنامیم. باید راهکاری ارائه کنیم که آنرا تخمین بزنیم و تاثیر آنها را در فرایند یادگیری فعال حذف و یا کم کنیم. فرض کنیم تابعی مانند f_o داشته باشیم که اگر نقطه داده $x_i \in D_o$ ، مقدار صفر و اگر نقطه داده نویزی باشد، مقدار y_i را بازگرداند:

$$f_o(x_i) = \begin{cases} 0 & i \in D - D_o \\ y_i & i \in D_o \end{cases}$$

روشن است اگر طبقه بند f_o نقطه ای را جزء داده های حذفی ارزیابی کند، اتلاف این نقطه نباید در تابع هدف لحاظ شود. بنابراین برای اینکه اتلاف نقطه ای در مسئله بهینه سازی بالا محاسبه شود، باید تابع f_o برابر صفر باشد. در نتیجه می توانیم ضریب c_i را برابر با اتلاف ذیل برای تابع قرار دهیم. یعنی

$$c_i = \begin{cases} 1 & y_i f_o(x_i) = 0 \\ 0 & y_i f_o(x_i) = 1 \end{cases}$$

متأسفانه داده های حذفی، داده هایی که باعث انحراف فرایند یادگیری می شوند، مجهول است. باوجود مجهول بودن این داده ها چگونه می توانیم آنها را از فرایند یادگیری و یادگیری فعال حذف کنیم؟

فرض اصلی ما آنستکه برای اینکه تابع f_o بتواند به درستی این داده ها را شناسایی کند، لازم است بسیار پیچیده تر از تابع f باشد. برای روشن شدن علت این موضوع لازم است به هم ارزی رگولاریزاسیون و اعوجاج در نقاط داده توجه کنیم [۱۵۷]. میدانیم که تحمل اعوجاج بیشتر در نقاط داده توسط تابع معادل رگولاریزه بودن بیشتر است [۱۵۷]. اگر در متغیر مستقل در نقاط داده اعوجاج بزرگی ایجاد کنیم و تابع تغییری نکند، در واقع با تابعی ساده سروکار داریم. برعکس داده های حذفی، داده هایی هستند که تغییرات کوچک در آنها، باعث تغییرات زیادی در طبقه بند می شود. این داده ها از هندسه توزیع پیروی نمی کنند و در نتیجه براساس فرض مانیفولد^۱ با حذف آنها، یادگیری بهبود خواهد یافت [۵]. در نتیجه می توان با تعیین خصوصیات مناسب برای تابع f_o ، باعث شد که این تابع نقطه داده های مضر برای یادگیری را شناسایی کند. ابتدا به این طبقه بند که آنرا طبقه بند ساده-پیچیده^۲ می نامیم، می پردازیم.

^۱Manifold Assumption^۲Simple-Complex Classifier

طبقه بند ساده-پیچیده

اولین خصوصیت لازم برای f_o بسیار پیچیده تر بودن آن نسبت به تابع f است. دومین خصوصیت آن، محدود بودن مجموع قدرمطلق آن در همه نقاط داده یا بعبارت دیگر نرم یک آن است. در واقع فرض کرده ایم که داده های نامناسب برای یادگیری، زیرمجموعه کوچکی با اندازه n_o از داده ها هستند. قرار می دهیم: $f(x) = w^T \phi(x), w \in \mathcal{H}, f_o(x) = w_o^T \psi(x), w_o \in \mathcal{H}_o$. آنگاه با فرض تابع اتلاف Hinge خواهیم داشت: $l(y_i, w^T \phi(x_i)) = (1 - y_i w^T \phi(x_i))_+$ ، $\Psi(X) = [\psi(x_1), \dots, \psi(x_n)]$ and $l_i^o = (1 - y_i w_o^T \psi(x_i))_+$ خواهد شد:

$$\bar{J}(w, w_o) = \sum_{i \in \mathcal{D}} (1 - y_i w_o^T \psi(x_i))_+ (1 - y_i w^T \phi(x_i))_+ + \frac{\lambda}{2} \|w\|_{\mathcal{H}}^2 + \frac{\lambda_o}{2} \|w_o\|_{\mathcal{H}_o}^2 \quad (۶-۳)$$

که در آن تابع w_o با استفاده از خصوصیات فضای هیلبرت $\mathcal{H}_o$ و پارامتر λ_o بسیار پیچیده تر از تابع w است. بنابراین مسئله بهینه سازی حاصل برای یادگیری طبقه بند ساده-پیچیده برابر است با

$$\min_{w, w_o} \bar{J}(w, w_o) \quad (۷-۳)$$

$$\text{s.t.} \quad \|\Psi(X)^T w_o\|_1 \leq n_o$$

این مسئله را می توان بصورت ذیل نیز نوشت:

$$\min_{w, w_o} \bar{J}(w, w_o) + c_p \|\Psi(X)^T w_o\|_1 \quad (۸-۳)$$

مسئله ۷-۳ را می توان بصورت معادل ذیل نوشت:

$$\min_{w, w_o, p} \bar{J}(w, w_o)$$

$$\text{s.t.} \forall i, |w_o^T \phi(x_i)| \leq p_i$$

$$p^T \mathbf{1} \leq n_o, p_i \in [0, 1]$$

$$\lambda \gg \lambda_o \quad (۹-۳)$$

به منظور ساده سازی می توانیم فرض کنیم که دو فضای $\mathcal{H}$ و $\mathcal{H}_o$ یکسان هستند.

قضیه ۱.۱.۳. مسئله ۷-۳ معادل است با مسئله ذیل:

$$\begin{aligned} \min_{w_o, p} \max_{\alpha} \sum_{i \in D} \alpha_i (1 - y_i w_o^T \phi(x_i))_+ - \frac{1}{2\lambda} \alpha^T Y K \odot G Y \alpha + \frac{\lambda_o}{2} \|w_o\|^2 \\ s.t. \quad 0 \leq \alpha \leq 1 \\ |\Phi(X)^T w_o| \leq p, p \leq 1, p^T 1 \leq n_o \\ G \succeq (1 - Y \Phi(X)^T w_o)(1 - Y \Phi(X)^T w_o)^T \\ \text{diag}(G) = 1 - Y \Phi(X)^T w_o \\ \text{rank}(G) = 1 \end{aligned} \quad (۱۰-۳)$$

که در آن $Y = \text{diag}(y)$

در صورتیکه داده های بدون برچسب داشته باشیم، با توجه به مجهول بودن برچسب آنها، قید مربوط به مرتبه ماتریس G باعث می شود، مسئله فوق نامحدب باشد. قضیه ذیل تقریب محدبی از این مساله ارائه می کند:

قضیه ۲.۱.۳. قرار بدهید: $g' = 1 - Y \Phi(X)^T w_o$. تقریب محدب مسئله بالا برابر است با

$$\begin{aligned} \min_{y_u} \min_{w_o, p, G} \min_{\beta', \eta'} \quad t + \frac{\lambda_o}{2} \|w_o\|^2 + \beta'^T 1 \\ s.t. \quad \begin{bmatrix} K \odot H & g' + \eta' - \beta' \\ (g' + \eta' - \beta')^T & \frac{2}{\lambda} t \end{bmatrix} \succeq 0 \\ \beta', \eta' \geq 0 \\ |\Phi(X)^T w_o| \leq p, p \leq 1, p^T 1 \leq n_o \\ \begin{bmatrix} H & Y 1 - \Phi(X)^T w_o \\ (Y 1 - \Phi(X)^T w_o)^T & 1 \end{bmatrix} \succeq 0 \end{aligned}$$

$$\text{diag}(H) = 1 - \Phi(X)^T w_o \quad (۱۱-۳)$$

اثبات این قضایا در پیوست قرار دارد.

نکته ای که ممکن است بنظر برسد آنستکه با ضرب اتلاف در یک ضریب، احتمال دارد آریبی نمونه در یادگیری فعال تشدید شود. با توجه به قضیه ۳.۲.۲ چون ضریب تابع اتلاف محدود است، بنابراین براساس این قضیه، روش ساده-پیچیده سازگار^۱ است به این معنی که با افزایش تعداد مثالهای برچسب دار، به طبقه بند بهینه همگرا می شویم.

در پیوست، خصوصیات مهمی را برای طبقه بند ساده-پیچیده اثبات کرده ایم. بررسی جزئیات این نتایج از محدوده این رساله خارج است و بنابراین به آن نمی پردازیم. اما بعنوان مثال، ثابت کردیم که اگر داده پرتی وجود داشته باشد و پارامترهای مدل در شرایط ساده ای برای آن صدق کنند، آنگاه طبقه بند ساده-پیچیده تاثیر آنرا در طبقه بندی حذف می کند. بعلاوه ثابت کرده ایم که با وجود شرایطی، طبقه بند ساده-پیچیده آریبی را تشدید نمی کند.

طبقه بند ساده-پیچیده از جنبه ای به یادگیری با داشتن گزینه رد^۲ [۴] مرتبط است. در این نوع از یادگیری نقاطی در دو طرف مرز که باعث افزایش ریسک تجربی می شوند، رد (حذف) می شوند و الگوریتم طبقه بندی اثر آنها را در یادگیری کاهش داده و یا حذف می کند. چنانکه دیدیم توسعه الگوریتم یادگیری فوق البته مستقل از ارتباط با این نوع الگوریتم های یادگیری بوده است. در مراحل پایانی این بخش از کار، مقاله ای توسط خانم Corrina Cortes به همراه Mehryar Mohri برای مسئله یادگیری با گزینه رد ابتدا در وبسایت شخصی ایشان بارگذاری و سپس چندماه پس از آن در [۲۲] ارائه شد. اگرچه این مقاله صرفا طبقه بند برای این هدف ارائه می کند اما رویکرد این مقاله از این جنبه که از تابعی کمکی برای پیدا کردن داده های ردی استفاده کرده اند، به رویکرد ارائه شده در بخش فوق در این رساله شبیه است. البته هیچکدام از رویکردهای پیشنهادی در این رساله برای محدب سازی مسئله در این مقاله ارائه نشده است. تحقیق ارائه شده در این قسمت از رساله در همان تاریخ در arXiv ارسال شده است [۴۶]. نکته جالب آنکه مولفین در [۲۲] اظهار کرده اند که براساس نتایج [۴] انتظار داشته اند که نقاط رد شده، در نزدیکی مرز طبقه بند باشند اما اظهار تعجب کرده اند که با این وجود این روش نقاط را در نواحی دور از مرز طبقه بند هم رد می کند. چنانکه در اثبات های پیوست نشان داده شده است، روش پیشنهادی در اینجا هر دو نوع داده های نویزی، یعنی داده های پرت و داده های برچسب نویزی را از یادگیری حذف می کند. جالب اینجاست که در این مقاله عنوان شده است که الگوریتم های مبتنی بر یادگیری

^۱Consistent

^۲Learning with a Reject Option


با گزینه رد می تواند برای توسعه راه حل هایی برای مسائل یادگیری دیگر مانند یادگیری فعال بکار رود. البته باگذشت نزدیک به چهارسال از آن تاریخ و فراخوان و دعوت مولفین در کارگاه در کنفرانس ICML برای توسعه چنین الگوریتم هایی، تاکنون این کار برای یادگیری فعال صورت نگرفته است.

قبل از ادامه بحث، جالب است که نتایج طبقه بند ساده-پیچیده را بر روی داده های سنتزی ملاحظه کنیم.

بررسی نتایج روی داده های سنتزی

طبقه بند ساده-پیچیده به منظور کاهش تاثیر داده های نویزی، داده هایی که تاثیر منفی روی یادگیری دارند، ارائه شد. به منظور مطالعه رفتار الگوریتم، چند پایگاه داده^۱ سنتزی ساخته ایم. انتظار داریم که طبقه بند ساده تاثیر کمی از این داده ها دریافت کند و طبقه بند پیچیده این مثال ها را شناسایی کند. در اولین پایگاه داده، به داده ها، داده های پرت اضافه می کنیم. با هدف روشن بودن، نتایج الگوریتم در تصاویر، داده های پرت بسیار واضح اضافه کرده ایم. چنانکه در شکل (۱.۱.۳) دیده می شود، طبقه بند پیچیده داده های پرت را شناسایی کرده است و کانتور طبقه بند ساده تاثیر کمی از داده های پرت دریافت کرده است. در عوض کانتور SVM نسبتاً تغییر کرده است. ممکن است بنظر برسد که چون مرز SVM تغییری نداشته است پس اهمیت چندانی ندارد. برای روشن شدن این موضوع، در شکل (۱.۱.۳) داده های برجسب نویزی در دو طرف مرز اضافه شده اند. چنانکه دیده می شود، در این حالت مرز SVM به شدت دچار پیچیدگی شده است در حالیکه مرز طبقه بند ساده تقریباً هیچ تغییری نکرده است. بعلاوه مجدداً طبقه بند پیچیده داده های برجسب نویزی را به درستی شناسایی کرده است. وقتی داده های برجسب نویزی، در فاصله زیادی از مرز طبقه بند قرار دارند، طبیعی است که باید تاثیر آنها روی طبقه بند SVM بسیار بیشتر باشد. این حالت را در شکل (۱.۱.۳) ملاحظه می کنید. اما تاثیر این داده ها روی طبقه بند ساده تقریباً صفر است. این به مدد افزودن یک تابع، طبقه بند پیچیده، برای شناسایی داده های مضر برای یادگیری است. شکل (۱.۱.۳) رفتار الگوریتم را در حالتی می بینید که داده های پرت در نزدیکی مرز قرار دارند.

^۱Dataset




شکل ۱.۳: داده های پرت بسیار واضح برای نشان دادن کانتور توابع به داده اضافه شده اند. چنانکه دیده می شود، طبقه بند ساده تاثیر نسبتاً کمی از داده های پرت پذیرفته است و طبقه بند پیچیده همه داده های پرت را در خود جذب کرده است. در مقایسه کانتور تابع SVM به شدت تاثیر گرفته است. این موضوع در مرز طبقه بند در انتخاب یادگیری فعال تاثیر می گذارد.

تقریب محدب برای یادگیری فعال مقاوم

اکنون تقریب محدب برای یادگیری فعال را ارائه می کنیم. به دلیل اینکه مجموعه داده های پرس و جو $\mathcal{Q}$ زیرمجموعه ای از داده ها است، برای تعیین تابع هدف متغیر عدد صحیح $q_i \in \{0, 1\}$ را برای این انتخاب استفاده می کنیم به شکلی که اگر $q_i = 1$ آنگاه داده i ام عضو مجموعه پرس و جو است و در غیر این صورت نیست. بنابراین تابع هدف برابر خواهد بود با:

$$\bar{J}(w, w_o) = \sum_{i \in \mathcal{D}} (1 - q_i)(1 - y_i w_o^T \psi(x_i))_+ + \sum_{j \in \mathcal{Q}} q_j |w^T \phi(x_j)| + \frac{\lambda}{2} \|w\|_{\mathcal{H}}^2 + \frac{\lambda_o}{2} \|w_o\|_{\mathcal{H}_o}^2 \quad (۱۲-۳)$$




شکل ۲.۳: برای بررسی رفتار طبقه بند ساده-پیچیده وقتی پایگاه داده سنتزی با چند مثال با برچسب نویزی در نزدیکی مرز طبقه بند افزوده شده اند. چنانکه دیده می شود، کانتور طبقه بند ساده انحراف پیدا نکرده است. برعکس، طبقه بندی پیچیده مثالهای برچسب-نویزی را شناسایی کرده است. مرز SVM به شدت اعوجاج پیدا کرده است.

در نتیجه، تابع هدف یادگیری فعال برابر خواهد بود با:

$$\begin{aligned}
 x_s^* &= \arg \min_q \min_{w, w_o} \min_{\substack{y_i \in \{-1, 1\}, \\ \forall x_i \in \mathcal{U}}} \bar{J}(w, w_o, q) \\
 \text{s.t. } & \mathbf{1}^T q = b, q_i \in \{0, 1\} \\
 & \|\Psi(X)^T w_o\|_1 \leq n_o
 \end{aligned} \tag{۱۳-۳}$$

این مسئله ای بسیار مشکل است. متغیرهای $q_i, y_i, \forall x_i \in \mathcal{U}$ اعداد صحیح هستند. بعلاوه مسئله، به شدت نامحدب است. تلاش می کنیم در مراحل این مسئله را با مسئله ای ساده تر تقریب بزنیم.



شکل ۳.۳: مثالهای با برجسب نویزی وقتی که دور از مرز طبقه بند هستند. کانتور SVM به شدت انحراف پیدا کرده است. بعلاوه مرز طبقه بند SVM نیز شدیداً دچار اعوجاج شده است. در حالیکه طبقه بند ساده تقریباً هیچ تغییری نکرده است و طبقه بند پیچیده این مثالها را شناسایی کرده است.

قضیه: مسئله فوق معادل است با


$$\min_{q, w_o, p} \min_{\substack{y_i \in \{-1, 1\}, \\ \forall x_i \in \mathcal{U}}} \max_{\alpha} \sum_{i \in D} \alpha_i (1 - g_i) + \frac{\lambda_o}{2} \|w_o\|^2 - \frac{1}{2\lambda} \alpha^\top (K \odot \hat{G}) \alpha$$

$$\text{s.t.} \quad 0 \leq \alpha \leq \mathbf{1}, -1 \leq \tau \leq \mathbf{1}, y_i \in \{-1, 1\}, \forall x_i \in \mathcal{U}$$

$$\hat{G} = \begin{bmatrix} Y(\mathbf{1} - g) \\ Y(\mathbf{1} - g) \end{bmatrix}^\top$$

$$g = \mathbf{1} - (I - \text{diag}(q))(\mathbf{1} - Y\Phi(X)^\top w_o)$$

$$|\Phi(X)^\top w_o| \leq p, p_i \in \{0, 1\}, \mathbf{1}^\top p \leq n_o \quad (۱۴-۳)$$



شکل ۴.۳: بررسی رفتار الگوریتم وقتی داده های پرت نزدیک مرز هستند. اگرچه هر دو طبقه بند SVM و طبقه بند پیشنهادی نسبتاً خوب عمل کرده اند، کانتور SVM تاثیر نسبتاً بیشتری پذیرفته است.

اثبات این قضیه در پیوست قرار دارد.

این مسئله به دلیل وجود $\hat{G}$ نامحدب است. در اینجا تقریب محدبی از مسئله ارائه می کنیم. ابتدا آنرا در حالت ساده بدون

w_o و p در نظر می گیریم. در این حالت مسئله بالا تبدیل می شود به مسئله ذیل:

$$\min_{q, y_u} \max_{\alpha} \sum_{i \in D} \alpha_i (1 - g_i) - \frac{1}{2\lambda} \alpha^T (K \odot \hat{G}) \alpha$$

$$\text{s.t.} \quad 0 \leq \alpha \leq 1, -1 \leq \tau \leq 1, y_i \in \{-1, 1\}, \forall x_i \in \mathcal{U}$$

$$\hat{G} = \begin{bmatrix} Y^{(1-q)} \\ Y^{(q)} \end{bmatrix} \begin{bmatrix} Y^{(1-q)} \\ Y^{(q)} \end{bmatrix}^T$$

$$g = q$$

$$q_i \in \{0, 1\}, \sum_{i \in Q} q_i = b \quad (۱۵-۳)$$

قید مربوط به ماتریس $\hat{G}$ به شدت نامحدب است. در [۴۷] تقریب محدبی برای مسئله satisfiability پیشنهاد شده است که در

اینجا از آن تقریب استفاده می‌کنیم. به این منظور قید $\hat{G} = \left[Y^{(1-q)}_q \right] \left[Y^{(1-q)}_q \right]^T$ را با قید

$$\hat{G} \succcurlyeq \left[Y^{(1-q)}_q \right] \left[Y^{(1-q)}_q \right]^T$$

$$diag(\hat{G}) = \left[\mathbf{1}^{1-\hat{q}}_q \right], \forall i \in D_l, \hat{q}_i = 0, \forall i \in D_u, \hat{q}_i = q_i$$

$$rank(\hat{G}) = 1 \quad (۱۶-۳)$$

جایگزین می‌کنیم. اکنون با حذف قید مرتبه یک بودن ماتریس $\hat{G}$ تقریب محدب بدست می‌آید. البته در این مسئله با چالشی

دیگر نیز مواجه هستیم که باعث نامحدب شدن ماتریس حاصل می‌شود. براساس قضیه schur خواهیم داشت:

$$\begin{bmatrix} & & & y_l \\ & & & \\ & \hat{G} & & Y_u(1-q) \\ & & & q \\ y_l^T & (1-q)^T Y_u & q^T & 1 \end{bmatrix} \succcurlyeq 0$$

$$diag(\hat{G}) = \mathbf{1} - q, \forall i \in D_l, q_i = 0 \quad (۱۷-۳)$$

متأسفانه این قید هنوز به دلیل وجود عبارت $v_u = Y_u(1-q)$ نامحدب است. خوشبختانه با توجه به $Y_{ui} \in \{-1, 1\}$ می

توانیم آنرا بصورت ذیل نشان بدهیم.

$$\begin{bmatrix} & & & y_l \\ & & & \\ & \hat{G} & & v_u \\ & & & q \\ y_l^T & v_u^T & q & 1 \end{bmatrix} \succcurlyeq 0$$

$$|v_u| + q = 1$$

$$\text{diag}(\widehat{G}) = \mathbf{1} - q, \quad \forall i \in D_l, \quad = 0 \quad (۱۸-۳)$$

با آزاد کردن مقادیر گسسته $q_i \in [0, 1]$ و $y_i \in [-1, 1], \forall x_i \in \mathcal{U}$ خواهیم داشت:

$$\min_{q, y_u, G} \max_{\alpha} \sum_{i \in D} \alpha_i (1 - q_i) - \frac{1}{2\lambda} \alpha^\top (K \odot \widehat{G}) \alpha$$

$$\text{s.t.} \quad 0 \leq \tilde{\alpha} \leq 1, -1 \leq \tau \leq 1, y_i \in \{-1, 1\}, \forall x_i \in \mathcal{U}$$

$$G = \begin{bmatrix} & & & y_l \\ & \widehat{G} & & r \\ & & & q \\ y_l^\top & r^\top & q^\top & 1 \end{bmatrix} \succcurlyeq 0$$

$$|r| + q = 1$$

$$\text{diag}(\widehat{G}) = \mathbf{1} - q, \forall i \in D_l, q_i = 0$$

$$\mathbf{1}^\top q = b, q \in [0, 1] \quad (۱۹-۳)$$

اکنون حالت اصلی مسئله را به شکل ذیل حل می کنیم. این مسئله چالش های بزرگتری دارد. علاوه بر مشکلات مسئله قبلی،

در این مسئله تابع هدف پیچیده تری داریم. این مسئله معادل است با

$$\min_{q, y_u, w_o, p} \max_{\alpha} \sum_{i \in D} \alpha_i (1 - g_i) + \frac{\lambda_o}{2} \|w_o\|^2 - \frac{1}{2\lambda} \alpha^\top (K \odot \widehat{G}) \alpha$$

$$\text{s.t.} \quad 0 \leq \alpha \leq 1, -1 \leq \tau \leq 1, y_i \in \{-1, 1\}, \forall x_i \in \mathcal{U}$$

$$\widehat{G} = \begin{bmatrix} Y(\mathbf{1}-g) \\ Y(\mathbf{1}-g) \end{bmatrix} \begin{bmatrix} Y(\mathbf{1}-g) \\ Y(\mathbf{1}-g) \end{bmatrix}^\top$$

$$\mathbf{1} - g = (I - \text{diag}(q))(\mathbf{1} - Y\Phi(X)^T w_o)$$

$$|\Phi(X)^T w_o| \leq p,$$

$$\mathbf{1}^T p \leq n_o, p_i \in \{0, 1\}$$

$$\mathbf{1}^T q = b, q_i \in \{0, 1\} \quad (۲۰-۳)$$

$$\widehat{G} = \begin{bmatrix} Y(1-g) \\ q \end{bmatrix} \begin{bmatrix} Y(1-g) \\ q \end{bmatrix}^T \quad \text{قید}$$

$$\widehat{G} \succcurlyeq \begin{bmatrix} Y(1-g) \\ q \end{bmatrix} \begin{bmatrix} Y(1-g) \\ q \end{bmatrix}^T$$

$$\text{diag}(\widehat{G}) = \begin{bmatrix} 1-g \\ q \end{bmatrix}$$

$$\text{rank}(\widehat{G}) = 1 \quad (۲۱-۳)$$

جایگزین می کنیم. براساس قضیه schur خواهیم داشت:

$$\begin{bmatrix} & & v_l \\ & \widehat{G} & v_u \\ & & q \\ v_l^T & v_u^T & q^T & 1 \end{bmatrix} \succcurlyeq 0 \quad (۲۲-۳)$$

که در آن

$$v_u = Y_u \text{diag}(1 - Y_u \Phi(X_u)^T w_o)(1 - q)$$

$$|v_u| = \text{diag}(1 - Y_u \Phi(X_u)^T w_o)(1 - q)$$

$$= 1 - Y_u \Phi(X_u)^T w_o - q + \text{diag}(q) Y_u \Phi(X_u)^T w_o$$

$$v_l = Y_l \text{diag}(1 - Y_l \Phi(X_l)^T w_o) \quad (۲۳-۳)$$

روشن است که نمی خواهیم داده های نویزی را برای پرس وجو انتخاب کنیم. در حالت ایده آل فقط یکی از دو مقدار q_i و p_i برابر یک خواهد بود و دیگری برابر صفر است. بنابراین قید $|\Phi(X_u)^T w_o Y_u| \leq 1 - q$ را اعمال می کنیم. در این شرایط می توانیم تقریب زیر را بکار ببریم. با توجه به کوچک بودن حداقل یکی از مقادیر p_i یا q_i تقریب ذیل تقریب مناسبی خواهد بود:

$$|v_u| + q + Y_u \Phi(X_u)^T w_o = 1 \quad (۲۴-۳)$$

$$|\Phi(X_u)^T w_o| + q \leq 1$$

قید ۲۴-۳ همچنان نامحدب است. با توجه به پیچیدگی تابع w_o می توانیم فرض کنیم $p_i = Y_u \Phi(X_u)^T w_o$

فرم نهایی برای حل این مسئله عبارتست از

$$\min_{G, q, y_u, w_o, p} \max_{\alpha} \sum_{i \in D} \tilde{\alpha}_i (1 - g_i) + \frac{\lambda_o}{2} \|w_o\|^2 - \frac{1}{2\lambda} \alpha^T (K \odot \hat{G}) \alpha + c_a \mathbf{1}^T a$$

$$\text{s.t.} \quad 0 \leq \tilde{\alpha} \leq 1, -1 \leq \tau \leq 1, q, p \in [0, 1]$$

$$G = \begin{bmatrix} & & & v_l \\ & \hat{G} & & v_u \\ & & q & \\ v_l^T & v_u^T & q^T & 1 \end{bmatrix} \succcurlyeq 0$$

$$\text{diag}(\hat{G}) = \begin{bmatrix} \mathbf{1}_q^{-g} \end{bmatrix}, g = 1 - |v|, |v| \leq a$$

$$a + q + p = 1, \quad \mathbf{1}^T q = b$$

$$|\Phi(X_u)^T w_o| \leq 1 - q$$

$$|\Phi(X)^T w_o| \leq p$$

$$\mathbf{1}^T p \leq n_o, \quad \sum_{i, \forall x_i \in \mathcal{L}} p_i \leq n_l \quad (۲۵-۳)$$

۲.۱.۳ یادگیری فعال چند وظیفه ای

در این بخش، روشی برای یادگیری فعال چندوظیفه ای براساس رویکرد کمینه سازی ریسک تجربی پیشنهاد می کنیم. فرض کنید که تعداد T وظیفه داریم و مجموعه

$$\mathcal{L}_t = \{(x_{it}, y_{it}) | x_{it} \in \mathbb{R}^d, y_{it} \in \{-1, 1\}\}, \quad \forall t \in [1, \dots, T]$$

مجموعه داده های برچسب دار مربوط به وظیفه t ام و

$$\mathcal{U}_t = \{x_{it} | x_{it} \in \mathbb{R}^d\}, \quad \forall t \in [1, \dots, T]$$

مجموعه داده های بدون برچسب مربوط به همان وظیفه و همچنین مجموعه داده های برچسب دار و بدون برچسب

$$\mathcal{D}_t = \{(x_{it}, y_{it}) | x_{it} \in \mathbb{R}^d, y_{it} \in \{-1, 1\}\}, \quad \forall t \in [1, \dots, T]$$

باشد که در آن برچسب داده های بدون برچسب مجهول است. همچنین مجموعه داده های برچسب دار همه وظیفه ها برابر است با $\mathcal{L} = \{\mathcal{L}_1, \dots, \mathcal{L}_T\}$ و مجموعه همه داده ها برابر است با $\mathcal{D} = \{\mathcal{D}_1, \dots, \mathcal{D}_T\}$. تابع هزینه روی مجموعه، $\mathcal{L}$ ، مجموعه داده های برچسب دار برای وظیفه های $t \in \{1, \dots, T\}$ را با استفاده از تابع اتلاف l بصورت

$$J(W, \mathcal{L}, \lambda) = \sum_{t=1}^T \sum_{i=1}^{|\mathcal{L}_t|} l(y_{it}, w_t^* x_{it}) + \frac{\lambda}{2} \|W\|_{2,1}$$

تعریف می کنیم که w_t ستون t ام از ماتریس W ، $w_t = W_{*,t}$ است. ، آنگاه براساس کمینه سازی ریسک تجربی، وظیفه های بهینه برابر خواهند بود با

$$W^* = \arg \min_W J(W, \mathcal{L}, \lambda)$$

مشابه قبل برای انتخاب نقطه پرس و جو براساس رویکرد کاهش فضای نسخه، باید نقطه داده ای را مورد پرس و جو قرار دهیم که با هر برچسبی و صرفنظر از اینکه از چه وظیفه ای است، کمترین اتلاف را داشته باشد. بعبارت دیگر

$$x_{st}^* = \arg \min_{\substack{x_{st} \in \mathcal{U}_t, \\ \forall t,s}} \max_{y_{st}} l(y_{st}, w_t^* x_{st}) \quad (۲۶-۳)$$

مشابه بخش قبل بتدریج با افزایش تعداد نمونه های برچسب دار، انتظار می رود تفاوت طبقه بند های جاری وظیفه ها با طبقه بند بهینه کاهش پیدا کند. در نتیجه خواهیم داشت:

$$x_{st}^* = \arg \min_{\substack{x_{st} \in \mathcal{U}_t, \\ \forall t, s}} \min_{W, \{J(W, \mathcal{L}, \lambda) \leq J(W^*, \mathcal{L}, \lambda)\}} \max_{y_{st}} l(y_{st}, w_t^T x_{st}) \quad (27-3)$$

میدانیم که برای این مسئله بهینه سازی مقید، $\exists c_s \geq 0$ که مسئله فوق معادل است با

$$x_s^* = \arg \min_{\substack{x_{st} \in \mathcal{U}_t, \\ \forall t, s}} \min_W \max_{y_{st}} c_{st} l(y_{st}, w_t^T x_{st}) + J(W, \mathcal{L}, \lambda) \quad (28-3)$$

به منظور ساده سازی مسئله، c_s را برابر یک قرار می دهیم. در نتیجه با در نظر گرفتن داده های برچسب دار و بعلاوه مجهول بودن برچسب آنها مشابه بخش ۱.۰.۳، مسئله یادگیری فعال چندوظیفه ای برابر خواهد بود با

$$x_{st}^* = \arg \min_{\substack{x_{st} \in \mathcal{U}_t, \\ \forall t, s}} \min_W \max_{y_{st}} J(W, \mathcal{D}, \lambda) \quad (29-3)$$

در تابع هدف این مسئله، جمله ای مشتق ناپذیر و یا اصطلاحاً ناهموار^۱ وجود دارد. برای حل این مسئله از روش همجواری^۲ استفاده می کنیم [۹۸]. به منظور ساده سازی، از تابع اتلاف مربع خطا استفاده می کنیم و قرار می دهیم: $l(y_{it}, w_t^T \phi(x_{it})) = (y_{it} - w_t^T x_{it})^2$. تابع هدف (۲۹-۳) وقتی بیشینه می شود که برچسب نقطه پرس وجو را برابر مقدار مخالف برچسب تعیین شده توسط طبقه بند قرار بدهیم بعبارت دیگر:

$$y_{st} = -\text{sign}(w_t^T x_{st})$$

در نتیجه تابع هدف برابر خواهد بود با

$$J(W, \mathcal{L}, \lambda) = \sum_{t=1}^T \sum_{i=1}^{|\mathcal{L}_t|} (y_{it} - w_t^T x_{it})^2 + (2 + 2|w_t^T x_{st}|) + \frac{\lambda}{2} \|W\|_{2,1}$$

$$\text{جمله } g(W) = \|W\|_{2,1} + \frac{4}{\lambda} |w_t^T x_{st}| \quad \text{جمله } h(W) = \frac{2}{\lambda} \sum_{t=1}^T \sum_{i=1}^{|\mathcal{L}_t|} (y_{it} - w_t^T x_{it})^2$$

^۱Non-smooth

^۲Proximal

مشتق ناپذیر است. بنابراین حل مسئله با تکرار رابطه ذیل

$$W^{k+1} = \mathbf{prox}_{\mu g}(W^k - \mu \nabla h(W^k)) \quad (۳-۳۰)$$

نسبت به W بدست می آوریم که در آن

$$\mathbf{prox}_{\mu f}(v) = \arg \min_x \left(f(x) + \frac{1}{2\mu} \|x - v\|^2 \right) \quad (۳-۳۱)$$

تعریف می شود. داریم:

$$g(W) = \sum_{u=1, u \neq t}^T \|W_{*,u}\|_2 + \|W_{*,t}\|_2 + \frac{4}{\lambda} |W_{*,t}^\top x_{st}|$$

در نتیجه

$$\begin{aligned} \mathbf{prox}_{\mu g}(v) &= \arg \min_W \left(g(W) + \frac{1}{2\mu} \|W - v\|^2 \right) \\ &= \arg \min_x \left(\sum_{u=1, u \neq t}^T \|W_{*,u}\|_2 + \|W_{*,t}\|_2 + \frac{4}{\lambda} |x_{st}^\top W_{*,t}| + \frac{1}{2\mu} \|W - v\|^2 \right) \end{aligned}$$

چون مسئله فوق نسبت به مولفه های $W_{*,u}$ جداپذیر است، بنابراین دو مسئله ذیل را خواهیم داشت:

$$\begin{aligned} \mathbf{prox}_{\mu g}(v)_{*,u,u \neq t} &= \arg \min_{W_{u=1, u \neq t}} \left(\sum_{u=1, u \neq t}^T \|W_{*,u}\|_2 + \frac{1}{2\mu} \|W_{*,u,u \neq t} - v_{*,u,u \neq t}\|^2 \right) \\ \mathbf{prox}_{\mu g}(v)_{*,t} &= \arg \min_{W_{*,t}} \left(\|W_{*,t}\|_2 + \frac{4}{\lambda} |x_{st}^\top W_{*,t}| + \frac{1}{2\mu} \|W_{*,t} - v_{*,t}\|^2 \right) \end{aligned}$$

برای مسئله اول می دانیم که [۹۸] :

$$\left[\mathbf{prox}_{\mu g}(W) \right]_{*,u,u \neq t} = \left[\left(1 - \frac{\mu}{\|W_{*,u}\|_2} \right)_+ W_{*,u} \right]_{u=1, u \neq t}^T$$

میدانیم که برای تابع قدرمطلق، تابع همجواری ذیل را داریم:

$$\mathbf{prox}_{\mu|\cdot|}(v) = (v - \mu x)_+ - (-v - \mu x)_+$$

در نتیجه برای مسئله دوم، خواهیم داشت:

$$\left[\text{prox}_{\mu g}(W)\right]_{*,t} = \left(1 - \frac{\mu}{\|r\|_2}\right)_+ r$$

که در آن r برابر است با:

$$r = \left(W_{*,t} - \mu \frac{4}{\lambda} x_{st}\right)_+ - \left(-W_{*,t} - \mu \frac{4}{\lambda} x_{st}\right)_+$$

بنابراین در رابطه تکراری (۳-۳۰)، $\text{prox}_{\mu g}(W)$ را محاسبه کرده ایم.

گرایان تابع h برابر است با:

$$\nabla h(W) = 2X(X^t W - Y)$$

اکنون تمام اجزاء رابطه تکراری (۳-۳۰) را داریم. با قرار دادن آنها در این رابطه، جواب مسئله بدست می آید.

۳.۱.۳ یادگیری مبتنی بر انتقال دانش ممتاز

یک شاگرد با کمک معلم بسیار سریعتر از یک ماشین یادگیر می تواند یک مفهوم را یاد بگیرد. در یکی از آخرین کارهایش، Vapnik پرسشی مطرح کرد که پایه رویکرد یادگیری با استفاده از دانش ممتاز^۱ شد: چه چیزی باعث می شود که شاگرد (یادگیر انسانی) سریعتر از یک ماشین یادگیر یاد بگیرد؟ و پاسخش این بود: معلم به شاگرد دانش ممتاز^۲ ارائه می دهد [۱۴۲]. معلم به شاگرد، منبعی از دانش ارائه می دهد که به شاگرد کمک می کند مفهوم را دقیقتر و با تلاش کمتر یاد بگیرد. چون این دانش صرفاً در زمان آموزش وجود دارد و نه در زمان آزمون، Vapnik آنرا دانش ممتاز نامید.

این مفهوم ذاتاً به داده های جدانپذیر/جدانپذیر در طبقه بندی مرتبط است. وقتی کلاسه های متفاوت جدانپذیر هستند، احتمال خطا در پیش بینی برچسب نقاط از مرتبه $O(\frac{1}{l})$ است که l تعداد نقاط برچسب دار است. در مقایسه، حالت جدانپذیر، احتمال خطا از مرتبه $O(\frac{1}{\sqrt{l}})$ است. این تفاوت فوق العاده زیادی است بعنوان مثال برای دقت تقریباً یکسان تعداد ۳۲۰ مثال در برابر ۱۰۰۰۰۰۰ مثال در حالت جدانپذیر نیاز است. دقت یادگیری ماشین در حالت جدانپذیر می تواند با استفاده از دانش ارائه شده توسط معلم بهبود یابد [۱۴۲].

^۱Learning Using Privileged Information

^۲Privileged Knowledge

فرض کنید که پیش‌گویی وجود دارد که می‌تواند داده‌ها را مجدداً با ارائه میزان slack مورد نیاز برای هر مثال جداپذیر کند. پیش‌گو به شاگرد تابعی با VC Dimension بینهایت ارائه می‌کند که slack را برای هر مثال محاسبه می‌کند. در این حالت، میزان خطا، به $O(\frac{1}{l})$ بهبود پیدا می‌کند. بهرحال، چنین پیشگویی در دسترس نیست. بنابراین Vapnik پیشنهاد کرد که یک معلم هوشمند^۲ معلم هوشمند سه گانه (x_i, y_i, x_i^*) را برای هر مثال ارائه می‌کند که (x_i, y_i) زوج مثال-برچسب و x_i^* دانش ممتاز است. دانش ممتاز x_i^* در فضای X^* قرار دارد که در آن محاسبه slack یا پیش‌بینی برچسب بسیار ساده‌تر است. [۱۴۲]. عبارت دیگر، تابعی که slack را محاسبه می‌کند بسیار ساده‌تر است. این رویکرد یادگیری با استفاده از اطلاعات ممتاز^۳ نامیده می‌شود.

تقریباً همیشه، اطلاعات ممتاز در یادگیری ماشین وجود دارد. برای مثال، فرض کنید کسی می‌خواهد نتیجه یک جراحی، اینکه بیمار نجات پیدا می‌کند یا نه، را پیش‌بینی کند. در اینجا، اطلاعات بسیاری در مورد علائم بیماران قبلی بعد از جراحی وجود دارد. البته، برای پیش‌بینی نتیجه جراحی بیمار حاضر، چنین اطلاعاتی در دسترس نیست. اطلاعات در دسترس در مورد بیماران قبلی بعد از جراحی می‌تواند به عنوان اطلاعات ممتاز استفاده شود [۱۴۲].

ماشین بردار پشتیبان^۴ تابع هدف ذیل را کمینه می‌کند:

$$\min_f \sum_{i=1}^n \xi_i + \frac{C}{2} \|f\|^2 \quad (۳۲-۳)$$

$$\text{s.t. } y_i f(x_i) \geq 1 - \xi_i \quad (۳۳-۳)$$

$$\xi_i \geq 0 \quad (۳۴-۳)$$

که در آن $f(x_i) = \sum_{j=1} K(x_i, x_j)$ [۲۳] است. LUP^۳ فرض می‌کند که تابع f^* وجود دارد که می‌تواند ξ_i را از x_i^* تخمین بزند. به شکل دقیقتر:

$$\xi_i = \max\{0, f^*(x_i^*, \alpha^*)\}, \quad \alpha^* \in \Lambda \quad (۳۵-۳)$$

^۱Oracle

^۲Intelligent Teacher

^۳Learning Using Privileged Information (LUP)

^۴Support Vector Machine (SVM)

نتیجه تابع هدف ذیل است [۱۴۳]:

$$\min_f \sum_{i=1}^n \max\{0, f^*(x_i^*, \alpha^*)\} + \frac{C}{2} \|f\|^2 + \frac{C^*}{2} \|f^*\|^2 \quad (۳۶-۳)$$

$$\text{s.t. } y_i f(x_i) \geq 1 - \max\{0, f^*(x_i^*, \alpha^*)\} \quad (۳۷-۳)$$

$$\alpha^* \in \Lambda \quad (۳۸-۳)$$

جالب است که مولفین در [۷۱] ثابت کردند که استفاده از دانش ممتاز به وزن دهی اهمیت^۱ ارتباط دارد و نشان دادند که ویژگیهای ممتاز می تواند توسط وزنهایی برای هر مثال آموزش بیان شود. بعلاوه نشان دادند که مجموعه جوابهای یک مسئله ماشین بردار پشتیبان وزن دهی شده، همیشه شامل مجموعه جوابهای مدل ارائه شده توسط Vapnik برای یادگیری ممتاز است. نکته جالب آنکه دانش ممتاز به مفهوم distillation که در شبکه های عصبی عمیق مطرح می شود، کاملاً مرتبط است [۷۹]. در اینجا، تعدادی نمونه $D_i, i = 1, 2, \dots, n$ که هر کدام از یک توزیع P_i برداشته شده اند، در اختیار داریم. هر نمونه D_i شامل مجموعه ای نقاط داده $D_i = \{x_{ij}, j = 1, 2, \dots, n_{ij}\}$ است. فرض می کنیم که P_i همه توزیع ها از یک توزیع مادر برداشته شده اند [۸۰].

در یادگیری روی توزیع، می خواهیم تابع $f(P_i)$ برای هر توزیع P_i یاد بگیریم. همانطور که قبلاً مطرح شد، چون در عمل دسترسی به خودتوزیع ها نداریم و صرفاً به تعدادی نمونه برداشته شده از توزیع ها دسترسی داریم، یادگیری روی توزیع با استفاده از این نمونه ها انجام می شود.

در اینجا، پیشنهاد می کنیم که معلم اطلاعاتی مربوط به جزئیات مفهوم تحت یادگیری را به سیستم یادگیر ارائه بدهد. معلم می تواند به شاگرد طبقه بندی بدهد که مفهومی مهم در رابطه با نقطه داده ها، که هر نمونه از تعدادی از آنها ساخته شده است، را نشان بدهد. اما چون به مثالی در یادگیری روی توزیع دسترسی نداریم، معلم نمی تواند اینکار را انجام بدهد. در عوض، او برچسب هایی برای زیرمجموعه ای از نقطه داده ها ارائه می کند.

بنابراین، به عنوان اطلاعات ممتاز، تعدادی برچسب برای زیرمجموعه D_i^l با اندازه n_i^l از نقطه داده های برداشته شده از توزیع P_i در اختیار داریم. بعبارت دیگر، سه تایی $(\{x_i^j\}_{j=1}^{n_i}, \{x_i^j, y_i^j\}_{j \in D_i^l}, y_i)$ برای توزیع P_i که $\{x_i^j, y_i^j\}_{j \in D_i^l}$ دانش ممتاز

^۱Importance Weighting

است، را به سیستم یادگیر ارائه می دهد. فرض کنید $\mu_g(P_i) = \mathbb{E}_{x \sim P_i} g(P_i, x)$ میانگین توزیع براساس نمونه برداشته شده از P_i باشد. فرض کنید $\mu_{P_i} = \mathbb{E}_{x \sim P_i} \phi(P_i, \cdot)$ داریم:

$$\mu_g(P_i) = \mathbb{E}_{x \sim P_i} g(P_i, x) \quad (۳-۳۹)$$

$$= \langle g, \mathbb{E}_{x \sim P_i} \phi(P_i, \cdot) \rangle \quad (۳-۴۰)$$

$$= \langle g, \mu_{P_i} \rangle \quad (۳-۴۱)$$

وقتی که یک کرنل مشخصه^۱ داشته باشیم، می دانیم که μ_{P_i} شامل همه اطلاعات توزیع P_i [۱۲۸] است.

تابع هدف ذیل را تعریف می کنیم:

$$\mathcal{T}(f, g, \mu_g) = \frac{1}{2} \|f\|^2 + \frac{C_g}{2} \|g\|^2 + C \sum_{i=1}^n [y_i \mu_g(P_i)]_+ + C_v \sum_{i=1}^n \sum_{j \in \mathcal{D}_i^t} [1 - y_i^j g(P_i, x_i^j)]_+ \quad (۳-۴۲)$$

برای یادگیری طبقه بند مورد نظر، مسئله بهینه سازی ذیل باید حل شود:

$$\min_{f, g} \quad \mathcal{T}(f, g, \mu_g) \quad (۳-۴۳)$$

$$\text{s.t.} \quad y_i f(P_i) \geq 1 - [y_i \mu_g(P_i)]_+ \quad \forall i \in [1, n] \quad (۳-۴۴)$$

علاوه برچالش های مسئله فوق، ساختار تابع g باید تعیین شود. براساس کار [۷] فرض می کنیم که

$$g(P_i, x_i^j) = \sum_{t=1}^n \sum_{h=1}^{n_t} \beta_t^h K(P_i, P_t) k(x_i^j, x_t^h) \quad (۳-۴۵)$$

برای تخمین $\mu_g(P_i)$ یک نمونه برداشته شده از P_i را استفاده می کنیم:

$$\hat{\mu}_g(P_i) = \frac{1}{n_i} \left(\sum_{j \in \mathcal{D}_i} g(P_i, x_i^j) \right) \quad (۳-۴۶)$$

بنابراین مسئله بهینه سازی بالا تبدیل می شود به:

$$\min_{f, g} \quad \mathcal{T}(f, g, \hat{\mu}_g) \quad (۳-۴۷)$$

^۱Characteristic Kernel

$$\text{s.t. } y_i f(P_i) \geq 1 - [y_i \hat{\mu}_g(P_i)]_+ \quad \forall i \in [1, n]$$

قضیه ذیل ثابت می کند که مسئله بهینه سازی بالا معادل است با:

قضیه ۳.۱.۳. مسئله بهینه سازی (۴۷-۳) معادل است با:

$$\min_{\eta, \alpha, \theta} \quad \frac{1}{2} \alpha^T Y K Y \alpha + \frac{1}{2C_g} \left(A^T Y (\eta + \alpha - C \mathbf{1}) + Z \theta \right)^T L \left(L A^T Y (\eta + \alpha - C \mathbf{1}) + L Z \theta \right) \quad (۴۸-۳)$$

$$\text{s.t. } \eta, \alpha, \theta \geq 0 \quad (۴۹-۳)$$

$$\alpha^T Y \mathbf{1} = 0 \quad (۵۰-۳)$$

$$\mathbf{1}^T A^T Y (\eta + \alpha) + \mathbf{1}^T Z^T \theta = C \mathbf{1}^T A^T Y \mathbf{1} \quad (۵۱-۳)$$

$$\theta \geq C_v B^T \mathbf{1} \quad (۵۲-۳)$$

$$\eta + \alpha \geq (C + \Delta C) \mathbf{1} \quad (۵۳-۳)$$

برهان. میدانیم که

$$\mathcal{T}(f, g, \hat{\mu}_g) = \frac{1}{2} \|f\|^2 + \frac{C_g}{2} \|g\|^2 + C \sum_{i=1}^n [y_i \mu_g(P_i)]_+ + C_v \sum_{i=1}^n \sum_{j \in \mathcal{D}_i^l} [1 - y_i^j g(P_i, x_i^j)]_+ \quad (۵۴-۳)$$

برای تخمین $\mu_g(P_i)$ از یک نمونه برداشته شده از P_i استفاده می کنیم یعنی

$$\hat{\mu}_g(P_i) = \frac{1}{n_i} \left(\sum_{j \in \mathcal{D}_i} g(P_i, x_i^j) \right) \quad (۵۵-۳)$$

این مسئله بهینه سازی غیرخطی است. تقریب آن براساس روش [۱۴۲] عبارتست از کمینه سازی تابع هدف

$$\mathcal{T}(f, g) = \frac{1}{2} \|f\|^2 + \frac{C_g}{2} \|g\|^2 + C \sum_{i=1}^n [y_i \hat{\mu}_g(P_i) + \xi_i] + \Delta C \sum_{i=1}^l \xi_i + C_v \sum_{i=1}^n \sum_{j \in \mathcal{D}_i^l} [1 - y_i^j g(P_i, x_i^j)]_+ \quad (۵۶-۳)$$

نسبت به f, g به همراه قیود

$$\xi_i \geq 0 \quad (۵۷-۳)$$

$$y_i \hat{\mu}_g(P_i) + \xi_i \geq 0 \quad (۵۸-۳)$$

$$y_i f(P_i) + y_i \hat{\mu}_g(P_i) \geq 1 - \xi_i \quad (۵۹-۳)$$

توابع مورد نظر را بدست می دهد. فرض کنید $\zeta_i^j = [1 - y_i^j g(P_i, x_i^j)]_+$ آنگاه، مسئله بهینه سازی تبدیل می شود به کمینه سازی تابع هدف

$$\mathcal{T}(f, g) = \frac{1}{2} \|f\|^2 + \frac{C_g}{2} \|g\|^2 + C \sum_{i=1}^n [y_i \hat{\mu}_g(P_i) + \xi_i] + \Delta C \sum_{i=1}^l \xi_i + C_v \sum_{i=1}^n \sum_{j \in \mathcal{D}_i^l} \zeta_i \quad (۶۰-۳)$$

نسبت به قیود

$$\xi_i \geq 0, \quad \zeta_i \geq 0 \quad (۶۱-۳)$$

$$y_i \hat{\mu}_g(P_i) + \xi_i \geq 0 \quad (۶۲-۳)$$

$$y_i f(P_i) + y_i \hat{\mu}_g(P_i) \geq 1 - \xi_i \quad (۶۳-۳)$$

$$y_i^j g(P_i, x_i^j) \geq 1 - \zeta_i^j \quad (۶۴-۳)$$

فرض کنید $f(P_i) = \sum_{t=1}^n \gamma_t K(P_i, P_t) + b$ و

$$g(P_i, x_i^j) = \sum_{t=1}^n \sum_{h=1}^{n_t} \beta_t^h K(P_i, P_t) k(x_i^j, x_t^h) + b_g \quad (۶۵-۳)$$

و فرض کنید L ماتریسی با مولفه های $L(x_i^j, x_t^h) = K(P_i, P_t) k(x_i^j, x_t^h)$ و f برداری با المان های $f(P_i)$ باشد، آنگاه داریم:

$$g(P_i, x_i^j) = L(x_i^j, :) \beta + b_g \quad (۶۶-۳)$$

$$f(P_i) = K(P_i, :) \gamma + b \quad (۶۷-۳)$$

که β, g دو بردار متناظرا با مولفه های $\beta_t^h, h \in \mathcal{D}_i$ و $\beta_t^j, j \in \mathcal{D}_i$ هستند. بنابراین

$$\|f\|^2 = \gamma^\top K \gamma \quad (۶۸-۳)$$

$$\|g\|^2 = (L(., :)\beta)^\top L(., :)\beta \quad (۶۹-۳)$$

$$= \beta^\top L\beta \quad (۷۰-۳)$$

فرض کنید $\mathbf{1}_i(x) = I(x \in \mathcal{D}_i)$ برداری با مقدار صفر برای همه نقطه داده های همه توزیع های دیگر و یک برای نقطه داده های برداشته شده از توزیع P_i باشد. آنگاه

$$\mu_g(P_i) = \frac{1}{n_i} \sum_{i \in \mathcal{D}_i} g(P_i, x_i^j) = \frac{1}{n_i} \mathbf{1}_i^\top g \quad (۷۱-۳)$$

بنابراین، مسئله بهینه سازی بالا تبدیل می شود به کمینه سازی تابع هدف

$$\mathcal{T}(f, g) = \frac{1}{2} \|f\|^2 + \frac{C_g}{2} \|g\|^2 + C \sum_{i=1}^n \left[y_i \frac{1}{n_i} \mathbf{1}_i^\top g + \xi_i \right] + \Delta C \sum_{i=1}^l \xi_i + C_v \sum_{i=1}^n \sum_{j \in \mathcal{D}_i^l} \zeta_i \quad (۷۲-۳)$$

نسبت به قیود

$$\xi_i \geq 0, \quad \zeta_i \geq 0 \quad (۷۳-۳)$$

$$y_i \frac{1}{n_i} \mathbf{1}_i^\top g + \xi_i \geq 0 \quad (۷۴-۳)$$

$$y_i f(P_i) + y_i \frac{1}{n_i} \mathbf{1}_i^\top g \geq 1 - \xi_i \quad (۷۵-۳)$$

$$y_i^j g(P_i, x_i^j) \geq 1 - \zeta_i^j \quad (۷۶-۳)$$

فرض کنید $A(i, ;) = \frac{1}{n_i} \mathbf{1}_i^\top$ و $\mathbf{1}_i^l(x) = I(x \in \mathcal{D}_i^l)$ و $B(i, ;) = \mathbf{1}_i^l$ برای همه نقطه داده های توزیعها، قرار بدهید $z_i^j = y_i^j, j \in \mathcal{D}_i^l$ و $z_i^j = 0, j \notin \mathcal{D}_i^l$ همچنین $Y = \text{diag}(y)$ and $Z = \text{diag}(z)$ مسئله بهینه سازی بالا تبدیل می شود به

$$\mathcal{T}(f, g) = \frac{1}{2} \gamma^\top K \gamma + \frac{C_g}{2} \beta^\top L \beta + C \mathbf{1}^\top [Y A (L \beta + b_g \mathbf{1}) + \xi] + \Delta C \mathbf{1}^\top \xi + C_v \mathbf{1}^\top B \zeta \quad (۷۷-۳)$$

به همراه قیود

$$\xi \geq 0, \quad \zeta \geq 0 \quad (۷۸-۳)$$

$$YA(L\beta + b_g \mathbf{1}) + \xi \geq 0 \quad (۷۹-۳)$$

$$Y(K\gamma + b) + YA(L\beta + b_g \mathbf{1}) \geq \mathbf{1} - \xi \quad (۸۰-۳)$$

$$Z(L\beta + b_g \mathbf{1}) \geq \mathbf{1} - \zeta \quad (۸۱-۳)$$

تابع لاگرانژ^۱ این مسئله بهینه سازی برابر است با

$$\mathcal{L}(\gamma, b, \beta, b_g, \xi, \zeta; u, v, \eta, \alpha, \theta) = \mathcal{T}(f, g) - u^\top \xi - v^\top \zeta - \eta^\top (YA(L\beta + b_g \mathbf{1}) + \xi) \quad (۸۲-۳)$$

$$- \alpha^\top (Y(K\gamma + b) + YA(L\beta + b_g \mathbf{1}) + \xi - \mathbf{1}) \quad (۸۳-۳)$$

$$- \theta^\top (Z(L\beta + b_g \mathbf{1}) + \zeta - \mathbf{1}) \quad (۸۴-۳)$$

$$= \frac{1}{2} \gamma^\top K \gamma - \alpha^\top Y K \gamma \quad (۸۵-۳)$$

$$+ \frac{C_g}{2} \beta^\top L \beta - (LA^\top Y(\eta + \alpha - C\mathbf{1}) + LZ\theta)^\top \beta \quad (۸۶-۳)$$

$$- \alpha^\top Y \mathbf{1} b - (\eta^\top Y A + \alpha^\top Y A + \theta^\top Z - C\mathbf{1}^\top Y A) \mathbf{1} b_g \quad (۸۷-۳)$$

$$- (v + \theta - C_v B^\top \mathbf{1})^\top \zeta - (u + \eta + \alpha - (C + \Delta C)\mathbf{1})^\top \xi \quad (۸۸-۳)$$

با کمینه سازی نسبت به متغیرهای مسئله اولیه^۲ مسئله دوگان بدست می آید:

$$\frac{\partial \mathcal{L}}{\partial \zeta} = C_v B^\top \mathbf{1} - v - \theta = 0 \quad (۸۹-۳)$$

$$\frac{\partial \mathcal{L}}{\partial \xi} = (C + \Delta C)\mathbf{1} - u - \eta - \alpha = 0 \quad (۹۰-۳)$$

$$\frac{\partial \mathcal{L}}{\partial b_g} = C\mathbf{1}^\top Y A \mathbf{1} - \eta^\top Y A \mathbf{1} - \alpha^\top Y A \mathbf{1} - \theta^\top Z \mathbf{1} = 0 \quad (۹۱-۳)$$

$$\frac{\partial \mathcal{L}}{\partial \beta} = C_g L \beta + C L A^\top Y \mathbf{1} - L A^\top Y \eta - L A^\top Y \alpha - L Z^\top \theta = 0 \quad (۹۲-۳)$$

$$\frac{\partial \mathcal{L}}{\partial b} = \alpha^\top Y \mathbf{1} = 0 \quad (۹۳-۳)$$

^۱Lagrangian

^۲Primal Problem

$$\frac{\partial \mathcal{L}}{\partial \gamma} = K\gamma - KY\alpha = 0 \quad (94-3)$$

بناباه فرض هردو L^{-1} و K^{-1} وجود دارند. در نتیجه

$$v + \theta = C_v B^T \mathbf{1} \quad (95-3)$$

$$u + \eta + \alpha = (C + \Delta C) \mathbf{1} \quad (96-3)$$

$$\mathbf{1}^T A^T Y(\eta + \alpha) + \mathbf{1}^T Z\theta = C \mathbf{1}^T Y A^T \mathbf{1} \quad (97-3)$$

$$C_g \beta = A^T Y(\eta + \alpha - C \mathbf{1}) + Z\theta \quad (98-3)$$

$$\alpha^T Y \mathbf{1} = 0 \quad (99-3)$$

$$\gamma = Y\alpha \quad (100-3)$$

بنابراین تابع هدف دوگان برابر است با:

$$\min_{\gamma, b, \beta, b_g, \xi, \zeta} \mathcal{L}(\gamma, b, \beta, b_g, \xi, \zeta; u, v, \eta, \alpha, \theta) \quad (101-3)$$

$$= -\frac{1}{2} \alpha^T Y K Y \alpha \quad (102-3)$$

$$- \frac{1}{2C_g} \left(A^T Y(\eta + \alpha - C \mathbf{1}) + Z\theta \right)^T L \left(L A^T Y(\eta + \alpha - C \mathbf{1}) + L Z\theta \right) \quad (103-3)$$

مسئله بهینه سازی دوگان برابر است با:

$$\max_{u, v, \eta, \alpha, \theta} -\frac{1}{2} \alpha^T Y K Y \alpha - \frac{1}{2C_g} \left(A^T Y(\eta + \alpha - C \mathbf{1}) + Z\theta \right)^T L \left(L A^T Y(\eta + \alpha - C \mathbf{1}) + L Z\theta \right) \quad (104-3)$$

$$\mathbf{s.t.} \quad u, v, \eta, \alpha, \theta \geq 0 \quad (105-3)$$

$$\alpha^T Y \mathbf{1} = 0 \quad (106-3)$$

$$(\eta + \alpha)^T Y A \mathbf{1} + \theta^T Z \mathbf{1} = C \mathbf{1}^T Y A \mathbf{1} \quad (107-3)$$

$$v + \theta = C_v B^T \mathbf{1} \quad (۱۰۸-۳)$$

$$u + \eta + \alpha = (C + \Delta C) \mathbf{1} \quad (۱۰۹-۳)$$

این مسئله معادل است با:

$$\max_{\eta, \alpha, \theta} -\frac{1}{2} \alpha^T Y K Y \alpha - \frac{1}{2C_g} \left(A^T Y (\eta + \alpha - C \mathbf{1}) + Z \theta \right)^T L \left(L A^T Y (\eta + \alpha - C \mathbf{1}) + L Z \theta \right) \quad (۱۱۰-۳)$$

$$\text{s.t.} \quad \eta, \alpha, \theta \geq 0 \quad (۱۱۱-۳)$$

$$\alpha^T Y \mathbf{1} = 0 \quad (۱۱۲-۳)$$

$$\mathbf{1}^T A^T Y (\eta + \alpha) + \mathbf{1}^T Z^T \theta = C \mathbf{1}^T A^T Y \mathbf{1} \quad (۱۱۳-۳)$$

$$\theta \geq C_v B^T \mathbf{1} \quad (۱۱۴-۳)$$

$$\eta + \alpha \geq (C + \Delta C) \mathbf{1} \quad (۱۱۵-۳)$$

□

به دلیل پیچیدگی این روش بهتر است از روش بسیار ساده نزدیکی به مرکز که باعث کاهش فضای نسخه می شود، برای یادگیری فعال استفاده کنیم. با حل مسئله بالا، دو تابع $f(P_i)$ و $g(P_i, x_{ij})$ را داریم. برای یادگیری فعال برای برجسب نقاط داده در هر نمونه برداشته شده داریم:

$$(i, j) = \arg \min_{i, j} |g(P_i, x_{ij})|$$

و برای پرس وجو برجسب توزیع ها از تابع هدف ذیل استفاده می کنیم:

$$P_q = \arg \min_{P_i} |f(P_i)|$$

۴.۱.۳ یادگیری فعال بیشینه-کمینه احتمالاتی

مقدمه

در یادگیری فعال روی توزیع به توزیع ها دسترسی مستقیم نداریم بلکه به هر توزیع از طریق یک نمونه برداشته شده از آن دسترسی داریم. بنابراین مشابه یادگیری مقاوم، هر تخمین از مثال نادقیق است. این موضوع چالش مثال های نادقیق را به مسئله پرچالش یادگیری فعال اضافه می کند. برای حل این چالش ها، یک حد بالا برای ریسک طبقه بند در مرحله بعدی یادگیری فعال که مثالهای برجسب دار بیشتر می شوند، ارائه می کنیم. براساس این حدبالا، به منظور مواجهه با چالش های موجود در یادگیری فعال مقاوم، روش یادگیری فعال بیشینه-کمینه احتمالاتی^۱ را ارائه می کنیم و ثابت می کنیم که این الگوریتم مثالی را انتخاب می کند که دانش برجسب آن، ریسک را کمینه می کند. متاسفانه محاسبه این تابع هدف برای مسئله یادگیری فعال مقاوم رام نشدنی^۲ است. بنابراین تخمین کارآمدی از تابع هدف ارائه می دهیم. به منظور بهره برداری بیشتر از اطلاعات موجود در مورد تخمین توزیع ها، یک روش یادگیری فعال مقاوم براساس یادگیری بیزی نهفته سازی کرنلی توزیع ها ارائه می کنیم. آ

در یادگیری روی توزیع مثالها دارای عدم قطعیت ذاتی هستند. هر مثال، با استفاده از نمونه ای با اندازه محدود تخمین زده می شود. بخوبی روشن است که تخمین توزیع از روی نمونه با اندازه محدود دارای عدم قطعیت است. بنابراین نیاز داریم روشی ارائه کنیم که در برابر عدم دقت در مثالها مقاوم باشد. مقاوم بودن در یادگیری فعال بسیار چالش برانگیزتر است زیرا منبع عدم قطعیت دیگری که همان مجهول بودن برجسب بسیاری از نقاط است اضافه می شود.

برای حل این مشکل با یک رویکرد اصولی، ابتدا مسئله یادگیری فعال را در کلی ترین شکل در نظر می گیریم. به این منظور یک حدبالا روی ریسک طبقه بند در مرحله بعدی یادگیری فعال که داده های پرس وجو به داده های برجسب دار افزوده شده ارائه میکنیم. این حدبالای ریسک پیش از تعیین برجسب داده های پرس وجو ارائه می شود. سپس مثالهایی پرس وجو می شود که انتخاب آنها، این حدبالا را کمینه کند. ما روش حاصل را یادگیری فعال بیشینه-کمینه احتمالاتی می نامیم. PMAL می تواند در رویکرد بیزی^۳ بکار رود.

¹Probabilistic Minimax Active Learning³Bayesian²Intractable

جدول ۱.۳: جدول نمادهای مربوط به یادگیری بیشینه-کمینه احتمالاتی

(X, Y)	متغیرهای تصادفی در $\mathbb{R}^d \times \{-1, 1\}$
n	تعداد مثالها،
l	تعداد مثالهای برچسب دار
$\mathcal{L} = \{1, \dots, l\}$	مجموعه اندیس های داده های برچسب دار
$\mathcal{L}q = \{1, \dots, l, q\}$	مجموعه اندیس های داده های برچسب دار بعلاوه پرس و جو
$\mathcal{U} = \{l + 1, \dots, n\}$	مجموعه اندیس های داده های بدون برچسب
$\mathcal{D} = \{(x_1, y_1), \dots, (x_n, y_n)\}$	مجموعه داده های برچسب دار و بدون برچسب
$\mathcal{D}_l = \{(x_i, y_i) i \in \mathcal{L}\}$	مجموعه داده های برچسب دار
$\mathcal{D}_u = \{(x_i, y_i) i \in \mathcal{U}\}$	مجموعه داده های بدون برچسب
$\mathbf{x}_{\mathcal{L}} = (x_1, \dots, x_l)$ $\mathbf{y}_{\mathcal{L}} = (y_1, \dots, y_l)$	لیست مرتب شده از داده های بدون برچسب و برچسب آنها
$\mathbf{x}_{\mathcal{U}} = (x_{l+1}, \dots, x_n)$ $\mathbf{y}_{\mathcal{U}} = (y_{l+1}, \dots, y_n)$	لیست مرتب داده های بدون برچسب و برچسب های مجهول آنها
$\mathbf{x} = \mathbf{x}_{\mathcal{LU}} = (x_1, \dots, x_n)$ $\mathbf{y} = \mathbf{y}_{\mathcal{LU}} = (y_1, \dots, y_n)$	لیست مرتب مثالها و برچسب های آنها

روش پیشنهادی

مثال ها را به شکل حروف کوچک نشان می دهیم و حروف کوچک پررنگ لیست مرتب مثالها را نشان می دهند مانند

$\mathbf{x} = (x_1, \dots, x_n)$ یا برچسب آنها $\mathbf{y} = (y_1, \dots, y_n)$. برای اختصار نمادها در جدول ۲.۳ آمده اند.

چنانکه قبلا اشاره شد، تخمین دقیقی از توزیع ها وجود ندارد. این چنین شرایطی مشابه یادگیری مقاوم است اما همچنین از این جهت با آن متفاوت است که اطلاعات خاصی در مورد تخمین توزیع ها با استفاده نمونه ها در اختیار داریم که می توان از آنها بهره ببریم.

برای بهره برداری موثر از این اطلاعات ابتدا رویکرد یادگیری فعال بیشینه-کمینه احتمالاتی یا PMAL را در بخش ۶.۱.۳ معرفی می کنیم. با استفاده از PMAL می توانیم به عدم قطعیت در یادگیری فعال یا همان یادگیری فعال مقاوم بصورتی مبتنی بر اصول پیردازیم. اگرچه در بخش های بعدی به یادگیری فعال مقاوم روی فضای ورودی نمی پردازیم، در ۳.۳.۳ الگوریتمی برای یادگیری فعال مقاوم در فضای ورودی ارائه می کنیم. این مسئله مبانی یادگیری فعال مقاوم در توزیع را به خواننده ارائه می کند، تا وی براحتمی بتواند تفاوت این دو را درک کند. بعلاوه در ۳.۳.۳ یک فرم ساده تر از یادگیری فعال مقاوم روی توزیع ارائه می کنیم. در ۴.۳.۳ به هدف اصلی این فصل که یادگیری فعال مقاوم روی توزیع است می پردازیم. در ادامه ابتدا تعاریف و پیش نیازهای

بخش ۳.۳.۳ بررسی می شود.

پیش زمینه و تعاریف

تعریف ۴.۱.۳. تابع تصمیم بیز و ریسک بیز [۳۰]

فرض کنید $\eta^*(x, y)$ تابع توزیع (مجهول) برچسب ها به فرض مثال ها یعنی

$$\eta^*(x, y) = \mathbf{P}(Y = y | X = x) \quad (۱۱۶-۳)$$

باشد. طبقه بند بهینه یا تابع تصمیم بهینه بیز $g^*(x)$ و ریسک بیز بترتیب عبارتند از

$$g^*(x) = \arg \max_{y \in \mathcal{C}} \{\eta^*(x, y)\}, \quad L^* = \mathbf{P}(g^*(X) \neq Y) \quad (۱۱۷-۳)$$

تعریف ۵.۱.۳. طبقه بند الحاقی و ریسک آن

فرض کنید y برچسب نقطه x باشد، تابع طبقه بند $g^{\mathcal{D}}(x)$ که آنرا طبقه بند الحاقی^۱ با استفاده از مجموعه $\mathcal{D}$ نیز می نامیم،

را در نظر بگیرید. ریسک این طبقه بند برابر است با $L^{\mathcal{D}} = \mathbf{P}\{g^{\mathcal{D}}(X) \neq Y | \mathcal{D}\}$ [۳۰].

روشن است که

$$\begin{aligned} L^{\mathcal{D}} &= 1 - \mathbf{P}\{g^{\mathcal{D}}(X) = Y | \mathcal{D}\} \\ &= 1 - \sum_{y \in \mathcal{C}} \mathbf{P}\{g^{\mathcal{D}}(X) = y, Y = y | \mathcal{D}\} \\ &= 1 - \sum_{y \in \mathcal{C}} \int_{\mathbb{R}^d} I_{[g^{\mathcal{D}}(x)=y]} \mathbf{P}\{Y = y | \mathcal{D}, X = x\} \mu(dx) \end{aligned}$$

کمیت $\mathbf{P}\{Y = y | \mathcal{D}, X = x\}$ را به عنوان η ، $\eta^{\mathcal{D}}$ برابر با

$$\eta(x, y; \mathbf{x}_{\mathcal{D}}, \mathbf{y}_{\mathcal{D}}) \equiv \eta^{\mathcal{D}}(x, y) := \mathbf{P}\{Y = y | \mathcal{D}, X = x\} \quad (۱۱۸-۳)$$

تعریف می کنیم.

همچنین قرار دهیم: $\mathcal{A}(x, \mathcal{D}) := \max_{y \in \mathcal{C}} \{\eta^*(x, y) - \eta(x, y; \mathbf{x}_{\mathcal{D}}, \mathbf{y}_{\mathcal{D}})\}$

^۱plug-in

به منظور کمینه سازی ریسک، طبقه بند الحاقی g^D برابر است با $g^D(x) = \arg \max_{y \in \mathcal{C}} \{\eta(x, y; \mathbf{x}_D, \mathbf{y}_D)\}$ [۱۹].

به منظور رسیدن به طبقه بند بهینه در طبقه بند الحاقی، تابع η می بایست بتواند تخمین مناسبی از احتمال شرطی y به شرط x بزند. عبارت دیگر، برای کمینه سازی ریسک، تابع η باید تقریباً برابر تابع η^* در (x, y) با استفاده از داده $(\mathbf{x}, \mathbf{y})$ به عنوان پارامتر باشد. در واقع بسیار اساسی است که نوعی فرض داشته باشیم که معیار توزیع، تابع توزیع احتمال تخمین برچسب نسبت به داده η و تابع توزیع احتمال برچسب نسبت به داده واقعی η^* را به هم مرتبط کند. بدون چنین فرضی، یادگیری غیرممکن است. این درواقع به این معنی است که فرایند تولید داده را به فرایند انتساب برچسب مرتبط می کند تا بتوانیم از وجود داده های بدون برچسب استفاده بهینه کنیم [۱۲۲]. Tsybakov از فرض ذیل به این منظور استفاده کرد. این فرض برای انواع تخمین زن ها و انواع توزیع های داده $\mathcal{P}$ ، صادق است [۲]، [۳۰].

فرض ۱.۱.۳. فرض کنید η^D یک تخمین زن تابع η^* با استفاده از داده $\mathcal{D}$ است و $\mathcal{P}$ یک کلاس توزیع های احتمال روی (X, Y) بنحوی است که برای ثابت هایی مانند $C_1 > 0, C_2 > 0$ و سری مثبتی مانند a_n تقریباً برای همه x ها نسبت به P_X داریم:

$$\sup_{P \in \mathcal{P}} P\{\mathcal{A}(x, \mathcal{D}) \geq \delta\} \leq C_1 \exp(-C_2 a_n \delta^2)$$

لم ۱.۱.۳. فرض کنید داده های بدون برچسب در کاهش ریسک طبقه بند روی $\mathcal{P}$ کمک کنند. با فرض ۱.۱.۳ آنگاه، $\exists c_U > 1$ بنحویکه با احتمال $1 - C_1 \exp(-C_2 a_n \delta^2)$ ، داریم:

$$\int_{\mathbb{R}^d} \mathcal{A}(X, \mathcal{D}) \mu(dx) \leq c_U^{-1} \int_{\mathbb{R}^d} \mathcal{A}(X, \mathcal{L}) \mu(dx) + 2\delta$$

برهان. ریسک طبقه بندهای $g^D(x)$ و $g^L(x)$ $\forall P \in \mathcal{P}$ برابر است با

$$\begin{aligned} L^D - L^* &\leq \int_{\mathbb{R}^d} \mathcal{A}(x, \mathcal{D}) \mu(dx) \\ L^L - L^* &\leq \int_{\mathbb{R}^d} \mathcal{A}(x, \mathcal{L}) \mu(dx) \end{aligned} \quad (۱۱۹-۳)$$

که در آن $\mu \in \mathcal{P}$. چون ما فرض می کنیم که داده های بدون برچسب ریسک طبقه بند را برای توزیع $\mathcal{P}$ کاهش می دهند،

بنابراین برای همه $(\mu, \eta) \in \mathcal{P}$ داریم:

$$\min_{\mathcal{U}} \int_{\mathbb{R}^d} \mathcal{A}(x, \mathcal{D}) \mu(dx) < \int_{\mathbb{R}^d} \mathcal{A}(x, \mathcal{L}) \mu(dx) \quad (۱۲۰-۳)$$

براساس فرض ۱.۱.۳ و شرایط رگولاریزاسیون داریم:

$$\sup_{P \in \mathcal{P}} P \left\{ \int_{\mathbb{R}^d} \mathcal{A}(x, \mathcal{D}) \mu(dx) \leq \delta \right\} \geq 1 - C_1 \exp(-C_2 a_n \delta^2)$$

بنابراین، با احتمال بالا، داریم:

$$\begin{aligned} & \int_{\mathbb{R}^d} \max_y \min_{\mathcal{U}} \{ \eta^*(x, y) - \eta(x, y; \mathbf{x}, \mathbf{y}) \} \mu(dx) \\ & \leq \min_{\mathcal{U}} \int_{\mathbb{R}^d} \mathcal{A}(x, \mathcal{D}) \mu(dx) + 2\delta \end{aligned} \quad (۱۲۱-۳)$$

با استفاده از رابطه (۱۲۱-۳) در (۱۲۰-۳) با احتمال $1 - C_1 \exp(-C_2 a_n \delta^2)$ خواهیم داشت:

$$\int_{\mathbb{R}^d} \mathcal{A}(x, \mathcal{D}) \mu(dx) < \int_{\mathbb{R}^d} \mathcal{A}(x, \mathcal{L}) \mu(dx) + 2\delta$$

□

یادگیری فعال بیشینه-کمینه احتمالاتی

در هر مرحله از یادگیری فعال دوست داریم مثالهایی را انتخاب کنیم که دانستن برچسب آنها، به ساختن یک مدل دقیق کمک کند. آرزوی ما این است که مدل جاری بتواند برچسب تقریباً همه نقاط داده های بدون برچسب را پیش بینی کند. ما این برچسب ها را بهترین برچسب ها برای مدل جاری می نامیم. اما بهرحال، بدترین شرایط وقتی است که با فرض مدل جاری، احتمال برچسب معکوس برای یک مثال بزرگ است. در اینجا منظور از برچسب معکوس برچسبی مخالف برچسب پیش بینی شده توسط مدل جاری است.

بدلیل عدم وجود اطلاعات در مورد برچسب یک مثال بدون برچسب تا قبل از پرس و جو از کاربر، لازم است که آماده بدترین شرایط برای برچسب نقطه پرس و جو باشیم. همزمان باید امیدوار باشیم که برچسب برخی مثالهای بدون برچسب دارای بهترین برچسب، برچسب پیش بینی شده توسط مدل، باشند. توجه کنید که ما یک مدل ساده را به یک مدل پیچیده ترجیح می دهیم.

بنابراین برای داده های بدون برچسب به جز نقطه ای که قرار است پرس و جو کنیم، انتظار داریم که بهترین برچسب رخ بدهد زیرا فرض می کنیم که مدل جاری ساده تر از مدل های مراحل بعدی در یادگیری فعال است که در آنجا تعداد مثالهای برچسب دار افزایش پیدا می کند. بنابراین شعار این رویکرد، برای بدترین شرایط آماده باش و انتظار بهترین شرایط را داشته باش^۱ گذاشته ایم.

در یک مرحله از یادگیری فعال، تنها زیرمجموعه $\mathcal{D}_L$ برای آموزش استفاده می شود و برچسب داده های بدون برچسب، $y_i, i \in \mathcal{U}$ مجهول است. پرسش این است که حتی اگر برچسب یک مثال را ندانیم چه به سر دقت طبقه بند خواهد آمد اگر آنرا به داده های بدون برچسب اضافه کنیم؟ در هر مرحله از یادگیری فعال، فقط یک زیرمجموعه $\mathcal{D}_L$ برای آموزش استفاده می شود. روشن است که برچسب داده های بدون برچسب، $y_i, i \in \mathcal{U}$ مجهول است.

سؤال اساسی در اینجا این است که آیا می توانیم قبل از دریافت برچسب هر نقطه ای، بدانیم چه برسر دقت طبقه بند خواهد آمد، اگر یک مثال به داده های برچسب دار اضافه شود؟

قضیه ای که در ذیل ارائه می کنیم به این سؤال بصورت تئوریک پاسخ می دهد. قضیه ۸.۱.۳، حدبالایی برای ریسک طبقه بند در شرایط فوق الذکر ارائه می کند که غیرقابل بهبود است. به این معنا که قبل از داشتن داده های برچسب دار جدید نمی توانیم بیش از این در مورد طبقه بند در شرایط مطرح شده بدانیم.

اما قبل از ارائه این قضیه، لازم است در مورد ریسک طبقه بند چندکلاسه الحاقی بیش از این بدانیم. قضیه ۷.۱.۳ حدبالای ریسک برای طبقه بند چندکلاسی ارائه می کند. این حدبالای ریسک مبتنی بر هیچ گونه فرض اضافی در مورد توزیع داده ها، نیست.

قضیه ۷.۱.۳. فرض کنید $\mathcal{T}^D(x, y) = \eta^*(x, y) - \eta^D(x, y)$. آنگاه داریم:

$$L^D - L^* \leq \sum_{i=1}^{|\mathcal{C}|} E|\mathcal{T}^D(X, c_i)| \leq |\mathcal{C}| \max_{y \in \mathcal{C}} E|\mathcal{T}^D(X, y)| \quad (۱۲۲-۳)$$

برهان. با استفاده از تعاریف ارائه شده در بخش ۵.۱.۳ داریم:

$$\eta(X, c) = E(I_{\{Y=c\}} | X)$$

ریسک طبقه بند g^D برابر است با

$$\begin{aligned} L^D &= \sum_{y \in \mathcal{C}} E(I_{\{g^D(X) \neq y, Y=y\}}) \\ &= \sum_{y \in \mathcal{C}} \sum_{c \in \mathcal{C} - \{y\}} E(E(I_{\{g^D(X)=c\}} I_{\{Y=y\}} \mid X)) \\ &= \sum_{y \in \mathcal{C}} \sum_{c \in \mathcal{C} - \{y\}} E(I_{\{c = \arg \max_z \eta^D(X, z)\}} \eta^*(X, y)) \end{aligned} \quad (۱۲۳-۳)$$

به همین ترتیب، براحتی می توانیم بدست آوریم که:

$$L^* = \sum_{y \in \mathcal{C}} \sum_{c \in \mathcal{C} - \{y\}} E(I_{\{c = \arg \max_z \eta^*(X, z)\}} \eta^*(X, y)) \quad (۱۲۴-۳)$$

مجموعه $A_\eta(c) := \{c = \arg \max_z \eta^D(X, z)\}$ می تواند به عنوان

$$A_\eta(c) = \cup_{i=1}^{|\mathcal{C}|} B(c, c_i)$$

که در آن B با استفاده از η^* تعریف شده است:

$$B(c, c') = \{c = \arg \max_z \eta^D(X, z), c' = \arg \max_z \eta^*(X, z)\}$$

$$E(c, c') = \{\{c, c'\} = \{\arg \max_z \eta(X, z), \arg \max_z \eta^*(X, z)\}\}$$

به همین ترتیب، مجموعه $A_{\eta^*}(c) := \{c = \arg \max_z \eta^*(X, z)\}$ می تواند بصورت

$$A_{\eta^*}(c) = \cup_{i=1}^{|\mathcal{C}|} B(c_i, c)$$

نوشته شود. با استفاده از این مجموعه ها، داریم:

$$E\{I_{A_\eta(c)} \eta^*(X, y)\} = \sum_{t \in \mathcal{C}} E(I_{B(c, t)} \eta^*(X, y))$$

$$E\{I_{A_{\eta^*}(c)} \eta^*(X, y)\} = \sum_{t \in \mathcal{C}} E(I_{B(t, c)} \eta^*(X, y))$$

برای محاسبه $L^D - L^*$ با حذف جملات برابر در عبارت ذیل، خواهیم داشت:

$$\begin{aligned} & \sum_{c \in \mathcal{C} - \{y\}} \left(E\{I_{A_{\eta}(c)} \eta^*(X, y)\} - E\{I_{A_{\eta^*}(c)} \eta^*(X, y)\} \right) \\ &= \sum_{c \in \mathcal{C} - \{y\}} \left(E\{I_{B(c, y)} \eta^*(X, y)\} - E\{I_{B(y, c)} \eta^*(X, y)\} \right) \end{aligned} \quad (۱۲۵-۳)$$

با استفاده از (۱۲۳-۳)، (۱۲۴-۳) و (۱۲۵-۳) بدست می آید که

$$\begin{aligned} L^D - L^* &= \sum_{i=1}^{|\mathcal{C}|-1} \sum_{j=i+1}^{|\mathcal{C}|} \left(E(I_{B(c_j, c_i)} (\eta^*(X, c_i) - \eta^*(X, c_j))) \right. \\ &\quad \left. + E(I_{B(c_i, c_j)} (\eta^*(X, c_j) - \eta^*(X, c_i))) \right) \end{aligned} \quad (۱۲۶-۳)$$

در $B(c_j, c_i)$ داریم: $\eta(X, c_j) - \eta(X, c_i) \geq 0$. بطور مشابه در $B(c_i, c_j)$ خواهیم داشت: $\eta(X, c_i) - \eta(X, c_j) \geq 0$.

افزودن این جملات به سمت راست رابطه (۱۲۶-۳) و تغییر ترتیب عبارات، خواهیم داشت:

$$\begin{aligned} L^D - L^* &\leq \sum_{i=1, j=i+1}^{|\mathcal{C}|-1, |\mathcal{C}|} E(I_{E(c_j, c_i)} (|\mathcal{T}^D(X, c_i)| + |\mathcal{T}^D(X, c_j)|)) \\ &\leq \sum_{i=1}^{|\mathcal{C}|} \left(E(|\mathcal{T}^D(X, c_i)|) \right) \end{aligned}$$

□

اکنون که اثبات این قضیه را ارائه کردیم، می توانیم به ارائه قضیه ذیل برای حدبالای طبقه بند الحاقی با فرض هر برچسبی برای داده های پرس وجو بپردازیم. این قضیه حدبالایی برای ریسک طبقه بند الحاقی آموزش داده شده روی داده های برچسب دار بعلاوه هر برچسبی روی داده های بدون برچسب ارائه می کند:

قضیه ۸.۱.۳. در صورتیکه فرض های لم ۶.۱.۳ برقرار باشد، قرار بدهید:

$$\Delta_{\mathcal{L}} \equiv \zeta \int_{\mathbb{R}^d} \max_{y \in \mathcal{C}} \{ \eta^*(x, y) - \eta(x, y; \mathbf{x}, \mathbf{y}) \} \mu(dx)$$

و $\beta = 1 - c_{\mathcal{U}}^{-1}$. آنگاه با احتمال $1 - C_1 \exp(-C_2 a_n \delta^2)$ حدبالای ریسک طبقه بند آموزش دیده با استفاده از برچسب دار

بعلاوه پرس و جوی Q ، $L^{\mathcal{L}Q}$ ، برابر است با

$$L^{\mathcal{L}Q} - L^* \leq \beta \Delta_{\mathcal{L}} + 2\zeta\delta + \zeta\alpha(1 - c_0 \min_{\mathbf{y}_Q} \max_{\mathbf{y}_U} \mathbf{P}(\mathbf{y}|\mathbf{x})) E_{\eta}$$

که در آن

$$E_{\eta} = \mathbf{E}(\max_{y \in \mathcal{C}} \eta(X, y; \mathbf{x}_{\mathcal{L}}, \mathbf{y}_{\mathcal{L}})),$$

$\alpha > 0$ ، $c_0 > 1$ و $\zeta \geq 2$ ثابت هایی مستقل از داده ها هستند.

برهان. فرض کنید که g طبقه بند آموزش دیده با استفاده از داده های $\mathbf{x}, \mathbf{y}$ باشد. با استفاده از قضیه ۷.۱.۳ و $|a| =$

$\max\{a, -a\}$ ، خواهیم داشت:

$$\begin{aligned} L^{\mathcal{D}} - L^* &\leq |\mathcal{C}| \max_{y \in \mathcal{C}} E|\mathcal{T}^{\mathcal{D}}(X, y)| \\ &= \int_{\mathbb{R}^d} |\mathcal{C}| \max_{y \in \mathcal{C}} \max\{\mathcal{T}^{\mathcal{D}}(x, y), -\mathcal{T}^{\mathcal{D}}(x, y)\} \mu(dx) \end{aligned} \quad (۱۲۷-۳)$$

آنگاه چون

$$\begin{aligned} \eta^*(x, y) &= 1 - \sum_{c \in \{\mathcal{C} - \{y\}\}} \eta^*(x, c) \\ \eta^{\mathcal{D}}(x, y) &= 1 - \sum_{c \in \{\mathcal{C} - \{y\}\}} \eta^{\mathcal{D}}(x, c) \end{aligned}$$

خواهیم داشت:

$$\max_{y \in \mathcal{C}} \{-\mathcal{T}^{\mathcal{D}}(x, y)\} = \max_{y \in \mathcal{C}} \sum_{c \in \{\mathcal{C} - \{y\}\}} (\mathcal{T}^{\mathcal{D}}(x, c))$$

بنابراین

$$\max_{y \in \mathcal{C}} \{-\mathcal{T}^{\mathcal{D}}(x, y)\} \leq |\mathcal{C}| \max_{y \in \mathcal{C}} \{\mathcal{T}^{\mathcal{D}}(x, y)\} = |\mathcal{C}| \mathcal{A}(x, \mathcal{D}) \quad (۱۲۸-۳)$$

قراردادن (۱۲۸-۳) در عبارت (۱۲۷-۳) به این نتیجه می‌رسیم که $\exists \zeta \geq 2$ ، بنحویکه

$$L^{\mathcal{D}} - L^* \leq \zeta \int_{\mathbb{R}^d} \mathcal{A}(x, \mathcal{D}) \mu(dx) \equiv \Delta_{\mathcal{L}} \quad (۱۲۹-۳)$$

با فرض اینکه داده‌های بدون برچسب $\mathcal{Y}_{\mathcal{U}}$ ریسک طبقه‌بند را برای توزیع $(\mu, \eta) \in \mathcal{P}$ افزایش نمی‌دهند، بنابراین کمینه‌کردن حدبالای ریسک روی $\mathcal{Y}_{\mathcal{U}}$ ، نتیجه می‌دهد:

$$\begin{aligned} L^{\mathcal{D}} - L^* &\leq \zeta \min_{\mathcal{Y}_{\mathcal{U}}} \int_{\mathbb{R}^d} \mathcal{A}(x, \mathcal{D}) \mu(dx) \\ &= \zeta \int_{\mathbb{R}^d} \max_{y \in \mathcal{C}} \{ \eta^*(x, y) - \max_{\mathcal{Y}_{\mathcal{U}}} \eta(x, y; \mathbf{x}, \mathbf{y}) \} \mu(dx) \end{aligned} \quad (۱۳۰-۳)$$

که آخرین تساوی به دلیل این است که کمیت $\eta^*(x, y) - \eta(x, y; \mathbf{x}, \mathbf{y})$ نسبت به y مقعر و نسبت به $\mathcal{Y}_{\mathcal{U}}$ محدب است. بدلیل اینکه $\mathcal{Y}_{\mathcal{Q}}$ هنوز مجهول است، لازم است که ریسک را در بدترین شرایط در نظر بگیریم. بدترین شرایط وقتی است که برچسب داده پرس و جو شده، تخمین جاری از ریسک را بیشینه می‌کند. حدبالای ریسک با استفاده از داده‌های برچسب دار، بدون برچسب و مثالهای پرس و جو شده، براساس (۱۳۰-۳) برابر است با

$$\begin{aligned} L^{\mathcal{D}} - L^* &\leq \zeta \int_{\mathbb{R}^d} \max_{y \in \mathcal{C}} \{ \eta^*(x, y) - \max_{\mathcal{Y}_{\mathcal{U}}} \eta(x, y; \mathbf{x}, \mathbf{y}) \} \mu(dx) \\ &\leq \zeta \int_{\mathbb{R}^d} \max_{y \in \mathcal{C}} \{ \eta^*(x, y) - \min_{\mathcal{Y}_{\mathcal{Q}}} \max_{\mathcal{Y}_{\mathcal{U}}} \eta^{\mathcal{D}}(x, y) \} \mu(dx) \end{aligned}$$

اکنون، این حدبالای ریسک را به ریسک طبقه‌بند آموزش داده شده فقط روی داده‌های بدون برچسب مرتبط می‌کنیم. فرض کنید $\beta = 1 - c_{\mathcal{U}}^{-1}$ ، با استفاده از لم ۶.۱.۳، نتیجه می‌شود که $\exists \alpha > 0$ ، بنحویکه با احتمال $1 - C_1 \exp(-C_2 a_n \delta^2)$ خواهیم داشت:

$$\begin{aligned} L^{\mathcal{D}} - L^* &\leq \zeta \int_{\mathbb{R}^d} \max_{y \in \mathcal{C}} \{ \eta^*(x, y) - \eta(x, y; \mathbf{x}_{\mathcal{L}}, \mathbf{y}_{\mathcal{L}}) \\ &\quad + \eta(x, y; \mathbf{x}_{\mathcal{L}}, \mathbf{y}_{\mathcal{L}}) - \min_{\mathcal{Y}_{\mathcal{Q}}} \max_{\mathcal{Y}_{\mathcal{U}}} \eta(x, y; \mathbf{x}, \mathbf{y}) \} \mu(dx) \\ &\leq \zeta \Delta_{\mathcal{L}} + \zeta \alpha \int_{\mathbb{R}^d} \max_{y \in \mathcal{C}} \{ \beta \eta(x, y; \mathbf{x}_{\mathcal{L}}, \mathbf{y}_{\mathcal{L}}) \\ &\quad - \min_{\mathcal{Y}_{\mathcal{Q}}} \max_{\mathcal{Y}_{\mathcal{U}}} \eta(x, y; \mathbf{x}, \mathbf{y}) \} \mu(dx) + 2\zeta \delta \end{aligned} \quad (۱۳۱-۳)$$

بنابه تعریف، داریم:

$$\begin{aligned}\eta(x, y; \mathbf{x}, \mathbf{y}) &= \frac{\mathbf{P}(y, \mathbf{y}|x, \mathbf{x})}{\mathbf{P}(\mathbf{y})} \\ &= \frac{\mathbf{P}(y, \mathbf{y}_{\mathcal{U}}|x, \mathbf{x}, \mathbf{y}_{\mathcal{LQ}})\mathbf{P}(\mathbf{y}_{\mathcal{LQ}})}{\mathbf{P}(\mathbf{y})} \\ &= \frac{\mathbf{P}(y|x, \mathbf{x}, \mathbf{y}_{\mathcal{LQ}})\mathbf{P}(\mathbf{y}_{\mathcal{U}}|x, y, \mathbf{x}, \mathbf{y}_{\mathcal{LQ}})\mathbf{P}(\mathbf{y}_{\mathcal{LQ}})}{\mathbf{P}(\mathbf{y})}\end{aligned}\quad (۱۳۲-۳)$$

با فرض استقلال y از $\mathbf{x}_{\mathcal{U}}$ و همچنین استقلال $\mathbf{y}_{\mathcal{U}}$ از y ، خواهیم داشت:

$$\begin{aligned}\eta(x, y; \mathbf{x}, \mathbf{y}) &= \frac{\mathbf{P}(y|x, \mathbf{x}_{\mathcal{LQ}}, \mathbf{y}_{\mathcal{LQ}})\mathbf{P}(\mathbf{y}_{\mathcal{U}}|x, \mathbf{x}, \mathbf{y}_{\mathcal{LQ}})\mathbf{P}(\mathbf{y}_{\mathcal{LQ}})}{\mathbf{P}(\mathbf{y})} \\ &= \frac{\mathbf{P}(y|x, \mathbf{x}_{\mathcal{LQ}}, \mathbf{y}_{\mathcal{LQ}})\mathbf{P}(\mathbf{y}_{\mathcal{U}}, \mathbf{y}_{\mathcal{LQ}}|x, \mathbf{x})}{\mathbf{P}(\mathbf{y})}\end{aligned}$$

فرض کنید $\mathbf{x}$ ، $(\mathbf{y}_{\mathcal{U}}, \mathbf{y}_{\mathcal{LQ}})$ مستقل از x باشد، داریم:

$$\begin{aligned}\eta(x, y; \mathbf{x}, \mathbf{y}) &= \frac{\mathbf{P}(y|x, \mathbf{x}_{\mathcal{LQ}}, \mathbf{y}_{\mathcal{LQ}})\mathbf{P}(\mathbf{y}_{\mathcal{U}}, \mathbf{y}_{\mathcal{LQ}}|\mathbf{x})}{\mathbf{P}(\mathbf{y})} \\ &= \frac{\eta(x, y; \mathbf{x}_{\mathcal{LQ}}, \mathbf{y}_{\mathcal{LQ}})\mathbf{P}(\mathbf{y}|\mathbf{x})}{\mathbf{P}(\mathbf{y})}\end{aligned}$$

بدلیل اینکه $0 < \mathbf{P}(\mathbf{y}) < 1$ ، می توانیم فرض کنیم که $\exists c_0 > 1$ ، بنحویکه

$$\eta(x, y; \mathbf{x}, \mathbf{y}) \geq c_0 \eta(x, y; \mathbf{x}_{\mathcal{LQ}}, \mathbf{y}_{\mathcal{LQ}})\mathbf{P}(\mathbf{y}|\mathbf{x}) \quad (۱۳۳-۳)$$

با استفاده از (۱۳۳-۳) در (۱۳۱-۳)، با احتمال $1 - C_1 \exp(-C_2 a_n \delta^2)$ داریم:

$$\begin{aligned}L^{\mathcal{LQ}} - L^* &\leq \beta \Delta_{\mathcal{L}} + 2\zeta \delta \\ &\quad + \zeta \alpha \int_{\mathbb{R}^d} \max_{y \in \mathcal{C}} \{ (1 - c_0 \min_{\mathbf{y}_{\mathcal{Q}}} \max_{\mathbf{y}_{\mathcal{U}}} \mathbf{P}(\mathbf{y}|\mathbf{x})) \times \\ &\quad \eta(x, y; \mathbf{x}_{\mathcal{L}}, \mathbf{y}_{\mathcal{L}}) \} \mu(dx) \\ &\leq \beta \Delta_{\mathcal{L}} + 2\zeta \delta \\ &\quad + \zeta \alpha (1 - c_0 \min_{\mathbf{y}_{\mathcal{Q}}} \max_{\mathbf{y}_{\mathcal{U}}} \mathbf{P}(\mathbf{y}|\mathbf{x})) E_{\eta}\end{aligned}$$

□

اکنون پرسش آنست که برچسب کدام مثالها بیشترین بهبود را در دقت طبقه بند ایجاد می کند؟ براساس قضیه فوق می توان گفت مثالهایی که حذبالای ریسک مورد انتظار برای طبقه بند آموزش داده شده با استفاده از داده های برچسب دار بعلاوه داده های پرس وجو را کمینه می کند.

نتیجه ۹.۱.۳. براساس قضیه ۸.۱.۳، بهترین پرس جو برای برچسب که ریسک مورد انتظار را کمینه می کند برابر است با

$$Q = \arg \max_{\{Q, |Q|=b\}} \min_{y_Q} \max_{y_U} P(y|x) \quad (۱۳۴-۳)$$

این قضیه اساسا بیان می کند که به منظور رسیدن به دقت های بالاتر، لازم است برچسب مثالهایی که صرفنظر از طبقه بند بیشترین بهبود را در دانش ما از احتمال شرطی برچسب به شرط مثال ها $P(Y|X)$. اگر این توزیع را بهتر بشناسیم، ساخت یک یادگیر برای آن راحتتر است. می دانیم که $\forall y_U, \forall y_Q$

$$\min_{y_Q} P(y|x) \leq \min_{y_Q} \max_{y_U} P(y|x) \leq \max_{y_U} P(y|x) \quad (۱۳۵-۳)$$

همزمان، می دانیم که با استفاده از همه دانش موجود، هنوز مثالهایی وجود دارند که احتمال برچسب آنها کم است. این اتفاق در نقاطی می افتد که انتظار داریم طبقه بندی اشتباه رخ بدهد [۱۱۱]. این موضوع ما را به تابع هدف (۱۳۴-۳) می رساند. در این حالت برای حصول به دقت های بالاتر باید روی مثالها/نواحی ای تمرکز کنیم که برچسب معکوس آنها با استفاده از همه دانش موجود بیشترین مقدار است. مقایسه (۱۳۴-۳) با (۱۳۵-۳) روشن می کند که نقاط انتخابی داده های بدون برچسب را به دو قسمت می کند.

هدف اصلی ما، ارائه یک روش برای یادگیری فعال روی داده های توزیعی است. چنانکه بعدا خواهیم دید، دسترسی به توزیع P_i از طریق نمونه $\{x_i^1, x_i^2, \dots, x_i^n\}$ است. بنابراین تخمین دقیق از P_i نداریم. به منظور توسعه روشی برای یادگیری فعال روی توزیع، این عدم دقت باید در هنگام انتخاب نقاط استفاده شود. به این منظور در بخش بعدی، ابتدا یک روش یادگیری فعال در فضای ورودی با خطای اندازه گیری ارائه می کنیم.

اگر اندازه دسته (b) کوچک باشد، می توانیم براحتی تابع هدف (۱۳۴-۳) را حل کنیم. اما اگر این اندازه بزرگ باشد، تقریب هایی مانند تقریب ارائه شده در [۴۷] یا تکنیک های اکتشافی می تواند استفاده شود.

در این بخش، یک رویکرد کلی و تئوریک یادگیری فعال ارائه کردیم. این رویکرد بویژه در شرایطی که عدم قطعیت در مثالها به همراه عدم قطعیت در مجهول بودن برچسب اکثریت مثالها وجود دارد، بسیار مفید است. وقتی مثالها نادقیق اند، نشان داده شد که در نظرگرفتن این عدم قطعیت در حین انتخاب نمونه ها در یادگیری فعال بسیار موثر است.

۲.۳ رویکرد تابعی به یادگیری فعال بیشینه کمینه احتمالاتی

یادگیری فعال با انتخاب نمونه برای پرس جوی برچسب آنها از داده های بدون برچسب برای یادگیری استفاده می کند. با انتخاب نمونه ها، روشهای یادگیری فعال تلاش می کنند به طبقه بندی با کمترین هزینه برچسب بسازند. در ابتدای فرایند یادگیری فعال، دانش موجود بسیار محدود است.

یادگیری فعال فرض می کند که سهم هر نقطه داده از این دانش محدود در همه نواحی داده یکسان نیست. انتخاب نقطه داده ها در نواحی با دانش بیشتر بسیار مفید تر است زیرا این نقاط باعث می شوند که هزینه برچسب زنی بسیار کاهش پیدا کند [۱۰۵، ۸۴]. هدف انتخاب نقاط به بیشترین میزان دانش و پرسش برچسب آنها است. این نقاط حاوی اطلاعات برای طبقه بند و نماینده سایر نقاط هستند. به عنوان معیاری حاوی اطلاعات بودن یا نماینده سایر نقاط بودن معمولاً یک طبقه بند روی داده های بدون برچسب آموزش داده می شود. تخمین طبقه بند معمولاً در الگوریتم هایی مانند SVM بصورت پارامتریک انجام می شود [۱۱۸، ۱۲۰]. این رویکردها کمبود دانش در یادگیری فعال را در نظر نمی گیرند.

وقتی میزان دانش محدود است، طبیعی تر است که تابعی پیدا کنیم که تقریباً تابع یادگیر را تخمین بزند. در واقع در چنین شرایطی انسانها معمولاً تلاش می کنند که یک قانون سرانگشتی بسازند و سپس با پرسیدن سئوالاتی ساده بررسی کنند آیا این قانون سرانگشتی به اندازه کافی در بدترین شرایط دقیق هست یا خیر. یک قانون سرانگشتی می تواند بصورت یک قانون یا تابع ساده که تقریباً داده های در اختیار را تخمین می زند، در نظر گرفته شود.

ممکن است از خود بپرسیم چگونه یک قانون سرانگشتی را در یک مسئله یادگیری مثلاً طبقه بندی انتخاب کنیم بویژه وقتی بخشی از برچسب داده نامعلوم است. جواب سراسر آنست که قانونی را انتخاب کنید که برای بدترین برچسب ها تحت مدل جاری خوب کار می کند و سپس پرس و جویی داشته باشیم تا دقت آن را چک کنیم. این مبنی استراتژی یادگیری فعال پیشنهادی است. رویکرد پیشنهادی به یک مدل پارامتریک وابسته نیست بلکه مبتنی بر فضایی از قوانین یا توابع ساده است. بعبارت دیگر،


یادگیری در فضای تابعی انجام می شود. برخلاف روشهای پارامتریک، رویکرد تابعی مسئله بهینه سازی را در فضای توابع و نه در فضای پارامترهای مدل فرموله می کند. هدف از روش جاری، توسعه یک رویکرد تابعی به یادگیری فعال است که قادر باشد هردو معیار حاوی اطلاعات بودن و نماینده نقاط بودن را در نظر بگیرد.

کار در این فضای تابعی می تواند چالش آفرین باشد. یک راه برای مواجهه با این چالش ها بهره بردن از روشهای گرادیان تابعی است. مشابه بهینه سازی مبتنی بر گرادیان تابع هدف، روشهای گرادیان تابعی در جهت گرادیان تابع هدف حرکت می کنند. اما برخلاف آن روشها که در آنها گرادیان یک بردار در فضای $\mathbb{R}^n$ از پارامترهای مدل است، در اینجا بردار گرادیان یک تابع است. این رویکرد گرادیان تابعی نامیده می شود [۴۲].

اکنون پرسش این است: چگونه یک روش یادگیری فعال با خصوصیات حاوی اطلاعات و نماینده سایر نقاط بودن در فضای تابعی توسعه بدهیم؟ هدف فصل جاری پیشنهاد یک روش برای پاسخ به این سؤال است. بر مبنای دانش ما، تاکنون روشی بر مبنای گرادیان تابعی که دو معیار حاوی اطلاعات بودن و نماینده سایر نقاط بودن را در نظر بگیرد، ارائه نشده است. رویکرد گرادیان تابعی عمیقاً به روشهای Ensemble و Boosting در ادبیات یادگیری ماشین مرتبط است [۴۲]. همه روشهای مبتنی بر Ensemble و Boosting در یادگیری فعال، صرفاً بر داشتن یک مجموعه متنوع از طبقه بندها برای حصول معیار حاوی اطلاعات بودن در یادگیری فعال تمرکز کرده اند [۸۱]. اگرچه روشهای یادگیری فعال مبتنی بر Boosting قبلاً ارائه شده اند [۱۱۷]، این روشها نماینده سایر نقاط بودن را در انتخاب نقاط در نظر نمی گیرند.

وقتی تعداد نقاط برچسب دار خیلی کم است، هردو معیار حاوی اطلاعات بودن و نماینده سایر نقاط بودن می تواند تخمین جاری از طبقه بند را بهبود بدهد. چالش البته این است که چگونه هردو معیار را در نظر بگیریم و توازن مناسب بین آنها را در رویکرد تابعی حفظ کنیم.

فصل جاری یک رویکرد گرادیان تابعی به یادگیری بیشینه-کمینه احتمالاتی پیشنهاد می کند. در فصل قبل ثابت کردیم که PMAL ریسک طبقه بند را در مرحله بعدی یادگیری فعال، کمینه می کند. با دارا بودن یک تابع هدف معنا دار، PMAL توازن بین دو معیار اصلی در انتخاب نقاط حفظ می کند. مهمتر اینکه، PMAL هردو معیار را در احتمال شرطی برچسب ها به شرط نقاط داده یکتا می کند. از دیدگاه دیگر، در هر مرحله از یادگیری فعال، PMAL داده های بدون برچسب را با استفاده از احتمال شرطی برچسب ها به شرط نقاط به دو نیمه تقسیم می کند.



شکل ۵.۳: رویکرد گرادیان تابعی به یادگیری بیشینه-کمینه احتمالاتی

فصل جاری یک فرم کلی و یک فرم خاص از الگوریتم را روی کلاس ساده ای از توابع معرفی می کند. الگوریتم کلی می تواند به نیازهای خاص یک دامنه از کاربردها تطبیق داده شود، در حالیکه الگوریتم خاص یک فرم ساده از الگوریتم است که به راحتی در دامنه بزرگی از کاربردها قابل استفاده است. جالب است که فرم خاص الگوریتم پیشنهاد شده ذاتا به فیلترینگ طیف مرتبط است. رویکرد پیشنهادی یادگیری فعال را به دو فیلد مهم پژوهش مرتبط می کند: فیلترینگ طیف و رویکرد گرادیان تابعی به یادگیری. این ارتباط می تواند برای ارائه الگوریتم های یادگیری فعال دیگر مورد کندو کاو قرار بگیرد. قالب کاری مبتنی بر گرادیان تابعی پیشنهاد شده پلت فرمی برای توسعه الگوریتم های یادگیری فعال بهتر طراحی شده برای کاربردهای متفاوت ارائه می کند. رویکرد پیشنهادی از جنبه دقت و سرعت در مسائل عمومی یادگیری فعال موثر است. آزمایشهای مفصل روی ۲۸ پایگاه داده نشان می دهد که رویکرد گرادیان تابعی پیشنهاد شده در انتخاب نقاط در کاربردهای مختلف کارآمد است.

رویکرد تابعی به یادگیری فعال

فرض کنید $\mathbf{y} = [y_1, y_2, \dots, y_n]^T$ and $\mathbf{x} = [x_1, x_2, \dots, x_n]^T$ در یک مرحله از یادگیری فعال، مجموعه ای از داده های برچسب دار $\mathcal{D}_{\mathcal{L}} = (\mathbf{x}_{\mathcal{L}}, \mathbf{y}_{\mathcal{L}})$ و یک مجموعه از داده های بدون برچسب $\mathcal{D}_{\mathcal{U}} = (\mathbf{x}_{\mathcal{U}}, \mathbf{y}_{\mathcal{U}})$ در اختیار داریم. بدون از دست

رفتن عمومیت، فرض کنید $\mathbf{x} = (\mathbf{x}_L, \mathbf{x}_U)$ و $\mathbf{y} = (\mathbf{y}_L, \mathbf{y}_U)$ که در آن $\mathbf{y}_U$ مجهول است.

به جای استفاده از یک مدل پارامتریک، در این فصل یک رویکرد تابعی بکار می‌بریم. تابع احتمال را بصورت $P(y_i|x_i, \mathbf{y}, \mathbf{x}, \Psi)$ فرض می‌کنیم که در آن Ψ یک تابع است. در هر تکرار، با استفاده از گرادیان تابعی، Ψ را تخمین می‌زنیم. تابع Ψ_m که یک تخمین از Ψ در تکرار m است، می‌تواند با جمع مجموعه‌ای از گام‌های گرادیان در جهت بهینه تخمین زده شود:

$$\Psi_m = \Psi_0 + \sum_{t=1}^m g_t \quad (۱۳۶-۳)$$

مشابه گرادیان در فضای پارامتر، هر $g_t, t \in [1, m]$ یک گام گرادیانی در فضای تابعی است که برابر است با:

$$g_m^* = E_{x,y}[\nabla_{\Psi} \log P(y|x, \mathbf{y}, \mathbf{x}, \Psi)|_{\Psi_{m-1}}] \quad (۱۳۷-۳)$$

خوشبختانه، گرادیان تابعی در نقاط داده می‌تواند بصورت ذیل محاسبه شود:

$$g_m(y_i, x_i) = \nabla_{\Psi} \log P(y_i|x_i, \mathbf{y}, \mathbf{x}, \Psi)|_{\Psi_{m-1}} \quad (۱۳۸-۳)$$

رویکرد گرادیان تابعی و داده‌های بدون برچسب

با دارا بودن داده‌های بدون برچسب، لازم است که برای هر برچسبی برای داده‌های بدون برچسب آماده باشیم. بنابراین برای تخمین گام گرادیان با استفاده از نزدیک‌ترین تابع در فضای کلاس توابع (۱۳۹-۳) تابعی از فضای کلاس توابع را انتخاب کنیم که کمترین فاصله با گرادیان در نقاط داده با بدترین برچسب برای داده‌های بدون برچسب را دارد:

$$\{a_m^*, \beta_m\} = \arg \min_{a, \beta} \max_{y_i, i \in \mathcal{D}_u} \sum_{i=1}^n [g_m(x_i, y_i) - \beta h(x_i; a)]^2 \quad (۱۳۹-۳)$$

اگر حل این مسئله بهینه‌سازی مشکل باشد، می‌توانیم روی داده‌های برچسب دار علاوه یک نقطه داده بدون برچسب j تابع هدف را کمینه کنیم. با این استراتژی، یک تابع ساده در هر تکرار از الگوریتم اضافه می‌شود. عبارت دیگر، در هر تکرار، عبارت ذیل را محاسبه می‌کنیم:

$$\{a_m^*, \beta_m\} = \arg \min_{a, \beta} \max_{y_j \in \{-1, 1\}} \sum_{i \in D_L \cup \{(x_j, y_j)\}} [g_m(x_i, y_i) - \beta h(x_i; a)]^2 \quad (۱۴۰-۳)$$

در برخی شرایط ممکن است که یک مثال را از داده‌های بدون برچسب حذف کنیم تا نتیجه را بیشتر به داده‌های بدون برچسب

وابسته کنیم. در هر تکرار m تابع Ψ برابر خواهد بود با:

$$\begin{aligned}\Psi_m &= \Psi_{m-1} + \beta_m^* h_m \\ h_m(x_i) &= h(x_i; a_m^*)\end{aligned}\quad (۱۴۱-۳)$$

الگوریتم کامل را در الگوریتم (۱) ملاحظه می کنید. چنانکه در مراحل (۳)-(۸)، دیده می شود رویکرد پیشنهادی $P(y_i|x_i, \mathbf{y}, \mathbf{x}, \Psi_m)$ را با رویکرد تابعی در هرگام محاسبه می کند. گام (۱۰) پرس و جو را محاسبه می کند. توجه داشته باشید که این الگوریتم کلی است. اغلب یک فرم خاص برای $P(y_i|x_i, \mathbf{y}, \mathbf{x}, \Psi)$ براساس داده های در دست در اختیار داریم. برای مثال، بخش بعد یک توزیع نرمال برای $P(y_i|x_i, \mathbf{y}, \mathbf{x}, \Psi)$ در نظر می گیرد. برای محاسبه گرادیان تابع $P(y_i|x_i, \mathbf{y}, \mathbf{x}, \Psi)$ نسبت به Ψ می توان از احتمال شرطی برچسب ها نسبت به مثالها استفاده کرد. در بخش بعدی یک الگوریتم ساده براساس الگوریتم (۱) ارائه می کنیم.

Algorithm 1 General Functional Gradient Probabilistic Active Learning

```

1: procedure GFPG Active Learning( $K, y_l, \Psi_{m_0}, m_l$ )
2:    $m \leftarrow m_0 + 1$ 
3:   while  $m \leq m_0 + m_l$  or  $\|\Psi_m - \Psi_{m-1}\| > \delta$  do
4:      $g_m(y_i, x_i) = \nabla_{\Psi} \log p(y_i|x_i, \mathbf{y}, \mathbf{x}, \Psi)|_{\Psi_{m-1}}, \forall i \in [1, n]$ 
5:     Compute  $a_m^*, \beta_m^*$  using (3-139) or (3-140).
6:      $\Psi_m = \Psi_{m-1} + \beta_m^* h(., .; a_m^*)$ 
7:      $m \leftarrow m + 1$ 
8:   end while
9:    $q \leftarrow \arg \max_q \min_{y_q} \max_{y_{\bar{q}}} \prod_{i=1}^n P(y_i|x_i, \mathbf{y}, \mathbf{x}, \Psi_m)$ 
10:  return  $q, \Psi_m(x)$  ▷ Query instance  $x_q$ 
11: end procedure

```

رویکرد بیشینه-کمینه به یادگیری فعال در مدل L_2 Boost

این بخش مدل ذیل برای احتمال شرطی برای برچسب به فرض $\mathbf{x}$ را در نظر می گیرد.

$$y_i = \Psi_m(x_i, \mathbf{x}, \alpha) + \epsilon, \epsilon \sim \mathcal{N}(0, \sigma^2) \quad (۱۴۲-۳)$$

که در آن $\mathcal{N}$ توزیع نرمال و σ^2 واریانس آن است. بنابراین

$$p(y_i|x_i, \mathbf{y}, \mathbf{x}, \Psi) = \mathcal{N}(y_i; \Psi_m(x_i, \mathbf{x}, \alpha), \sigma^2) \quad (۱۴۳-۳)$$

برای ساده سازی نمادها، فرض کنید

$$\Psi(\mathbf{x}, \alpha) = [\Psi_m(x_1, \mathbf{x}, \alpha), \dots, \Psi_m(x_n, \mathbf{x}, \alpha)]^T \text{ و } p(\mathbf{y}|\mathbf{x}, \alpha) = \prod_{i=1}^n p(y_i|x_i, \mathbf{y}, \mathbf{x}, \Psi(\cdot, \alpha))$$

$$p(\mathbf{y}|\mathbf{x}) = \int p(\mathbf{y}|\mathbf{x}, \alpha)p(\alpha)d\alpha \quad (۱۴۴-۳)$$

متأسفانه، محاسبه این انتگرال چالش آفرین است. در عوض، مطالعه جاری از مقدار ماکزیمم $p(\mathbf{y}|\mathbf{x}, \alpha)$ برای $p(\mathbf{y}|\mathbf{x})$ استفاده می‌کنیم. برای محاسبه ماکزیمم از رویکرد گرادیان تابعی استفاده می‌کنیم. لم ذیل تقریبی برای تابع هدف PMAL برای این مدل ارائه می‌کند.

لم ۱.۲.۳. قرار بدهید $K = \mathbf{x}^T \mathbf{x}$. با فرض یک مدل خطی

$$h(\mathbf{x}, \alpha) = K\alpha \quad (۱۴۵-۳)$$

در مدل گرادیان تابعی بالا، داریم:

$$p(\mathbf{y}|\mathbf{x}) \propto \exp\left(-\frac{1}{2}\mathbf{y}^T \mathcal{M} \mathbf{y}\right) \quad (۱۴۶-۳)$$

که در آن $\mathcal{M} = \sum_{t=1}^m R^t$ ، $R = (I - \eta K)$ و $\eta \in (0, 1/\lambda_{\max}(K))$.

برهان. براساس روش گرادیان تابعی داریم:

$$\alpha^t = \alpha^{t-1} - \eta_t \nabla_{\Psi} \log p(\mathbf{y}|\mathbf{x}, \alpha)|_{\alpha^{t-1}} \quad (۱۴۷-۳)$$

$$= \alpha^{t-1} + \eta_t (\mathbf{y} - \Psi_t(\mathbf{x}, \alpha^{t-1})) \quad (۱۴۸-۳)$$

در نتیجه:

$$\alpha^t = \alpha^{t-1} + \eta_t (\mathbf{y} - \Psi_{t-1}(\mathbf{x}, \alpha^{t-1}) - K\alpha^{t-1})$$

$$\begin{aligned}
&= (I - \eta_t K) \alpha^{t-1} + \eta_t (\mathbf{y} - \Psi_{t-1}(\mathbf{x}, \alpha^{t-1})) \\
&= (I - \eta_t K) \{ (I - \eta_{t-1} K) \alpha^{t-2} + \eta_{t-1} (\mathbf{y} - \Psi_{t-2}(\mathbf{x}, \alpha^{t-2})) \} + \eta_t (\mathbf{y} - \Psi_{t-1}(\mathbf{x}, \alpha^{t-1})) \\
&= (I - \eta_t K) (I - \eta_{t-1} K) \alpha^{t-2} + (I - \eta_t K) \eta_{t-1} (\mathbf{y} - \Psi_{t-2}(\mathbf{x}, \alpha^{t-2})) + \eta_t (\mathbf{y} - \Psi_{t-1}(\mathbf{x}, \alpha^{t-1})) \\
&= \prod_{i=0}^{t-1} (I - \eta_{t-i} K) \alpha^0 + \left\{ \sum_{i=0}^{t-1} \eta_{t-i} \prod_{j=0}^i (I - \eta_{t-j+1} K) (\mathbf{y} - \Psi_{t-i-1}(\mathbf{x}, \alpha^{t-i-1})) \right\} \quad (۱۴۹-۳)
\end{aligned}$$

که در آن $\eta_{t+1} = 0$ با استفاده از (۱۴۹-۳) و (۱۴۵-۳) در (۱۴۴-۳) خواهیم داشت:

$$\begin{aligned}
p(\mathbf{y}|\mathbf{x}, \alpha^{t+1}) &\propto \exp\left(-\frac{1}{2} \|\mathbf{y} - \Psi_t(\mathbf{x}, \alpha^t) - K \alpha^t\|^2\right) \\
&\propto \exp\left(-\frac{1}{2} \|\mathbf{y} - \Psi_t(\mathbf{x}, \alpha^t) - K \{ (I - \eta_t K) \alpha^{t-1} + \eta_t \mathbf{y} \}\|^2\right) \\
&\propto \exp\left(-\frac{1}{2} \|(I - \eta_t K) \mathbf{y} - K (I - \eta_t K) \alpha^{t-1}\|^2\right) \\
&\propto \exp\left(-\frac{1}{2} \|\mathbf{y} - K \left\{ \prod_{i=0}^{t-1} (I - \eta_{t-i} K) \alpha^0 + \left\{ \sum_{i=0}^{t-1} \eta_{t-i} \prod_{j=0}^i (I - \eta_{t-j+1} K) \right\} \mathbf{y} \right\}\|^2\right) \\
&\propto \exp\left(-\frac{1}{2} \left\| \left\{ I - K \sum_{i=0}^{t-1} \eta_{t-i} \prod_{j=0}^i (I - \eta_{t-j+1} K) \right\} \mathbf{y} - K \prod_{i=0}^{t-1} (I - \eta_{t-i} K) \alpha^0 \right\|^2\right)
\end{aligned}$$

با شروع از صفر، $\alpha^0 = 0$ ، بعد از تکرار t ام

$$p(\mathbf{y}|\mathbf{x}) \propto \exp\left(-\frac{1}{2} \mathbf{y}^\top \mathcal{M} \mathbf{y}\right) \quad (۱۵۰-۳)$$

where

$$\mathcal{M} = I - K \sum_{i=0}^{t-1} \eta_{t-i} \prod_{j=0}^i (I - \eta_{t-j+1} K) \quad (۱۵۱-۳)$$

فرض کنید $\eta_i = \eta, \forall i$ و $R = (I - \eta K)$ ، آنگاه

$$\begin{aligned}
\mathcal{M} &= I - \eta K \sum_{i=0}^{t-1} (I - \eta K)^i \\
&= I + (R - I) \sum_{i=0}^{t-1} R^i
\end{aligned}$$

$$\begin{aligned}
&= I + \sum_{i=0}^{t-1} R^{i+1} - \sum_{i=0}^{t-1} R^i \\
&= R^t
\end{aligned} \tag{۱۵۲-۳}$$

□

گزاره ۲.۲.۳. فرض کنید $d_k, k = 1, \dots, n$ مقادیر ویژه ماتریس کرنل $K = U \text{diag}(d_k) U^\top$ و $\mathbf{f} = [f(x_1), \dots, f(x_n)]^\top$ یک بردار شامل مقادیر مجهول تابع f در نقاط داده باشد. آنگاه ارببی و واریانس برابرند با:

$$\begin{aligned}
b^2(m, K; \mathbf{f}) &\propto \mu^{2m+2} \mathbf{f}^\top U \text{diag}(1/(d_k + \mu)) U^\top \mathbf{f} \\
\text{var}(m, K; \sigma^2) &\propto \sigma^2 \sum_{t=1}^n \left(1 - \frac{\mu^{m+1}}{(d_k + \mu)^{m+1}}\right)^2
\end{aligned} \tag{۱۵۳-۳}$$

برهان. قرار بدهید $K = UDU^\top$ تجزیه SVD ماتریس K ، نشان می دهیم که ماتریس ذیل متقارن است.

$$\begin{aligned}
\mathcal{H} &= K(K + \mu I)^{-1} K^\dagger K = UDU^\top U(D + \mu I)^{-1} U^\top U D^\dagger U^\top UDU^\top \\
&= UD(D + \mu I)^{-1} D^\dagger DU^\top \\
&= KK^\dagger(K + \mu I)^{-1} K
\end{aligned} \tag{۱۵۴-۳}$$

رابطه (۱۵۴-۳) رابطه مقادیر ویژه ماتریس $\mathcal{H}$ و K را نشان میدهد. فرض کنید d_k مقدار ویژه ماتریس K باشد، آنگاه یک رابطه یک-به-یک بین d_k و λ_k وجود دارد:

$$\lambda_k = \frac{d_k}{d_k + \mu} = \frac{1}{1 + \frac{\mu}{d_k}} \tag{۱۵۵-۳}$$

گزاره ۳ در [۹] خطای MSE برای اپراتور boosting را محاسبه می کند:

$$MSE = \text{bias}^2 + \text{var}$$

$$\begin{aligned}
\text{bias}^2(m, \mathcal{H}; \mathbf{f}) &= n^{-1} \mathbf{f}^\top U \text{diag}((1 - \lambda_k)^{2m+2}) U^\top \mathbf{f} \\
\text{var}(m, \mathcal{H}; \sigma^2) &= n^{-1} \sigma^2 \sum_{k=1}^n (1 - (1 - \lambda_k)^{m+1})^2
\end{aligned} \tag{۱۵۶-۳}$$

که در آن $Y_i = f(x_i) + \epsilon_i$ ، $\mathbb{E}(\epsilon_i) = 0$ ، $\text{var}(\epsilon_i) = \sigma^2$ و $\mathbf{f}$ مقدارهای تابع محاسبه شده در نقاط داده است. رابطه (۱۵۶-۳) نشان میدهد که شماره تکرار در الگوریتم boosting نقش پارامتر رگولاریزاسیون را دارد. با افزایش آن، تابع پیچیده تر می شود. مهم است که توجه کنیم چون این ماتریس متقارن است، همه مقادیر ویژه آن حقیقی و بین صفر و یک هستند یعنی $\{\lambda_i \in \mathbb{R} | 0 \leq \lambda_i < 1\}$. براساس گزاره ۳ از [۹] نتیجه ثابت می شود. $\square$

قراربدهید $\bar{\mathcal{U}} = \mathcal{U} - \{q\}$ ، با این تقریب تابع هدف عبارتست از

$$\begin{aligned} q &= \arg \max_{q \in \mathcal{U}} \min_{y_q} \max_{y_{\bar{\mathcal{U}}}} p(\mathbf{y}|\mathbf{x}) \\ &= \arg \max_{q \in \mathcal{U}} \min_{y_q} \max_{y_{\bar{\mathcal{U}}}} \log p(\mathbf{y}|\mathbf{x}) \\ &= \arg \min_{q \in \mathcal{U}} \max_{y_q} \min_{y_{\bar{\mathcal{U}}}} \mathbf{y}^T \mathcal{M} \mathbf{y} \end{aligned} \quad (۱۵۷-۳)$$

الگوریتم حاصل، الگوریتم (۲) است. برای مطمئن شدن از نیمه معین مثبت بودن ماتریس $\mathcal{M}$ و پایدار بودن الگوریتم، پارامتر η را برابر $1/\lambda_{\max}(K)$ انتخاب می کنیم که $\lambda_{\max}(K)$ بزرگترین مقدار ویژه ماتریس K است.

Algorithm 2 Active KernelL2Boost Algorithm

```

1: procedure AL2BOOSTKernel( $K, y_l$ )                                 $\triangleright$  L2Boost Kernel Active Learning algorithm
2:    $\eta \leftarrow 1/\lambda_{\max}(K), n_l \leftarrow \text{sizeof}(y_l)$ 
3:    $\mathcal{M}, R, L \leftarrow I$ 
4:    $L \leftarrow (I - \eta K)$ 
5:   for  $t = 1$  to  $4 * n_l$  do                                        $\triangleright$  Compute the matrix  $L$ 
6:      $R \leftarrow RL$ 
7:      $\mathcal{M} \leftarrow \mathcal{M} + R$ 
8:   end for
9:   Compute  $q = \arg \min_q \max_{y_q} \min_{y_u} y^T \mathcal{M} y$ 
10:  return  $q$                                                           $\triangleright$  Query instance  $x_q$ 
11: end procedure

```

چنانکه قبلاً مطرح شد، الگوریتم (۱) روی یک فضای تابعی برای انجام یادگیری فعال کار می کند. در هر تکرار از الگوریتم، یک مولفه تابعی که خود یک گرادیان تابعی از $p(y|x)$ و در گام (۴) محاسبه شده به تقریب تابعی از طبقه بند اضافه می شود. با استفاده از توابع هدف (۱۳۹-۳) یا (۱۴۰-۳)، یک تابع به فرم $h(\cdot, \cdot; a)$ انتخاب می شود که نزدیکترین به گرادیان محاسبه

شده برای مدل جاری در مرحله (۴) با بدترین برچسب برای داده های بدون برچسب باشد.

چون برچسب های داده های بدون برچسب مجهول هستند، تابع هدف (۳-۱۳۹) یا (۳-۱۴۰) برای دسترسی به یک مولفه تابعی برای یادگیری فعال مهم هستند. با استفاده از این توابع هدف، یک مولفه تابعی به تابع Ψ_{m-1} اضافه می شود که برای همه برچسب های داده های بدون برچسب که بعداً در فرایند یادگیری فعال آشکار می شود، مناسب است. این حلقه تکرار می شود تا یک تعداد تکرار معلوم یا تغییر قابل ملاحظه ای در تقریب تابعی Ψ_m ملاحظه نشود.

تابع هدف در خط (۹) پرس وجو را محاسبه می کند. این تابع هدف بدترین برچسب برای داده های بدون برچسب، $y_{\bar{u}}$ را محاسبه می کند. بنابراین روش محاسبه کاملاً با نحوه محاسبه مولفه های تابع Ψ_m در مراحل قبلی کاملاً تطبیق دارد.

الگوریتم (۲) با توجه به فرض نرمال برای $p(y|x, \mathbf{x}, \mathbf{y}, \Psi)$ و خطی بودن h بسیار ساده تر است. در هر تکرار از الگوریتم، یک بردار ویژه به تقریب اضافه می شود. نتیجه یک الگوریتم کارآمد در انتخاب مثالها است.

تابع هدف در لم ۱.۲.۳ شامل ماتریس $\mathcal{M} = \sum_{t=1}^m (I - \eta K)^t$ است که یک فیلتر طیفی پذیرفتنی admissible اعمال شده روی ماتریس K است [۳]. فیلترهای طیفی پذیرفتنی دیگری مانند Tikhonov iterated بصورت $G_{\lambda}(\sigma) = \frac{(\sigma + \lambda)^t - \lambda^t}{\sigma(\sigma + \lambda)^t}$ وجود دارند. با کمک روش پیشنهادی هر یک از این فیلترهای طیفی می تواند در الگوریتم های یادگیری فعال با خصوصیات مختلف بکار روند.

رویکرد پیشنهادی رگولاریزاسیون تابع یادگیری را باروشی متفاوت انجام می دهد. چنانکه قبلاً گفته شد، در هرتکرار از الگوریتم، اضافه کردن یک مولفه به تابع مرحله به مرحله stage-wise است. عبارت دیگر، هر مولفه جدید به تابع اضافه می شود بدون اینکه مولفه های قبلاً اضافه شده، به روزرسانی شوند. هر مولفه تلاش می کند که تا حد ممکن تفاوت تابع مورد نظر و تابع به روزرسانی شده Ψ_m کم شود. بنابراین، مولفه های جدیدتر اضافه شده، سریعتر تغییر می کند. توقف زودهنگام، الگوریتم را از اضافه کردن مولفه های سریع تغییر یابنده باز می دارد. به بیان دیگر، نحوه ساخت تابع Ψ_m را رگولاریزه می کند. این پدیده بخوبی در ادبیات هر دو موضوع گرادیان تابعی و فیلترهای طیفی بخوبی شناخته شده است [۳، ۴۲].

آنالیز زمانی

آزمایشهای مطالعه چاری نشان می دهد که بهترین تعداد تکرار، ضربی از تعداد داده های برجسب دار است. این یافته بسیار قابل درک است، چون وقتی تعداد بسیار کمی مثالهای برجسب دار وجود داشته باشد، افزودن مولفه های کوچک به تابع تقریب حاصل ممکن است، طبقه بند را بیش برازش overfit کند. بنابراین، در مراحل ابتدایی یادگیری فعال، محاسبه طبقه بند، تکرارهای بسیار کمی لازم داد. اما وقتی تعداد داده های برجسب دار زیاد می شود، باید تعداد تکرار بیشتری داشته باشیم تا برای پیچیده تر شدن تابع طبقه بند برای داده ها آماده باشیم. در واقع، در فیلتر طیفی، تعداد تکرارها، نقش پارامتر رگولاریزاسیون را بازی می کند [۳]. این پدیده در گردایان تابعی نیز برقرار است. بنابراین، تعداد تکرارها در الگوریتم (۲) برابر با $O(n_l)$ است. بعلاوه زمان صرف شده در هر تکرار از الگوریتم (۲) برابر است با $O(n^2)$. محاسبه q شامل حل یک تابع هدف درجه دو است و بنابراین مرتبه زمانی آن $O(n^3)$ است. چون ماتریس کرنل، در کل فرایند یادگیری فعال ثابت است، صرفا لازم است یک بار بزرگترین مقدار ویژه آن را محاسبه کنیم و بنابراین زمان محاسبه آن قابل صرفنظر کردن است. چون تعداد تکرارها $O(n_l)$ است، پیچیدگی زمانی الگوریتم $O(n^3 + n_l n^2)$ یا $O(n^3)$ چون داریم $n_l < n$.

۳.۳ یادگیری فعال در حوزه توزیع

اگر داده های مورد نظر ما توزیع باشند، آنگاه یادگیری و یادگیری فعال روی این داده ها تفاوت زیادی با یادگیری روی بردارها خواهد داشت. علت این موضوع آنستکه معمولا به توزیع داده ها دسترسی نداریم اما می توانیم از توزیع نمونه برداری کنیم. بنابراین تعدادی نمونه از هر توزیع نمونه برداری کرده ایم. دقت تخمین هر توزیع بستگی به تعداد نمونه هایی دارد که از آن انتخاب کرده ایم. در نتیجه یادگیری براساس این نمونه ها بستگی به تعداد نمونه هایی دارد که از هر توزیع انتخاب کرده ایم.

۱.۳.۳ یادگیری روی توزیع

یکی از رویکردهای یادگیری روی توزیع، انتقال توزیع ها به فضای هیلبرت با استفاده از Hilbert Space Embedding of Distributions است. این روش امکان می دهد که به توزیع ها به عنوان یک نقطه در فضای هیلبرت نگاه کنیم. در نتیجه همه

روشهای معمول یادگیری که قابلیت استفاده از کرنل را دارند، می توانند برای یادگیری روی توزیع ها استفاده شود.

اما این موضوع مشکلاتی دارد. یکی از این مشکلات عدم دقت تخمین از توزیع ها به دلیل تعداد کم نمونه ها در حوزه تبدیل است. اغلب از برخی توزیع ها نمونه های کم و از برخی توزیع ها نمونه های بیشتری داریم. این امر باعث می شود که دقت نمونه ها با یکدیگر متفاوت باشد. بنابراین دقت نمونه ها یکسان نیست.

یک پیشنهاد تخمین وزندار نمونه ها متناسب با دقت آنها به شکلی است که یادگیری اریب نباشد. این باعث می شود که بتوانیم از تفاوت دقت تخمین نمونه ها در یادگیری روی توزیع استفاده کنیم. در این روش نمونه ها ارزش یکسانی ندارند. نمونه هایی که دقت بیشتری دارند، ارزش بیشتر و نمونه هایی که دقت کمتری دارند، ارزش کمتری خواهند داشت. (این مسئله براساس باندهایی که برای مسئله بدست آمده است می تواند محاسبه شود. این باند ها در [۸۹] مطرح شده است. مقاله اصلی در مورد باند مربوط به کار [۸۰] است.)

الگوریتم های یادگیری فعال تلاش می کنند با کاهش تعداد مثالهای برچسب دار مورد نیاز هزینه ساخت سیستم های یادگیری را کاهش بدهند. در سالهای اخیر سیستم های یادگیری زیادی برای فرمهای سطح بالاتر و انتزاعی تر داده مانند یادگیری روی توزیع توسعه داده شده اند. در یادگیری روی توزیع هر مثال خود یک توزیع است. در این فصل یادگیری فعال روی توزیع را به عنوان یک نوع سطح بالاتر و موثر تر از الگوریتم های یادگیری فعال را پیشنهاد می کنیم. در یادگیری فعال روی توزیع به توزیع ها دسترسی مستقیم نداریم بلکه به هر توزیع از طریق یک نمونه برداشته شده از آن دسترسی داریم. بنابراین مشابه یادگیری مقاوم، هر تخمین از مثال نادقیق است. این موضوع چالش مثال های نادقیق را به مسئله پرچالش یادگیری فعال اضافه می کند. برای حل این چالش ها، یک حد بالا برای ریسک طبقه بند در مرحله بعدی یادگیری فعال که مثالهای برچسب دار بیشتر می شوند، ارائه می کنیم. براساس این حدبالا، به منظور مواجهه با چالش های موجود در یادگیری فعال مقاوم، روش یادگیری فعال بیشینه-کمینه احتمالاتی^۱ را ارائه می کنیم و ثابت می کنیم که این الگوریتم مثالی را انتخاب می کند که دانش برچسب آن، ریسک را کمینه می کند. متأسفانه محاسبه این تابع هدف برای مسئله یادگیری فعال مقاوم رام نشدنی^۲ است. بنابراین تخمین کارآمدی از تابع هدف ارائه می دهیم. به منظور بهره برداری بیشتر از اطلاعات موجود در مورد تخمین توزیع ها، یک روش یادگیری فعال مقاوم براساس یادگیری بیزی نهفته سازی کرنلی توزیع ها ارائه می کنیم. آزمایشها کارآمدی الگوریتم را روی تعدادی پایگاه داده توزیعی سنتزی و

^۱ Probabilistic Minimax Active Learning

^۲ Intractable

واقعی نشان می دهند.

برای یادگیری یک مفهوم^۱ سیستم های یادگیری نیاز به دانش دارند. هدف سیستم های یادگیری پیش بینی برچسب داده های آزمون که در حین ساخت سیستم یادگیری دیده نشده اند، است. بدون دانش سیستم های یادگیری قادر نیستند که مفهوم را به داده های دیده نشده تعمیم بدهند.

انتقال دانش از انسان به ماشین جنبه ای اساسی از سیستم های یادگیری است. دانش اغلب به فرم نظارت روی داده ارائه می شود. ده های اخیر شاهد ظهور پارادایم های جدید برای انتقال دانش از انسان به ماشین بوده است. یکی از این پارادایم ها یادگیری فعال است که در آن ماشین داده را برای نظارت انتخاب می کند.

به منظور کمینه سازی نیاز به نظارت، یادگیری فعال به استفاده هوشمندانه از منابع محدود نظارت و دانش انسانی می پردازد. با انتخاب زیرکانه بخش هایی از داده و پرسش از کاربر انسانی برای ارائه داده های نظارتی برای آنها، یادگیری فعال زحمات لازم برای دسترسی به سطح خاصی از کارایی را کاهش می دهد. اما بهر حال، انسان معمولاً دانش را در فرم های مجرد و سطح بالایی می بیند در حالیکه الگوریتم ها و ماشین ها معمولاً نیاز به دانش در فرم های سطح پایین مانند برچسب بردارهای ساده دارند. در عمل، انتقال دانش در فرم های سطح بالا می تواند در یادگیری فعال مزیت باشد زیرا کاربران ممکن است بتوانند بهتر اطلاعات را ارائه بدهند. در چنین شرایطی، الگوریتم های یادگیری فعال ممکن است اطلاعات غنی تری از کاربر در مقایسه با دریافت برچسب برای بردارهای ساده کسب کنند. برای مثال [۳۴] یک نوع پرس و جو تعمیم یافته، معادل تعداد زیادی پرس و جو خاص برای ارتباط غنی بین کاربر و ماشین ارائه کرد.

از دهه گذشته، سیستم های یادگیری بتدریج پیچیده تر شدند و روی داده های سطح بالاتری مانند داده های ساخت یافته ساخت-یافته^۲ یا داده های توزیعی^۳ کار کردند. در یادگیری از داده های ساخت-یافته داده دارای ساختاری مانند گراف [۴۵] است، در حالیکه در یادگیری روی توزیع [۸۸] هر نقطه داده خود یک توزیع است. بسیار مورد نیاز است که روشهای موثری برای کاهش هزینه های نظارت روی این نوع داده ها ارائه شود.

در بسیاری از کاربردها، طبیعی تر است که فرض کنیم دانش در هر عضو از نمونه وجود ندارد، بلکه دانش در توزیع هایی وجود دارد که نمونه از آن برداشته شده است. برای مثال، در وظیفه هایی مانند شناسایی بی-نظمی^۴ هر نقطه ممکن است نرمال باشد

¹Concept

²Structured data

³Distributional data

⁴Anomaly detection

اما یک گروه از نقاط ممکن است بی نظم باشند [۱۰۴]. درچنین کاربردهایی بهتراست مسئله را بعنوان یادگیری روی توزیع مدل کنیم. چنین مسائلی شامل یادگیری از گروه ها مانند شناسایی بی-نظمی گروهی^۱ و یادگیری ترجیحات^۲ می باشد. در سالهای اخیر، روش های بسیاری برای یادگیری روی توزیع توسعه داده شده اند [۸۹، ۹۵، ۱۳۲، ۱۵۶].

دراین فصل یک رویکرد یادگیری فعال روی توزیع ارائه می کنیم. در یادگیری روی توزیع مثالها دارای عدم قطعیت ذاتی هستند. هر مثال توزیعی با استفاده از نمونه ای با اندازه محدود تخمین زده می شود. بخوبی روشن است که تخمین توزیع از روی نمونه با اندازه محدود دارای عدم قطعیت است. روش ارائه شده در برابر عدم دقت در مثالها مقاوم است. مقاوم بودن در یادگیری فعال بسیار چالش برانگیزتر است وقتی که اطلاعات جزئی در مورد داده داریم.

برای حل این مشکل با یک رویکرد اصولی، ابتدا مسئله یادگیری فعال را در کلی ترین شکل در نظر می گیریم. در این شرایط یک حدبالا روی ریسک طبقه بند در مرحله بعدی یادگیری فعال با تعداد داده های برچسب دار افزایش یافته درشرایطی ارائه می کنیم که هنوز هیچ مثال برچسب دار جدیدی در اختیار نگرفته ایم. سپس یک مثال بنحوی پرس وجو می شود که انتخاب آن، این حدبالا را کمینه کند. ما روش حاصل را یادگیری فعال بیشینه-کمینه احتمالاتی می نامیم. PMAL می تواند در رویکرد بیزی^۳ بکار رود.

براساس PMAL یک الگوریتم یادگیری فعال مقاوم ارائه می کنیم. در اینجا، مثال ها می توانند نادقیق باشند. متأسفانه محاسبه PMAL برای یادگیری فعال مقاوم رام نشدنی است. بنابراین، یک تخمین کارآمد برای یادگیری مقاوم فعال بیشینه-کمینه احتمالاتی^۴ ارائه می کنیم. تخمین مورد نظر دقیق است از این جنبه که برچسب هایی برای داده های بدون برچسب وجود دارد که خطای تخمین قابل صرفنظر است.

مسئله یادگیری روی توزیع می تواند به عنوان نوع خاصی از یادگیری مقاوم تلقی شود. با اینکه یک الگوریتم کلی یادگیری فعال مقاوم ارائه می کنیم که عدم قطعیت در تخمین مثالها را درنظر می گیرد، تمرکز ما در اینجا برچگونگی مواجهه با عدم قطعیت در حین تخمین مثالهای توزیعی است. توجه کنید که در اینجا، یادگیری مقاوم متفاوت از برخی دیگر از تحقیقات [۴۶، ۱۵۷] است که هدف آنها مقاوم بودن در برابر داده های پرت و نویزی است. مقاله [۱۵۷] نیز این تفاوت را مطرح کرده است که دو دسته الگوریتم های مقاوم یادگیری وجود دارد. دسته ای که در برابر عدم دقت در مثال مقاوم هستند، مانند الگوریتم های مطرح در این

^۱Group anomaly detection^۲Preference learning^۳Bayesian^۴Probabilistic Minimax Active Robust Learning (PMARL)

فصل و دسته ای دیگر که در برابر داده های نویزی مقاوم هستند که در فصل های قبل به آنها پرداختیم. براساس بررسی های ماین اولین الگوریتم یادگیری فعال که بصورت ویژه روی یادگیری روی توزیع طراحی شده باشد، است. هر الگوریتم یادگیری روی توزیع، مبتنی بر تخمین توزیع است. اخیرا رویکردهایی برای تخمین توزیع در روشهای مبتنی بر کرنل پیشنهاد شده است.

رویکردهای مبتنی بر کرنل که برای یادگیری روی توزیع توسعه یافته اند، معمولا از نهفته سازی میانگین کرنل^۱ توزیع ها استفاده می کنند [۱۲۵]، که در آن هر توزیع به عنوان یک تابع میانگین در یک فضای هیلبرت نمایش داده می شود. چون اندازه نمونه برای یک توزیع محدود است، نهفته سازی میانگین کرنل تجربی^۲ استفاده می شود که صرفا یک مئانگین از تابع کرنل برای هر نقطه موجود در نمونه است [۸۹]. اخیرا نشان داده شد، نهفته سازی میانگین کرنل تجربی بهترین تخمین برای توزیع ها نیست [۹۱]. بخوبی می دانیم که نهفته سازی میانگین کرنل توزیع ها دارای عدم قطعیتی است که تابعی از اندازه نمونه است.

بسیاری از الگوریتم های یادگیری روی توزیع از عدم قطعیت ذاتی تخمین صرفنظر می کنند. با استفاده از رویکرد یادگیری بیزی نهفته سازی کرنل^۳ که اخیرا پیشنهاد شده است [۴۰]، در فصل جاری، روشی برای یادگیری فعال مقاوم روی توزیع پیشنهاد می شود. این روش را

یادگیری فعال مقاوم بیشینه-کمینه احتمالاتی روی توزیع بارویکرد بیزی^۴ می نامیم. این روش، از یادگیری بیزی نهفته سازی کرنل برای بامواجه به عدم قطعیت در تخمین نهفته سازی کرنل می پردازد. آزمایشها نشان می دهد که روش پیشنهادی در تخمین عدم قطعیت ذاتی و انتخاب مثال های توزیعی با استفاده از نمونه ها کارآمد است. برای جمع بندی، دو نوآوری اصلی در این کار ارائه شده است:

- یک الگوریتم یادگیری فعال روی توزیع مقاوم از این جنبه که تخمین نمونه ها دارای عدم قطعیت است.
- یادگیری فعال بیشینه-کمینه احتمالاتی که قابلیت کاربرد در مسائل یادگیری فعال را دارد و می تواند در یادگیری بیزی در الگوریتم ها استفاده شود. ثابت کردیم که این روش مثالها را به شکلی انتخاب می کند که ریسک طبقه بند را کمینه می کند.

^۱Kernel Mean Embedding

^۲Empirical Kernel Mean Embedding

^۳Bayesian learning of kernel embedding

^۴Probabilistic Minimax Active Robust Learning on Distributions with Bayesian learning of kernel embeddings

جدول ۲.۳: جدول نمادهای مربوط به یادگیری فعال روی توزیع

نمادهای یادگیری روی توزیع	
نهفته سازی کرنل مربوط به توزیع P	μ_P^*
نهفته سازی تجربی کرنل مربوط به توزیع P_i	$\hat{\mu}_{P_i}$
ارزیابی مقدار نهفته سازی کرنل مربوط به تابع P_i در نقطه x .	$\hat{\mu}_{P_i}(x)$
نمونه برداشته شده از توزیع P_i	$x_i \sim P_i$
$\forall u \in [1..n_i], x_i^u \in \mathbb{R}^d$	$x_i = \{x_i^1, x_i^2, \dots, x_i^{n_i}\}$
ارزیابی میانگین کرنل	$\hat{\mu}_{P_i}(x_i) \in \mathbb{R}^{n_i}$
نهفته سازی P_i در هر نقطه از $x_i^1, \dots, x_i^{n_i}$	$= [\hat{\mu}_{P_i}(x_i^1), \dots, \hat{\mu}_{P_i}(x_i^{n_i})]^T$
لیست میانگین تجربی نهفته سازی کرنل توزیع های $P_1, \dots, P_n$	$\hat{\mu}_P = [\hat{\mu}_{P_1}, \hat{\mu}_{P_2}, \dots, \hat{\mu}_{P_n}]^T$
لیست مرتب ارزیابی از	$\hat{\mu}_P(\mathbf{x})$
نهفته سازی کرنل ها به ازاء نمونه ها	$= (\hat{\mu}_{P_1}(x_1), \dots, \hat{\mu}_{P_n}(x_n))$

در ادامه این فصل، در ۲.۳.۳ رویکرد پیشنهادی را ارائه می کنیم. روش یادگیری فعال بیشینه-کمینه احتمالاتی در ۶.۱.۳ و روش یادگیری فعال مقاوم در ۳.۳.۳ ارائه می شود. در ۴.۳.۳ روش اصلی یادگیری فعال روی توزیع بررسی می شود. پس از آن، نتایج آزمایشهای تجربی و بلاخره نتیجه گیری ارائه شده است.

۲.۳.۳ یادگیری فعال روی توزیع مبتنی بر یادگیری فعال بیشینه-کمینه احتمالاتی

مثال ها را به شکل حروف کوچک نشان می دهیم و حروف کوچک پررنگ لیست مرتب مثالها را نشان می دهند مانند

$\mathbf{x} = (x_1, \dots, x_n)$ یا برچسب آنها $\mathbf{y} = (y_1, \dots, y_n)$. برای اختصار نمادها در جدول ۲.۳ آمده اند.

چنانکه قبلا اشاره شد، تخمین دقیقی از توزیع ها وجود ندارد. این چنین شرایطی مشابه یادگیری مقاوم است اما همچنین از این جهت با آن متفاوت است که اطلاعات خاصی در مورد تخمین توزیع ها با استفاده نمونه ها در اختیار داریم که می توان از آنها بهره ببریم.

برای بهره برداری موثر از این اطلاعات ابتدا رویکرد یادگیری فعال بیشینه-کمینه احتمالاتی یا PMAL را در بخش ۶.۱.۳ معرفی می کنیم. با استفاده از PMAL می توانیم به عدم قطعیت در یادگیری فعال یا همان یادگیری فعال مقاوم بصورتی مبتنی بر اصول پردازش. اگرچه در بخش های بعدی به یادگیری فعال روی فضای ورودی نمی پردازیم، در ۳.۳.۳ الگوریتمی برای یادگیری فعال مقاوم در فضای ورودی ارائه می کنیم. این مسئله مبانی یادگیری فعال مقاوم در توزیع را به خواننده ارائه می کند، تا وی

براحتی بتواند تفاوت این دو را درک کند. بعلاوه در

۳.۳.۳ یک فرم ساده تر از یادگیری فعال مقاوم روی توزیع ارائه می کنیم. در ۴.۳.۳ به هدف اصلی این فصل که یادگیری فعال مقاوم روی توزیع است می پردازیم. در ادامه ابتدا تعاریف و پیش نیازهای بخش ۳.۳.۳ بررسی می شود.

۳.۳.۳ یادگیری فعال بیزی مقاوم روی فضای ورودی

در تنظیمات یادگیری مقاوم، هر مثال نادقیق است. برای این عدم دقت دلایل بسیاری می تواند وجود داشته باشد. در هر صورت در اینجا فرض می کنیم که احتمال خطایی در مثالها وجود دارد. از طرف دیگر، کارایی الگوریتم یادگیری نباید به دلیل این موضوع کاهش یابد. بعبارت دیگر، الگوریتم می باید در مقابل این عدم دقت مقاوم باشد. فرض کنید x_i نشان دهنده یک نقطه و x_i^* مقدار واقعی آن باشد.

در اینجا فرض می کنیم هر نقطه داده x_i دارای عدم قطعیتی نمایش داده شده توسط توزیع شرطی ذیل

$$x_i^* | x_i \sim \mathcal{N}(0, \sigma_i^2) \quad (۱۵۸-۳)$$

است. با فرض یک مدل خطی داریم

$$y_i = x_i^{*T} w + \epsilon, \quad \epsilon \sim \mathcal{N}(0, \sigma^2) \quad (۱۵۹-۳)$$

بنابراین، برای محاسبه $\mathbf{P}(\mathbf{y}|\mathbf{x})$ ابتدا $\mathbf{P}(\mathbf{y}|\mathbf{x}, w) = \prod_i \mathbf{P}(y_i|x_i, w)$ را محاسبه می کنیم. داریم:

$$\begin{aligned} \mathbf{P}(y_i|x_i, w) &= \int \mathbf{P}(y_i|w, x_i^*) \mathbf{P}(x_i^*|x_i) dx_i^* \\ &= \int \mathcal{N}(y_i; x_i^{*T} w, \sigma^2) \mathcal{N}(x_i^*; x_i, \sigma_i^2) dx_i^* \\ &= \mathcal{N}(y_i; x_i^T w, \sigma^2 + \sigma_i^2 \|w\|^2) \end{aligned} \quad (۱۶۰-۳)$$

اولین تساوی، قانون انتگرال کل^۱ است. تساوی دوم از رابطه ۱۵۹-۳ حاصل می شود. آخرین تساوی انتگرال معروف دو توزیع

گوسی است. اول، قانون انتگرال بیز است. تساوی دوم قانون بیز است. قراردهید $\sigma^i(w) = \sigma^2 + \sigma_i^2 \|w\|^2$. آنگاه داریم:

$$\mathbf{P}(\mathbf{y}|\mathbf{x}, w) \propto \prod_i \sigma^i(w)^{-\frac{1}{2}} \exp\left(-\frac{1}{2} \sum_i \frac{(y_i - w^T x_i)^2}{\sigma^i(w)}\right) \quad (۱۶۱-۳)$$

این رابطه بیان می کند اگر یک نقطه دارای واریانس بیشتری در مقایسه با سایر نقاط باشد، باید تاثیر کمتری روی طبقه بند داشته باشد و بنابراین احتمال انتخاب آن در یادگیری فعال می باید نسبت به نقاط دیگر که دارای تاثیر بیشتری روی طبقه بند هستند، کمتر باشد. این رابطه همچنین نشان می دهد که اگر طبقه بند ساده باشد، یعنی اگر $\|w\|$ کوچک باشد، واریانس توزیع شرطی $\mathbf{P}(\mathbf{y}|\mathbf{x}, w)$ کمتر از عدم قطعیت یک نقطه تاثیر خواهد پذیرفت. با در نظر گرفتن دانش پیشین^۱ ذیل $p(w) = \mathcal{N}(0, \sigma_w^{-2})$ برای w به منظور محاسبه $\mathbf{P}(\mathbf{y}|\mathbf{x})$ داریم:

$$\mathbf{P}(\mathbf{y}|\mathbf{x}) = \int \mathbf{P}(\mathbf{y}|\mathbf{x}, w) \mathbf{P}(w) dw \quad (۱۶۲-۳)$$

متأسفانه این انتگرال رام نشدنی است. مهمتر اینکه $\mathbf{y}_U$ مجهول است. بنابراین باید تخمینی از $\mathbf{P}(\mathbf{y}|\mathbf{x})$ به عنوان تابعی از $\mathbf{y}_U$ پیدا کنیم. همچنین باید راهی برای محاسبه کارآمد آن پیدا کنیم.

به این منظور تابع چگالی احتمال گوسی برای تقریب، $\tilde{\mathbf{P}}(\mathbf{y}|\mathbf{x}, w)$ را در نظر می گیریم. این تابع برابر است با

$$\tilde{\mathbf{P}}(\mathbf{y}|\mathbf{x}, w) = \prod_{i=1}^n \mathcal{N}(y_i; w^T x_i, \sigma^2 + \sigma_i^2 v^2) \quad (۱۶۳-۳)$$

که در آن v را به زودی تعیین می کنیم. استفاده از $\tilde{\mathbf{P}}$ بجای $\mathbf{P}$ مشکل رام نشدنی بودن انتگرال را حل می کند. اما سؤال اینست که چقدر اینها به ازای هر مقدار $\mathbf{y}_U$ به هم نزدیک هستند، در شرایطی که نمی توانیم انتگرال را محاسبه کنیم؟

قضیه ای که در ذیل می آید، دیورژانس KL^۲ بین دو توزیع $\mathbf{P}$ و $\tilde{\mathbf{P}}$ را تقریب می زند. این قضیه براساس پیشرفت هایی است که اخیراً در تقریب لاپلاسی انتگرال های رام نشدنی حاصل شده است. برای اطلاعات بیشتر رجوع کنید به [۱۵۴]، [۶۹]، [۶۸].

قضیه ۱.۳.۳. قرار بدهید

$$w^* = \arg \max_w \mathbf{P}(\mathbf{y}, w|\mathbf{x})$$

$$\lambda = \frac{1}{\max_i \{\sigma_i^2\}}$$

همچنین

$$h(w; \mathbf{y}, \mathbf{x}) = \frac{1}{2} \sum_{i=1}^n \left\{ \frac{(y_i - w^\top x_i)^2}{\sigma^i(w)} + \log \sigma^i(w) \right\} + \frac{1}{2\sigma_w^2} \|w\|^2$$

$$g(w, v) = \frac{1}{2} \sum_{i=1}^n \left\{ \frac{\sigma_i^2(\|w\|^2 - v^2)(y_i - w^\top x_i)^2}{\sigma^i(v)\sigma^i(w)} + \log \frac{\sigma^i(v)}{\sigma^i(w)} \right\}$$

آنگاه داریم:

$$KL(\mathbf{P}(\mathbf{y}, w|\mathbf{x}) || \tilde{\mathbf{P}}(\mathbf{y}, w|\mathbf{x})) = c_\lambda \left\{ D(\mathbf{P}, \tilde{\mathbf{P}}; \mathbf{y}, \mathbf{x}, \lambda, v) + \epsilon(\lambda) \right\}$$

که در آن

$$D(\mathbf{P}, \tilde{\mathbf{P}}; \mathbf{y}, \mathbf{x}, \lambda, v) \propto \frac{e^{-h(w^*; \mathbf{y}, \mathbf{x})} g(w^*, v)}{\sqrt{\det D^2 h(w^*; \mathbf{y}, \mathbf{x})}} \quad (۱۶۴-۳)$$

همچنین، $c_\lambda = (\frac{2\pi}{\lambda})^{d/2}$ و $\epsilon(\lambda) = e^{-h(w^*; \mathbf{y}, \mathbf{x})} \frac{O(1)}{\sqrt{\lambda}}$ هنگامیکه $\lambda \rightarrow \infty$.

برهان. دیورژانس KL بین این دو توزیع برابر است با

$$D_{\mathbf{P}\tilde{\mathbf{P}}} = KL(\mathbf{P} || \tilde{\mathbf{P}}) = \int_{\mathbb{R}^d} \mathbf{P}(\mathbf{y}, w|\mathbf{x}) \log \frac{\mathbf{P}(\mathbf{y}, w|\mathbf{x})}{\tilde{\mathbf{P}}(\mathbf{y}, w|\mathbf{x})} dw \quad (۱۶۵-۳)$$

میدانیم که

$$\mathbf{P}(\mathbf{y}, w|\mathbf{x}) = (2\pi)^{-d} \exp \left(-h(w; \mathbf{y}, \mathbf{x}) \right)$$

همچنین، قرار بدهید

$$\lambda = 1 / \max_{i=1}^n \sigma_i^2$$

توجه کنید وقتی $\lambda \rightarrow \infty$ آنگاه $P(\mathbf{y}, w|\mathbf{x})$ تبدیل به یک گوسی تک-متغیره می شود. برای سادگی نمادها، قرار بدهید

$$f(w; \mathbf{y}, \mathbf{x}, \lambda) = h(w; \mathbf{y}, \mathbf{x}) / \lambda$$

بنابراین، داریم

$$\mathbf{P}(\mathbf{y}, w|\mathbf{x}) = (2\pi)^{-d} \exp(-\lambda f(w; \mathbf{y}, \mathbf{x}, \lambda))$$

به سادگی می بینیم که

$$\log \frac{\mathbf{P}(\mathbf{y}, w|\mathbf{x})}{\tilde{\mathbf{P}}(\mathbf{y}, w|\mathbf{x})} = g(w, v) \quad (۱۶۶-۳)$$

براساس قضیه ۲ از [۶۹] و همچنین قضیه ۳.۲ در [۶۸]، چون $w^* = \arg \min_w f(w; \mathbf{y}, \mathbf{x}, \lambda)$ ، به تقریبی از انتگرال (۱۶۵-۳) برابر با

$$\begin{aligned} D_{\mathbf{P}\tilde{\mathbf{P}}} &= \int_{\mathbb{R}^d} e^{-\lambda f(w; \mathbf{y}, \mathbf{x}, \lambda)} g(w, v) \\ &= c_\lambda e^{-\lambda f(w^*; \mathbf{y}, \mathbf{x}, \lambda)} \left(\frac{g(w^*, v)}{\sqrt{\det D^2 f(w^*; \mathbf{y}, \mathbf{x}, \lambda)}} + \frac{\epsilon(\lambda)}{\sqrt{\lambda}} \right) \end{aligned} \quad (۱۶۷-۳)$$

می رسمیم که برای $\lambda \geq \lambda_0$ ، وقتی $\lambda \rightarrow \infty$ داریم: $\epsilon(\lambda) = O(1)$. با قراردادن h در روابط، به نتیجه مورد نظر می رسمیم. $\square$

اگر قرار بدهیم $v = \|w^*\|$ براساس قضیه ۱.۳.۳، $g(w^*, v)$ برابر صفر خواهد بود و بنابراین دیورژانس KL بین $\mathbf{P}$ و $\tilde{\mathbf{P}}$ تقریباً صفر خواهد شد.

اما بهرحال چون h نامحدب است، محاسبه w^* مشکل است. لم ذیل حدبالایی برای h محاسبه می کند. این نشان می دهد که بجای محاسبه مستقیم w^* ، می توانیم یک تابع محدب ساده که در آن w بیشتر رگولاریزه شده است، را کمینه کنیم. نکته جالب آنست که لم ۲.۳.۳ یادگیری مقاوم را به رگولاریزاسیون بیشتر تابع یادگیری مرتبط می کند. این موضوع در زمینه یادگیری مقاوم SVM در [۱۵۷] نشان داده شده است.

لم ۲.۳.۳. فرض کنید $\sigma_{w^*}^{-2} = \sigma^2 \left(\frac{1}{\sigma_w^2} + \sum_{i=1}^n \frac{\sigma_i^2}{\sigma^2} \right)$ و

$$h'(w; \mathbf{y}, \mathbf{x}) = \frac{1}{2} \sum_{i=1}^n \frac{(y_i - w^\top x_i)^2}{\sigma^2} + \frac{1}{2} \frac{\sigma_{w^*}^{-2}}{\sigma^2} \|w\|^2 \quad (۱۶۸-۳)$$

آنگاه داریم:

$$h(w; \mathbf{y}, \mathbf{x}) \leq h'(w; \mathbf{y}, \mathbf{x}) + n \log \sigma$$

برهان. با استفاده از نامساوی

$$\alpha + \beta \leq \alpha e^{\frac{\beta}{\alpha}}, \alpha \neq 0$$

داریم

$$\sigma^2 \leq \sigma^2 + \sigma_i^2 \|w\|^2 \leq \sigma^2 e^{\sigma_i^2 \|w\|^2 / \sigma^2} \quad (۱۶۹-۳)$$

با استفاده از (۱۶۹-۳) در h ، داریم $h(w; \mathbf{y}, \mathbf{x}) \leq h'$ که در آن

$$h' = \frac{1}{2} \sum_{i=1}^n \frac{(y_i - w^\top x_i)^2}{\sigma^2} + n \log \sigma + \frac{\sigma_{w^*}^{-2}}{2} \|w\|^2 \quad (۱۷۰-۳)$$

□

بنابراین، h' می تواند برای کمینه سازی h بکار رود. اما در هرحال، مهم است که تفاوت جواب های آنها را بدانیم تا بصورتی قاعده مند بتوانیم از جواب h' بجای جواب h استفاده کنیم.

قضیه ۳.۳.۳. فرض کنید w^* یک جواب رگولاریزه شده از مسئله $\arg \min_w h(w; \mathbf{y}, \mathbf{x})$ باشد و داشته باشیم:

$$\tilde{w} = \arg \min_w h'(w, \mathbf{y}, \mathbf{x})$$

آنگاه خواهیم داشت:

$$\frac{\|w^* - \tilde{w}\|}{\|w^*\|} \leq \frac{D_x + N_x}{\sigma_w^{-2} \sigma_{w^*}^{-2}} \|w^*\| + \sigma_w^2 \left\{ \sum_{i=1}^n \frac{\sigma_i^2}{\sigma^2} \right\}$$

$$\cdot \lim_{\sigma_1, \dots, \sigma_n \rightarrow 0} \|w^* - \tilde{w}\| = 0$$

همچنین

$$D_{\mathbf{x}} = \sum_{i=1}^n \sum_{j=1}^n \frac{\|D_{ij}\| |\sigma_j^2 - \sigma_i^2|}{\sigma^i(w^*) \sigma^j(w^*)} \leq \sum_{i=1}^n \sum_{j=1}^n \frac{\|D_{ij}\|}{\sigma^4} |\sigma_j^2 - \sigma_i^2|$$

که در آن

$$D_{ij} = \sigma^{-2} (x_j x_j^\top + \sigma_j^2 I) (x_i y_i)$$

$$N_{\mathbf{x}} = \frac{1}{\sigma_w^2 \sigma^2} \sum_{i=1}^n \|x_i y_i\| \frac{\sigma_i^2}{\sigma^i(w^*)} \leq \frac{1}{\sigma_w^2 \sigma^4} \sum_{i=1}^n \|x_i y_i\| \sigma_i^2$$

توجه کنید که

$$\lim_{\|w^*\| \rightarrow \infty} D_{\mathbf{x}} \|w^*\|^2 = \lim_{\|w^*\| \rightarrow \infty} N_{\mathbf{x}} = 0$$

برهان. قراردهید

$$h_{\rho}(w, \rho; \mathbf{y}, \mathbf{x}) = \frac{1}{2} \sum_{i=1}^n \left\{ \frac{(y_i - w^{\top} x_i)^2}{\rho_i} + \log(\rho_i) \right\} + \frac{1}{2\sigma_w^2} \|w\|^2$$

مسئله ذیل معادل مسئله $\min_w h(w; \mathbf{y}, \mathbf{x})$ است.

$$\min. \quad h_{\rho}(w, \rho; \mathbf{y}, \mathbf{x}) \quad \text{s.t.} \quad \rho_i = \sigma^2 + \sigma_i^2 \|w\|^2, \forall i \in [1, n]$$

تابع لاگرانژ برای مسئله (۱۷۱-۳) برابر است با

$$L(w, \rho; \theta) = h_{\rho}(w, \rho; \mathbf{y}, \mathbf{x}) - \theta^{\top} (\rho - \sigma^2 - \sigma_I^2 \|w\|^2) \quad (171-3)$$

شرط مرتبه اول لازم برای این مسئله عبارتست از

$$\nabla h_{\rho}(w^*, \rho^*; \mathbf{y}, \mathbf{x}) - \sum_{i=1}^n \theta_i \nabla (\rho_i^* - \sigma^2 - \sigma_i^2 \|w^*\|^2) = 0$$

که می تواند نسبت به متغیرهای w, ρ_i بصورت

$$\begin{aligned} \sum_{i=1}^n \frac{x_i (x_i^{\top} w^* - y_i)}{\rho_i^*} + \frac{w^*}{\sigma_w^2} + \sum_{i=1}^n \theta_i 2\sigma_i^2 w^* &= 0 \\ \frac{1}{2} \frac{-(y_i - x_i^{\top} w^*)^2}{(\rho_i^*)^2} + \frac{1}{2} \frac{1}{\rho_i^*} - \theta_i &= 0 \end{aligned} \quad (172-3)$$

نوشته شود. با استفاده از (۱۷۲-۳)، داریم

$$\mathcal{V} := \sum_{i=1}^n \frac{\sigma_i^2 (y_i - x_i^{\top} w^*)^2}{(\rho_i^*)^2} = \sum_{i=1}^n \frac{\sigma_i^2}{\rho_i^*} - \sum_{i=1}^n 2\theta_i \sigma_i^2 \quad (173-3)$$

با استفاده از شرایط کافی مرتبه دوم $\nabla^2 L \succ 0$ ، باید حداقل داشته باشیم:

$$\begin{aligned}\nabla_{w,w}^2 L &= \sum_{i=1}^n \frac{x_i x_i^\top}{\rho_i^*} + \left(\frac{1}{\sigma_w^2} + \sum_{i=1}^n \theta_i 2\sigma_i^2 \right) I \succ 0 \\ \nabla_{\rho_i, \rho_i}^2 L &= \frac{2(y_i - x_i^\top w^*)^2 - (\rho_i^*)}{2(\rho_i^*)^3} \succ 0, \forall i\end{aligned}\quad (۱۷۴-۳)$$

بدلیل اینکه، ما فرض می کنیم w^* به اندازه کافی رگولاریزه شده است، در نتیجه $\sum_{i=1}^n \theta_i 2\sigma_i^2 \geq 0$.

بنابراین، اولین شرط در (۱۷۴-۳) توسط (۱۷۳-۳) ارضاء می شود.

$$\mathcal{V} = \sum_{i=1}^n \frac{\sigma_i^2 (y_i - x_i^\top w^*)^2}{(\rho_i^*)^2} \leq \sum_{i=1}^n \frac{\sigma_i^2}{\rho_i^*} \leq \sum_{i=1}^n \frac{\sigma_i^2}{\sigma^2} \quad (۱۷۵-۳)$$

از دومین شرط (۱۷۴-۳)، خواهیم داشت:

$$(y_i - x_i^\top w^*)^2 \geq \frac{1}{2}(\rho_i^*) \quad (۱۷۶-۳)$$

با استفاده از (۱۷۶-۳) داریم:

$$\mathcal{V} = \sum_{i=1}^n \frac{\sigma_i^2 (y_i - x_i^\top w^*)^2}{(\rho_i^*)^2} \geq \frac{1}{2} \sum_{i=1}^n \frac{\sigma_i^2}{\rho_i^*} \quad (۱۷۷-۳)$$

فرض کنید

$$A = \sum_{i=1}^n \frac{x_i x_i^\top}{\rho_i^*} + \left(\frac{1}{\sigma_w^2} + \sum_{i=1}^n \frac{\sigma_i^2}{\rho_i^*} \right) I$$

با استفاده از (۱۷۲-۳)، داریم:

$$w^* = A^{-1} \sum_{i=1}^n \frac{x_i y_i}{\rho_i^*} + A^{-1} \mathcal{V} w^* \quad (۱۷۸-۳)$$

قرار بدهید

$$B = \sum_{i=1}^n \frac{x_i x_i^\top}{\sigma^2} + \sigma_{w^*}^{-2} I$$

کمینه سازی تابع h' در (۳-۱۶۸)، خواهیم داشت:

$$\tilde{w} = B^{-1} \sum_{i=1}^n \frac{x_i y_i}{\sigma^2} \quad (۳-۱۷۹)$$

با استفاده از روابط (۳-۱۷۸) و (۳-۱۷۹) و همینطور نامساوی مثلثی خواهیم داشت:

$$\|w^* - \tilde{w}\| \leq \|A^{-1} \sum_{i=1}^n \frac{x_i y_i}{\rho_i^*} - B^{-1} \sum_{i=1}^n \frac{x_i y_i}{\sigma^2}\| + \|A^{-1} \mathcal{V} w^*\|$$

قراردهید: $\mathcal{W} = B \sum_{i=1}^n \frac{x_i y_i}{\rho_i^*} - A \sum_{i=1}^n \frac{x_i y_i}{\sigma^2}$. با استفاده از (۳-۱۷۵) و نامساوی کوشی-شوارتز داریم:

$$\|w^* - \tilde{w}\| \leq \|A^{-1}\| \|B^{-1}\| \|\mathcal{W}\| + \|A^{-1}\| \left\{ \sum_{i=1}^n \frac{\sigma_i^2}{\sigma^2} \right\} \|w^*\|$$

با کمی ساده سازی، براحتی دیده می شود که

$$\mathcal{W} = \sum_{i=1}^n \sum_{j=1}^n D_{ij} \left\{ \frac{1}{\rho_i^*} - \frac{1}{\rho_j^*} \right\} + \frac{1}{\sigma_w^2} \sum_{i=1}^n x_i y_i \left\{ \frac{\sigma^2 - \rho_i^*}{\sigma^2 (\rho_i^*)} \right\}$$

که در آن $D_{ij} = \frac{(x_j x_j^T + \sigma_j^2 I) x_i y_i}{\sigma^2}$. بنابراین،

$$\|\mathcal{W}\| \leq \{D_x + N_x\} \|w^*\|^2$$

به سادگی می توان دید که

$$\|A^{-1}\| = \lambda_{\max}(A^{-1}) \leq \sigma_w^2, \|B^{-1}\| = \lambda_{\max}(B^{-1}) \leq \sigma_{w*}^2$$

با استفاده از این مقادیر، به این نتیجه می رسیم که

$$\frac{\|w^* - \tilde{w}\|}{\|w^*\|} \leq \sigma_w^2 \sigma_{w*}^2 (D_x + N_x) \|w^*\| + \sigma_w^2 \left\{ \sum_{i=1}^n \frac{\sigma_i^2}{\sigma^2} \right\}$$

□

محاسبه حد، نشان می دهد که $\lim_{\sigma_1, \dots, \sigma_n \rightarrow 0} \|w^* - \tilde{w}\| = 0$.

به دلیل اینکه $\tilde{w}$ به اندازه کافی به w^* نزدیک است، می توانیم از مقدار آن برای تقریب w^* برای محاسبه $\tilde{\mathbf{P}}$ استفاده کنیم و

براساس قضیه بالا و قضیه ۱.۳.۳، فاصله بین $\tilde{\mathbf{P}}$ و $\mathbf{P}$ به اندازه کافی به ازاء هر مقدار از y_u کوچک است. چون $e^{-h(w^*; y, x)}$

و $e^{-h'(w^*; \mathbf{y}, \mathbf{x})}$ بسیار بیشتر از g نسبت به $\mathbf{y}_{\mathcal{U}}$ تغییر می کنند، ما از $\min_{\mathbf{y}_{\mathcal{U}}} \min_w h'(w; \mathbf{y}, \mathbf{x})$ برای تقریب استفاده می کنیم. فرض کنید K ماتریس کرنل باشد و همچنین $L = (K + \sigma_w^{-2} I)^{-1} K (K + \sigma_w^{-2} I)^{-1}$ ، آنگاه قضیه ذیل تخمین تابع هدف را تعیین می کند:

قضیه ۴.۳.۳. فرض کنید،

$$\tau = \mathbf{y}_{\mathcal{L}}^{\top} (L_{ll} - L_{lu} L_{uu}^{-1} L_{ul}) \mathbf{y}_{\mathcal{L}}$$

$$\kappa_i = (\sigma^2 + \sigma_i^2 \tau)^{-1}$$

$$\Upsilon = \text{diag}(\kappa)$$

$$\mathcal{S} = \Upsilon - \Upsilon \left\{ \sigma_w^2 (K^{-1} + \sigma_w^2 \Upsilon)^{-1} \right\} \Upsilon$$

داریم:

$$\tilde{\mathbf{P}}(\mathbf{y}|\mathbf{x}) \propto \exp\left(-\frac{1}{2} \mathbf{y}^{\top} \mathcal{S} \mathbf{y}\right)$$

برهان. برای محاسبه $\tilde{\mathbf{P}}$ مشابه (۱۶۳-۳)، ابتدا تخمین $v^2 = \|\tilde{w}\|^2$ را محاسبه می کنیم که در آن، $\tilde{w} = \arg \min_w h'(w; \mathbf{y}, \mathbf{x})$ براساس لم ۲.۳.۳ است. فرض کنید $X = [x_1, x_2, \dots, x_n]$ ، روشن است که $\tilde{w} = (X X^{\top} + \sigma_{w*}^{-2} I)^{-1} X \mathbf{y}$ بنابراین

$$v^2 = \|\tilde{w}\|^2 = \mathbf{y}^{\top} X^{\top} (X X^{\top} + \sigma_{w*}^{-2} I)^{-1} (X X^{\top} + \sigma_{w*}^{-2} I)^{-1} X \mathbf{y}$$

با استفاده از L و تساوی [۱۰۱]

$$P B^{\top} (B P B^{\top} + R)^{-1} = (P^{-1} + B^{\top} R^{-1} B)^{-1} B^{\top} R^{-1} \quad (۱۸۰-۳)$$

داریم:

$$\begin{aligned} \|\tilde{w}\|^2 &= \mathbf{y}^{\top} (X^{\top} X + \sigma_{w*}^{-2} I)^{-1} X^{\top} X (X^{\top} X + \sigma_{w*}^{-2} I)^{-1} \mathbf{y} \\ &= \mathbf{y}_{\mathcal{L}}^{\top} L_{ll} \mathbf{y}_{\mathcal{L}} + 2 \mathbf{y}_{\mathcal{L}}^{\top} L_{lu} \mathbf{y}_{\mathcal{U}} + \mathbf{y}_{\mathcal{U}}^{\top} L_{uu} \mathbf{y}_{\mathcal{U}} \end{aligned}$$

با کمینه سازی آن نسبت به $\mathbf{y}_U$ ، خواهیم داشت:

$$\mathbf{y}_U = -H_{uu}^{-1}H_{ul}\mathbf{y}_L$$

و همینطور

$$v^2 = \|\tilde{w}\|^2 \geq \mathbf{y}_L^\top (L_{ll} - L_{lu}L_{uu}^{-1}L_{ul})\mathbf{y}_L \equiv \tau$$

برای محاسبه $\tilde{\mathbf{P}}(\mathbf{y}|\mathbf{x})$ ، ابتدا محاسبه می کنیم که

$$\begin{aligned}\tilde{\mathbf{P}}(\mathbf{y}, w|\mathbf{x}) &= \tilde{\mathbf{P}}(\mathbf{y}|\mathbf{x}, w)\mathbf{P}(w) \\ &= \mathbf{P}(w) \prod_{i=1}^n \mathcal{N}(y_i; w^\top x_i, \sigma^2 + \sigma_i^2 \tau^2) \\ &\propto \exp\left(-\frac{1}{2}\left\{\sum_i \kappa_i (y_i - w^\top x_i)^2 + \sigma_w^{-2} \|w\|^2\right\}\right)\end{aligned}$$

فرض کنید

$$\begin{aligned}M &= \left\{\sigma_w^{-2}I + \sum_i \kappa_i x_i x_i^\top\right\} \\ \nu &= M^{-1} \sum_i \kappa_i y_i x_i\end{aligned}$$

با کامل کردن مربعات، داریم:

$$\tilde{\mathbf{P}}(\mathbf{y}|\mathbf{x}) = \int \tilde{\mathbf{P}}(\mathbf{y}, w|\mathbf{x}) dw \propto \exp\left(-\frac{1}{2}\left\{\sum_i \kappa_i y_i^2 - \|\nu\|_M^2\right\}\right)$$

با کمی ساده سازی

$$\sum_i \kappa_i y_i^2 - \|\nu\|_M^2 = \mathbf{y}^\top \left\{ \Upsilon - \Upsilon X^\top M^{-1} X \Upsilon \right\} \mathbf{y}$$

با استفاده از تساوی Woodbury و $K = X^\top X$ ، بدست می آید که

$$X^\top M^{-1} X = \sigma_w^2 \{X^\top X - X^\top X (\sigma_w^{-2} \Upsilon^{-1} + X^\top X)^{-1} X^\top X\}$$

□ مجدداً با استفاده از Woodbury [۱۰۱]، خواهیم داشت: $\mathcal{S} = \Upsilon \left\{ \sigma_w^2 (K^{-1} + \sigma_w^2 \Upsilon)^{-1} \right\} \Upsilon$

تابع هدف نهایی برای رویکرد یادگیری فعال بیشینه کمینه احتمالاتی مقاوم^۱ یا بصورت اختصار PMARL برابر است با

$$Q = \arg \min_{\{Q, |Q|=b\}} \max_{y \in Q} \min_{y \in U} y^T S y \quad (۱۸۱-۳)$$

خوشبختانه به دلیل اینکه این تابع هدف درجه دو است، براحتی وقتی که $b = 1$ می توانیم Q را محاسبه کنیم.

کاربردهای جهان-واقعی بسیاری برای مسئله یادگیری فعال مقاوم وجود دارد. یکی از این کاربردها، یادگیری فعال روی توزیع است. تابع هدف (۱۸۱-۳) می تواند برای یادگیری فعال روی توزیع بصورت مستقیم استفاده شود. به این منظور کافیت قرار دهیم: $\sigma_i = \beta n_i^{-\frac{1}{2}}$ و $\Upsilon = \text{diag}(1 \otimes (\sigma^2 + \sigma_I \tau))$ ، که در آن β یک پارامتر است. این روش را یادگیری فعال بیشینه کمینه مقاوم روی توزیع با استفاده تشابه^۲ یا بصورت اختصار PMARLDS می نامیم.

۴.۳.۳ یادگیری فعال مقاوم روی توزیع با استفاده از یادگیری بیزی نهفته سازی کرنل

به منظور روشن شدن تفاوت، در این بخش نقاطی که روی آنها یادگیری انجام می شود را مثال^۳ می نامیم و نقاطی که عضو یک نمونه برداشته شده از توزیع هستند را نقطه می نامیم. تعدادی توزیع، $P_i, i \in \{1, \dots, n\}$ به عنوان مثال در اختیار داریم. برای هر توزیع P_i یک نمونه $x_i = \{x_i^1, x_i^2, \dots, x_i^{n_i}\}$ که از آن نمونه برداری شده است، در اختیار داریم. هر عضو این نمونه یک بردار است. بعبارت دیگر $x_i^u \in \mathbb{R}^d, \forall u \in [1, n_i]$.

نهفته سازی کرنل توزیع P_i با استفاده از تابع کرنل k عبارتست از

$$\mu_{P_i}^* := \int_{\mathcal{Z}} k(x, \cdot) dP_i(z)$$

که در آن k یک تابع کرنل پیوسته، محدود و معین مثبت است [۸۰]. نهفته سازی تجربی کرنل برای توزیع P_i عبارتست از

$$\hat{\mu}_{P_i} = \frac{1}{n_i} \sum_{j=1}^{n_i} k(x_i^j, \cdot) \quad (۱۸۲-۳)$$

فرض کنید $\mathcal{H}$ فضای هیلبرت منتسب به تابع کرنل k باشد، $\mu(x)$ به معنی ارزیابی μ در محل x است. بصورت خاص برای یک مقدار مشخص x داریم، مقدار

$$\hat{\mu}_{P_i}(x) = \frac{1}{n_i} \sum_{j=1..n_i} k(x_i^j, x) \quad (۱۸۳-۳)$$

به عنوان ارزیابی نهفته سازی تجربی نسبت به توزیع P_i در محل x است.

لازم است مقدار $p(\mathbf{y}|\hat{\mu}_P)$ را محاسبه کنیم. نهفته سازی $\hat{\mu}_P$ بهترین تخمین برای توزیع P نیست [۸۹]. اخیراً نشان داده شد می توانیم نهفته سازی های کرنل دقیقتری با یک معیار عدم قطعیت در فضای هیلبرت با استفاده از یک قالب کاری بیزین بدست آوریم. [۴۰]. ما از این قالب کاری برای در نظر گرفتن عدم قطعیت در تخمین نهفته سازی کرنل برای توزیع استفاده می کنیم. فرض کنید k_θ یک تابع کرنل معین مثبت با پارامتر θ باشد، نهفته سازی کرنل بیزی پیشنهاد می کند به منظور اینکه مطمئن شویم که نهفته سازی کرنل در فضای کرنل مربوطه قرار میگیرد، بعبارت دیگر، $\mu^* \in \mathcal{H}_k$ [۴۰] احتمال پیشین روی μ^* را به شکل ذیل تعریف کنیم:

$$\mu^*|\theta \sim \mathcal{GP}(0, r_\theta(.,.)),$$

$$r_\theta(x, y) = \int k_\theta(x, u)k_\theta(u, y)du \quad (۱۸۴-۳)$$

که در آن $\mathcal{GP}$ یک فرایند گوسی است. انتخاب r_θ تضمین می کند که $\mu_{P_i}^* \in \mathcal{H}$ [۴۰]. θ پارامتر تابع کرنل است و از این پس به منظور سادگی آن را در روابط نشان نخواهیم داد.

لم ذیل احتمال یک برچسب برای مثال P_i با فرض مقدار نهفته سازی کرنل برای مثال P_i در هر محل $x_i^t, t \in [1, n_i]$ را تعیین می کند.

لم ۵.۳.۳. فرض کنید r تابع کرنل مطابق با (۱۸۴-۳) باشد و $r_{xx} = r(x, x)$ و $R^i = [r(x_i^t, x_i^v)]_{t,v=1}^n$. همچنین

$$R_x^i = [r(x, x_i^1), r(x, x_i^2), \dots, r(x, x_i^n)]^T$$

بعلاوه فرض کنید

$$B_i = (R^i + (\rho^2/n_i)I_n)^{-1}R_x^i$$

$$C_i = r_{xx} - R_x^i (R^i + (\rho^2/n_i)I_n)^{-1} R_x^i \quad (۱۸۵-۳)$$

بافرض یک مدل خطی $y_i = w^T \mu_{P_i}^* + \epsilon, \epsilon \sim \mathcal{N}(0, \sigma^2)$ داریم:

$$\mathbf{P}(y_i | \hat{\mu}_{P_i}(x_i), w)$$

$$\propto \sigma_i(w)^{1/2} \exp\left(-\frac{1}{2\sigma_i(w)}(y_i - w^T B_i \hat{\mu}_{P_i}(x_i))^2\right)$$

$$\sigma_i(w) = \sigma^2 + w^T C_i w \quad \text{که در آن}$$

برهان. براساس قضیه ۱.۱.۲ واریانس تابع likelihood function $\mathbf{P}(\hat{\mu}_{P_i}(x) | \mu_{P_i}^*(x))$ متناسب با $n_i^{-\frac{1}{2}}$ است. بنابراین، می توانیم فرض کنیم که این تابع برابر است با

$$\mathbf{P}(\hat{\mu}_{P_i}(x) | \mu_{P_i}^*(x)) = \mathcal{N}(\hat{\mu}_{P_i}(x); \mu_{P_i}^*(x), \rho^2/n_i) \quad (۱۸۶-۳)$$

که در آن ρ یک پارامتر است. این موضوع همچنین در [۴۰] براساس قضیه حد مرکزی اثبات شده است.

با استفاده از یک نتیجه ساده در فرایندهای گوسی^۱ [۱۱۱]، توزیع پسین برابر است با

$$\mathcal{N}(\mu_{P_i}^*(x); B_i^T \hat{\mu}_{P_i}(x), C_i)$$

کمیت $\mu_{P_i}^*$ ، مجهول است. بنابراین با محاسبه حاشیه نسبت به $\mu_{P_i}^*$ به همراه فرض مدل خطی $y_i = w^T \mu_{P_i}^* + \epsilon, \epsilon \sim \mathcal{N}(0, \sigma^2)$

خواهیم داشت:

$$\mathbf{P}(y_i | \hat{\mu}_{P_i}(x_i), w)$$

$$= \int \mathbf{P}(y_i | \mu_{P_i}^*, w) \mathbf{P}(\mu_{P_i}^* | \hat{\mu}_{P_i}(x_i)) d\mu_{P_i}^*$$

$$= \int \mathcal{N}(y_i; w^T \mu_{P_i}^*, \sigma^2) \mathcal{N}(\mu_{P_i}^*; \hat{\mu}_{P_i}(x_i), C_i) d\mu_{P_i}^*$$

$$\propto (\sigma^i(w))^{-\frac{1}{2}} \exp\left(-\frac{1}{2} \frac{(y_i - w^T B_i \hat{\mu}_{P_i}(x_i))^2}{\sigma^i(w)}\right)$$

□

¹Gaussian Processes

اگر توزیع P_i دارای کوواریانس بزرگ C_i به این معنی باشد که مقدار $w^T C_i w$ بزرگ شود، در نتیجه اثر آن روی طبقه بند، کم خواهد بود. بنابراین احتمال انتخاب P_i برای پرس وجو در یادگیری فعال می باید کم باشد. با نگاهی به رابطه (۳-۱۸۵) می بینیم که می توانیم بینشی در مورد زمانیکه این اتفاق می افتد بدست آوریم. این اتفاق زمانی رخ می دهد که مقدار نرمال شده R_x^i یعنی $(R^i + (\rho/n_i)I)^{-1/2} R_x^i$ تقریباً بر w در فضای هیلبرت عمود است.

به منظور محاسبه $\mathbf{P}(\mathbf{y}|\hat{\mu}_{\mathbf{P}})$ داریم:

$$\mathbf{P}(\mathbf{y}|\hat{\mu}_{\mathbf{P}}(\mathbf{x})) = \int \mathbf{P}(\mathbf{y}|\hat{\mu}_{\mathbf{P}}(\mathbf{x}), w) p(w) dw \quad (۳-۱۸۷)$$

مشابه ۳.۳.۳ این انتگرال رام نشدنی است و لازم است راهی برای محاسبه کارآمد تخمین آن پیدا کنیم.

مسئله اکنون این است که چگونه یک حدپایین تنگ برای τ_i for $w^T C_i w + \sigma^2$ پیدا کنیم. در اینجا کمینه ترین مقدار برای $w^T C_i w$ را از شرایط ساده تری تخمین می زنیم. در این شرایط ساده تر فرض می کنیم هیچ عدم قطعیتی برای هر توزیع وجود ندارد و بنابراین توزیع با میانگین آن در فضای هیلبرت مشخص می شود. طبیعتاً وقتی C_i ثابت است با در نظر گرفتن عدم قطعیت برای هر توزیع P_i ، مقدار $w^T C_i w$ افزایش پیدا نخواهد کرد زیرا این خود معیاری برای پیچیدگی w است. قضیه ذیل حدپایین τ_i برای $w^T C_i w$ را تعیین می کند.

قضیه ۳.۳.۶. فرض کنید $\mathcal{U}$ داده های بدون برچسب و $\mathcal{L}$ داده های برچسب داری باشد که برای آنها برچسب معلوم $\mathcal{Y}_{\mathcal{L}}$ را در اختیار داریم. بدون از دست دادن تعمیم پذیری فرض کنید $\mathbf{y} = (\mathbf{y}_{\mathcal{L}}, \mathbf{y}_{\mathcal{U}})$ که در آن $\mathbf{y}_{\mathcal{U}}$ مجهول است. بعلاوه فرض کنید نهفته سازی کرنل از طریق نمونه ها باعث ساده تر شدن $\mathbf{P}(\mathbf{y}|\hat{\mu}_{\mathbf{P}}(\mathbf{x}))$ نشود. آنگاه $\mathbf{P}(\mathbf{y}|\hat{\mu}_{\mathbf{P}}(\mathbf{x}))$ در رابطه (۳-۱۸۷) دارای حدپایین تنگ ذیل است:

$$\tilde{\mathbf{P}}(\mathbf{y}|\hat{\mu}_{\mathbf{P}}(\mathbf{x})) \leq \mathbf{P}(\mathbf{y}|\hat{\mu}_{\mathbf{P}}(\mathbf{x})) \quad (۳-۱۸۸)$$

این حدپایین متناسب است با

$$\tilde{\mathbf{P}}(\mathbf{y}|\hat{\mu}_{\mathbf{P}}(\mathbf{x})) \propto \exp(-\frac{1}{2} \mathbf{y}^T \mathcal{S} \mathbf{y})$$

$$\mathcal{S} = \Upsilon - \sigma_w^2 \Upsilon \left\{ K_{\mu}^B - K_{\mu}^B \{ \sigma_w^{-2} \Upsilon^{-1} + K_{\mu}^B \}^{-1} K_{\mu}^B \right\} \quad (۳-۱۸۹)$$

فرض کنید $\mu_{R_i} = (R^i + (\tau^2/n_i)I_n)^{-1}\hat{\mu}_{P_i}(x_i)$ آنگاه K_μ^B یک ماترس با المان های

$$K_\mu^B(i, j) = [\mu_{R_i}^\top R^{ij} \mu_{R_j}]$$

9

$$\Upsilon = \Upsilon = \text{diag}(1 \oslash \tau), \quad \tau_i = \mathbf{y}_{\mathcal{L}}^\top (H_{ll} - H_{lu} H_{uu}^{-1} H_{ul}) \mathbf{y}_{\mathcal{L}}$$

که درآن

$$\begin{aligned} L^t &= (K_\mu^B + \sigma_w^{-2} I)^{-1} E^t (K_\mu^B + \sigma_w^{-2} I)^{-1} \\ E^t &= K_\mu^B - P_t^\top (R^t + (\tau^2/n_t) I_n)^{-1} P_t \\ P_t &= [R^{ti} \mu_{R_i}]_{i=1}^n \in \mathbb{R}^{n_t \times n} \end{aligned} \quad (۱۹۰-۳)$$

است. آنگاه داریم: $\tau_i = y_l^\top \{L_{ll}^i - L_{ul}^{i\top} (L_{uu}^i)^{-1} L_{ul}^i\} y_l$. این حدپایین تنگ است به این معنی که برچسب $y_u \in [-1, 1]^{n_u}$ وجود دارد که مقدار $\mathbf{P}(\mathbf{y}|\hat{\mu}_{\mathbf{P}}(\mathbf{x}))$ برابر با این حد پایین خواهد بود.

برهان. برای محاسبه $\tilde{\mathbf{P}}$ ، لازم است که مقدار $v_i^2 = \tilde{w}^\top C_i \tilde{w}$ را ارزیابی کنیم. ابتدا باید تخمینی از $\tilde{w}$ بزنیم. فرض کنید

$$\begin{aligned} \hat{\mu}_{\mathbf{B}}(\mathbf{x}) &= [\hat{\mu}_{B_1}(x_1), \dots, \hat{\mu}_{B_n}(x_n)]^\top \\ K_\mu^B &= \hat{\mu}_{\mathbf{B}}(\mathbf{x}) \hat{\mu}_{\mathbf{B}}(\mathbf{x})^\top \end{aligned}$$

براساس لم، خواهیم داشت: ۲.۳.۳،

$$\tilde{w} = \arg \min_w h'(w; \mathbf{y}, \hat{\mu}_{\mathbf{P}}(\mathbf{x})) = (K_\mu^B + \sigma_{w*}^{-2} I)^{-1} \hat{\mu}_{\mathbf{B}}(\mathbf{x}) \mathbf{y}$$

با جایگذاری $\hat{\mu}_{B_i}(x_i)$ با استفاده از μ_{R_i} و $R^{i*} R^{j* \top} = R^{ij}$ داریم: $K_\mu^B = [\mu_{R_i}^\top R^{ij} \mu_{R_j}]$. فرض کنید $K_{reg} = K_\mu^B + \sigma_{w*}^{-2} I$ داریم:

$$\|\tilde{w}\|_{C_t}^2 = \{\hat{\mu}_{\mathbf{B}}(\mathbf{x}) \mathbf{y}\}^\top (K_{reg})^{-1} C_t (K_{reg})^{-1} \hat{\mu}_{\mathbf{B}}(\mathbf{x}) \mathbf{y}$$

قرار بدهید $E^t = \hat{\mu}_{\mathbf{B}}(\mathbf{x})^\top C_t \hat{\mu}_{\mathbf{B}}(\mathbf{x})$ ، ب استفاده از تساوی (۳-۱۸) و L^t ، نتیجه می شود که

$$\begin{aligned}\|\tilde{w}\|_{C_t}^2 &= \mathbf{y}^\top (K_\mu^B + \sigma_{w*}^{-2} I)^{-1} E^t (K_\mu^B + \sigma_{w*}^{-2} I)^{-1} \mathbf{y} \\ &= \mathbf{y}^\top L^t \mathbf{y} = \mathbf{y}_{\mathcal{L}}^\top L_{ll}^t \mathbf{y}_{\mathcal{L}} + 2 \mathbf{y}_{\mathcal{L}}^\top L_{lu}^t \mathbf{y}_{\mathcal{U}} + \mathbf{y}_{\mathcal{U}}^\top L_{uu}^t \mathbf{y}_{\mathcal{U}}\end{aligned}$$

با کمینه سازی آخرین تساوی نسبت به مقادیر مجهول $\mathbf{y}_{\mathcal{U}}$ ، خواهیم داشت:

$$\|\tilde{w}\|_{C_t}^2 \geq \mathbf{y}_{\mathcal{L}}^\top L_{ll}^t \mathbf{y}_{\mathcal{L}} - \mathbf{y}_{\mathcal{L}}^\top L_{lu}^t (L_{uu}^t)^{-1} L_{ul}^t \mathbf{y}_{\mathcal{L}} \equiv \tau_t$$

قرار دادن B_i ، $\hat{\mu}_{\mathbf{B}}(\mathbf{x})$ و استفاده از μ_{R_i} ، به دست می آید که

$$\begin{aligned}E^t(i, j) &= \hat{\mu}_{\mathbf{B}}(\mathbf{x})^\top C_t \hat{\mu}_{\mathbf{B}}(\mathbf{x})(i, j) = \hat{\mu}_{P_i}(x_i)^\top B_i C_t B_j^\top \hat{\mu}_{P_j}(x_j) \\ &= \hat{\mu}_{P_i}(x_i)^\top \left\{ (R^i + (\rho^2/n_i) I_n)^{-1} R^{i*} \right\} C_t \\ &\quad \left\{ (R^j + (\rho^2/n_j) I_n)^{-1} R^{j*} \right\}^\top \hat{\mu}_{P_j}(x_j) \\ &= \mu_{R_i}^\top R^{i*} C_t R^{j*} \mu_{R_j}\end{aligned}$$

نتیجه $R_\theta^{i*} C_t R_\theta^{j*}$ می تواند بصورت ذیل ساده شود:

$$\begin{aligned}R^{i*} C_t R^{j*} &= R^{i*} \left\{ R^{**} - R^{t*} (R^t + (\rho^2/n_t) I_n)^{-1} R^{t*} \right\} R^{j*} \\ &= R^{ij} - R^{it} (R^t + (\rho^2/n_t) I_n)^{-1} R^{tj}\end{aligned}\quad (۳-۱۹۱)$$

آنگاه

$$\begin{aligned}E^t(i, j) &= \mu_{R_i}^\top \{ R^{ij} - R^{it} (R^t + (\rho^2/n_t) I_n)^{-1} R^{tj} \} \mu_{R_j} \\ &= K_\mu^B(i, j) - \mu_{R_i}^\top R^{it} (R^t + (\rho^2/n_t) I_n)^{-1} R^{tj} \mu_{R_j}\end{aligned}$$

با استفاده از P_t خواهیم داشت:

$$E^t = K_\mu^B - P_t^\top (R^t + (\rho^2/n_t) I_n)^{-1} P_t$$

بنابراین

$$\tilde{\mathbf{P}}(\mathbf{y}|\hat{\mu}_{\mathbf{P}}(\mathbf{x}), w) = \prod_{i=1}^n \tilde{\mathbf{P}}(y_i|\hat{\mu}_{P_i}(x_i), w) \propto \exp(-\frac{1}{2}H)$$

که در آن

$$H = \sum_{i=1}^{n_i} \kappa_i (y_i - w^T \hat{\mu}_{B_i}(x_i))^2$$

مشابه قضیه ۴.۳.۳، با قراردادن

$$M = \sigma_w^{-2} I + \sum_{i=1}^{n_i} \kappa_i \hat{\mu}_{B_i}(x_i) \hat{\mu}_{B_i}(x_i)^T$$

کامل کردن مربع و ساده سازی با استفاده از $K_{\mu}^B = \hat{\mu}_{\mathbf{B}}(\mathbf{x}) \hat{\mu}_{\mathbf{B}}(\mathbf{x})^T$ نتیجه می شود:

$$\begin{aligned} \tilde{\mathbf{P}}(\mathbf{y}|\hat{\mu}_{\mathbf{P}}(\mathbf{x})) &= \int \tilde{\mathbf{P}}(\mathbf{y}|\hat{\mu}_{\mathbf{P}}(\mathbf{x}), w) \mathbf{P}(w) dw \\ &\propto \exp\{-\frac{1}{2} \mathbf{y}^T \mathcal{S} \mathbf{y}\} \end{aligned}$$

□

این نتیجه از نظر شهودی بسیار معنا دار است زیرا اساسا شباهت بین دو توزیع (i, j) برای انتخاب برچسب توزیع t را

براساس یک معیار مشترک یعنی متریک موجود در توزیع t بیان می کند.


فصل ۴

آزمایشها

در این فصل به بررسی عملکرد روشهای پیشنهادی می پردازیم. در ابتدا به عملکرد روش پیشنهادی رویکرد گرادیان تابعی به یادگیری بیشینه-کمینه فعال احتمالاتی می پردازیم. سپس در بخش ۳.۰.۴ به بررسی عملکرد روش پیشنهادی یادگیری فعال روی توزیع می پردازیم.

۱.۰.۴ آزمایشهای مربوط به رویکرد گرادیان تابعی


هدف از این آزمایشها بررسی کارآمدی روش پیشنهادی نسبت به سایر استراتژی های مطرح در یادگیری فعال است. بنابراین مجموعه ای از آزمایشها طراحی شد که تعیین کند آیا روش پیشنهادی مبتنی بر یادگیری بیشینه-کمینه احتمالاتی مکانیزم انتخاب بهتری نسبت به سایر روشهای یادگیری فعال و همچنین نسبت به روشهای مبتنی بر boosting ارائه می دهد. به این منظور آزمایشها را روی مجموعه بزرگی از پایگاه داده های پرکاربرد در مقالات و مسائل یادگیری ماشین انجام دادیم.



شکل ۱.۴: مقایسه کارایی الگوریتم پیشنهادی و سایر الگوریتم‌ها روی پایگاه داده‌های مختلف

آزمایشها روی پایگاه داده‌های مختلف

در این بخش مجموعه‌ای از آزمایشها برای نشان دادن کارآمدی روش پیشنهادی در مقایسه با سایر استراتژی‌های یادگیری فعال روی تعداد زیادی از پایگاه داده‌ها انجام می‌شود. هدف آنستکه موثر بودن روش پیشنهادی را در انتخاب مثال‌ها برای پرس و جو



شکل ۲۰۴: مقایسه کارایی الگوریتم پیشنهادی و سایر الگوریتم ها روی پایگاه داده های مختلف

براساس رویکرد تابعی به یادگیری فعال نشان بررسی کنیم.

در این آزمایشها روشهای ذیل بررسی شدند:

- RANDOM: نمونه برداری تصادفی که مثالها را بصورت تصادفی انتخاب می کند.

Dataset	# of Features	# of Examples	Dataset	# of Features	# of Examples
a1a	123	1605	a2a	123	2265
a3a	123	3185	a4a	123	4781
a5a	123	6414	Breast Cancer	10	683
Bupa Liver	7	345	CORDNA	8	59525
FOUR Class	2	862	GERNMAN Numer	24	1000
GISETTE	5000	6000	GLASS	10	214
IJCNN	22	49990	IMAGESEGMENT	19	2310
Ionoshpere	34	351	MUSHROOMS	22	8124
PIMA Diabettes	8	768	SONAR	60	208
phishing	68	11,055	liver-disorders	5	145

جدول ۱۰۴: خصوصیات پایگاه داده ها

- UNCERTAIN: نمونه برداری عدم قطعیت که مثالها را براساس میزان عدم قطعیت در مورد برجسب آن تعیین می کند.
- MARGIN: این روش نزدیکترین مثال به مرز جاری طبقه بند را صرفنظر از نوع برجسب آن انتخاب می کند [۱۳۷].
در اینجا، طبقه بند SVM استفاده شده با استفاده از کتابخانه LIBSVM پیاده سازی شده است.

- HARMONIC: روش هارمونیک گوسی یک روش یادگیری نیمه نظارت شده و فعال [۱۶۹] است.

- SPCTL2BOOST: روش پیشنهادی

برای ارزیابی الگوریتم، مجموعه متنوعی از پایگاه داده ها در کاربردهای مختلف را انتخاب کردیم. این پایگاه داده ها شامل پایگاه داده های UCI [۳۵] از قبیل Breast Cancer, Bupa Liver, CODRNA, COVTYPE, ECOLI, Four Class, German Numer, Gisette, Glass, IJCNN, Image Segment, Ionosphere, Mushrooms, Pima Diabettes, Sonar, Glass, IMAGESegment, Ionoshpere, MUSHROOMS, PIMA Diabettes, and Sonar ger- همچنین مجموعه پایگاه داده های دیگری که به همراه مجموعه ابزارهای libsvm ارائه می شود [۱۶] شامل پایگاه داده های- man.numer, IJCNN1, phishing, liver-disorders, a1a, a2a, a3a, a4a, a5a بکار نیز در آزمایشها استفاده کردیم. GIslette پایگاه داده دیگری است که در چالش NIPS feature بکار رفته است [۵۵]. همچنین برخی دیگر از پایگاه داده ها از منابع مشهور دیگر تهیه شده اند [۱۴۱] [۶۱]. جدول ۱۰۰۴ شامل جزئیات پایگاه داده های بکار رفته است.

در هریک از این آزمایشها، پایگاه داده را بصورت تصادفی به دو زیرمجموعه مجزا یکی برای آموزش و دیگری برای آزمون تقسیم کردیم. زیرمجموعه آزمون در طول مدت آزمایشه برای ارزیابی دقت طبقه بند استفاده شد. یادگیری فعال با یک نقطه

انتخاب شده بصورت تصادفی از هر کلاس شروع می شود تا اینکه بودجه برچسب زنی پایان یابد. وقتی که یک بودجه بزرگتر تاثیری روی دقت ندارد، بودجه برچسب زنی را به اندازه لازم کوچک کردیم. در هرتکرار از یادگیری فعال، یک مثال انتخاب شده و برچسب آن برای آموزش مجدد طبقه بند و ارزیابی طبقه بند روی زیرمجموعه آزمون بکار رفته است. کتابخانه LIBSVM برای آموزش طبقه بند و مقایسه نتایج برای همه روشها بکار برده شده است [۱۶]. مقدار پارامتر C در LIBSVM برابر یک قرار دادیم. پهنای باند کرنل RBF را با استفاده از median heuristic تعیین کردیم [۴۹]. شکل ۹۹ نتایج آزمایشها را ارائه می کند. کارآیی روش RANDOM در ابتدا در برخی از پایگاه داده ها مناسب است و در انتها می تواند دقت خوبی ارائه کند. برخی از مثالها دارای برچسب هایی هستند که توسط طبقه بند جاری به درستی شناسایی می شوند و مرز جاری طبقه بند را تغییر نمی دهند، که به آنها مثالهای بی فایده می گوئیم [۸۳]. وقتی همه مثالها، مثالهای بی فایده هستند، رویکردهای یادگیری فعال این مثالها را انتخاب می کنند که بودجه برچسب زنی را هدر می دهد. رویکرد MARGIN که پرتعدادترین رویکرد یادگیری فعال برای طبقه بند SVM است، در برخی از پایگاه داده ها بسیار خوب عمل می کند. البته در برخی از پایگاه داده ها مانند Breast و IJCNN نیز بسیار بد عمل کرده است. کارآیی روش Harmonic در برخی از پایگاه داده ها مناسب است اما در برخی از پایگاه داده ها دقت آن بسیار کاهش پیدا می کند. در نهایت، چنانکه در نتایج آزمایش دیده می شود، فرم ساده روش پیشنهادی برای تنظیمات کلی، SPCTL₂BOOST نسبت به سایر روشها راندمان بهتری ارائه می کند.

جدول (۲.۴) زمان صرف شده برای هر روش را نشان می دهد. برای این منظور، لازم است که میانگین زمان صرف شده در روش پرس وجو برای هر الگوریتم را محاسبه کنیم. چنانکه در جدول (۲.۴) دیده می شود، میزان مصرف الگوریتم پیشنهادی اغلب قابل مقایسه با MARGIN است. زمان صرف شده در روش پیشنهادی اغلب از زمان صرف شده توسط UNCERT کمتر است. زمان صرف شده در روش HARMON بیشتر از UNCERT است و بنابراین درجدول آورده نشده است.

۲.۰.۴ مقایسه با رویکردهای مبتنی بر boosting

در این بخش می خواهیم روش پیشنهادی را با سایر روشهای مبتنی بر boosting مقایسه کنیم. بنابراین یک مجموعه آزمایش طراحی شد، که تمرکز براین مقایسه باشد.

همانطور که قبلا متذکر شدیم، روش پیشنهادی می تواند به عنوان یک الگوریتم boosting که در آن مجموعه ای از طبقه

جدول ۲۰۴: زمان صرف شده توسط روشهای یادگیری فعال روی پایگاه داده های مختلف

Dataset	RANDOM	SPCTL2BOOST	MARGIN	UNCERT
a1a	0.69	8.75	2.29	44.07
a2a	0.69	8.69	2.29	43.24
a3a	0.71	8.66	2.30	43.27
a4a	0.69	8.78	2.28	43.35
a5a	0.69	8.89	2.30	43.32
breast	0.77	24.254	1.98	132.92
Bupa	0.71	36.50	1.82	69.58
CODRNA	0.69	9.07	1.83	41.71
COVTYPE	0.70	8.88	2.00	42.67
ECOLI	0.70	13.15	1.85	44.12
FOURCLASS	0.67	9.04	1.79	42.20
german	0.69	8.94	1.95	42.31
gisette	0.68	8.70	31.72	106.39
GLASS	0.70	4.36	1.73	31.62
ijcnn1	0.67	8.83	1.85	42.13
IMAGESEG	0.78	228.58	2.13	127.59
ionosphere	0.67	38.67	2.03	70.18
PIMA	0.76	328.53	2.04	146.07
sonar	0.70	9.03	2.06	40.31

بندهای ضعیف از داده ها یاد می گیرند، دیده شود. این زیربخش، روش پیشنهادی را با روش یادگیری فعال مبتنی بر boosting مقایسه می کند. چنانکه در [۱۱۷] آمده است، رویکرد boosting به یادگیری فعال، نقاطی را انتخاب می کند که کمترین فاصله را با ensemble فعلی از طبقه بندها در طبقه بند boosting دارند.

برای تعیین اینکه آیا رویکرد گرادیان تابعی به یادگیری بیشینه-کمینه احتمالاتی موثرتر از سایر روشهای مبتنی بر boosting است، سه الگوریتم را با استفاده از یک طبقه بند ضعیف مشترک با دارا بودن یک تعداد یکسان از مولفه های تابعی/طبقه بند مقایسه کردیم. روش حاصل، FUNCGRDSTAL، روش یادگیری فعال بدست آمده است. برای همه روشها از L₂Boosting [۹] استفاده کردیم. پایگاه داده های استفاده شده در کار معروف [۱۰۲] را برای این آزمایشها بکار بردیم. در اینجا روش مبتنی بر boosting را MARGINBOOST نام گذاری کردیم. تنظیمات این آزمایشها دقیقا مانند آزمایشهای قبلی است. شکل (۴.۴) نتایج آزمایشها را نشان می دهد. چنانکه روشن است روش پیشنهادی SPCTL₂BOOST کارایی بیشتری نسبت به دو روش دیگر دارد. نتایج نشان می دهند که روش پیشنهادی کارآمدتر است زیرا نقاط حاوی اطلاعات و نماینده بهتری انتخاب می کند.

مقایسه با روشهای مبتنی بر تفاوت توزیع ها

هدف بخش حاضر مقایسه روش پیشنهادی با الگوریتم های یادگیری فعالی است که تفاوت بین مجموعه های داده های برچسب دار، بدون برچسب و مجموعه پرس وجو را اندازه می گیرند. بصورت مشخص، الگوریتم پیشنهادی با دو روش جدید ذیل مقایسه

جدول ۳.۴: زمان صرف شده در الگوریتم ها روی تعدادی از پایگاه داده

Dataset	RANDOM	SPCTL2BOOST	BMDR	EXPREFINF
ionosphere	0.00076	0.00239	3.76450	1.72880
liver-disorders	0.00062	0.00101	4.09025	1.72851
sonar	0.00068	0.00106	4.29759	1.85681
phishing	0.00063	0.00103	4.66769	1.96604
a1a	0.00062	0.00122	4.72226	2.11856
a2a	0.00063	0.00094	5.16078	2.22566
a3a	0.00067	0.00104	5.19418	2.38561
a4a	0.00079	0.00158	5.55162	2.61149

شده است:

• BMDR: رویکرد پیشنهاد شده توسط [۱۵۳].

• EXPREFINF: رویکرد پیشنهاد شده توسط [۳۳].

برای این الگوریتم ها، پارامترها را براساس مقاله های اصلی، تنظیم کردیم. همه تنظیمات و همچنین تنظیمات پارامترهای روش پیشنهادی همان تنظیمات آزمایشهای قبل تعیین شدند. آزمایشها را ده بار تکرار کردیم و میانگین نتایج را گزارش کردیم. هر تکرار از یادگیری فعال، بسیار بیشتر از آزمایشها در مرحله قبل طول کشید. علت این مسئله این بود که هر دو روش BMDR و EXPREFINF نیاز به حل یک مسئله درجه دو مقید در هر تکرار دارند. مسئله های درجه دو مقید را با استفاده از mosek حل کردیم. شکل (۵.۴) نتایج آزمایشها را در مقایسه با روشهای مبتنی بر تفاوت توزیع نشان می دهد. چنانکه در شکل (۵.۴) دیده می شود، نتایج روش پیشنهادی در مقایسه با این روشها بهبود نشان می دهد.

۳.۰.۴ پایگاه داده های توزیعی

در این بخش نتایج آزمایشهای یادگیری فعال روی توزیع را بررسی می کنیم. ابتدا به منظور نشان دادن کارآمدی روش پیشنهادی در شرایط کنترل شده تعدادی آزمایش روی یک پایگاه داده سنتز شده انجام می دهیم. پس از آن تعدادی آزمایش روی داده های واقعی انجام می دهیم. در هر آزمایش نتایج روش پیشنهادی را با روشهای ذیل مقایسه می کنیم:

• DISTRAND: این روش بصورت تصادفی مثالهای توزیعی را انتخاب می کند.

• DISTQUIRE: میانگین هر توزیع را در فضای ورودی محاسبه می کنیم. سپس برای هر پرس وجو نقاط را براساس

روش Quire [۶۷] انتخاب می‌کنیم.

• DISTHARM: میانگین هر توزیع محاسبه شده و سپس مثالها با استفاده از روش هارمونیک گوسی [۱۶۹] انتخاب می‌شوند. این روش یادگیری فعال را به همراه یادگیری نیمه-نظارت شده از طریق توابع هارمونیک انجام می‌دهد.

• DISTMARGIN: با استفاده از میانگین های محاسبه شده برای هر توزیع یادگیری فعال مبتنی بر حاشیه در طبقه بند SVM، نقاط حاوی بیشترین اطلاع را انتخاب می‌کند [۱۳۷].

• HILBQUIRE: در اینجا، ما روش HILBQUIRE پیشنهاد کردیم. در این روش پیشنهادی نقاط را براساس روش QUIRE [۶۷] انتخاب می‌کنیم. در این روش ماتریس کرنل بین مثالها در QUIRE با استفاده از نهفته سازی میانگین توزیع ها محاسبه می‌شود [۸۹].

درهمه آزمایشها هر پایگاه داده بصورت تصادفی به دو پایگاه داده مجزا برای آموزش و آزمون تقسیم می‌شود. در هر مرحله از یادگیری فعال طبقه بند را براساس داده های برجسب دار آموزش داده و دقت را روی داده های آزمون گزارش می‌کنیم. طبقه بند SMM [۸۸] را با استفاده از بسته LIBSVM [۱۶] برای آموزش و آزمون روی داده های توزیعی پیاده سازی کردیم. در این آزمایشها کرنل امیدتجربی را به همراه کرنل RBF بین توزیع ها با استفاده از رابطه (۱-۲) استفاده کردیم.

برای پایگاه داده سنتزی توزیعی از پایگاه داده ارائه شده در [۸۸] استفاده کردیم. ما این پایگاه داده را GAUSSDIST می‌نامیم. دو کلاس از توزیع های گوسی برای هردو کلاس مثبت و منفی در نظر گرفته شده اند. میانگین پارامترهای این توزیع های گوسی بصورت نرمال بین $(1, 1, \dots, 1)$ و $(2, 2, \dots, 2)$ با کوواریانس $\Sigma = 0.5I$ در نظر گرفته شدند. کوواریانس این توزیع ها توسط توزیع ویشارت^۱ با کوواریانس $\Sigma^+ = 0.6I$ و $\Sigma^- = 1.2I$ با درجه آزادی 10 بدست آمدند.

30 درصد از نمونه ها را برای آزمون بصورت تصادفی انتخاب کردیم. مجموعه آموزش شامل 15° توزیع برای کلاس های مثبت و منفی بود. پارامترهای کرنل برای سطح ورودی و سطح دوم را برابر $\gamma = \gamma_{is} = 0.1$ انتخاب کردیم و پارامتر رگولاریزاسیون را برابر $\lambda = 2^{-7}$ قرار دادیم. هرآزمایش را 5° بار تکرار کردیم.

به منظور نشان دادن کارآمدی روش پیشنهادی یادگیری فعال که عدم قطعیت را در تخمین نهفته سازی کرنلی توزیعا در نظر می‌گیرد، آزمایشی با اندازه نمونه هایی کاملاً متفاوت از هر توزیع طراحی کردیم. به این منظور، اندازه نمونه 5 یا 100 بصورت

¹Wishart

تصادفی برای هر توزیع انتخاب شد. نتایج آزمایش ها را در شکل (۶.۴) ملاحظه می کنید. هنگامیکه تعداد نقاط نمونه برداری شده از هر توزیع متفاوت است، روش پیشنهادی ما PMARLDB بسیار بهتر از سایر روشها عمل می کند. دلیل این موضوع می تواند این باشد که برخی توزیعهای با اندازه نمونه بزرگ یادگیری را به سمت خود اریب می کنند.

با مدلسازی مستقیم عدم قطعیت در تخمین توزیعها، دقت روش پیشنهادی در شرایطی که عدم قطعیت زیاد است، افزایش پیدا می کند. رویکرد پیشنهادی ما، از اطلاعات عدم قطعیت در هردو وضعیت اندازه نمونه کوچک و بزرگ استفاده می کند تا توزیع های بهتری انتخاب کند. حتی وقتی تعداد نقاط نمونه برداری شده از هر توزیع مساوی و کم است، روش پیشنهادی ما، از سایر روشها بهتر عمل میکند. اگرچه HILBQUIRE در شرایط اندازه های متفاوت خوب عمل می کند، در شرایط اندازه نمونه کم دقت مناسبی ندارد. این وضعیت معمولاً وقتی رخ میدهد که عدم قطعیت بسیاری در تخمین نهفته سازی کرنل برای توزیع ها که در HILBQUIRE استفاده شده وجود دارد.

۴.۰.۴ پایگاه داده های دنیای واقعی

شناسایی ارقام دستنویس

در اینجا نتایج آزمایشهای انجام شده روی پایگاه داده ارقام دستنویس را USPSDIST [۸۸] ارائه می کنیم. این پایگاه داده یک پایگاه داده توزیعی است که از تصاویر ارقام صفر تا نه ساخته شده است. نقطه ها با استفاده از تبدیلات پایه (انتقال، تغییراندازه، دوران) روی تصاویر بدست آمده اند. هر تصویر از یک رقم، یک ماتریس 16×16 است. احتمال پیشین روی پارامترهای تبدیلات کلاسه های معادل از توزیع ها را تعیین می کند.

دو دسته از پارامترها برای تغییراندازه و انتقال استفاده کرده ایم، یکی برای محور افقی و دیگری برای محور عمودی. برای دوران یک تک پارامتر برای زاویه دوران استفاده نمودیم. مشابه [۸۸] مقادیر $\mathcal{N}([1, 1], 0.1I_2)$ و $\mathcal{N}([0, 0], 5I_2)$ و $\mathcal{N}(0, \pi)$ متناظراً برای تغییراندازه، انتقال و دوران بکار برده شدند. بصورت تصادفی زیرمجموعه ای از جفت مقادیر کلاسه های ۳-۹، ۳-۸، ۳-۴ و ۱-۸ انتخاب شدند. در هر وظیفه طبقه بندی ذکر شده، ۱۰۰ توزیع استفاده شد. باری هر توزیع P_i تعداد نقطه های تصادفی n_i براساس همان روش [۸۸] تولید شد. عدد n_i برابر $\max(1, \text{round}(\mathcal{N}(2, 10)))$ قرار داده شد.

یادگیری فعال را با دو مثال برچسب دار شروع و با ۵۰ مثال خاتمه دادیم. آزمایشها برای هر پایگاه داده ۵۰ بار تکرار شدند.

نتایج آزمایشات را در شکل (۹.۴) ملاحظه می کنید.

چنانکه در این شکل ملاحظه می کنید، حتی با واریانس کم در اندازه نمونه ها برای هر نقاط توزیعی، رویکرد این تحقیق پیاده سازی شده در روش PMARLDB از سایر روشها نتایج بهتری دارد. مقایسه روش PMARLDB با روش نمونه برداری تصادفی نشان می دهد که PMARLDB نقاط توزیعی را انتخاب می کند که برجسته آنها، به بهبود کارایی طبقه بند کمک شایانی می کنند.

بسته کلمات

در این بخش به آزمایشهای انجام شده روی تعدادی پایگاه داده متنی می پردازیم. برای نمایش هر سند، نمایش بسته کلمات^۱ را استفاده نمودیم. فرض می کنیم هر سند می تواند با استفاده از یک توزیع که کلمات از آن نمونه برداری شده اند، نمایش داده شود. هر کلمه می تواند توسط یک بردار نمایش داده شود و هر سند توسط یک توزیع از این بردارها نمایش داده می شود. بدلیل اینکه هر سند شامل تعدادی متغیر از کلمات است، مجموعه هایی با اندازه های متفاوت برای اسناد در اختیار داریم.

در اینجا، از word2vec [۸۶] برای تبدیل کلمات به بردار استفاده کردیم. در آزمایشها پایگاه داده ۲۰newsgroup^۲ که شامل بیست کلاس مختلف است را بکار بردیم. چون این پایگاه داده یک پایگاه داده چندکلاسی است، تعدادی از جفت کلاسهایی که طبقه بندی آنها دشوارتر است را انتخاب کردیم. همچنین تعداد کمتری از وظایف ساده تر را برای نمایش کارایی روش پیشنهادی در هر دو دسته وظایف سخت و آسان انتخاب کردیم.

بدلیل اینکه برخی از اسناد در این پایگاه داده تعداد کلمات بسیار زیادی دارند، اسناد با بیشتر از ۱۰۰ کلمه را حذف کردیم. سپس بصورت تصادفی ۳۰۰ سند برای هر کلاس انتخاب کردیم. شکل (۹.۴) نتایج آزمایشات را نشان می دهد. چنانکه در این شکل ملاحظه می کنید، روش پیشنهادی PMARLDB در مقایسه با تقریباً اکثر روش ها نتایج بهتری ارائه می دهد و بصورت منطقی از نمونه برداری تصادفی بهتر است.

^۱Bag of Words

^۲<http://people.csail.mit.edu/jrennie/۲۰NewsGroups/>

جدول ۴.۴: کلاسهای پایگاه داده 20newsgroup

label	class
1	alt.atheism
2	comp.graphics
3	comp.os.ms-windows.misc
4	comp.sys.ibm.pc.hardware
5	comp.sys.mac.hardware
6	comp.windows.x
7	misc.forsale
8	rec.autos
9	rec.motorcycles
10	rec.sport.baseball
11	rec.sport.hockey
12	sci.crypt
13	sci.electronics
14	sci.med
15	sci.space
16	soc.religion.christian
17	talk.politics.guns
18	talk.politics.mideast
19	talk.politics.misc
20	talk.religion.misc

۵.۰.۴ آنالیز اثر یادگیری بیزی نهفته سازی کرنلی توزیع ها

سئوالی که بطور طبیعی به ذهن متبادر می شود آنستکه آیا استفاده از یادگیری بیزی نهفته سازی کرنل توزیع ها در رویکرد یادگیری فعال روی توزیع PMARLDB باعث بهبود نتایج آن می شود یا اینکه صرفا در نظرگرفتن عدم دقت مثالها در یادگیری فعال مقاوم در فضای توزیع باعث بهبود نتایج شده اند.

از طرف دیگر روش یادگیری فعال پیشنهادی در ۳.۳.۳ می تواند در حمله به مسئله یادگیری فعال روی توزیع استفاده شود. برای تعیین خصوصیات عدم قطعیت در مثالها قضیه ۱.۱.۲ عدم قطعیت در نهفته سازی میانگین تجربی توزیع ها را بیان می کند. این عدم قطعیت می تواند با استفاده از یک توزیع گوسی با میانگین برابر میانگین نهفته سازی تجربی توزیع ها و واریانس متناسب با $\frac{1}{\sqrt{n}}$ بیان شود. این رویکرد اساسا یک نسخه با خصوصیات ضعیفی تر از روش PMARLDB است که در آن یادگیری بیزی نهفته سازی کرنل در نظر گرفته نشده است.

بعبارت دیگر، پرسش ما این است آیا روش یادگیری فعال مقاوم مربوط به بخش ۳.۳.۳ با استفاده از قضیه ۱.۱.۲ برای در نظرگرفتن عدم قطعیت در مثالها به منظور انتخاب نقاط توزیعی موثر است یا خیر.


قضیه ۱.۱.۲ اساسا می گوید که تخمین توزیع ها با استفاده از نهفته سازی میانگین توزیع ها در فضای هیلبرت دارای واریانسی از مرتبه $O(n^{-\frac{1}{2}})$ است. بنابراین می توان از فرمولاسیون بخش ۳.۳.۳ برای انتخاب مثالها استفاده کرد. چنانکه قبلا متذکر شدیم، این روش را PMARLDS مینامیم. در این بخش این روش را با روش اصلی مقاله مقایسه می کنیم تا موثر بودن روش اصلی پیشنهادی را نشان بدهیم. به این منظور آزمایش هایی روی پایگاه داده ۲۰newsgroup برای مقایسه روشهای

PMARLDB و PMARLDS انجام می دهیم. نتایج را در شکل ۱۰.۴ ملاحظه می کنید. در این شکل روشن است که روش اصلی پیشنهادی PMARLDB همیشه از روش PMARLDS بهتر است. روش PMARLDB به دلیل یادگیری همزمان نهفته سازی کرنل به روش بیزی بهبود قابل ملاحظه ای را نشان می دهد.


۱.۴ نتیجه گیری

در این فصل، یک رویکرد کلی و تئوریک یادگیری فعال ارائه کردیم. این رویکرد بویژه در شرایطی که عدم قطعیت در مثالها به همراه عدم قطعیت در مجهول بودن برجسب اکثریت مثالها وجود دارد، بسیار مفید است. وقتی مثالها نادقیق اند، نشان داده شد که در نظرگرفتن این عدم قطعیت در حین انتخاب نمونه ها در یادگیری فعال بسیار موثر است. هدف اصلی ما انتخاب مثالهای توزیعی با اندازه های متفاوت از هرتوزیع بود. به این منظور همزمان یادگیری بیزی نهفته سازی توزیع ها در فضای کرنل در حین یادگیری فعال را انجام دادیم که به یک فرمولاسیون با معنا از نظر شهودی برای مقایسه توزیعها و انتخاب آنها دست یافتیم. آزمایشها روی پایگاه داده های توزیعی و پایگاه داده های واقعی کارآمدی روش پیشنهادی را نشان دادند.


یکی از محدودیت های یادگیری روی توزیع مبتنی برکرنل این است که نمونه های برداشته شده از توزیع ها باید ذخیره سازی شوند. این بتدریج وقتی تعداد توزیع ها و نقاط نمونه برداری شده از آنها زیاد شوند، به مانع بزرگی تبدیل می شود. در آینده قصد داریم، از روشهای ویژگیهای خطی برای کاهش نیاز به ذخیره سازی برای پایگاه داده های بزرگ استفاده کنیم.




(a) ECOLI




(b) Four Class




(c) German Numer




(d) Gisette




(e) Glass




(f) IJCNN




(g) IMAGESEGMENT




(h) Ionosphere



(i) MUSHROOMS




(j) PIMA Diabetes




(k) SONAR


شکل ۳.۴: مقایسه کارایی الگوریتم پیشنهادی و سایر الگوریتم ها روی پایگاه داده های مختلف




شکل ۴.۴: مقایسه روش پیشنهادی با سایر روشهای boosting



شکل ۵.۴: مقایسه روش پیشنهادی با روشهای مبتنی بر تفاوت بین دو توزیع




(ب) نمونه با اندازه 5 برای هر توزیع




(آ) نمونه با اندازه های {5, 100} برای هر توزیع


شکل ۶.۴: مقایسه دقت طبقه بند در یادگیری فعال روی پایگاه داده GAUSSDIST برای دو حالت با اندازه نمونه متفاوت و اندازه نمونه ثابت از هر توزیع.




شکل ۷.۴: مقایسه دقت طبقه بندی برای گروهی از مجموعه پایگاه داده ۲۰newsgroup. هر شکل در بالا یک طبقه بندی بین دو کلاس با شماره کلاسهای مذکور را نشان می دهد. شماره کلاس ها در جدول ۴.۴ قرار دارند.




(a) 5 and 6




(b) 5 and 7




(c) 5 and 13




(d) 8 and 11




(e) 9 and 10




(f) 10 and 11




(g) 12 and 15




(h) 16 and 17



(i) 16 and 18




(j) 18 and 19




(k) 19 and 20

شکل ۸.۴: مقایسه دقت طبقه بندی برای گروه دیگری از مجموعه پایگاه داده ۲۰newsgroup. هر شکل در بالا یک طبقه بندی بین دو کلاس با شماره کلاسهای مذکور را نشان می دهد. شماره کلاس ها در جدول ۴.۴ قرار دارند.



شکل ۹.۴: مقایسه دقت در یادگیری فعال برای پایگاه داده USPDSDIST



شکل ۱۰.۴: مقایسه دقت طبقه بندی بین یادگیری فعال بیزی در فضای هیلبرت PMARLDS با PMARLDB برای پایگاه داده 20newsgroup. شماره کلاس ها در جدول ۴.۴ قرار دارند.

فصل ۵

نتیجه گیری

تحقیقات در حوزه یادگیری ماشین نشان می دهد که یادگیری فعال مسئله ای بنیادی در یادگیری ماشین است. بویژه از این جهت که قابل شکسته شدن به سایر مسائل مطرح در یادگیری ماشین نیست. بنظر میرسد که یادگیری فعال بخش اساسی از هر رویکردی به هدف غایی یادگیری ماشین یعنی هوش همه منظوره مصنوعی^۲ (AGI) است. در این رساله، روشی برای یادگیری فعال در سطح انتزاعی بالاتری نسبت به بردارهای ساده، در سطح توزیع، ارائه کردیم. توزیع، مفهومی فوق العاده اساسی است؛ می توان فرض کرد که اغلب پدیده ها به نوعی از یک توزیع برداشته می شوند. ارائه رویکرد یادگیری فعال روی توزیع، گامی مهم در این راستا است.

به منظور ارائه یادگیری فعال روی توزیع، ابتدا تلاش کردیم که مسئله یادگیری فعال را به شکلی اساسی و قاعده مند حل کنیم. به این منظور برخلاف تقریبا همه روشهای ارائه شده در یادگیری فعال، بر کمینه کردن ریسک در پایه ای ترین شکل تمرکز کردیم. نشان دادیم که می توان رفتار مسئله یادگیری را در حضور داده های بدون برچسب براساس هر برچسبی از یک زیرمجموعه از داده ها، بیان کرد. با این رویکرد نامساوی بدست آوردیم که رفتار مسئله یادگیری را در پایه ای ترین شکل بیان می کند.

²Artificial General Intelligence

با کمینه کردن حدبالای این نامساوی روشی برای یادگیری فعال ارائه کردیم که ریسک را کمینه می کند و بنابراین بهینه بیز^۱ است. می توان گفت که این الگوریتم، با کمترین فرض روی شرایط مسئله، تعریف ریاضیاتی مسئله یادگیری فعال در هنگامی است که داده های بدون برچسب به کمینه سازی ریسک کمک می کنند. پیش از این، چنین درکی از مسئله یادگیری فعال ارائه نشده است.

سپس به یادگیری فعال روی توزیع پرداختیم. به دلیل عدم دسترسی مستقیم به توزیع ها در مسائل دنیای واقعی، یادگیری فعال باید بر روی مثالهایی انجام شود که از آنها تخمین واقعی نداریم. رویکرد پیشنهادی بویژه در شرایطی که عدم قطعیت در مثالها به همراه عدم قطعیت در مجهول بودن برچسب اکثریت مثالها وجود دارد، بسیار مفید است. وقتی مثالها نادقیق اند، نشان داده شد که در نظرگرفتن این عدم قطعیت در حین انتخاب نمونه ها در یادگیری فعال بسیار موثر است. هدف اصلی ما انتخاب مثالهای توزیعی با اندازه های متفاوت از هرتوزیع بود. به این منظور همزمان یادگیری بیزی نهفته سازی توزیع ها در فضای کرنل در حین یادگیری فعال را انجام دادیم که به یک فرمولاسیون با معنا از نظر شهودی برای مقایسه توزیعها و انتخاب آنها دست یافتیم. آزمایشها روی پایگاه داده های توزیعی و پایگاه داده های واقعی کارآمدی روش پیشنهادی را نشان دادند.

۱.۵ پیشنهادی های آتی

دربسیاری از مسائل دنیای واقعی، امکان تهیه برچسب از جامعه بزرگی از کاربران وجود دارد. این موضوع باعث می شود که هزینه برچسب زنی بسیار کاهش یابد زیرا کاربران ممکن است تقریباً بدون هزینه اقدام به تعیین برچسب مثالها داشته باشند. اما در عوض، دقت برچسبهای این کاربران ممکن است بسیار پایین باشد. به این موضوع در یادگیری ماشین جمع سپاری^۲ می گوئیم. اخیراً تحقیقات بسیار گسترده ای در زمینه جمع سپاری صورت گرفته است. این موضوع در شرایط یادگیری فعال روی توزیع بسیارچالش زا است. توسعه ریاضیات مربوط به یادگیری فعال روی توزیع در محیط جمع سپاری مسیر را برای ارائه این الگوریتم ها هموار می کند.

یکی از محدودیت های یادگیری روی توزیع مبتنی بر کرنل این است که نمونه های برداشته شده از توزیع ها باید ذخیره سازی شوند. این بتدریج وقتی تعداد توزیع ها و نقاط نمونه برداری شده از آنها زیاد شوند، مشکلاتی در سرعت ایجاد می کند. راهکارهای

^۱Bayes Optimal

^۲Crowd-Sourcing

بسیاری برای افزایش سرعت روشهای مبتنی بر کرنل ارائه شده اند. برخی از این راهکارها به یادگیری فعال روی توزیع هم گسترش پیدا کرده اند.

در برخی از مسائل یادگیری روی توزیع، خروجی نیز یک توزیع است. این مسائل اگرچه بسیار پیچیده هستند اما کاربردهای بسیاری می توانند داشته باشند. در این کاربردها، تهیه خروجی یا عبارتی همان برچسب به دلیل اینکه ماهیت توزیعی دارد، بسیار پرهزینه تر است. بنابراین توسعه الگوریتم های یادگیری فعال در این حوزه موضوعی بسیار چالش و در عین حال بسیار مفید است. هر الگوریتم یادگیری فعال روی توزیع، مبتنی بر تخمین از توزیع و مقایسه توزیع ها است. ارائه تخمین های دقیق تری از توزیع ها براساس خصوصیات و دانشی که در مورد شباهت توزیع ها و تفاوت های آنها داریم، اهمیت فوق العاده ای در یادگیری فعال دارد. می توان روشهایی برای تخمین دقیق تر توزیع ها با استفاده از اطلاعات موجود ارائه داد. بعلاوه می توان با استفاده از اطلاعاتی جانبی از کاربر نتایج بسیار بهتری حاصل کرد.

در بسیاری از کاربردهای واقعی داده های برداری با عدم قطعیت وجود دارد. این موضوع بویژه زمانی اتفاق می افتد که در اندازه گیری در کمیت مورد نظر، خطا داریم که به آن خطای اندازه گیری^۱ می گویند. یادگیری فعال در این حوزه می تواند بسیار پرکاربرد باشد. تحقیقات چندانی در زمینه یادگیری فعال در حضور خطای اندازه گیری انجام نشده است.

رویکرد کمینه سازی ریسک تجربی به یادگیری فعال ماهیتی رام نشدنی دارد. تخمین محدب از مسئله بهینه سازی حاصل بسیار چالش آفرین و حل آن از نظر زمانی بسیار هزینه بر است. با این وجود حل مسئله با روشهای بهینه سازی نامحدب^۲ بسیار جالب توجه خواهد بود. استراتژی های بسیاری می توان در این راستا مطرح کرد که انتظار می رود برخی از آنها به جواب های بسیار خوبی در زمان های قابل قبول برای بسیاری از مسائل همگرا شوند.

^۱Measurement Error^۲Non-convex Optimization

پیوست آ

اثبات های خصوصیات تئوریک طبقه بند-ساده

پیچیده

اثبات خصوصیات تئوریک طبقه بند ساده-پیچیده

برای بررسی خواص مدل، آنرا بصورت طبقه بند با ناظر در نظر می گیریم:

$$C = \min_{w, w_o, \xi, p} \sum_{i \in D} (1 - y_i w_o^T \phi(x_i))_+ (1 - y_i w^T \phi(x_i))_+ + \frac{\lambda_o}{2} \|w_o\|^2 + \frac{\lambda}{2} \|w\|^2$$

$$\text{s.t.} \quad \forall i, |w_o^T \phi(x_i)| \leq p_i$$

$$p^T \mathbf{1} \leq n_o, p_i \in [0, 1]$$

$$\lambda \gg \lambda_o \quad (\bar{1})$$

مدل ارائه شده نامحدب است. به منظور تحلیل آن از لم ذیل استفاده می کنیم.

لم ۱ : اگر C_1, C_2 و C بصورت ذیل تعریف کنیم:

$$\begin{aligned}
 C_1 &= \min_w \sum_{i \in D} (1 - y_i w^\top \phi(x_i))_+ + \frac{\lambda}{2} \|w\|^2 \\
 w^* &= \operatorname{argmin}_w \sum_{i \in D} (1 - y_i w^\top \phi(x_i))_+ + \frac{\lambda}{2} \|w\|^2, l_i^* = (1 - y_i w^{*\top} \phi(x_i))_+ \\
 C_2 &= \min_{w_o, p} w_o^\top \left(- \sum_{i \in D} y_i l_i^* \phi(x_i) \right)_+ + \frac{\lambda_o}{2} \|w_o\|^2 \\
 \text{s.t.} \quad & \forall i, |w_o^\top \phi(x_i)| \leq p_i \\
 & p^\top \mathbf{1} \leq n_o, p_i \in [0, 1] \\
 & \lambda \gg \lambda_o
 \end{aligned} \tag{۲-آ}$$

خواهیم داشت:

$$C_1 + C_2 \leq C \tag{۳-آ}$$

اثبات:

$$\begin{aligned}
 C &= \min_{w, w_o, \xi, p} \sum_{i \in D} (1 - y_i w_o^\top \phi(x_i))_+ (1 - y_i w^\top \phi(x_i))_+ + \frac{\lambda_o}{2} \|w_o\|^2 + \frac{\lambda}{2} \|w\|^2 \\
 C &= \min_{w, w_o, \xi, p} \sum_{i \in D} (1 - y_i w^\top \phi(x_i))_+ + \frac{\lambda}{2} \|w\|^2 \\
 &\quad + \sum_{i \in D} \left(- y_i w_o^\top (1 - y_i w^\top \phi(x_i))_+ \phi(x_i) \right) + \frac{\lambda_o}{2} \|w_o\|^2 \\
 C &\geq \min_{w, w_o, \xi, p} \left\{ \sum_{i \in D} (1 - y_i w^\top \phi(x_i))_+ + \frac{\lambda}{2} \|w\|^2 \right\} \\
 &\quad + \min_{w, w_o, \xi, p} \left\{ \sum_{i \in D} \left(- y_i w_o^\top (1 - y_i w^\top \phi(x_i))_+ \phi(x_i) \right) + \frac{\lambda_o}{2} \|w_o\|^2 \right\} \\
 w^* &= \operatorname{argmin}_w \sum_{i \in D} (1 - y_i w^\top \phi(x_i))_+ + \frac{\lambda}{2} \|w\|^2, l_i^* = (1 - y_i w^{*\top} \phi(x_i))_+
 \end{aligned}$$

$$C \geq C_1 + C_2 \quad (۴-آ)$$

□

دوگان مسئله C_1 عبارتست از

$$\max_{0 \leq \alpha \leq 1} -\frac{1}{2\lambda} \alpha^T (K \odot YY^T) \alpha + \alpha^T \mathbf{1}$$

براساس تعریف، نقاط پرت از توزیع داده ها برداشته نشده اند. بنابراین این داده ها نباید در تعیین طبقه بند اصلی نقش ایفا

کنند. لم ذیل حدبالایی برای مجموع اتلاف در نقطه بهینه برای مسئله C_1 ارائه می کند.

لم ۲: اگر تعداد نقاط پرت حداکثر n_o باشد، آنگاه خواهیم داشت:

$$\sum_i l_i^* \leq n_s - \lambda \|w^*\|^2 = n_s - \frac{1}{\lambda} \alpha^T (K \odot YY^T) \alpha$$

اثبات: شرایط KKT برای مسئله C_1 عبارتست از

$$\alpha_i^* (1 - y_i w^{*T} \phi(x_i) - l_i^*) = 0$$

$$\alpha_i^* \gamma_i^* = 0$$

$$0 \leq \alpha_i^* \leq 1$$

$$w^* = \frac{1}{\lambda} \sum_i \alpha_i y_i \phi(x_i) \quad (۵-آ)$$

با توجه به ارضاء شرایط slater^۱ بنابراین دوگانی قوی وجود دارد و خواهیم داشت: $p^* = d^*$.

دوگان مسئله C_1 برابر است با

$$\max_{0 \leq \alpha \leq 1} -\frac{\lambda}{2} \|w\|^2 + \mathbf{1}^T \alpha$$

از صفر بودن شکاف دوگانی، خواهیم داشت:

$$\mathbf{1}^T l^* + \lambda \|w\|^2 = \mathbf{1}^T \alpha \quad (۶-آ)$$

$$\sum_i l_i^* \geq 0 \text{ چون } ^1$$

از طرفی چون تعداد n_o داده پرت داریم و داده های پرت نباید در تعیین طبقه بند شرکت کنند، بنابراین $\mathbf{1}^T \alpha \leq n - n_o$. با توجه به رابطه قبل خواهیم داشت:

$$\mathbf{1}^T l^* = \mathbf{1}^T \alpha - \lambda \|w\|^2 \leq n - n_o - \lambda \|w^*\|^2 = n_s - \lambda \|w^*\|^2 \quad (7-\bar{A})$$

□

حال به بررسی مسئله C_2 می پردازیم.

لم ۳: دوگان مسئله C_2 برابر است با

$$\begin{aligned} \max_{r, h, g, b \geq 0} & - \left\{ \frac{1}{2\lambda_o} (Yl^* + r - h)^T (K \odot YY^T)^\dagger (Yl^* + r - h) + \mathbf{1}^T g + n_o b \right\} \\ \text{s.t } & r + h = g + b\mathbf{1} \end{aligned} \quad (8-\bar{A})$$

اثبات: ابتدا تابع لاگرانژ مسئله را می نویسیم.

$$\begin{aligned} \mathcal{L}(w_o, p; r, h, g, b) &= w_o^{*T} \left(- \sum_i y_i l_i^* \phi(x_i) \right) + \frac{\lambda_o}{2} \|w_o\|^2 + \\ & h^T (\Phi(X)^T w_o - p) - r^T (\Phi(X)^T w_o + p) + g^T (p - \mathbf{1}) + b(p^T \mathbf{1} - n_o) \\ &= \left(\sum_i (-y_i l_i^* + h_i - r_i) \phi(x_i) \right)^T w_o + \frac{\lambda_o}{2} \|w_o\|^2 \\ & - (h + r)^T p + (g + b\mathbf{1})^T p - \mathbf{1}^T g - bn_o \end{aligned} \quad (9-\bar{A})$$

تابع دوگان مسئله برابر است با

$$\max_{r, h, g, b \geq 0} \min_{w_o, p} \mathcal{L}$$

برای بدست آوردن تابع دوگان مقدارهای کمینه مربوط به متغیرهای اولیه به ازاء مقدارثابتی از متغیرهای دوگان (ضرایب لاگرانژ)

را در تابع لاگرانژ قرار می دهیم. ابتدا برای w_o از

$$\frac{\partial \mathcal{L}}{\partial w_o} = 0$$

بدست می آید:

$$w_o = \frac{1}{\lambda_o} \Phi(X)(Yl^* + r - h) \quad (10-)$$

وسپس برای متغیر p از

$$\frac{\partial \mathcal{L}}{\partial p} = 0 \quad (11-)$$

خواهیم داشت:

$$h + r = g + b\mathbf{1} \quad (12-)$$

□

لم ۴: در صورتیکه در نقطه بهینه داشته باشیم، $\forall i, p_i < 1$ ، آنگاه خواهیم داشت: $r^* + h^* = b^*\mathbf{1}$ و $g^* = 0$

اثبات: شرایط KKT برای مسئله دوگان C_2 برابر است با:

$$g_i^*(p_i^* - 1) = 0$$

$$b^*(p^{*\top})\mathbf{1} - n_o = 0$$

$$h_i^*(\phi(x_i)^\top w_o - p_i^*) = 0$$

$$r_i^*(\phi(x_i)^\top w_o + p_i^*) = 0 \quad (13-)$$

اگر $\forall i, p_i - 1 < 0$ براساس اولین شرط از شرایط بالا خواهیم داشت:

$$\forall i, g_i^* = 0$$

با توجه به نتیجه فوق وقید مسئله، خواهیم داشت:

$$r^* + h^* = b^*\mathbf{1}$$

□

لم ۵: اگر داشته باشیم: $r_i^* \neq 0$ ، $h_i^* \neq 0$ و نیز $w_o^{*T} \phi(x_i) \neq 0$ باشد، آنگاه $p_i \neq 0$ و نیز $\text{sign}(r_i^* - h_i^*) = \text{sign}(w_o^{*T} \phi(x_i))$

اثبات: ابتدا ثابت می‌کنیم در صورت مخالف صفر بودن مقدار تابع $w_o^{*T} \phi(x_i)$ ، از بین h_i^* و r_i^* حداقل یکی برابر صفر است. براساس شرایط KKT در لم ۴ خواهیم داشت:

$$\begin{aligned} h_i^* \phi(x_i)^T w_o &= h_i^* p_i^* \\ r_i^* \phi(x_i)^T w_o &= -r_i^* p_i^* \end{aligned} \quad (۱۴-آ)$$

با تقسیم طرفین بر $w_o^{*T} \phi(x_i)$ ، با توجه به مخالف صفر بودن آن بدست می‌آید:

$$\begin{aligned} h_i^* &= h_i^* \frac{p_i^*}{\phi(x_i)^T w_o} \\ r_i^* &= -r_i^* \frac{p_i^*}{\phi(x_i)^T w_o} \end{aligned} \quad (۱۵-آ)$$

اگر هردو r_i^* و h_i^* مخالف صفر باشند، رابطه بالایی را در r_i^* و پایینی را در h_i^* ضرب می‌کنیم و سپس دو رابطه باهم جمع می‌کنیم.

$$2r_i^* h_i^* = r_i^* h_i^* \frac{p_i^*}{\phi(x_i)^T w_o} - r_i^* h_i^* \frac{p_i^*}{\phi(x_i)^T w_o} = 0$$

این نتیجه غیر ممکن است. بنابراین یکی از این دو برابر صفر است.

حال دو رابطه سوم و چهارم را در شرایط KKT باهم جمع می‌کنیم.

$$(r_i^* + h_i^*) w_o^{*T} \phi(x_i) + (r_i^* - h_i^*) p_i^* = 0 \quad (۱۶-آ)$$

از آنجاکه p_i نامنفی است و مقدار تابع $w_o^{*T} \phi(x_i)$ مخالف صفر است و ثابت کردیم، یکی از مقادیر h_i^* یا r_i^* برابر صفر است. بنابراین با توجه به شرط این لم هر دو نمی‌توانند صفر باشند، بنابراین $r_i^* \neq h_i^*$. در نتیجه برای تحقق رابطه بالا لازم است علامت $w_o^{*T} \phi(x_i)$ و $r_i^* - h_i^*$ مخالف یکدیگر باشند. با توجه به مخالف صفر بودن $w_o^{*T} \phi(x_i)$ و قید مسئله اولیه C_2 ، p_i^* بزرگتر از صفر خواهد بود. $\square$ تعریف ذیل براساس تعریف پرت بودن در [۳۶] با کمی تغییرات ارائه شده است:

تعریف: نقاط یک مجموعه داده $\mathcal{D}_o$ را γ -نویزی تعریف می کنیم، اگر جهتی مانند w_β وجود داشته باشد که

$$\min_{t \in \mathcal{D}_o} \{y_t w_\beta^\top \phi(x)_t\} \geq \frac{\gamma}{n_s} \sum_{i \in \mathcal{D} - \mathcal{D}_o} y_i w_\beta^\top \phi(x)_i \quad (۱۷-آ)$$

و $n_s = |\mathcal{D} - \mathcal{D}_o|$.

لم ۶: اگر طبقه بند نتیجه مسئله C_2 هیچ داده γ -پرت ای را جدانکند، خواهیم داشت:

$$p^* \leq \frac{n_o}{1 + \frac{n-1}{\gamma}} \mathbf{1} \quad (۱۸-آ)$$

اثبات: اگر هیچ داده γ -پرت ای را جدانکند، بنابر تعریف خواهیم داشت:

$$\forall t : p_t < \frac{\gamma}{n-1} \sum_{i \neq t} p_i^*$$

$$\sum_i p_i = p_t + \sum_{i \neq t} p_i \leq n_o$$

$$p_t^* (1 + \frac{n-1}{\gamma}) \leq n_o$$

$$p_t^* < \frac{n_o}{1 + \frac{n-1}{\gamma}}$$

□

بنابراین اگر بخواهیم در چنین طبقه بندی هیچگاه $p_i^* = 1$ نباشد، مگر اینکه داده γ -پرتی وجود داشته باشد، لازم است

$$\frac{n_o}{1 + \frac{n-1}{\gamma}} < 1 \quad (۱۹-آ)$$

و یا بعبارت دیگر $\gamma < \frac{n-1}{n_o-1}$.

هرچه تعداد داده های پرت بیشتر باشد، درجه پرت بودن کاهش پیدا می کند. □

لم ۷: اگر داشته باشیم: $\lambda_o n_o < \sum_i |\sum_j K(x_i, x_j) y_j l_j|$ و نیز $p_i^* < 1 \forall i$: آنگاه $b^* > 0$ و $\sum_i p_i^* = n_o$ و از بین h_i^* و r_i^* حداقل یکی مخالف صفر خواهد بود.

اثبات: چون $p_i^* < 1 \forall i$ ، بنابراین براساس لم ۴ خواهیم داشت: $g^* = 0$ و بنابراین $r^* + h^* = b^* 1$ اگر $b^* = 0$

آنگاه $h^* = r^* = 0$ خواهد بود. در نتیجه خواهیم داشت:

$$\Phi(X)^T w_o = \frac{1}{\lambda_o} KYl$$

با در نظر گرفتن قید مسئله اولیه و جایگذاری رابطه بالا در آن خواهیم داشت:

$$\sum_i \left| \frac{1}{\lambda_o} \sum_j K(x_i, x_j) y_j l_j \right| \leq n_o$$

$$\sum_i \left| \sum_j K(x_i, x_j) y_j l_j \right| \leq \lambda_o n_o$$

رابطه اخیر با فرض لم تناقض دارد. بنابراین $b^* > 0$ و براساس شرایط KKT نتیجه می شود: $p^{*T} = n_o$

لم ۸: فرض کنید علاوه بر شرایط لم ۷، $p_i^* > 0$ آنگاه خواهیم داشت:

$$r^* - h^* = b^* Z \mathbf{1}$$

$$Z = \text{diag}(z), z_i = \begin{cases} 1 & r_i^* = 0, h_i^* = b^* \\ -1 & r_i^* = b^*, h_i^* = 0 \end{cases} \quad (20-\bar{A})$$

اثبات: چون $p_i^* \neq 0$ ، یکی از r_i^* و h_i^* برابر صفر است. براساس لم ۷، هر دو آنها نمی توانند صفر باشند، بنابراین دقیقا یکی از آنها در نقطه بهینه برابر صفر است و یکی مخالف صفر.

با توجه به $\forall i, p_i < 1$ ، براساس لم ۴، $r^* + h^* = b^* \mathbf{1}$. در نتیجه یکی از دو حالت ذیل می تواند رخ دهد: حالت اول،

$r_i^* = 0$ و $h_i^* = b^*$ و حالت دوم، برعکس حالت اول. بنابراین لم اثبات شده است.

اگر w_o^* پاسخ بهینه مسئله C_2 باشد در عین حال جداکننده داده های γ -پرت نباشد، براساس لم ۶،

$$\forall i, p_i^* \leq \frac{n_o}{1 + \frac{n-1}{\gamma}} < 1$$

حال فرض کنید جهتی مانند w_β وجود داشته باشد که در آن داده γ -پرت جدا شود یعنی

$$|w_\beta^T \phi(x_t)| \geq \frac{\gamma}{n_s} \sum_i |w_\beta^T \phi(x_i)| \quad (21-\bar{A})$$

آنگاه در اینصورت می توانیم ضربی از جهت فوق را به w_o^* اضافه کنیم و تحت شرایطی نشان می دهیم که جهتی وجود دارد که

تابع هدف این مسئله برای آن کمینه تر از تابع هدف برای w_o^* است. $\square$

لم ۹: اگر w_o^* پاسخ بهینه مسئله C_2 باشد و جهت $w_\beta = \sum_i y_i l_i^* \beta_i \phi(x_i)$ را به آن اضافه کنیم. مقدار تابع هدف این مسئله برای جهت $w_o = w_o^* + \mu w_\beta$ برابر است با

$$C_2(w_o) - C_2(w_o^*) = -\mu l^{*\top} Y B K Y l^* + \lambda_o \mu w_o^{*\top} \Phi(X) B Y l^* + \frac{\mu^2 \lambda_o}{2} l^{*\top} Y B K B Y l^* \quad (22-آ)$$

که در آن $B = \text{diag}(\beta)$

اثبات: با جایگذاری در تابع هدف خواهیم داشت:

$$C_2(w_o) = (w_o^* + \mu w_\beta)^\top \left(-\sum_i y_i l_i^* \phi(x_i) \right) + \frac{\lambda_o}{2} \|w_o^* + \mu w_\beta\|^2$$

$$C_2(w_o) - C_2(w_o^*) = -\mu w_\beta^\top \left(\sum_i y_i l_i^* \phi(x_i) \right) + \lambda_o \mu w_o^{*\top} w_\beta + \frac{\mu^2 \lambda_o}{2} \|w_\beta\|^2$$

$$C_2(w_o) - C_2(w_o^*) = -\mu l^{*\top} Y B K Y l^* + \lambda_o \mu w_o^{*\top} \Phi(X) B Y l^* + \frac{\mu^2 \lambda_o}{2} l^{*\top} Y B K B Y l^*$$

$\square$

لم ۱۰: اگر طبقه بند w_o^* داده های γ -پرت را جدا نکند، آنگاه خواهیم داشت:

$$\Phi(X)^\top w_o^* Y \leq \frac{n_o}{1 + \frac{n-1}{\gamma}} \mathbf{1}$$

اثبات: با استفاده از لم ۶،

$$-\frac{n_o}{1 + \frac{n-1}{\gamma}} \mathbf{1} \leq -p^* \leq \Phi(X)^\top w_o^* \leq p^* \leq \frac{n_o}{1 + \frac{n-1}{\gamma}} \mathbf{1}$$

از طرفی $Y_{ii} = +1$ یا $Y_{ii} = -1$ $\square$

اگر w_β جداکننده داده γ -پرت بوده و به فرم فرض لم ۹ باشد، آنگاه اگر z_i علامت $w_\beta^\top$ در نقطه x_i باشد، عبارت دیگر

می‌توانیم بنویسیم: $z_i = \text{sign}(w_\beta^\top \phi(x_i))$

$$\forall t \in D_o : e_t^\top Z\Phi(X)^\top w_\beta \geq \frac{\gamma}{n_s} e_S^\top Z\Phi(X)^\top w_\beta$$

$$Z = \text{diag}(z)$$

$$\gamma > 1 \quad (23-\tilde{A})$$

بدون از بین رفتن عمومیت، فرض می‌کنیم $e_S^\top Z\Phi(X)^\top w_\beta = 1$ می‌توانیم بنویسیم:

$$e_S^\top Z\Phi(X)^\top w_\beta = e_S^\top ZKYBl^* = 1 \quad (24-\tilde{A})$$

با تعیین مقادیرهای γ_t برای هر نقطه x_t می‌توانیم رابطه نامساوی بالا را به رابطه مساوی تبدیل کنیم:

$$\forall t \in D_o : e_t^\top Z\Phi(X)^\top w_\beta = e_t^\top ZKYBl^* = \frac{\gamma_t}{n_s}$$

$$\gamma_t \geq \gamma \quad (25-\tilde{A})$$

با در نظر گرفتن دو رابطه اخیر، می‌توانیم بنویسیم:

$$ZKYBl^* = \frac{1}{n_s} (e_S + \Gamma e_{D_o})$$

$$\Gamma = \text{diag}(\gamma)$$

$$\gamma_i = \begin{cases} \gamma_i & x_i \in D_o \\ 1 & x_i \in S \end{cases}$$

$$e_A(i) = \begin{cases} 1 & x_i \in A \\ 0 & x_i \notin A \end{cases} \quad (26-\tilde{A})$$

با توجه به اینکه $Z^2 = I$ بنابراین

$$KYBl^* = \frac{1}{n_s} Z(e_S + \Gamma e_{D_o}) = \frac{1}{n_s} Z(\mathbf{1} + (\Gamma - I)e_{D_o})$$

با استفاده از مقدار B در رابطه تفاوت تابع هدف در لم ۹، خواهیم داشت:

$$\begin{aligned}
 C_2(w_o) - C_2(w_o^*) &= -\frac{\mu}{n_s}(e_S + \Gamma e_{D_o})^\top ZYl^* + \lambda_o \mu w_o^{*\top} \Phi(X)BYl^* + \frac{\mu^2 \lambda_o}{2n_s}(e_S + \Gamma e_{D_o})^\top ZYBl^* \\
 C_2(w_o) - C_2(w_o^*) &= -\frac{\mu}{n_s}(\mathbf{1} + (\Gamma - I)e_{D_o})^\top ZYl^* + \lambda_o \mu w_o^{*\top} \Phi(X)BYl^* + \frac{\mu^2 \lambda_o}{2n_s}(\mathbf{1} \\
 &\quad + (\Gamma - I)e_{D_o})^\top ZYBl^* \\
 C_2(w_o) - C_2(w_o^*) &= -\frac{\mu}{n_s}\mathbf{1}^\top ZYl^* - \frac{\mu}{n_s}e_{D_o}^\top (\Gamma - I)ZYl^* + \lambda_o \mu w_o^{*\top} \Phi(X)BYl^* \\
 &\quad + \frac{\mu^2 \lambda_o}{2n_s}\mathbf{1}^\top ZYBl^* + \frac{\mu^2 \lambda_o}{2n_s}e_{D_o}^\top (\Gamma - I)ZYBl^*
 \end{aligned}$$

با جابجایی جملات خواهیم داشت:

$$\begin{aligned}
 C_2(w_o) - C_2(w_o^*) &= -\frac{\mu}{n_s}\mathbf{1}^\top ZYl^* + \frac{\mu^2 \lambda_o}{2n_s}\mathbf{1}^\top ZYBl^* + \lambda_o \mu w_o^{*\top} \Phi(X)YBl^* \\
 &\quad - \frac{\mu}{n_s}e_{D_o}^\top (\Gamma - I)ZYl^* + \frac{\mu^2 \lambda_o}{2n_s}e_{D_o}^\top (\Gamma - I)ZYBl^*
 \end{aligned} \tag{۲۷-آ}$$

حال ثابت می کنیم که این مقدار تحت شرایطی منفی خواهد بود.

قضیه: اگر طبقه بند اصلی به اندازه کافی ساده باشد و جهتی مانند w_β وجود داشته باشد که علامت آن z با برچسب نقاط

به اندازه کافی تطابق داشته باشد که در دو نامساوی

$$\begin{aligned}
 \mathbf{1}^\top ZYl^* &\geq \frac{\lambda_o}{m} \left(\frac{\mu}{2} + \frac{n_o}{(1 + \frac{n-1}{\gamma})/n_s} \right) \sqrt{1 + \frac{n_o}{n_s}} \sqrt{1 + \frac{\sum_{t \in D_o} \gamma_t^2}{n_s}} \\
 e_{D_o}^\top (\Gamma - I)ZY(I - \frac{\mu \lambda_o}{2}B)l^* &\geq 0
 \end{aligned} \tag{۲۸-آ}$$

صدق کند، که در آن $Z = \text{diag}(z)$ آنگاه در پاسخ مسئله بهینه سازی C_2 داده های پرت جدا خواهند شد.

اثبات: براساس فرض داریم:

$$ZKYBl^* = \frac{1}{n_s}(e_S + \Gamma e_{D_o}) \tag{۲۹-آ}$$

براساس مقاله A Matrix Lower bound خواهیم داشت:

$$\begin{aligned}
 m &= \|(ZKY)^{-1}\|^{-1} \\
 m\|Bl^*\|_2 &\leq \left\| \frac{1}{n_s}(e_S + \Gamma_t e_{D_o}) \right\|_2 \\
 \|Bl^*\|_2 &\leq \frac{1}{mn_s} \sqrt{n_s + \sum_{t \in D_o} \gamma_t^2}
 \end{aligned}
 \tag{۳۰-آ}$$

با توجه به مثبت بودن β و l^* خواهیم داشت:

$$\beta^T l^* = \mathbf{1}^T Bl^* = \|Bl^*\|_1 \leq \sqrt{n} \|Bl^*\|_2$$

از این رابطه و رابطه قبل نتیجه می شود:

$$\begin{aligned}
 \mathbf{1}^T Bl^* &= \beta^T l^* \leq \sqrt{n} \frac{1}{mn_s} \sqrt{n_s + \sum_{t \in D_o} \gamma_t^2} \\
 \mathbf{1}^T Bl^* &\leq \frac{1}{m} \sqrt{1 + \frac{n_o}{n_s}} \sqrt{1 + \frac{\sum_{t \in D_o} \gamma_t^2}{n_s}}
 \end{aligned}
 \tag{۳۱-آ}$$

با توجه به ۲۷-آ و لم ۱۰ خواهیم داشت:

$$\begin{aligned}
 C_2(w_o) - C_2(w_o^*) &\leq -\frac{\mu}{n_s} \mathbf{1}^T ZYl^* + \frac{\mu^2 \lambda_o}{2n_s} \mathbf{1}^T ZYBl^* + \lambda_o \mu \frac{n_o}{1 + \frac{n-1}{\gamma}} \mathbf{1}^T Bl^* \\
 &\quad - \frac{\mu}{n_s} e_{D_o}^T (\Gamma - I) ZYl^* + \frac{\mu^2 \lambda_o}{2n_s} e_{D_o}^T (\Gamma - I) ZYBl^*
 \end{aligned}
 \tag{۳۲-آ}$$

با توجه به ۳۱-آ خواهیم داشت:

$$\begin{aligned}
 C_2(w_o) - C_2(w_o^*) &\leq -\frac{\mu}{n_s} \mathbf{1}^T ZYl^* + \left(\frac{\mu^2 \lambda_o}{2n_s} + \frac{\lambda_o \mu n_o}{1 + \frac{n-1}{\gamma}} \right) \frac{1}{m} \sqrt{1 + \frac{n_o}{n_s}} \sqrt{1 + \frac{\sum_{t \in D_o} \gamma_t^2}{n_s}} \\
 &\quad - \frac{\mu}{n_s} e_{D_o}^T (\Gamma - I) ZYl^* + \frac{\mu^2 \lambda_o}{2n_s} e_{D_o}^T (\Gamma - I) ZYBl^*
 \end{aligned}$$

$$C_2(w_o) - C_2(w_o^*) \leq -\frac{\mu}{n_s} \left(\mathbf{1}^\top ZY l^* - \left(\frac{\mu \lambda_o}{2} + \frac{\lambda_o n_o}{(1 + \frac{n-1}{\gamma})/n_s} \right) \frac{1}{m} \sqrt{1 + \frac{n_o}{n_s}} \sqrt{1 + \frac{\sum_{t \in D_o} \gamma_t^2}{n_s}} \right) - \frac{\mu}{n_s} \left(e_{D_o}^\top (\Gamma - I) ZY (I - \frac{\mu \lambda_o}{2} B) l^* \right) \quad (33-آ)$$

باتوجه به شروط، مقدار فوق منفی است. این قضیه نشان می دهد اگر طبقه بند اصلی ساده باشد در عین حال جهتی وجود داشته باشد که علامت آن در نقاط داده با برچسب ها تاحدی تطبیق داشته باشد، آنگاه جهتی مانند w_β با شرایط فوق الذکر جواب کمینه تری برای تابع هدف خواهد بود. بنابراین در صورت وجود جهتی که تطبیق با برچسب نقاط طبق شرط قضیه داشته باشد و در عین حال داده های پرت را جدا کند، آن جهت مقدار کمینه تری ارائه می کند و در نتیجه جواب مسئله بهینه سازی C_2 در صورت امکان داده های پرت را جدا می کند. $\square$

قضیه: فرض کنید توزیع اصلی داده ها P باشد. اما داده ها از توزیع دیگری مانند Q برداشته شود که بجز در مورد داده های پرت، دقیقا با توزیع P یکسان است. حال فرض کنید در نقطه بهینه الگوریتم، شرایط ذیل را داشته باشیم:

$$\forall i \in \mathcal{S}, |\phi(x_i)^\top w_o^*| \leq \epsilon_1$$

$$\forall i \in \mathcal{D}_o, |\phi(x_i)^\top w_o^*| \geq 1 - \epsilon_2$$

(34-آ)

آنگاه با فرض ثابت بودن $P(y|x)$ خواهیم داشت:

$$\sup_{l(\cdot, \cdot, \theta) \in \mathcal{G}} \left| \frac{1}{n} \sum_{i=1}^n (1 - y_i \phi(x_i)^\top w_o^*) l(x_i, y_i, \theta) - \mathbf{E}_{Y'|X'} \left[\frac{1}{n'} \sum_{i=1}^{n'} l(x'_i, y'_i, \theta) \right] \right| \leq \frac{(1 + \sqrt{(-\log \delta)/2}) 2CR}{\sqrt{M}} + C(\epsilon + \frac{1}{n} \sum_{i=1}^n (\epsilon_1 B + \frac{n_o}{n} (1 - \epsilon_1) B)) \quad (35-آ)$$

اثبات: اگر x_i را از Q برداشته و بنابراین دارای داده های پرت باشد و همچنین x'_i را از P برداریم، که توزیع اصلی داده ها و بدون داده پرت است، خواهیم داشت:

$$\left\| \frac{1}{n} \sum_{i=1}^n (1 - y_i \phi(x_i)^\top w_o^*) \phi(x_i) - \frac{1}{n'} \sum_{i=1}^{n'} \phi(x_i) \right\|^2 =$$

$$\begin{aligned}
& \left\| \frac{1}{n} \sum_{i=1}^n \phi(x_i) - \frac{1}{n'} \sum_{i=1}^{n'} \phi(x_i) - \frac{1}{n} \sum_{i=1}^n y_i \phi(x_i)^\top w_o^* \phi(x_i) \right\|^2 \leq \\
& \left\| \frac{1}{n} \sum_{i=1}^n \phi(x_i) - \frac{1}{n'} \sum_{i=1}^{n'} \phi(x_i) \right\|^2 + \left\| \frac{1}{n} \sum_{i=1}^n y_i \phi(x_i)^\top w_o^* \phi(x_i) \right\|^2 \leq \\
& \epsilon + \frac{1}{n^2} \sum_{i=1}^n |y_i \phi(x_i)^\top w_o^*|^2 \|\phi(x_i)\|^2 \leq \\
& \epsilon + \frac{1}{n^2} \sum_{i=1}^n ((n - n_o) \epsilon_1 B + n_o B) = \epsilon + \frac{1}{n} \sum_{i=1}^n (\epsilon_1 B + \frac{n_o}{n} (1 - \epsilon_1) B) \quad (۳۶-آ)
\end{aligned}$$

در نتیجه با فرض ثابت بودن توزیع شرطی $P(y|x)$ ، همچنین فرض $\|\Theta\| \leq C$ ، $l(x, \Theta) = \langle \phi(x), \Theta \rangle$ ، براساس لم ۶ از مقاله [۶۶] خواهیم داشت:

$$\begin{aligned}
& \sup_{l(.,.,\theta) \in \mathcal{G}} \left| E_{Y|X} \left[\frac{1}{n} \sum_{i=1}^n (1 - y_i \phi(x_i)^\top w_o^*) l(x_i, y_i, \theta) \right] - E_{Y'|X'} \left[\frac{1}{n'} \sum_{i=1}^{n'} l(x'_i, y'_i, \theta) \right] \right| \leq \\
& C \left(\epsilon + \frac{1}{n} \sum_{i=1}^n (\epsilon_1 B + \frac{n_o}{n} (1 - \epsilon_1) B) \right) \quad (۳۷-آ)
\end{aligned}$$

براساس لم ۷، از همان مقاله، فرض کنیم که فرض $\|\Theta\| \leq C$ و همچنین $\|\phi(x, y)\| \leq R$. قرار دهیم، $M = \frac{m^2}{\|1 - y_i \phi(x_i)^\top w_o^*\|^2}$ آنگاه با احتمال $1 - \delta$ روی توزیع $Y|X$ خواهیم داشت:

$$\sup_{l(.,.,\theta) \in \mathcal{G}} \left| \frac{1}{n} \sum_{i=1}^n \beta_i l(x_i, y_i, \theta) - \frac{1}{n} \sum_{i=1}^n \beta_i l(x_i, \theta) \right| \leq (1 + \sqrt{-\log \delta / 2}) 2CR / \sqrt{M} \quad (۳۸-آ)$$

که در آن $\beta_i = 1 - y_i \phi(x_i)^\top w_o^*$ حال براساس لم ۶ و ۷ نتیجه مورد نظر ذیل اثبات می شود (نتیجه ۸ از مقاله مورد نظر):

$$\begin{aligned}
& \sup_{l(.,.,\theta) \in \mathcal{G}} \left| \frac{1}{n} \sum_{i=1}^n (1 - y_i \phi(x_i)^\top w_o^*) l(x_i, y_i, \theta) - \mathbf{E}_{Y'|X'} \left[\frac{1}{n'} \sum_{i=1}^{n'} l(x'_i, y'_i, \theta) \right] \right| \leq \\
& \frac{(1 + \sqrt{(-\log \delta) / 2}) 2CR}{\sqrt{M}} + C \left(\epsilon + \frac{1}{n} \sum_{i=1}^n (\epsilon_1 B + \frac{n_o}{n} (1 - \epsilon_1) B) \right) \quad (۳۹-آ)
\end{aligned}$$

□

این قضیه نشان می دهد که اگر تابع ریسک وزندهی شده مبتنی بر طبقه بند ساده- پیچیده را کمینه سازی کنیم، با احتمال بالا، در حال کمینه کردن حد بالایی از امید ریاضی ریسک روی مجموعه تست هستیم. (ارجاع به مقاله مورد نظر). در نتیجه تابع هدف مورد نظر علاوه بر اینکه نمونه های پرت را از حذف می کند، باعث تصحیح اریبی مدل نیز می شود.

مراجع

- [1] Abe, N., and Mamitsuka, H. Query learning strategies using boosting and bagging. *Proceedings of the 25th International Conference on Machine learning* 388 (1998), 1–9.
- [2] Audibert, J. Y., and Tsybakov, A. B. Fast learning rates for plug-in classifiers. *Annals of Statistics* 35, 2 (2007), 608–633.
- [3] Baldassarre, L., Rosasco, L., Barla, A., and Verri, A. Multi-output learning via spectral filtering. *Machine Learning* 87, 3 (2012), 259–301.
- [4] Bartlett, P. L., and Wegkamp, M. H. Classification with a Reject Option using a Hinge Loss. *Journal of Machine Learning Research* 9 (2008), 1823–1840.
- [5] Belkin, M., Niyogi, P., and Sindhvani, V. Manifold regularization: A geometric framework for learning from labeled and unlabeled examples. *Journal of Machine Learning Research* 7, 2006 (2006), 2399–2434.
- [6] Beygelzimer, A., and Langford, J. Importance Weighted Active Learning. In *International Conference on Machine Learning* (2009), vol. 26.
- [7] Blanchard, G., Lee, G., and Scott, C. Generalizing from several related classification tasks to a new unlabeled sample. *Advances in neural information processing systems. 1* (2011), 2178–2186.

- [8] Borgwardt, K. M., Gretton, A., Rasch, M. J., Kriegel, H.-p., Smola, A. J., and Scho, B. Mean Discrepancy. *Bioinformatics* 22, 14 (2006), 49–57.
- [9] Bühlmann, P., and Yu, B. Boosting with the L2loss: Regression and classification. *Journal of the American Statistical Association* 98, 462 (2003), 324–339.
- [10] Cai, D., and He, X. Manifold adaptive experimental design for text categorization. *IEEE Transactions on Knowledge and Data Engineering* 24, 4 (2012), 707–719.
- [11] Cai, W., Zhang, M., and Zhang, Y. Batch mode active learning for regression with expected model change. *IEEE Transactions on Neural Networks and Learning Systems* 28, 7 (2017), 1668–1681.
- [12] Cardoso, T. N., Silva, R. M., Canuto, S., Moro, M. M., and Gonçalves, M. A. Ranked batch-mode active learning. *Information Sciences* 379 (2017), 313–337.
- [13] Chakraborty, S., Balasubramanian, V., and Panchanathan, S. Generalized batch mode active learning for face-based biometric recognition. *Pattern Recognition* 46, 2 (feb 2013), 497–508.
- [14] Chakraborty, S., Nallure Balasubramanian, V., Sun, Q., Panchanathan, S., and Ye, J. Active Batch Selection via Convex Relaxations with Guaranteed Solution Bounds. *IEEE Transactions on Pattern Analysis and Machine Intelligence* 8828, c (2015), 1–1.
- [15] Chang, C. C., and Liao, B. H. Active learning based on minimization of the expected path-length of random walks on the learned manifold structure. *Pattern Recognition* 71 (2017), 337–348.
- [16] Chang, C.-c., and Lin, C.-j. LIBSVM : A Library for Support Vector Machines. *ACM Transactions on Intelligent Systems and Technology (TIST)* 2, 3 (2011), 27.
- [17] Chang, C. C., and Lin, P. Y. Active learning for semi-supervised clustering based on locally linear propagation reconstruction. *Neural Networks* 63 (2015), 170–184.
- [18] Chatzilari, E., Nikolopoulos, S., Kompatsiaris, Y., and Kittler, J. SALIC: Social active learning for image classification. *IEEE Transactions on Multimedia* 18, 8 (2016), 1488–1503.

- [19] Chen, D.-R., Chen, D.-R., Sun, T., and Sun, T. Consistency of Multiclass Empirical Risk Minimization Methods Based on Convex Loss. *Journal of Machine Learning Research* 7 (2006), 2435–2447.
- [20] Chen, Y., Krause, A., and Zurich, E. T. H. Near-optimal Batch Mode Active Learning and Adaptive Submodular Optimization. In *International Conference on Machine Learning* (2013), vol. 28.
- [21] Cohn, D. a. Neural Network Exploration Using Optimal Experiment Design. *Neural networks : the official journal of the International Neural Network Society* 9, 6 (aug 1996), 1071–1083.
- [22] Cortes, C., Desalvo, G., Mohri, M., B, G. D., and Mohri, M. Learning with Rejection. In *International Conference on Algorithmic Learning Theory* (2016), vol. 2, pp. 67–82.
- [23] Cortes, C., and Vapnik, V. Support-Vector Networks. *Machine Learning* 20, 3 (1995), 273–297.
- [24] Cover, T., and Thomas, J. *Elements of information theory*. Wiley, 2006.
- [25] Cuong, N. V., Ye, N., and Chieu, H. L. Active Learning for Probabilistic Hypotheses Using the Maximum Gibbs Error Criterion. In *Neural Information Processing Systems* (2013), pp. 1–9.
- [26] Dagan, I., and Engelson, S. P. Committee-Based Sampling For Training Probabilistic Classifiers. In *Proceedings of the Twelfth International Conference on Machine Learning* (1995), 150–157.
- [27] Dai, H., and Dai, B. Discriminative Embeddings of Latent Variable Models for Structured Data. *International Conference on Machine Learning* 48 (2016).
- [28] Dasgupta, S. Consistency of Nearest Neighbor Classification under Selective Sampling. *Annual Conference on Learning Theory* 23 (2012).
- [29] Dasgupta, S., and Hsu, D. Hierarchical sampling for active learning. In *Proceedings of the 25th international conference on Machine learning - ICML '08* (2008), pp. 208–215.
- [30] Devroye, L., Györfi, L., and Lugosi, G. *A Probabilistic Theory of Pattern Recognition*. Springer New York, 1996.

- [31] Dong, A., and Bhanu, B. Active concept learning in image databases. *IEEE transactions on systems, man, and cybernetics* 35, 3 (2005), 450–66.
- [32] Dornaika, F. Active Two Phase Collaborative Representation Classifier. *ACM Transactions on Knowledge Discovery from Data* 13, 4 (2019).
- [33] Du, B., Wang, Z., Zhang, L. L. L. L., Zhang, L. L. L. L., Liu, W., Shen, J., and Tao, D. Exploring representativeness and informativeness for active learning. *IEEE Transactions on Cybernetics PP*, 99 (2015), 14–26.
- [34] Du, J., and Ling, C. X. Asking generalized queries to domain experts to improve learning. *IEEE Transactions on Knowledge and Data Engineering* 22, 6 (2010), 812–825.
- [35] Dua, D., and Karra Taniskidou, E. {UCI} Machine Learning Repository. 2017.
- [36] Dunagan, J. D. *A Geometric Theory of Outliers and Perturbation*. PhD thesis, Massachusetts Institute of Technology, 2002.
- [37] Evans, L. P. G., Adams, N. M., and Anagnostopoulos, C. Targeting Optimal Active Learning via Example Quality. *Journal of Machine Learning Research* 15 (2014).
- [38] Fang, M., Yin, J., Hall, L. O., and Tao, D. Active Multitask Learning With Trace Norm Regularization Based on Excess Risk. *IEEE Transactions on Cybernetics* 47, 11 (2016), 3906–3915.
- [39] Feng, Y., Xiao, J., Zha, Z., Zhang, H., and Yang, Y. Active learning for social image retrieval using Locally Regressive Optimal Design. *Neurocomputing* 95 (oct 2012), 54–59.
- [40] Flaxman, S., Sejdinovic, D., Cunningham, J. P., and Filippi, S. Bayesian Learning of Kernel Embeddings. *arXiv* (2016).
- [41] Freund, Y., SEUNG, H. S., Shamir, E., and Tishby, N. Selective Sampling Using the Query by Committee. *Machine Learning* 168 (1997), 133–168.

- [42] Friedman, J. H. Greedy function approximation: A gradient boosting machine. *Annals of Statistics* 29, 5 (2001), 1189–1232.
- [43] Fu, Y., Zhu, X., and Elmagarmid, A. Active Learning With Optimal Instance Subset Selection. *Cybernetics, IEEE Transactions ...* 43, 2 (2013), 464–475.
- [44] Gal, Y., Islam, R., and Ghahramani, Z. Deep Bayesian Active Learning with Image Data.
- [45] Getoor, L., Friedman, N., Koller, D., and Taskar, B. Learning Probabilistic Models of Link Structure. *Journal of Machine Learning Research* 3 (2003), 679–707.
- [46] Ghafarian, H., and Yazdi, H. S. Active Robust Learning. *arXiv preprint* (2016), 9.
- [47] Goemans, M. X., and Williamson, D. P. Improved approximation algorithms for maximum cut and satisfiability problems using semidefinite programming. *Journal Of The Association for Computing Machinery* 42, 6 (1995), 1115–1145.
- [48] Gorisse, D., Cord, M., and Precioso, F. SALSAS : Sub-linear active learning strategy with approximate k -NN search. *Pattern Recognition* 44, 10-11 (2011), 2343–2357.
- [49] Gretton, A., Sriperumbudur, B., Sejdinovic, D., Strathmann, H., and Pontil, M. Optimal kernel choice for large-scale two-sample tests. *Advances in Neural Information Processing Systems* 25 (2012), 1214–1222.
- [50] Gu, Q. Batch-Mode Active Learning via Error Bound Minimization. In *Uncertainty in Artificial Intelligence* (2014).
- [51] Gu, Q., Zhang, T., Ding, C., and Han, J. Selective Labeling via Error Bound Minimization. In *Advances in Neural Information Processing Systems* 25 (2012), pp. 332–340.
- [52] Gu, Y., and Jin, Z. Neighborhood preserving D-optimal design for active learning and its application to terrain classification. *Neural Computing and Applications* 23, 7-8 (2013), 2085–2092.

- [53] Guillory, A., Chastain, E., and Bilmes, J. Active Learning as Non-Convex Optimization. In *Proceedings of the 20th International Conference on Artificial Intelligence and Statistics ({AISTATS})* (2009), vol. 5, pp. 201–208.
- [54] Guo, H., and Wang, W. An active learning-based SVM multi-class classification model. *Pattern Recognition* 48, 5 (2015), 1577–1597.
- [55] Guyon, I., Gunn, S., Hur, A. B., and Dror., G. Result analysis of the NIPS 2003 feature selection challenge. In *Advances in Neural Information Processing Systems* (2005), p. 17.
- [56] Hanneke, S. *Theoretical Foundations of Active Learning*. PhD thesis, Carnegie Mellon University, 2009.
- [57] Hanneke, S. A Statistical Theory of Active Learning. *Foundations and Trends R in Machine Learning* xx, xx (2013), 1–212.
- [58] Hanneke, S. Minimax Analysis of Active Learning. *Journal of Machine Learning Research* 16 (2015), 3487–3602.
- [59] Hanneke, S., and Yang, L. Surrogate Losses in Passive and Active Learning. *arXiv:1207.3772v3* (2015), 1–67.
- [60] He, X., Ji, M., Zhang, C., and Bao, H. A variance minimization criterion to feature selection using laplacian regularization. *IEEE Transactions on Pattern Analysis and Machine Intelligence* 33, 10 (2011), 2013–2025.
- [61] Ho, T. K., and Kleinberg, E. M. Building projectable classifiers of arbitrary complexity. In *the 13th International Conference on Pattern Recognition* (1996), pp. 880–885.
- [62] Hoi, S. C. H., Jin, R., Zhu, J., and Lyu, M. R. Semi-supervised SVM batch mode active learning for image retrieval, 2008.
- [63] Hu, R., Mac Namee, B., and Delany, S. J. Active learning for text classification with reusability. *Expert Systems with Applications* 45 (2016), 438–449.

- [64] Hu, W., Hu, W., Xie, N., and Maybank, S. Unsupervised active learning based on hierarchical graph-theoretic clustering. *IEEE Transactions on Systems, Man, and Cybernetics, Part B: Cybernetics* 39, 5 (2009), 1147–1161.
- [65] Huang, J., Ertekin, S., Song, Y., Zha, H., and Giles, C. L. Efficient Multiclass Boosting Classification with Active Learning. In *SIAM International Conference on Data Mining* (2007), pp. 1–12.
- [66] Huang, J., Smola, A. J., Gretton, A., Borgwardt, K. M., and Schölkopf, B. Correcting Sample Selection Bias by Unlabeled Data. In *NIPS* (2007), pp. 601–608.
- [67] Huang, S. J., Jin, R., and Zhou, Z. H. Active Learning by Querying Informative and Representative Examples. *IEEE Transactions on Pattern Analysis and Machine Intelligence* 36, 10 (2014), 1936–1949.
- [68] Inglot, T., and Majerski, P. Simple upper and lower bounds for the multivariate Laplace approximation. *Journal of Approximation Theory* 186 (2014), 1–11.
- [69] Kolokoltsov, V. Multivariate Laplace approximation with estimated error and application to limit theorems. 1–15.
- [70] Kucher, K., Paradis, C., Sahlgren, M., and Kerren, A. Active Learning and Visual Analytics for Stance Classification with ALVA. *acm transaction on Interactive Intelligent Systems* 7, 3 (2017).
- [71] Lapin, M., Hein, M., and Schiele, B. Learning using privileged information: SV M+ and weighted SVM. *Neural Networks* 53 (2014), 95–108.
- [72] Law, H. C. L., Sutherland, D. J., Sejdinovic, D., and Flaxman, S. Bayesian Distribution Regression. *arXiv preprint* (2017).
- [73] Leng, Y., Xu, X., and Qi, G. Combining active learning and semi-supervised learning to construct SVM classifier. *Knowledge-Based Systems* 44 (2013), 121–131.
- [74] Lewis, D. D., and Gale, W. A. A sequential algorithm for training text classifiers. *ACM SIGIR Forum* 29, 2 (1995), 13–19.

- [75] Li, P., Bu, J., Chen, C., and Cai, D. Manifold optimal experimental design via dependence maximization for active learning. *Neurocomputing* 142 (oct 2014), 429–437.
- [76] Li, Y., Wang, Y., Yu, D.-j., Ye, N., Hu, P., and Zhao, R. ASCENT : Active Supervision for Semi-supervised Learning. *IEEE TRANSACTIONS ON KNOWLEDGE AND DATA ENGINEERING* 4347, c (2019), 1–15.
- [77] Li, Y.-f., and Zhou, Z.-H. Towards Making Unlabeled Data Never Hurt. *IEEE Transactions on Pattern Analysis and Machine Intelligence PP*, 1 (2014), 1–1.
- [78] Liao, H., Chen, L., Song, Y., and Ming, H. Visualization-Based Active Learning for Video Annotation. *IEEE Transactions on Multimedia* 18, 11 (2016), 2196–2205.
- [79] Lopez-Paz, D., Bottou, L., Schölkopf, B., and Vapnik, V. Unifying distillation and privileged information. *arXiv*, 1 (2015), 1–10.
- [80] Lopez-paz, D., Sch, B., and Scholkopf, B. Towards a Learning Theory of Cause-Effect Inference. *Proceedings of the 32nd International Conference on Machine Learning* 32 (2015).
- [81] Lu, Z., Wu, X., and Bongard, J. C. Active learning through adaptive heterogeneous ensembling. *IEEE Transactions on Knowledge and Data Engineering* 27, 2 (2015), 368–381.
- [82] Lughofer, E. On-line active learning: A new paradigm to improve practical useability of data stream modeling methods. *Information Sciences* 415-416 (2017), 356–376.
- [83] Luo, T., Kramer, K., Goldgof, D. B., Hall, L. O., Samson, S., Remsen, A., and Hopkins, T. Active learning to recognize multiple types of plankton. *Journal of Machine Learning Research* 6 (2005), 589–613.
- [84] Melendez, J., van Ginneken, B., Maduskar, P., Philipsen, R. H. H. M., Ayles, H., and Sanchez, C. I. On Combining Multiple-Instance Learning and Active Learning for Computer-Aided Detection of Tuberculosis. *IEEE Transactions on Medical Imaging* 35, 4 (2016), 1013–1024.
- [85] Melville, P., and Mooney, R. J. Diverse ensembles for active learning. *International Conference on Machine Learning* 69 (2004), 584–591.

- [86] Mikolov, T., Corrado, G., Chen, K., and Dean, J. Efficient Estimation of Word Representations in Vector Space. *Proceedings of the International Conference on Learning Representations (ICLR 2013)* (2013), 1–12.
- [87] Minsker, S. Plug-in Approach to Active Learning. *Journal of Machine Learning Research* 13 (2012), 67–90.
- [88] Muandet, K., Fukumizu, K., Dinuzzo, F., and Schölkopf, B. Learning from Distributions via Support Measure Machines. In *Neural Information Processing Systems* (2012), pp. 10–18.
- [89] Muandet, K., Fukumizu, K., Sriperumbudur, B., and Schölkopf, B. Kernel Mean Embedding of Distributions: A Review and Beyond. *Foundations and Trends® in Machine Learning* 10, 1-2 (2017), 1–141.
- [90] Muandet, K., and Schölkopf, B. One-Class Support Measure Machines for Group Anomaly Detection. In *Proceedings of the Twenty-Ninth Conference on Uncertainty in Artificial Intelligence* (2013), AUAI Press, pp. 449–458.
- [91] Muandet, K., Sriperumbudur, B., Fukumizu, K., Gretton, A., and Schölkopf, B. Kernel Mean Shrinkage Estimators. *Journal of Machine Learning Research* 17, 1 (may 2014), 41.
- [92] Mund, D., Triebel, R., and Cremers, D. Active online confidence boosting for efficient object classification. *Proceedings - IEEE International Conference on Robotics and Automation 2015-June*, June (2015), 1367–1373.
- [93] Nam, W., and Alur, R. Active learning of plans for safety and reachability goals with partial observability. *IEEE Transactions on Systems, Man, and Cybernetics, Part B: Cybernetics* 40, 2 (2010), 412–420.
- [94] Niu, B., Cheng, J., Bai, X., and Lu, H. Asymmetric propagation based batch mode active learning for image retrieval. *Signal Processing* 93, 6 (2013), 1639–1650.
- [95] Oliva, J. B., Neiswanger, W., Poczos, B., Schneider, J., and Xing, E. Fast Distribution To Real Regression. In *AISTATS* (2014), vol. 33.

- [96] Oliva, J. B., and Schneider, J. Distribution to Distribution Regression. In *International Conference on Machine Learning* (2013), pp. 1049–1057.
- [97] Paisley, J., Liao, X., and Carin, L. Active Learning and Basis Selection for Kernel-Based Linear Models: A Bayesian Perspective. *IEEE Transactions on Signal Processing* 58, 5 (may 2010), 2686–2700.
- [98] Parikh, N., and Boyd, S. Proximal Algorithms. *Foundations and Trends® in Optimization* 1, 3 (2014), 127–239.
- [99] Park, M., Nassar, M., Member, S., and Vikalo, H. Bayesian Active Learning for Drug Combinations. *IEEE Transactions on Biomedical Engineering* 60, 11 (2013), 3248–3255.
- [100] Patra, S., and Bruzzone, L. A cluster-assumption based batch mode active learning technique. *Pattern Recognition Letters* 33, 9 (jul 2012), 1042–1048.
- [101] Petersen, K., and Pedersen, M. S. *The Matrix Cookbook*. Technical University of Denmark, 2012.
- [102] Platt, J. C. Fast training of support vector machines using sequential minimal optimization. *Advances in kernel methods* (1999), 185–208.
- [103] Poczos, B., Rinaldo, A., Singh, A., and Wasserman, L. Distribution-Free Distribution Regression. In *International Conference on Artificial Intelligence and Statistics* (2013), vol. 31, pp. 507–515.
- [104] Póczos, B., Xiong, L., Sutherland, D. J., and Schneider, J. Support Distribution Machines. *arXiv preprint* (2012), 1–12.
- [105] Pohl, D., Bouchachia, A., and Hellwagner, H. Batch-based active learning: Application to social media data for crisis management. *Expert Systems with Applications* 93 (2018), 232–244.
- [106] Primpeli, A., and Bizer, C. Robust Active Learning of Expressive Linkage Rules. In *the 9th International Conference on Web Intelligence, Mining and Semantics*. ACM (2019).

- [107] Qi, G.-j., Hua, X.-s., Rui, Y., Tang, J., and Zhang, H.-J. Two-dimensional multilabel active learning with an efficient online adaptation model for image classification. *IEEE transactions on pattern analysis and machine intelligence* 31, 10 (2009), 1880–97.
- [108] Rahhal, M. M., Bazi, Y., Alhichri, H., Alajlan, N., Melgani, F., and Yager, R. R. Deep learning approach for active classification of electrocardiogram signals. *Information Sciences* 345 (2016), 340–354.
- [109] Ramirez-Loaiza, M. E., Sharma, M., Kumar, G., and Bilgic, M. Active learning: an empirical study of common baselines. *Data Mining and Knowledge Discovery* (2016), 1–27.
- [110] Ramirez-Loaiza, M. E., Sharma, M., Kumar, G., and Bilgic, M. Active learning: an empirical study of common baselines. *Data Mining and Knowledge Discovery* 31, 2 (2017), 287–313.
- [111] Rasmussen, C. E. Gaussian processes in machine learning. *Advanced Lectures on Machine Learning* 3176, 2 (2004), 63–71.
- [112] Reitmaier, T., Calma, A., and Sick, B. Transductive active learning - A new semi-supervised learning approach based on iteratively refined generative models to capture structure in data. *Information Sciences* 293, September (2015), 275–298.
- [113] Rodriguez, A., and Laio, A. Clustering by fast search and find of density peaks. *Science* 344, 6191 (2014), 1492–1496.
- [114] Roy, N., McCallum, A., and Com, M. W. Toward Optimal Active Learning through Sampling Estimation of Error Reduction Two common È. In *International Conference on Machine Learning* (2001), pp. 441–448.
- [115] Saito, P. T., Suzuki, C. T., Gomes, J. F., De Rezende, P. J., and Falcão, A. X. Robust active learning for the diagnosis of parasites. *Pattern Recognition* 48, 11 (2015), 3572–3583.
- [116] Samat, A., Li, J., Liu, S., Du, P., Miao, Z., and Luo, J. Improved hyperspectral image classification by active learning using pre-designed mixed pixels. *Pattern Recognition* 51 (2016), 43–58.

- [117] Schapire, R. E., and Freund, Y. *Boosting: Foundations and Algorithms*. MIT Press, 2012.
- [118] Settles, B. *Active Learning*. Synthesis Lectures on Artificial Intelligence and Machine Learning, 2012.
- [119] Seung, H. S., Oppor, M., and Sompolinsky, H. Query by committee. In *Proceedings of the fifth annual workshop on Computational learning theory - COLT '92* (1992), pp. 287–294.
- [120] Sharma, M., and Bilgic, M. Evidence-based uncertainty sampling for active learning. *Data Mining and Knowledge Discovery* 31, 1 (2017), 164–202.
- [121] Shu, Z. Learning from crowds with active learning and self-healing. *Neural Computing and Applications* 30, 9 (2018), 2883–2894.
- [122] Singh, A., and Nowak, R. D. Unlabeled data: Now it helps, now it doesn't. In *Advances in Neural Information Processing Systems 21* (2009), D. Koller and D. Schuurmans and Y. Bengio and L. Bottou, Ed., Curran Associates, Inc., pp. 1513—1520.
- [123] Sinha, S., Berkeley, U. C., and Darrell, T. Variational Adversarial Active Learning. *arXiv preprint* (2019).
- [124] Smailović, J., Grčar, M., Lavrač, N., and Žnidaršič, M. Stream-based active learning for sentiment analysis in the financial domain. *Information Sciences* 285, 1 (2014), 181–203.
- [125] Smola, A., Gretton, A., Song, L., and Schölkopf, B. A Hilbert Space Embedding for Distributions. In *International Conference on Algorithmic Learning Theory*. Springer-Verlag Berlin Heidelberg 2007, 2007, pp. 13–31.
- [126] Son, Y., and Lee, J. Active learning using transductive sparse Bayesian regression. *Information Sciences* 374 (2016), 240–254.
- [127] Song, Y., Wang, Z., Wang, Z., and Zhang, C. Efficient Active Learning with Boosting. In *SIAM International Conference on Data Mining* (2009), pp. 1232–1243.
- [128] Sriperumbudur, B., and Gretton, A. Hilbert space embeddings and metrics on probability measures. *The Journal of Machine Research* 11 (2010), 1517–1561.

- [129] Su, H., Yin, Z., Huh, S., Kanade, T., and Zhu, J. Interactive Cell Segmentation Based on Active and Semi-Supervised Learning. *IEEE Transactions on Medical Imaging* 35, 3 (2016), 762–777.
- [130] Szabó, Z., Gretton, A., Póczos, B., Sriperumbudur, B., Unit, G., Gretton, A., Sriperumbudur, B., Szabó, Z., Gretton, A., Póczos, B., and Sriperumbudur, B. Two-stage Sampled Learning Theory on Distributions. *International Conference on Artificial Intelligence and Statistics (AISTATS)* 38, 1997 (2015), 948–957.
- [131] Szabo, Z., Sriperumbudur, B., Poczos, B., and Gretton, A. Learning Theory for Distribution Regression. *Journal of Machine Learning Research* 1114 (2014).
- [132] Szabo, Z., Sriperumbudur, B., Poczos, B., and Gretton, A. Learning Theory for Distribution Regression. *Journal of Machine Learning Research* 17, 1 (nov 2016), 5272–5311.
- [133] Szafranski, M. Input Output Kernel Regression : Supervised and Semi-Supervised Structured Output Prediction with Operator-Valued Kernels. *Journal of Machine Learning Research* 17 (2016), 1–48.
- [134] Tekin, C., and Van Der Schaar, M. Active learning in context-driven stream mining with an application to image mining. *IEEE Transactions on Image Processing* 24, 11 (2015), 3666–3679.
- [135] Tipping, M. Sparse Bayesian Learning and the Relevance Vector Mach. *Journal of Machine Learning Research* 1 (2001), 211–244.
- [136] Tipping, M. E., and Faul, A. C. Fast Marginal Likelihood Maximisation for Sparse Bayesian Models. In *Artificial Intelligence and Statistics (AISTATS)* (2006), pp. 1–13.
- [137] Tong, Simon and Koller, D. Support Vector Machine Active Learning with Applications to Text Classification. *Journal of machine learning research* 2 (2001), 45–66.
- [138] Tran, T., Do, T.-t., Reid, I., and Carneiro, G. Bayesian Generative Active Deep Learning. In *International Conference on Machine Learning* (2019).
- [139] Trapeznikov, K., Saligrama, V., and Castañón, D. Active Boosted Learning (ActBoost). *Proceedings of the Fourteenth International Conference on Artificial Intelligence and Statistics* 15 (2011), 743–751.

- [140] Ukil, A., and Bernasconi, J. Neural network-based active learning in multivariate calibration. *IEEE Transactions on Systems, Man and Cybernetics Part C: Applications and Reviews* 42, 6 (2012), 1763–1771.
- [141] Uzilov, A. V., Keegan, J. M., and Mathews, D. H. Detection of non-coding RNAs on the basis of predicted secondary structure formation free energy change. *BMC Bioinformatics* 7, 173 (2006).
- [142] Vapnik, V. Learning Using Privileged Information : Similarity Control and Knowledge Transfer. *Journal of Machine Learning Research* 16 (2015), 2023–2049.
- [143] Vapnik, V., and Vashist, A. A new learning paradigm: Learning using privileged information. *Neural Networks* 22, 5-6 (2009), 544–557.
- [144] Vapnik, V. N. *Statistical Learning Theory*. John Wiley & Sons, 1998.
- [145] Vijayanarasimhan, S., and Grauman, K. Large-Scale Live Active Learning : Training Object Detectors with Crawled Data and Crowds. *International Journal of Computer Vision* 108 (2014), 97–114.
- [146] Wang, H., Jin, Y., and Doherty, J. Committee-Based Active Learning for Surrogate-Assisted Particle Swarm Optimization of Expensive Problems. *IEEE Transactions on Cybernetics* 47, 9 (2017), 2664–2677.
- [147] Wang, L. Smoothness , Disagreement Coefficient , and the Label Complexity of Agnostic Active Learning. *Journal of Machine Learning Research* 12 (2011), 2269–2292.
- [148] Wang, M., Min, F., Zhang, Z. H., and Wu, Y. X. Active learning through density clustering. *Expert Systems with Applications* 85 (2017), 305–317.
- [149] Wang, M. I. N., Zhang, Y.-y., and Min, F. A. N. Active Learning Through Multi-Standard Optimization. *IEEE Access* 7, July (2019), 56772–56784.
- [150] Wang, R., and Kwong, S. Active learning with multi-criteria decision making systems. *Pattern Recognition* 47, 9 (2014), 3106–3119.

- [151] Wang, R., Kwong, S., and Chen, D. Inconsistency-based active learning for support vector machines. *Pattern Recognition* 45, 10 (oct 2012), 3751–3767.
- [152] Wang, X. Y., Zhang, B. B., and Yang, H. Y. Active SVM-based relevance feedback using multiple classifiers ensemble and features reweighting. *Engineering Applications of Artificial Intelligence* 26, 1 (2013), 368–381.
- [153] Wang, Z., and Ye, J. Querying Discriminative and Representative Samples for Batch Mode Active Learning. *ACM Transactions on Knowledge Discovery from Data* 9, 3 (2015).
- [154] Wong, R. *Asymptotic Approximations of Integrals*. SIAM, 2001.
- [155] Wu, H., and Prasad, S. Dirichlet Process Based Active Learning and Discovery of Unknown Classes for Hyperspectral Image Classification. *IEEE Transactions on Geoscience and Remote Sensing* 54, 8 (2016), 4882–4895.
- [156] Xiong, L., and Schneider, J. Learning from Point Sets with Observational Bias. *Uncertainty in Artificial Intelligence* (2014).
- [157] Xu, H., Caramanis, C., and Mannor, S. Robustness and regularization of support vector machines. *The Journal of Machine Learning Research* 10 (2009), 1485–1510.
- [158] Ye, Z., Liu, P., Liu, J., Tang, X., and Zhao, W. Practice makes perfect: An adaptive active learning framework for image classification. *Neurocomputing* 196 (2016), 95–106.
- [159] Yoo, D., and Kweon, I. S. Learning Loss for Active Learning. In *the IEEE Conference on Computer Vision and Pattern Recognition* (2019), pp. 93–102.
- [160] Yoshikawa, Y., Iwata, T., and Sawada, H. Latent Support Measure Machines for Bag-of-Words Data Classification. In *Neural Information Processing Systems* (2014), pp. 1961–1969.
- [161] Zhang, J., Wu, X., and Sheng, V. S. Active Learning with Imbalanced Multiple Noisy Labeling. *IEEE Transactions on Cybernetics* (2014), 1–1.

- [162] Zhang, L., Chen, C., Bu, J., and He, X. A unified feature and instance selection framework using optimum experimental design. *IEEE Transactions on Image Processing* 21, 5 (2012), 2379–2388.
- [163] Zhang, L., Member, S., Chen, C., and Bu, J. Active Learning Based on Locally Linear Reconstruction. *IEEE Transaction on Pattern Analysis and Machine Intelligence* 33, 10 (2011), 2026–2038.
- [164] Zhang, X.-y., Wang, S., and Yun, X. Bidirectional Active Learning : A Two-Way Exploration Into Unlabeled and Labeled Data Set. *IEEE Transactions on Neural Networks and Learning Systems* 26, 12 (dec 2015), 1–11.
- [165] Zhao, L., Pan, S. J., and Yang, Q. A unified framework of active transfer learning for cross-system recommendation. *Artificial Intelligence* 245 (2017), 38–55.
- [166] Zhao, Y., Shi, Z., Zhang, J., Chen, D., and Gu, L. A novel active learning framework for classification : Using weighted rank aggregation to achieve multiple query criteria. *Pattern Recognition* 93 (2019), 581–602.
- [167] Zhdanov, F. Diverse mini-batch Active Learning. *arXiv preprint* (2019).
- [168] Zhou, J., and Sun, S. Active learning of Gaussian processes with manifold-preserving graph reduction. *Neural Computing and Applications* 25 (2014), 1615–1625.
- [169] Zhu, X., Ghahramani, Z., and Lafferty, J. Combining Active Learning and Semi-Supervised Learning Using Gaussian Fields and Harmonic Functions. *International Conference on Machine Learning* 20, 2 (2003), 912–919.

واژه‌نامه فارسی به انگلیسی

۱

hyperparameters	ابریارامتر
Bias	اریب
Sample Bias	اریب شدن به نمونه
Sampling Bias	اریبی به نمونه
Casual inference	استنتاج علی
Causal Inference	استنتاج علی
Fisher Information	اطلاع فیشر
Model Deterioration	انحراف مدل

ب

Locally Linear Reconstruction	بازسازی خطی محلی
Prepare for the worst and Hope for the best ...	برای بدترین شرایط آماده باش و انتظار بهترین شرایط را داشته باش
Label	برچسب
Crowd Sourcing	برچسب زنی جمعی
Bag-of-Words	بسته ای -از-کلمات
Bag of Words	بسته کلمات
Learning Budget	بودجه یادگیری
Best vs Second Best	بهترین در برابر دومین بهترین
Bayes Optimal	بهینه بیز
Submodular Optimization	بهینه سازی زیرپیمانه ای
Stochastic Gradient Descent	بهینه سازی گرادیانی تصادفی
Non-convex Optimization	بهینه سازی نامحدب
Bayesian	بیزی
Maximum Mean Discrepancy (MMD)	بیشترین اختلاف میانگین
min-max	بیشینه-کمینه

پ

Query	پرس وجو
Query by Committee	پرس وجو توسط کمیته
posterior	پسین
Rademacher Complexity	پیچیدگی رادماخر
Sample Complexity	پیچیدگی نمونه
Oracle	پیش گو

ت

Lagrangian	تابع لاگرانژ
Generalize	تعمیم

ج

Disjunct	جداشده
Crowd-Sourcing	جمع سپاری

خ

Measurement Error	خطای اندازه گیری
-------------------	------------------

د

Distributional data	داده های توزیعی
Imbalanced data	داده های نامتوازن
Prior Knowledge	دانش پیشین
Privileged Knowledge	دانش ممتاز
Batch	دسته
KL Divergence	دیورژانس KL

ر

Intractable	رام نشدنی
informative Methods	روشهای حاوی اطلاعات
Representative Methods	روشهای نماینده
Principled Approach to Active Learning	رویکردهای اصولی به یادگیری فعال

ز

Sub-optimal	زیر-بهینه
-------------	-----------

س

Structured data	ساخت-یافته
Consistent	سازگار

label-level	سطح برچسب
instance-level	سطح نسخه
Learning Systems	سیستم های یادگیری
Learning System	سیستم یادگیر

ش

Anomaly detection	شناسایی بی-نظمی
Group anomaly detection	شناسایی بی-نظمی گروهی
Group Anomaly Detection	شناسایی ناهنجاری گروهی

ط

Plug-in Classifier	طبقه بند الحاقی
Bayes Optimal Classifier	طبقه بند بهینه بیز
Simple-Complex Classifier	طبقه بند ساده-پیچیده
Optimal Experiment Design	طراحی بهینه آزمایشها
Manifold Optimal Experiment Design	طرح بهینه روی مانیفولد آزمایشها

ع

Inconsistency	عدم سازگاری
---------------------	-------------

ف

Gaussian Processes	فرایندهای گوسی
Low-density Assumption	فرض چگالی کم
Cluster Assumption	فرض خوشه
Tsybakov's Low noise assumption	فرض کم بودن نویز
Manifold Assumption	فرض مانیفولد
Version Space	فضای نسخه
Reproducing Kernel Hilbert Space	فضای هیلبرت کرنل بازتولیدکننده

ق

Total law of probability	قانون انتگرال کل
--------------------------------	------------------

ک

Expected Error Reduction	کاهش امیدخطا
Characteristics Kernel	کرنل مشخصه
Empirical Risk Minimization	کمینه سازی ریسک تجربی

م

Support Vector Machine (SVM)	ماشین بردار پشتیبان
Support Vector Machine	ماشین بردار پشتیبان
Support Measure Machine (SMM)	ماشین معیارپشتیبان
Manifold	مانیفولد
Rademacher Variables	متغیرهای رادماخر
Example	مثال
independent and identically distributed	مستقل و هم توزیع
Independent and identically distributed (i.i.d)	مستقل و هم توزیع بودن
Primal Problem	مسئله اولیه
Intelligent Teacher	معلم هوشمند
Informativeness Measure	معیار حاوی اطلاعات بودن
Representativeness Measure	معیار نماینده نقاط بودن
Concept	مفهوم
Gaussian Random Field	میدان تصادفی گوسی

ن

Non-smooth	ناهموار
Trace Norm	نرم اثر
Supervision	نظارت
Class Central Examples	نقاط مرکزی کلاس

Kernel Mean Map	نگاشت میانگین کرنل
Uncertainty Sampling	نمونه برداری عدم قطعیت
Kernel Mean Embedding	نهفته سازی میانگین کرنل
Empirical Kernel Mean Embedding	نهفته سازی میانگین کرنل تجربی

و

Importance Weighting	وزن دهی اهمیت
Wishart	ویشارت

ه

Proximal	همجواری
Artificial General Intelligence	هوش همه منظوره مصنوعی

ی

Learning Using Privileged Information (LUPI)	یادگیری با استفاده از اطلاعات ممتاز
Learning Using Privileged Information	یادگیری با استفاده از دانش ممتاز
Learning with a Reject Option	یادگیری با داشتن گزینه رد
Bayesian learning of kernel embedding	یادگیری بیزی نهفته سازی کرنل
Preference learning	یادگیری ترجیحات
Multi-Instance Learning	یادگیری چندنسخه ای
Learning On Distributions	یادگیری روی توزیع

Structured Learning	یادگیری ساخت یافته
Active Learning	یادگیری فعال
Probabilistic Minimax Active Robust Learning	یادگیری فعال بیشینه کمینه احتمالاتی مقاوم
Probabilistic Minimax Active Robust Learning on	یادگیری فعال بیشینه کمینه مقاوم روی توزیع با استفاده تشابه
Distributions using Similarity	
Probabilistic Minimax Active Learning (PMAL)	یادگیری فعال بیشینه-کمینه احتمالاتی
Batch Active Learning	یادگیری فعال دسته ای
Evidence based Active Learning framework	یادگیری فعال مبتنی بر شواهد
Probabilistic Minimax Active Robust	یادگیری فعال مقاوم بیشینه-کمینه احتمالاتی روی توزیع بارویکرد بیزی
Learning on Distributions with Bayesian learning of kernel embeddings	
Machine Learning	یادگیری ماشین
Probabilistic Minimax Active Robust Learning (PMARL)	یادگیری مقاوم فعال بیشینه-کمینه احتمالاتی
Supervised learning	یادگیری نظارت شده

واژه‌نامه انگلیسی به فارسی

A

Active Learning	یادگیری فعال
Anomaly detection	شناسایی بی-نظمی
Artificial General Intelligence	هوش همه منظوره مصنوعی

B

Bag of Words	بسته کلمات
Bag-of-Words	بسته ای -از- کلمات
Batch	دسته
Batch Active Learning	یادگیری فعال دسته ای
Bayes Optimal	بهینه بیز
Bayes Optimal Classifier	طبقه بند بهینه بیز
Bayesian	بیزی
Bayesian learning of kernel embedding	یادگیری بیزی نهفته سازی کرنل

Best vs Second Best بهترین در برابر دومین بهترین

Bias اریب

C

Casusal inference استنتاج علی

Causal Inference استنتاج علی

Characteristic Kernel کرنل مشخصه

Characteristics Kernel کرنل مشخصه

Class Central Examples نقاط مرکزی کلاس

Cluster Assumption فرض خوشه

Concept مفهوم

Consistent سازگار

Crowd Sourcing برچسب زنی جمعی

Crowd-Sourcing جمع سپاری

D

Disjunct جداشده

Distributional data داده های توزیعی

E

Empirical Kernel Mean Embedding	نهفته سازی میانگین کرنل تجربی
Empirical Risk Minimization	کمینه سازی ریسک تجربی
Evidence based Active Learning framework	یادگیری فعال مبتنی بر شواهد
Example	مثال
Expected Error Reduction	کاهش امیدخطا

F

Fisher Information	اطلاع فیشر
--------------------------	------------

G

Gaussian Processes	فرایندهای گوسی
Gaussian Random Field	میدان تصادفی گوسی
Generalize	تعمیم
Group Anomaly Detection	شناسایی ناهنجاری گروهی
Group anomaly detection	شناسایی بی-نظمی گروهی

H

.....
 hyperparameters ابرپارامتر

I

Imbalanced data داده های نامتوازن
 Importance Weighting وزن دهی اهمیت
 Inconsistency عدم سازگاری
 independent and identically distributed مستقل و هم توزیع
 Independent and identically distributed (i.i.d) مستقل و هم توزیع بودن
 informative Methods روشهای حاوی اطلاعات
 Informativeness Measure معیار حاوی اطلاعات بودن
 instance-level سطح نسخه
 Intelligent Teacher معلم هوشمند
 Intractable رام نشدنی

K

Kernel Mean Embedding نهفته سازی میانگین کرنل
 Kernel Mean Map نگاشت میانگین کرنل
 KL Divergence دیورژانس KL

L

Label	برچسب
label-level	سطح برچسب
Lagrangian	تابع لاگرانژ
Learning Budget	بودجه یادگیری
Learning On Distributions	یادگیری روی توزیع
Learning System	سیستم یادگیر
Learning Systems	سیستم های یادگیری
Learning Using Privileged Information	یادگیری با استفاده از دانش ممتاز
Learning Using Privileged Information (LUPI)	یادگیری با استفاده از اطلاعات ممتاز
Learning with a Reject Option	یادگیری با داشتن گزینه رد
Locally Linear Reconstruction	بازسازی خطی محلی
Low-density Assumption	فرض چگالی کم

M

Machine Learning	یادگیری ماشین
Manifold	مانیفولد
Manifold Assumption	فرض مانیفولد
Manifold Optimal Experiment Design	طرح بهینه روی مانیفولد آزمایشها
Maximum Mean Discrepancy (MMD)	بیشترین اختلاف میانگین
Measurement Error	خطای اندازه گیری

min-max	بیشینه-کمینه
Model Deterioration	انحراف مدل
Multi-Instance Learning	یادگیری چندنسخه ای

N

Non-convex Optimization	بهینه سازی نامحدب
Non-smooth	ناهموار

O

Optimal Experiment Design	طراحی بهینه آزمایشها
Oracle	پیش گو

P

Plug-in Classifier	طبقه بند الحاقی
posterior	پسین
Preference learning	یادگیری ترجیحات
Prepare for the worst and Hope for the best	برای بدترین شرایط آماده باش و انتظار بهترین شرایط را داشته باش
Primal Problem	مسئله اولیه
Principled Approach to Active Learning	رویکردهای اصولی به یادگیری فعال
Prior Knowledge	دانش پیشین
Privileged Knowledge	دانش ممتاز

Probabilistic Minimax Active Learning (PMAL)	یادگیری فعال بیشینه-کمینه احتمالاتی
Probabilistic Minimax Active Robust Learning	یادگیری فعال بیشینه کمینه احتمالاتی مقاوم
Probabilistic Minimax Active Robust Learning (PMARL)	یادگیری مقاوم فعال بیشینه-کمینه احتمالاتی
Probabilistic Minimax Active Robust Learning on	یادگیری فعال بیشینه کمینه مقاوم روی توزیع با استفاده تشابه
	Distributions using Similarity
Probabilistic Minimax Active Robust	یادگیری فعال مقاوم بیشینه-کمینه احتمالاتی روی توزیع بارویکرد بیزی
	Learning on Distributions with Bayesian learning of kernel embeddings
Proximal	همجواری

Q

Query	پرس وجو
Query by Committee	پرس وجو توسط کمیته

R

Rademacher Complexity	پیچیدگی رادماخر
Rademacher Variables	متغیرهای رادماخر
Representative Methods	روشهای نماینده
Representativeness Measure	معیار نماینده نقاط بودن
Reproducing Kernel Hilbert Space	فضای هیلبرت کرنل بازتولیدکننده

S

Sample Bias	اریب شدن به نمونه
Sample Complexity	پیچیدگی نمونه
Sampling Bias	اریبی به نمونه
Simple-Complex Classifier	طبقه بند ساده-پیچیده
Stochastic Gradient Descent	بهینه سازی گرادیانی تصادفی
Structured data	ساخت-یافته
Structured Learning	یادگیری ساخت یافته
Submodular Optimization	بهینه سازی زیرپیمانه ای
Sub-optimal	زیر-بهینه
Supervised learning	یادگیری نظارت شده
Supervision	نظارت
Support Measure Machine (SMM)	ماشین معیارپشتیبان
Support Vector Machine	ماشین بردار پشتیبان
Support Vector Machine (SVM)	ماشین بردار پشتیبان

T

Total law of probability	قانون انتگرال کل
Trace Norm	نرم اثر
Tsybakov's Low noise assumption	فرض کم بودن نویز

U

Uncertainty Sampling نمونه برداری عدم قطعیت

V

Version Space فضای نسخه

W

Wishart ویشارت

نمایه

Active Learning یادگیری فعال. ۶

Anomaly detection شناسایی بی-نظمی. ۸۶

Artificial General Intelligence هوش همه منظوره مصنوعی. ۱۲۹

Bag of Words بسته کلمات. ۱۱۶

Bag-of-Words بسته ای -از-کلمات. ۱۲

Batch دسته. ۱۵

Batch Active Learning یادگیری فعال دسته ای. ۱۵

Bayes Optimal بهینه بیز. ۱۳۰

Bayes Optimal Classifier طبقه بند بهینه بیز. ۱۶

Bayesian بیزی. ۸۶، ۶۲

Bayesian learning of kernel embedding یادگیری بیزی نهفته سازی کرنل. ۸۷

Best vs Second Best بهترین در برابر دومین بهترین. ۲۶

Bias اریب. ۷

Casusal inference استنتاج علی. ۱۴

Causal Inference استنتاج علی. ۱۳

Characteristic Kernel کرنل مشخصه. ۵۵

Characteristics Kernel کرنل مشخصه. ۱۳

Class Central Examples نقاط مرکزی کلاس. ۲۰

Cluster Assumption فرض خوشه. ۲۳

Concept مفهوم. ۳، ۸۵

Consistent سازگار. ۸، ۳۹

Crowd Sourcing برچسب زنی جمعی. ۳۲

Crowd-Sourcing جمع سپاری. ۱۳۰

Disjunct جداشده. ۱۶

Distributional data داده های توزیعی. ۸۶

Empirical Kernel Mean Embedding نهفته سازی میانگین کرنل تجربی. ۸۷

Empirical Risk Minimization کمینه سازی ریسک تجربی. ۳۴

Evidence based Active Learning framework یادگیری فعال مبتنی بر شواهد. ۱۸

Example مثال. ۴، ۱۰۰

Expected Error Reduction کاهش امیدخطا. ۲۱

۱۳ .

۳۰ .

Fisher Information اطلاع فیشر. ۲۲

Gaussian Processes فرایندهای گوسی. ۱۰۲

Gaussian Random Field میدان تصادفی گوسی. ۲۳

Generalize تعمیم. ۳

Group Anomaly Detection شناسایی ناهنجاری گروهی. ۱۲

Group anomaly detection شناسایی بی-نظمی گروهی. ۸۶

۹ .

hyperparameters ابرپارامتر. ۲۵

Imbalanced data داده های نامتوازن. ۳۲

Importance Weighting وزن دهی اهمیت. ۵۴

Inconsistency عدم سازگاری. ۸

independent and identically distributed مستقل و هم توزیع. ۱۶

Independent and identically distributed (i.i.d) مستقل و هم توزیع بودن. ۸

informative Methods روشهای حاوی اطلاعات. ۱۶

Informativeness Measure معیار حاوی اطلاعات بودن. ۱۶

instance-level سطح نسخه. ۲۷

Intelligent Teacher معلم هوشمند. ۵۳

Intractable رام نشدنی. ۸۵، ۶۲

Kernel Mean Embedding نهفته سازی میانگین کرنل. ۸۷

Kernel Mean Map نگاشت میانگین کرنل. ۱۳

KL Divergence دیورژانس KL. ۹۱، ۲۴

Label برچسب. ۴

label-level سطح برچسب. ۲۸

Lagrangian تابع لاگرانژ. ۵۹

Learning Budget بودجه یادگیری. ۷

Learning On Distributions یادگیری روی توزیع. ۱۲، ۵

Learning System سیستم یادگیر. ۴

Learning Systems سیستم های یادگیری. ۳

Learning Using Privileged Information یادگیری با استفاده از دانش ممتاز. ۵۲

یادگیری با استفاده از اطلاعات ممتاز. ۵۳ **Learning Using Privileged Information (LUPI)**

یادگیری با داشتن گزینه رد. ۳۹ **Learning with a Reject Option**

بازسازی خطی محلی. ۲۲ **Locally Linear Reconstruction**

فرض چگالی کم. ۱۷ **Low-density Assumption**

یادگیری ماشین. ۳ **Machine Learning**

مانیفولد. ۲۳ **Manifold**

فرض مانیفولد. ۱۷، ۲۳، ۳۶ **Manifold Assumption**

طرح بهینه روی مانیفولد آزمایشها. ۲۳ **Manifold Optimal Experiment Design**

بیشترین اختلاف میانگین. ۲۹ **Maximum Mean Discrepancy (MMD)**

خطای اندازه گیری. ۱۳۱ **Measurement Error**

بیشینه-کمینه. ۸، ۲۸ **min-max**

انحراف مدل. ۲۷ **Model Deterioration**

یادگیری چندنسخه ای. ۱۲ **Multi-Instance Learning**

بهینه سازی نامحدب. ۱۳۱ **Non-convex Optimization**

ناهموار. ۵۰ **Non-smooth**

طراحی بهینه آزمایشها. ۲۲ **Optimal Experiment Design**

Oracle پیش‌گو. ۴، ۵۳

Plug-in Classifier طبقه‌بند الحاقی. ۳۴، ۶۴

posterior پسین. ۲۰

Preference learning یادگیری ترجیحات. ۸۶

Prepare for the worst and Hope for the best برای بدترین شرایط آماده باش و انتظار بهترین شرایط را داشته باش.

۶۶

Primal Problem مسئله اولیه. ۵۹

Principled Approach to Active Learning رویکردهای اصولی به یادگیری فعال. ۲۸

Prior Knowledge دانش پیشین. ۴، ۹۰

Privileged Knowledge دانش ممتاز. ۵۲

Probabilistic Minimax Active Learning (PMAL) یادگیری فعال بیشینه-کمینه احتمالاتی. ۳۴، ۶۱، ۶۲، ۸۵،

۸۶

Probabilistic Minimax Active Robust Learning یادگیری فعال بیشینه-کمینه احتمالاتی مقاوم. ۹۹

Probabilistic Minimax Active Robust Learning (PMARL) یادگیری مقاوم فعال بیشینه-کمینه احتمالاتی.

۸۷

Probabilistic Minimax Active Robust Learning on Distributions using Similarity یادگیری فعال بیشینه

کمینه مقاوم روی توزیع با استفاده تشابه. ۹۹

Probabilistic Minimax Active Robust Learning on Distributions with Bayesian learning of kernel embeddings

یادگیری فعال مقاوم بیشینه-کمینه احتمالاتی روی توزیع بارویکرد بیزی. ۸۸

Proximal همجواری. ۵۰

Query پرس وجو. ۱۵

Query by Committee پرس وجو توسط کمیته. ۱۷

Rademacher Complexity پیچیدگی رادماخر. ۲۹

Rademacher Variables متغیرهای رادماخر. ۲۹

Representative Methods روشهای نماینده. ۱۷

Representativeness Measure معیار نماینده نقاط بودن. ۱۷

Reproducing Kernel Hilbert Space فضای هیلبرت کرنل بازتولیدکننده. ۱۳

Sample Bias اربیب شدن به نمونه. ۱۶

Sample Complexity پیچیدگی نمونه. ۱۶

Sampling Bias اربیبی به نمونه. ۳۱

Simple-Complex Classifier طبقه بند ساده-پیچیده. ۳۶

Stochastic Gradient Descent بهینه سازی گرادیانی تصادفی. ۳۰

Structured data ساخت-یافته. ۸۶

Structured Learning یادگیری ساخت یافته. ۵

Submodular Optimization بهینه سازی زیرپیمانه ای. ۲۸

Sub-optimal زیر-بهینه. ۸

Supervised learning یادگیری نظارت شده. ۴

Supervision نظارت. ۴

Support Measure Machine (SMM) ماشین معیارپشتیبان. ۱۲، ۱۳

Support Vector Machine ماشین بردار پشتیبان. ۵۳

Support Vector Machine (SVM) ماشین بردار پشتیبان. ۱۹

۳۰

Total law of probability قانون انتگرال کل. ۹۰

Trace Norm نرم اثر. ۳۰

Tsybakov's Low noise assumption فرض کم بودن نویز. ۳۰

Uncertainty Sampling نمونه برداری عدم قطعیت. ۲۰

Version Space فضای نسخه. ۱۵، ۱۹

Wishart ویشارت. ۱۱۴



In the name of God
Graduate Studies Dissertation Information
Ferdowsi University of Mashhad

Active Learning in input and parameter space

Author: Seyed Hossein Ghafarian

Supervisor: Hadi Sadoghi Yazdi

Faculty: Faculty of Engineering

Department: Computer Engineering

Specialization: Computer Software

Approval Date: 2019

Defence Date: 2019

Ph.D.


Number of Pages: 193

Abstract: Active learning tries to minimize the cost of building learning systems by reducing the number of labeled examples required. In recent years, many learning systems have been developed for higher level forms of data, such as learning on distributions in which each example itself is a distribution. The current thesis proposes active robust learning on distributions. In learning on distributions, there is no access to distributions themselves but rather access is through a sample drawn from a distribution. Therefore, similar to robust learning, any estimates of examples is inexact. This adds the challenge of inexact examples to the already challenging problem of active learning. In order to address these difficulties, we provide an upper bound on the risk of classifier in the next stage of active learning where the size of labeled data set increases. Based on this upper bound, we propose Probabilistic Minimax Active Learning (PMAL) to deal with the challenges in active robust learning and to prove that its selecting an example with knowledge of its label minimizes the expected risk. Unfortunately, it is intractable to compute the proposed probabilistic minimax objective for active robust learning. Therefore, we present an efficient approximation of the objective. To more efficiently utilize the information about the estimates of distributions, we propose an active robust learning on distributions method based on learning the kernel embedding of distributions by a recent Bayesian method. The experiments demonstrate the effectiveness of the resulting method on a set of synthetic and real-world distributional datasets.

Key Words: Active Learning in Input and Parameter Space

Signature of Supervisor:

Date:



**Ferdowsi University of Mashhad
Faculty of Engineering**

**Doctoral Thesis Submitted in Partial
Fulfillment of the Requirements for the
Degree of Doctor of Science in
Computer Engineering**

Title

Active Learning in input and parameter space

**Supervisor
Hadi Sadoghi Yazdi**

by

Seyed Hossein Ghafarian

2019